

Inferencia Estadística

Ejercicios de la
Asignatura

Grado en Ciencia e Ingeniería de Datos

AUTORES

- Víctor Aceña Gil
- Isaac Martín de Diego
- Carmen Lancho Martín

2025-2026



Índice de Ejercicios

Introducción	5
Estructura de los Ejercicios	5
Requisitos Previos	5
Introducción a la Inferencia Estadística	6
Ejercicio 1	6
Ejercicio 2	6
Ejercicio 3	6
Ejercicio 4	6
Ejercicio 5	6
Ejercicio 6	6
Ejercicio 7	7
Ejercicio 8	7
Ejercicio 9	7
Ejercicio 10	7
Análisis Exploratorio de Datos	8
Ejercicio 1	8
Ejercicio 2	8
Ejercicio 3	8
Ejercicio 4	8
Ejercicio 5	9
Ejercicio 6	9
Ejercicio 7	9
Ejercicio 8	9
Ejercicio 9	9
Ejercicio 10	10
Procesado y Limpieza de Datos	11
Ejercicio 1	11
Ejercicio 2	12
Proyecto City Bike NYC	13
Introducción City Bike NYC	13
Descripción de variables	13
Ejercicio 1	14

Ejercicio 2	14
Ejercicio 3	14
Ejercicio 4	14
Intervalos de Confianza	15
Ejercicio 1: Conceptos Básicos	15
Ejercicio 2: Intervalo de Confianza Básico	15
Ejercicio 3: Nivel de Confianza Diferente	15
Ejercicio 4: Interpretación Práctica	15
Ejercicio 5: Varianza Conocida	15
Ejercicio 6: Varianza Desconocida	16
Ejercicio 7: Muestra Grande	16
Ejercicio 8: Proporción	16
Ejercicio 9: Comparación de Proporciones	16
Ejercicio 10: Interpretación Crítica	16
Contrastes de Hipótesis	17
Ejercicio 1: Conceptos Básicos	17
Ejercicio 2: Pasos en un Contraste de Hipótesis	17
Ejercicio 3: Errores tipo I y tipo II. Potencia	17
Ejercicio 4: Contraste para la media de una población normal con varianza conocida	17
Ejercicio 5: Contraste para la media de una población normal con varianza desconocida	17
Ejercicio 6: Contraste de hipótesis para la igualdad de medias de dos muestras independientes	18
Ejercicio 7: Contraste de hipótesis para la diferencia de proporciones	18
Ejercicio 8: Aplicación en un contexto real	18
Ejercicio 9: Prueba t de Student	18
Ejercicio 10: Prueba z para grandes muestras	18
Estimación y contraste paramétrico	19
Ejercicio 1: Definición de Estadístico	19
Ejercicio 2: Estimación Puntual	19
Ejercicio 3: Propiedades de los Estimadores	19
Ejercicio 4: Método de los Momentos	19
Ejercicio 5: Método de la Máxima Verosimilitud	19
Ejercicio 6: Estimación por Intervalo	19
Ejercicio 7: Contraste de Hipótesis (Prueba Z)	20
Ejercicio 8: Contraste de Hipótesis (Prueba T)	20
Ejercicio 9: Contraste de Hipótesis (Prueba Chi-Cuadrado)	20
Ejercicio 10: Contraste de Hipótesis (Comparación de Dos Medias)	20

Estimación y contraste paramétrico 2	21
Ejercicio 1: Propiedades de los estimadores	21
Ejercicio 2: Propiedades de los estimadores	21
Ejercicio 3: Método de Máxima Verosimilitud	21
Ejercicio 4: Tamaño muestral	21
Ejercicio 5: Intervalos de confianza	22
Ejercicio 6: Contraste de Hipótesis	22
Ejercicio 7: Estimación en el muestreo	22
Ejercicio 8: Muestreo	22
Ejercicio 9: Contraste de Hipótesis	23
Ejercicio 10: Datos	23
 Contraste no paramétrico	 24
Ejercicio 1	24
Ejercicio 2	24
Ejercicio 3	25
Ejercicio 4	25
Ejercicio 5	25
Ejercicio 6	26
Ejercicio 7	26
Ejercicio 8	27
Ejercicio 9	27
Ejercicio 10	28
 Análisis de la varianza	 29
Ejercicio 1	29
Ejercicio 2	29
Ejercicio 3	30
Ejercicio 4	30
Ejercicio 5	31
Ejercicio 6	31
Ejercicio 7	33
Ejercicio 8	33
Ejercicio 9	34
Ejercicio 10	34

Introducción

Este documento recopila una serie de ejercicios prácticos y teóricos diseñados para complementar la asignatura “Inferencia Estadística” del Grado en Ciencia e Ingeniería de datos. El objetivo de esta colección es afianzar los conocimientos adquiridos en cada tema, fomentando tanto la comprensión de los fundamentos teóricos como la habilidad para implementar y diagnosticar modelos en R.

Estructura de los Ejercicios

Los ejercicios están organizados por temas, siguiendo la estructura del curso. Para cada tema, encontrarás una mezcla de:

- **Preguntas Conceptuales:** Diseñadas para reforzar la comprensión de la teoría subyacente.
- **Problemas Prácticos con R:** Enfocados en la aplicación de las técnicas a conjuntos de datos reales o simulados.
- **Ejercicios de Interpretación:** Centrados en la habilidad crítica de interpretar correctamente las salidas de los modelos estadísticos.

Requisitos Previos

Para abordar estos ejercicios, se asume que el estudiante ha estudiado el contenido teórico del tema correspondiente y posee un manejo básico del entorno de programación R y RStudio.

Introducción a la Inferencia Estadística

Ejercicio 1

Describe en tus propias palabras qué es la Ciencia de Datos y su importancia en el análisis de grandes volúmenes de datos.

Ejercicio 2

Enumera las herramientas estadísticas que se utilizan en la inferencia estadística y explica brevemente su propósito.

Ejercicio 3

Define los términos “población” y “muestra” y explica la diferencia entre ambos.

Ejercicio 4

¿Qué es una distribución de probabilidad y cómo se relaciona con las variables cualitativas y cuantitativas?

Ejercicio 5

Realiza un resumen descriptivo de un conjunto de datos utilizando medidas de tendencia central y dispersión.

Ejercicio 6

Explica la diferencia entre estadística descriptiva e inferencial y proporciona un ejemplo de cómo se utiliza cada una.

Ejercicio 7

Diseña un experimento para ilustrar cómo el muestreo aleatorio simple puede ser utilizado para estimar una característica de una población.

Ejercicio 8

Explica el Teorema Central del Límite y su relevancia en la inferencia estadística.

Ejercicio 9

Compara y contrasta la estadística paramétrica y no paramétrica, dando ejemplos de cuándo se utilizaría cada una.

Ejercicio 10

Discute las diferencias entre los enfoques frecuentista y bayesiano en la inferencia estadística y da un ejemplo de aplicación para cada uno.

Análisis Exploratorio de Datos

Utilizar el dataframe denominado *bank* con el que hemos trabajado en el tema 2 de la asignatura para responder a las siguientes cuestiones:

Ejercicio 1

Estructura del DataFrame:

- ¿Cuántos campos y observaciones tiene el dataframe **bank**? Utiliza las funciones **head** y **dim**.

Ejercicio 2

Resumen del DataFrame:

- Evalúa el dataframe con la función **summary**.
- ¿Tiene observaciones con elementos faltantes (NA)?
- ¿A qué categorías corresponden las observaciones en la variable **job**?

Ejercicio 3

Distribución de la Edad:

- ¿Cuál es la edad máxima y mínima de los clientes en el dataframe?
- ¿Cuál es la media y la mediana de la edad de los clientes?

Ejercicio 4

Balance Promedio:

- ¿Cuál es el balance promedio anual (balance) de los clientes?
- ¿Cuál es el balance promedio anual de los clientes que han suscrito un depósito a plazo fijo ($y = \text{"yes"}$)?

Ejercicio 5

Frecuencia de Contacto:

- ¿Cuál es el número máximo y mínimo de contactos realizados durante esta campaña (campaign)?

Ejercicio 6

Análisis de Duración:

- ¿Cuál es la duración media y mediana del último contacto en segundos (**duration**)?
- ¿Cuál es la duración media del último contacto en segundos para los clientes que suscribieron un depósito a plazo fijo (**y** = “yes”)?

Ejercicio 7

Relación entre Variables:

- ¿Existe alguna relación entre el balance promedio anual y la duración del último contacto? Utiliza una visualización adecuada para responder a esta pregunta.

Ejercicio 8

Segmentación por Trabajo:

- ¿Cuál es la media y mediana del balance anual de los clientes agrupados por tipo de trabajo (**job**)?

Ejercicio 9

Análisis de Contactos Anteriores:

- ¿Cuál es el número máximo y mínimo de días que pasaron desde el último contacto de una campaña anterior (**pdays**)?
- ¿Cuál es la media de **pdays** para los clientes que suscribieron un depósito a plazo fijo (**y** = “yes”)?

Ejercicio 10

Estudio General:

- Haciendo un estudio general de los datos, ¿qué puedes concluir?
- ¿Existe alguna relación significativa entre las variables **balance**, **duration**, y **campaign**?
Se recomienda hacer un análisis visual y estadístico de estas variables.

Procesado y Limpieza de Datos

Ejercicio 1

Crear el siguiente *dataframe* mediante estas instrucciones

```
set.seed(1234)

stocks = data.frame(time = as.Date("2009-01-01") + 0:9,
                    Wallmart = rnorm(10,20,1),
                    Target = rnorm(10,20,2),
                    Walgreens = rnorm (10,20,4)
                    )

stocks
```

	time	Wallmart	Target	Walgreens
1	2009-01-01	18.79293	19.04561	20.53635
2	2009-01-02	20.27743	18.00323	18.03726
3	2009-01-03	21.08444	18.44749	18.23781
4	2009-01-04	17.65430	20.12892	21.83836
5	2009-01-05	20.42912	21.91899	17.22512
6	2009-01-06	20.50606	19.77943	14.20718
7	2009-01-07	19.42526	18.97798	22.29902
8	2009-01-08	19.45337	18.17761	15.90538
9	2009-01-09	19.43555	18.32566	19.93945
10	2009-01-10	19.10996	24.83167	16.25621

A continuación, realizar las siguientes operaciones de limpieza de datos:

- Como se puede observar, hay un problema de clave-valor en las compañías con sus observaciones. Por lo tanto, se pide transformar los datos para que tengan una clave “*stock*” y un valor “*precio*”. Utilizar la instrucción “*gather*”.
- Devolver el dataframe al estado original empleando la instrucción *spread*.
- Utilizando el operador tubería `%>%` se desea realizar las siguientes operaciones anidadas:
 - Transformar los datos para que tengan una clave “*stock*” y el valor sea el “*precio*”. Utilizar la instrucción “*gather*”.

- Agrupar los datos por la clave “*stock*” mediante la instrucción “*group_by*”.
- Obtener el precio mínimo y el máximo utilizando la instrucción “*summarise*”.

Ejercicio 2

En este ejercicio vamos a manejar datos contenidos en distintos *dataframes* y operar sobre ellos con *dplyr*.

1. Descargar el paquete *nycflights13*.
2. Evaluar el contenido de los *dataframes* proporcionados por el paquete. Utilizar *head* y *summary*.
3. Simplificar los *dataframes* originales a 100 observaciones mediante el comando *head*. Asignarlos a una variable que indique el tipo de *dataframe* añadiendo la coletilla “*_simple”.
Ejemplo: “*flights_simple*”.
4. Selecciona los tipos de aerolínea (“*carrier*”) mediante la instrucción *select* y el operador *unique* concatenados con el operador tubería %>% (Utilizar “*airlines_simple*”).
5. Obtener la media y el número máximo de asientos (“*seats*”) que tienen los aviones. Utilizar el operador tubería %>% y la instrucción *summarise*.
6. Ordenar los aviones por su número de motores (“*engines*”) y número de asientos (“*seats*”). Utilizar la instrucción *arrange*.
7. Averigua qué número de cola (“*tailnum*”) comparten los *dataframes* “*flights_simple*” y “*planes_simple*” que has creado anteriormente. Obten su aerolínea (“*carrier*”). Utilizar la instrucción *inner_join*.
8. Cruzar los datos de vuelos (“*flights*”) con los aviones (“*planes*”) por el número de cola (“*tailnum*”) que no coincidan (usar la instrucción *anti_join*). De esos obtener aquellos con 2 o más motores(usar la instrucción *filter*). Finalmente obtener los distintos modelos de avión que satisfacen las premisas anteriores (usar la instrucción *unique*).
9. Crea una nueva variable (“*total_delay*”) que calcule el retraso total sumando los *delays* acumulados (“*dep_delay*”) y (“*arr_delay*”). Utilizar la instrucción *mutate*. Almacena el *dataframe* resultante en “*flights_total*”.
10. En base a la variable anteriormente obtenida (“*total_delay*”), devuelve los aviones que han llegado con antelación a su destino, es decir aquellos tal que la variable *total_delay* tiene valores negativos.

Proyecto City Bike NYC

Introducción City Bike NYC

El sistema de uso compartido de bicicletas en la ciudad de Nueva York (EE.UU.) publica diariamente gran cantidad de datos de actividad sobre su uso.

Estos datos han dado lugar, como no, a algunos [análisis sobre la evolución de este servicio y posibles factores que puedan influenciar su uso](#). En esta práctica vamos a proponer el análisis de datos resumen diarios sobre la utilización de este servicio entre julio de 2013 y noviembre de 2015.

La filosofía de esta práctica es fomentar que consultéis la documentación en línea tanto de Pandas como de Seaborn, para así familiarizaros más con los diferentes métodos disponibles para resolver los ejercicios propuestos. En cada pregunta, se ofrecen consejos sobre partes relevantes de esta documentación relacionadas con las tareas que se piden.

Descripción de variables

El archivo de datos que vamos a utilizar puede obtenerse de [esta url](#). Se trata de un fichero en formato CSV, que se ha creado mezclando datos del [City Bike System](#) con datos de la [National Oceanic and Atmospheric Administration \(NOAA\)](#), sobre NYC. El fichero cuenta con las siguientes columnas:

- **date**: fecha del dato, en formato YYYY-MM-DD.
- **trips**: entero positivo, número total de viajes acumulados ese día.
- **precipitation**: entero positivo, cantidad de lluvia total registrada ese día (pulgadas).
- **snow_depth**: entero positivo, altura de nieve (pulgadas).
- **snowfall**: entero positivo, registro de precipitación en forma de nieve (pulgadas).
- **max_temperature**: entero, temperatura máxima registrada (°F).
- **min_temperature**: entero, temperatura mínima registrada (°F).
- **average_wind_speed**: entero, velocidad promedio del viento (MPH, millas por hora).
- **dow**: [0, 7]; código de día de la semana, 0 corresponde al domingo.
- **year**: Año del registro.
- **month**: Mes del registro.
- **holiday**: Valor lógico, indica si esa fecha es festivo (TRUE) o no (FALSE).

- `stations_in_service`: Número de estaciones para tomar o dejar bicicletas que estaban en servicio ese día.
- `weekday`: Valor lógico, indica si esa fecha corresponde a un día entre semana (de lunes a viernes, ambos inclusive).
- `weekday_non_holiday`: Valor lógico, indica si la fecha corresponde a un día entre semana festivo.

Los datos están tomados con frecuencia diaria (filas del archivo).

Ejercicio 1

Genera una tabla con valores estadísticos resumen para las variables cuantitativas de este conjunto de datos.

Ejercicio 2

Crea un gráfico que represente la evolución del número total de viajes en bicicleta registrados en el sistema cada mes.

A continuación, genera otro gráfico con la evolución de la media mensual de temperaturas máximas y mínimas.

¿Se pueden observar patrones estacionales o algún tipo de relación entre ambas variables?

Ejercicio 3

Representa un gráfico con dos paneles, en el que cada panel muestre el histograma y función de densidad de probabilidad del número total de viajes diarios realizados. El panel izquierdo mostrará la distribución del total de viajes diarios en días no festivos y el panel derecho mostrará la misma distribución pero para días festivos.

Ejercicio 4

Calcula cual es, en promedio el día de la semana en el que más viajes en bicicleta se realizan y el día que menos viajes registra, usando toda la serie de valores. Si es posible, intenta visualizar estos datos por paneles para mostrar tus conclusiones.

Intervalos de Confianza

Ejercicio 1: Conceptos Básicos

Explica brevemente qué es un intervalo de confianza y por qué es importante en la estadística inferencial. Da un ejemplo sencillo de un intervalo de confianza.

Ejercicio 2: Intervalo de Confianza Básico

Dada una muestra aleatoria de tamaño 30 de una población normal con media muestral $\bar{x} = 50$ y desviación estándar $\sigma = 10$, calcula el intervalo de confianza del 95% para la media poblacional.

Ejercicio 3: Nivel de Confianza Diferente

Utilizando la misma muestra del ejercicio anterior, calcula el intervalo de confianza del 99% para la media poblacional. Compara ambos intervalos y explica las diferencias.

Ejercicio 4: Interpretación Práctica

Un investigador encuentra que el intervalo de confianza del 95% para la media de una variable es (45, 55). Explica qué significa este intervalo en términos prácticos y cómo debería interpretarlo el investigador.

Ejercicio 5: Varianza Conocida

Se sabe que la desviación estándar de las alturas de una población es de 5 cm. Se toma una muestra aleatoria de 40 individuos con una media muestral de 170 cm. Calcula el intervalo de confianza del 95% para la media poblacional.

Ejercicio 6: Varianza Desconocida

En un estudio de satisfacción laboral, se toma una muestra de 25 empleados y se encuentra una media muestral de 78 puntos con una desviación estándar muestral de 12 puntos. Calcula el intervalo de confianza del 95% para la media poblacional.

Ejercicio 7: Muestra Grande

Una encuesta a 200 estudiantes universitarios encuentra que el gasto promedio mensual en libros es de \$100 con una desviación estándar de \$20. Calcula el intervalo de confianza del 95% para la media del gasto mensual en libros para todos los estudiantes universitarios.

Ejercicio 8: Proporción

En una muestra de 150 votantes, 90 indican que planean votar por el candidato A. Calcula el intervalo de confianza del 95% para la proporción de votantes que planean votar por el candidato A.

Ejercicio 9: Comparación de Proporciones

Dos empresas están interesadas en la proporción de empleados que están satisfechos con su trabajo. En una muestra de 100 empleados de la empresa A, 60 se declaran satisfechos. En una muestra de 120 empleados de la empresa B, 90 se declaran satisfechos. Calcula el intervalo de confianza del 95% para la diferencia en las proporciones de empleados satisfechos entre las dos empresas.

Ejercicio 10: Interpretación Crítica

Un informe estadístico presenta el intervalo de confianza del 95% para la media de una variable como (75, 85). El informe concluye que la media poblacional es 80. ¿Es esta conclusión válida? Explica por qué o por qué no, utilizando conceptos de la interpretación de intervalos de confianza.

Contrastes de Hipótesis

Ejercicio 1: Conceptos Básicos

Define los conceptos básicos de un contraste de hipótesis: hipótesis nula (H_0), hipótesis alternativa (H_1), nivel de significación (α), región de rechazo y valor crítico.

Ejercicio 2: Pasos en un Contraste de Hipótesis

Describe los pasos necesarios para realizar un contraste de hipótesis. Ilustra estos pasos con un ejemplo simple en el que se quiera comprobar si la media de una muestra es igual a un valor específico.

Ejercicio 3: Errores tipo I y tipo II. Potencia

Explica la diferencia entre los errores tipo I y tipo II en un contraste de hipótesis. ¿Qué es la potencia de un test? Calcula la probabilidad de cometer un error tipo I (α) y un error tipo II (β) en un contraste de hipótesis dado.

Ejercicio 4: Contraste para la media de una población normal con varianza conocida

Se tiene una muestra de tamaño $n = 30$ con una media muestral de $\bar{x} = 50$ y una varianza conocida de $\sigma^2 = 25$. Realiza un contraste de hipótesis para verificar si la media poblacional es 52 con un nivel de significación $\alpha = 0.05$.

Ejercicio 5: Contraste para la media de una población normal con varianza desconocida

Una muestra de tamaño $n = 20$ tiene una media muestral de $\bar{x} = 30$ y una desviación estándar muestral de $s = 5$. Realiza un contraste de hipótesis para probar si la media poblacional es diferente de 32 con un nivel de significación $\alpha = 0.01$.

Ejercicio 6: Contraste de hipótesis para la igualdad de medias de dos muestras independientes

Se tienen dos muestras independientes: - Muestra A: $x_A = \{23, 21, 22, 24, 25, 23, 24, 22, 23, 24\}$
- Muestra B: $x_B = \{18, 19, 17, 20, 18, 19, 18, 19, 20, 18\}$ Realiza un contraste de hipótesis para verificar si las medias de las dos poblaciones son diferentes con un nivel de significación $\alpha = 0.05$.

Ejercicio 7: Contraste de hipótesis para la diferencia de proporciones

En un estudio se observa que de 200 hombres, 130 prefieren el producto A, mientras que de 250 mujeres, 140 prefieren el mismo producto. Realiza un contraste de hipótesis para determinar si existe una diferencia significativa en las proporciones de hombres y mujeres que prefieren el producto A con un nivel de significación $\alpha = 0.05$.

Ejercicio 8: Aplicación en un contexto real

Un fabricante afirma que el peso medio de sus paquetes de galletas es 500 gramos. Una muestra de 40 paquetes tiene una media de 495 gramos y una desviación estándar de 10 gramos. Realiza un contraste de hipótesis para comprobar la afirmación del fabricante con un nivel de significación $\alpha = 0.01$.

Ejercicio 9: Prueba t de Student

Se tiene una muestra de tamaño $n = 25$ de una población normal con una media muestral de $\bar{x} = 20$ y una desviación estándar muestral de $s = 4$. Realiza un contraste de hipótesis para probar si la media poblacional es mayor que 18 con un nivel de significación $\alpha = 0.05$.

Ejercicio 10: Prueba z para grandes muestras

Una encuesta a 500 personas revela que 320 están a favor de una nueva ley. Realiza un contraste de hipótesis para determinar si la proporción de personas a favor de la ley es diferente de 0.6 con un nivel de significación $\alpha = 0.05$.

Estimación y contraste paramétrico

Ejercicio 1: Definición de Estadístico

¿Qué es un estadístico? Da un ejemplo de un estadístico comúnmente utilizado en la estadística descriptiva.

Ejercicio 2: Estimación Puntual

Supongamos que tienes una muestra aleatoria de tamaño $n = 10$ de una población con media desconocida μ y varianza conocida $\sigma^2 = 25$. La muestra es: $x = \{10, 12, 9, 11, 10, 13, 10, 12, 11, 14\}$. Calcula la estimación puntual de la media poblacional μ utilizando la media muestral.

Ejercicio 3: Propiedades de los Estimadores

Demuestra que la media muestral es un estimador insesgado de la media poblacional μ .

Ejercicio 4: Método de los Momentos

Dado el siguiente conjunto de datos: $x = \{2, 4, 3, 5, 6, 4, 3, 5\}$. Utiliza el método de los momentos para estimar la media μ y la varianza σ^2 de la población.

Ejercicio 5: Método de la Máxima Verosimilitud

Supongamos que tenemos una muestra aleatoria de tamaño n de una distribución exponencial con parámetro λ . Deriva el estimador de máxima verosimilitud para λ .

Ejercicio 6: Estimación por Intervalo

Para la misma muestra del Ejercicio 2 ($x = \{10, 12, 9, 11, 10, 13, 10, 12, 11, 14\}$), calcula un intervalo de confianza del 95% para la media poblacional μ , asumiendo que la varianza poblacional es conocida y es igual a 25.

Ejercicio 7: Contraste de Hipótesis (Prueba Z)

Supón que quieres probar si la media poblacional μ es igual a 10. Utiliza la muestra del Ejercicio 2 y realiza un contraste de hipótesis con un nivel de significación $\alpha = 0.05$.

Ejercicio 8: Contraste de Hipótesis (Prueba T)

Para una muestra aleatoria de tamaño $n = 15$ de una población con distribución normal pero con varianza desconocida,

$$x = \{15, 17, 16, 14, 18, 16, 15, 17, 16, 18, 15, 17, 16, 14, 18\}$$

realiza un contraste de hipótesis para verificar si la media poblacional es diferente de 16 con un nivel de significación $\alpha = 0.05$.

Ejercicio 9: Contraste de Hipótesis (Prueba Chi-Cuadrado)

Una muestra de tamaño $n = 20$ de una población con varianza desconocida es $x = \{5, 7, 9, 6, 8, 10, 7, 9, 8, 10, 5, 7, 9, 6, 8, 10, 7, 9, 8, 10\}$. Realiza un contraste de hipótesis para probar si la varianza poblacional es igual a 4 con un nivel de significación $\alpha = 0.05$. Recuerda que $\frac{s^2(n-1)}{\sigma^2} \sim \chi_{n-1}^2$, es decir, el estadístico, insesgado para la varianza poblacional σ^2 , $\frac{s^2(n-1)}{\sigma^2}$ se distribuye como una χ_{n-1}^2 , siendo n el tamaño muestral, s^2 la cuasivarianza muestral.

Ejercicio 10: Contraste de Hipótesis (Comparación de Dos Medias)

Tienes dos muestras independientes:

- Muestra A:

$$x_A = \{23, 21, 22, 24, 25, 23, 24, 22, 23, 24\}$$

- Muestra B:

$$x_B = \{18, 19, 17, 20, 18, 19, 18, 19, 20, 18\}$$

Realiza un contraste de hipótesis para verificar si las medias de las dos poblaciones de las cuales se extrajeron las muestras son diferentes. Usa un nivel de significación $\alpha = 0.05$.

Estimación y contraste paramétrico 2

Ejercicio 1: Propiedades de los estimadores

Sera $X_1, \dots, X_3$ y X_4 una muestra aleatoria de tamaño cuatro de una población cuya distribución es exponencial con parámetros θ desconocido. De las siguientes estadísticas, ¿cuáles son estimadores insesgados de θ ?

$$T_1 = \frac{1}{3}(X_1 + X_2) + \frac{1}{6}(X_3 + X_4)$$

$$T_2 = \frac{(4X_1 + 3X_2 + 2X_3 + 1X_4)}{5}$$

$$T_3 = \frac{(X_1 + X_2 + X_3 + X_4)}{4}$$

Ejercicio 2: Propiedades de los estimadores

En un experimento binomial se observan x éxitos en n ensayos independientes. Se propone el siguiente estadístico como estimador del parámetro de proporción p :

$$T = \frac{x}{n}$$

Se pide demostrar que el estadístico T es un estimador consistente del parámetro binomial p .

Ejercicio 3: Método de Máxima Verosimilitud

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población cuya distribución es de Poisson con parámetro λ . Obtener el estimador de máxima verosimilitud de λ .

Ejercicio 4: Tamaño muestral

Una empresa quiere realizar una encuesta para estimar el nivel de satisfacción de sus clientes con un nuevo producto. La empresa desea que la estimación tenga un nivel de confianza del 95% y un margen de error del 5%. Basado en estudios previos, se espera que la proporción de clientes satisfechos sea aproximadamente del 70%. ¿Cuál es el tamaño muestral mínimo necesario para la encuesta?

Ejercicio 5: Intervalos de confianza

Una empresa quiere comparar la efectividad de dos programas de entrenamiento distintos para sus empleados. Para ello, selecciona dos grupos independientes de empleados y aplica un programa de entrenamiento diferente a cada grupo. Después del entrenamiento, se mide el rendimiento de cada empleado. Los resultados son los siguientes:

- Grupo 1 (Programa A): 15 empleados, media de rendimiento = 80, desviación estándar = 10
- Grupo 2 (Programa B): 12 empleados, media de rendimiento = 75, desviación estándar = 12

Se desea calcular un intervalo de confianza del 95% para la diferencia de las medias de rendimiento entre los dos programas de entrenamiento.

Ejercicio 6: Contraste de Hipótesis

Realiza un contraste de hipótesis para el problema planteado en el ejercicio anterior y proporciona un p -valor.

Ejercicio 7: Estimación en el muestreo

Mediante el empleo de R, genera 100 muestras, cada una de tamaño 15, de una distribución normal de media 120 y desviación estándar 8. Para cada muestra, construye un IC del 95% para la σ^2 . ¿Cuántos de estos intervalos contienen el verdadero valor de σ^2 ? ¿Este resultado está de acuerdo con lo que esperabas? Debes comenzar por derivar el IC para la varianza poblacional σ^2 . Para ello, recuerda que la cuasivarianza muestral

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

es un estimador insesgado para la varianza poblacional σ^2 y que, bajo condiciones de normalidad,

$$s^2 \sim \frac{\sigma^2 \chi_{n-1}^2}{n-1}.$$

Ejercicio 8: Muestreo

Una compañía de auditoría está llevando a cabo una revisión de los balances contables reportados por un banco. Quieren estimar la proporción de cuentas para las cuales existe una discrepancia entre lo reportado por el cliente y el banco. Se decide realizar un muestreo para obtener una estimación precisa de esta proporción. Se sabe que la proporción real de cuentas con

discrepancias es desconocida, pero la compañía de auditoría quiere obtener una estimación con un nivel de confianza del 99%. Además, desean que el margen de error máximo en la estimación sea de 0.01 unidades. ¿Cuántas cuentas deberán seleccionarse para satisfacer estos requisitos?

Ejercicio 9: Contraste de Hipótesis

Supongamos que un jugador de fútbol afirma que su tasa de éxito en los tiros de penalti es superior al 70%. Sin embargo, un analista deportivo cree que la tasa de éxito es menor que eso. Para probar su hipótesis, el analista revisa los datos de los últimos 50 tiros de penaltis del jugador y encuentra que lograron marcar en 30 de ellos. ¿Quién tiene razón?

Ejercicio 10: Datos

Se desea investigar si la edad media de los clientes de un banco excede los 40 años. Se realiza un análisis estadístico utilizando datos de una campaña de marketing bancario. Se calcula un intervalo de confianza para la edad promedio de los clientes basado en una muestra aleatoria de 1000 clientes. Posteriormente, se lleva a cabo un contraste de hipótesis para determinar si la edad media es mayor que 40 años, utilizando un nivel de significancia del 5%. Emplea para resolver este ejercicio los datos de la base de datos **bank** del repositorio UCI.

Contraste no paramétrico

Ejercicio 1

Un estudio quiere analizar si hay diferencias significativas en la distribución de la duración del sueño entre dos grupos de personas: estudiantes universitarios y trabajadores a tiempo completo. Para ello, se recolectaron dos muestras independientes de tamaño $n1 = 20$ para estudiantes y $n2 = 30$ para trabajadores. Los datos representan las horas de sueño por noche durante una semana para cada participante.

A partir de los datos recopilados, se desea determinar si hay evidencia estadística para afirmar que las distribuciones de horas de sueño difieren entre los dos grupos.

```
# Muestras de horas de sueño para estudiantes universitarios (grupo 1)
muestras_estudiantes <- c(7.2, 7.0, 6.8, 7.5, 7.1, 7.3, 7.2, 7.4, 7.0,
                          7.6, 7.5, 6.9, 7.2, 7.3, 7.1, 7.4, 7.5, 7.0,
                          7.2, 7.3)

# Muestras de horas de sueño para trabajadores a tiempo completo (grupo 2)
muestras_trabajadores <- c(6.5, 6.3, 6.7, 6.4, 6.6, 6.8, 6.7, 6.9, 6.5,
                          6.2, 6.8, 6.7, 6.3, 6.6, 6.9, 6.5, 6.4, 6.7,
                          6.6, 6.8, 6.7, 6.9, 6.1, 6.3, 6.6, 6.1, 6.9,
                          7.1, 6.3, 6.6)
```

Ejercicio 2

Un estudio realizado en una comunidad recopiló información sobre el género (hombre, mujer) y las preferencias de deportes (fútbol, baloncesto, tenis) de un grupo de personas. Los datos se muestran en la siguiente tabla de contingencia:

	Fútbol	Baloncesto	Tenis
Hombre	30	20	10
Mujer	20	25	15

Se desea determinar si hay una asociación significativa entre el género y las preferencias de deportes en la población utilizando la prueba de chi-cuadrado de independencia.

Ejercicio 3

Pregunta:

Se llevó a cabo un estudio para comparar los tiempos de respuesta entre dos grupos de personas expuestas a diferentes condiciones de entrenamiento. Para ello, se registraron los tiempos de respuesta (en milisegundos) de 15 personas en el Grupo A y 18 personas en el Grupo B. Los datos obtenidos se muestran a continuación:

Grupo A: 45.1, 38.0, 52.4, 40.1, 47.5, 41.2, 43.5, 39.7, 36.1, 44.2, 50.5, 48.1, 42.4, 46.1, 49.5

Grupo B: 55.3, 60.4, 58.9, 62.0, 54.1, 57.8, 59.3, 63.6, 56.4, 61.7, 58, 64.3, 53.7, 66.1, 67.1, 65.2, 68.3, 50.1

Determine si hay una diferencia significativa en los tiempos de respuesta entre los dos grupos. Para determinar si hay una diferencia significativa en los tiempos de respuesta entre los dos grupos, puedes utilizar la prueba de Mann-Whitney U. Esta prueba no paramétrica se utiliza para comparar las distribuciones de dos muestras independientes y determinar si una muestra tiene valores significativamente mayores o menores que la otra.

Ejercicio 4

Supongamos que estamos trabajando con un conjunto de datos de un modelo de clasificación que predice si los clientes de una tienda en línea harán una compra (Sí o No) basado en varias características. Queremos investigar si existe una asociación entre dos variables categóricas en nuestro conjunto de datos: “Género” (Hombre, Mujer) y “Compra” (Sí, No).

Hemos entrenado un modelo de clasificación y obtenido las siguientes predicciones y datos observados para una muestra de 200 clientes:

Género	Compra: Sí	Compra: No
Hombre	50	30
Mujer	70	50

Ejercicio 5

Supongamos que hemos desarrollado un modelo de clasificación para predecir el riesgo crediticio de los clientes de un banco, clasificándolos como “Alto Riesgo” o “Bajo Riesgo”. Queremos evaluar si existe una asociación significativa entre las predicciones del modelo y los valores reales observados en un conjunto de prueba.

Se toma una muestra de 300 clientes, y se obtiene la siguiente tabla de contingencia que muestra la distribución de las predicciones del modelo y los valores reales observados:

	Real: Alto Riesgo	Real: Bajo Riesgo	Total
Predicción: Alto Riesgo	80	30	110
Predicción: Bajo Riesgo	50	140	190
Total	130	170	300

Ejercicio 6

Un investigador desea evaluar si un nuevo método de enseñanza mejora las calificaciones de los estudiantes. Para ello, selecciona a 10 estudiantes y mide sus calificaciones en una prueba antes y después de aplicar el nuevo método durante un semestre. Los datos obtenidos son los siguientes:

Estudiante	Calificación Antes (X)	Calificación Después (Y)
1	65	75
2	70	78
3	60	65
4	72	80
5	68	74
6	75	85
7	63	68
8	70	77
9	67	73
10	66	69

Para determinar si hay una diferencia significativa en las calificaciones antes y después del nuevo método de enseñanza, se realizará un contraste de hipótesis utilizando la prueba de Wilcoxon para muestras pareadas.

Ejercicio 7

Un nutricionista quiere evaluar el efecto de una nueva dieta en la presión arterial de los pacientes. Se mide la presión arterial sistólica de 12 pacientes antes y después de seguir la dieta durante un mes. Los datos son los siguientes:

Paciente	Antes (X)	Después (Y)
1	135	130
2	140	135
3	150	145

Paciente	Antes (X)	Después (Y)
4	145	142
5	160	155
6	155	150
7	148	150
8	160	158
9	142	140
10	138	136
11	150	149
12	145	146

Determinar si hay una diferencia significativa en la presión arterial sistólica antes y después de seguir la dieta utilizando la prueba del signo para observaciones por pares.

Ejercicio 8

Un investigador desea determinar si existe una relación entre el nivel de educación y la preferencia por el tipo de música. Se realiza una encuesta a 200 personas y se obtienen los siguientes datos:

	Rock	Pop	Clásica	Total
Secundaria	30	40	10	80
Universitaria	20	50	30	100
Posgrado	10	5	5	20
Total	60	95	45	200

Determinar si hay una relación significativa entre el nivel de educación y la preferencia por el tipo de música utilizando la prueba chi-cuadrado de independencia.

Ejercicio 9

Una compañía de supermercados está interesada en la preferencia del consumidor con respecto a dos marcas (A, y B) de refresco que compiten entre sí. Se seleccionan, de modo aleatorio, 15 personas y se les pide que clasifiquen las bebidas mediante una escala del 1 (poca aceptación) al 5 (muchacha aceptación). El orden en la selección de la bebida fue aleatorio. Se obtiene la siguiente información:

ID	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
A	3	2	5	2	4	5	2	1	3	1	4	3	3	5	2
B	1	1	4	3	4	1	2	1	2	1	2	4	3	2	2

Mediante el uso de la prueba del signo. ¿Se tiene alguna razón para creer que existe una diferencia en la preferencia para estas dos marcas de refrescos? Supón $\alpha = 0.1$

Ejercicio 10

Para los datos del ejercicio anterior, emplea la prueba de rangos de signos de Wilcoxon ¿Se obtienen las mismas conclusiones?

Análisis de la varianza

Ejercicio 1

Se realizó un experimento para investigar si hay diferencias significativas en el tiempo de reacción ante un estímulo visual entre tres grupos de participantes que fueron sometidos a diferentes niveles de iluminación: normal, baja y alta. Se registraron los tiempos de reacción (en milisegundos) para cada participante en cada grupo. Los datos obtenidos se muestran a continuación:

Grupo Normal: 40, 45, 38, 42, 39

Grupo Baja: 48, 50, 55, 52, 51

Grupo Alta: 35, 37, 32, 40, 36

Usando un nivel de significancia de 0.05, ¿hay diferencias significativas en el tiempo de reacción entre los tres grupos?

Ejercicio 2

Un investigador quiere evaluar el efecto de dos factores en el rendimiento de los estudiantes URJC en un examen final. Los dos factores considerados son el tipo de método de estudio (Método Tradicional y Método Moderno) y el ambiente de estudio (Ambiente Silencioso y Ambiente con Ruido). Para ello, se seleccionan 5 estudiantes aleatoriamente para cada combinación de métodos y ambientes, y se registra su puntuación en el examen final.

Los datos obtenidos se muestran en la siguiente tabla:

Ambiente / Método	Método Tradicional	Método Moderno
Silencioso	85, 90, 88, 92, 87	91, 93, 89, 94, 92
Con Ruido	70, 75, 72, 78, 73	77, 79, 74, 80, 76

Utilizando un nivel de significancia de 0.05, determine si hay diferencias significativas en las puntuaciones del examen debido al tipo de método de estudio, al ambiente de estudio, y a la interacción entre ambos factores.

Ejercicio 3

Un equipo de investigadores quiere evaluar el efecto de dos factores en la satisfacción laboral de los empleados. Los dos factores considerados son el tipo de horario de trabajo (Horario Flexible y Horario Fijo) y el tipo de entorno de trabajo (Oficina Abierta y Oficina Cerrada). Se seleccionan 5 empleados aleatoriamente para cada combinación de horarios y entornos, y se registra su puntuación de satisfacción laboral en una escala de 1 a 100.

Los datos obtenidos se muestran en la siguiente tabla:

Entorno / Horario	Horario Flexible	Horario Fijo
Oficina Abierta	78, 82, 85, 80, 84	60, 65, 58, 63, 61
Oficina Cerrada	88, 90, 87, 85, 89	70, 73, 75, 72, 71

Utilizando un nivel de significancia de 0.05, determine si hay diferencias significativas en la satisfacción laboral debido al tipo de horario de trabajo, al entorno de trabajo, y a la interacción entre ambos factores.

Ejercicio 4

Un investigador quiere evaluar el efecto de dos factores en el rendimiento de los estudiantes en una prueba de matemáticas. Los dos factores considerados son el método de enseñanza (Tradicional y Moderno) y el tipo de material de apoyo (Libro, Video, Software, Sin material). Se seleccionan 3 estudiantes aleatoriamente para cada combinación de métodos y materiales, y se registra su puntuación en la prueba de matemáticas.

Los datos obtenidos se muestran en la siguiente tabla:

Material / Método	Método Tradicional	Método Moderno
Libro	75, 80, 85	90, 92, 88
Video	70, 72, 78	85, 87, 84
Software	65, 68, 70	80, 83, 79
Sin material	60, 62, 65	75, 77, 73

Utilizando un nivel de significancia de 0.05, determine si hay diferencias significativas en las puntuaciones de la prueba de matemáticas debido al método de enseñanza, al tipo de material de apoyo, y a la interacción entre ambos factores.

Ejercicio 5

¿Es posible simplificar el modelo anterior eliminando la iteración? ¿Es posible eliminar alguno de los efectos individuales? De ser así, construye el nuevo modelo. ¿Dónde aparecen las principales diferencias en la puntuación? Plantea un contraste de hipótesis de igualdad de distribuciones. Plantea un intervalo de confianza para la diferencia de medias.

Ejercicio 6

Una empresa de manufactura quiere evaluar el efecto de dos factores en la durabilidad de un producto. Los dos factores considerados son el tipo de material utilizado (Material A y Material B) y la temperatura de fabricación (Baja, Media y Alta). Se seleccionan 4 muestras aleatoriamente para cada combinación de materiales y temperaturas, y se mide la durabilidad en días. Los datos obtenidos se muestran en la siguiente tabla:

Temperatura / Material	Material A	Material B
Baja	15, 18, 16, 17	14, 17, 16, 15
Media	20, 22, 21, 19	19, 18, 20, 21
Alta	25, 27, 26, 24	23, 22, 24, 25

Se realiza un ANOVA de dos factores y se aplica la prueba de Tukey HSD.

```
# Datos de durabilidad
durabilidad <- c(15, 18, 16, 17, 14, 17, 16, 15,
                20, 22, 21, 19, 19, 18, 20, 21,
                25, 27, 26, 24, 23, 22, 24, 25)

# Factor de material
material <- factor(rep(c("A", "B"), each = 12))

# Factor de temperatura
temperatura <- factor(rep(c("Baja", "Media", "Alta"), each = 4, times = 2))

# Crear un data frame con los datos
datos <- data.frame(durabilidad, material, temperatura)

# Realizar ANOVA de dos factores
modelo <- aov(durabilidad ~ material * temperatura, data = datos)

# Resumen del modelo
summary(modelo)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
material	1	170.67	170.67	102.4	7.44e-09 ***
temperatura	2	65.33	32.67	19.6	3.03e-05 ***
material:temperatura	2	65.33	32.67	19.6	3.03e-05 ***
Residuals	18	30.00	1.67		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

En esta salida:

- El factor “material” no es significativo ($p > 0.05$).
- El factor “temperatura” es significativo ($p < 0.05$).
- La interacción “material:temperatura” no es significativa ($p > 0.05$).

Realizamos la prueba post-hoc de Tukey HSD de comparación de medias:

```
# Realizar la prueba de Tukey HSD
tukey <- TukeyHSD(modelo)

# Mostrar los resultados
print(tukey)
```

Tukey multiple comparisons of means
95% family-wise confidence level

```
Fit: aov(formula = durabilidad ~ material * temperatura, data = datos)
```

```
$material
      diff      lwr      upr p adj
B-A 5.333333 4.22605 6.440616      0
```

```
$temperatura
      diff      lwr      upr      p adj
Baja-Alta -4.0 -5.6474142 -2.3525858 0.0000216
Media-Alta -1.5 -3.1474142  0.1474142 0.0779292
Media-Baja  2.5  0.8525858  4.1474142 0.0030417
```

```
$`material:temperatura`
      diff      lwr      upr      p adj
B:Alta-A:Alta      3  0.09886432  5.901136 0.0403048
A:Baja-A:Alta     -4 -6.90113568 -1.098864 0.0041136
B:Baja-A:Alta     -1 -3.90113568  1.901136 0.8768907
```

A:Media-A:Alta	-5	-7.90113568	-2.098864	0.0004115
B:Media-A:Alta	5	2.09886432	7.901136	0.0004115
A:Baja-B:Alta	-7	-9.90113568	-4.098864	0.0000058
B:Baja-B:Alta	-4	-6.90113568	-1.098864	0.0041136
A:Media-B:Alta	-8	-10.90113568	-5.098864	0.0000009
B:Media-B:Alta	2	-0.90113568	4.901136	0.2889127
B:Baja-A:Baja	3	0.09886432	5.901136	0.0403048
A:Media-A:Baja	-1	-3.90113568	1.901136	0.8768907
B:Media-A:Baja	9	6.09886432	11.901136	0.0000001
A:Media-B:Baja	-4	-6.90113568	-1.098864	0.0041136
B:Media-B:Baja	6	3.09886432	8.901136	0.0000456
B:Media-A:Media	10	7.09886432	12.901136	0.0000000

A la vista de los resultados: ¿Qué contrastes de hipótesis tiene sentido plantear para realizar un experimento en el futuro?

Ejercicio 7

Un investigador quiere evaluar el efecto de dos factores en el rendimiento de los empleados en una tarea de productividad. Los dos factores considerados son el tipo de capacitación (Capacitación A y Capacitación B) y el horario de trabajo (Turno de Mañana, Turno de Tarde y Turno de Noche). Para ello, se seleccionan 3 empleados aleatoriamente para cada combinación de capacitación y horario, y se registra su rendimiento en la tarea (en puntos).

Los datos obtenidos se muestran en la siguiente tabla:

Horario / Capacitación	Capacitación A	Capacitación B
Mañana	78, 82, 81	85, 87, 88
Tarde	72, 75, 74	80, 82, 83
Noche	65, 68, 66	60, 62, 61

Utilizando un nivel de significancia de 0.05, determine si hay diferencias significativas en el rendimiento de los empleados debido al tipo de capacitación, al horario de trabajo, y a la interacción entre ambos factores.

Ejercicio 8

Aplica un método de comparación de medias al ejercicio anterior para estudiar dónde se encuentran las diferencias estadísticamente significativas.

Ejercicio 9

Un investigador quiere evaluar el efecto de tres diferentes dietas en el aumento de peso de ratones. Para ello, selecciona al azar 15 ratones y los divide en tres grupos de 5 ratones cada uno. Cada grupo es alimentado con una dieta diferente durante un período de 8 semanas. Al final del experimento, se mide el aumento de peso (en gramos) de cada ratón. Los datos obtenidos se muestran a continuación:

Dieta A: 20, 21, 19, 23, 22

Dieta B: 30, 32, 29, 31, 33

Dieta C: 25, 27, 26, 24, 28

Utilizando un nivel de significancia de 0.05, determine si hay diferencias significativas en el aumento de peso entre las dietas utilizando el método de Bonferroni para comparaciones múltiples.

Ejercicio 10

Un investigador quiere evaluar el efecto de tres factores en el rendimiento de un motor: el tipo de combustible (Gasolina, Diésel, Eléctrico), la temperatura (Baja, Media, Alta) y la presión (Baja, Media, Alta). Para ello, se mide el rendimiento del motor (en kilovatios) bajo todas las combinaciones posibles de estos factores. Los datos obtenidos se muestran a continuación:

Combustible	Temperatura	Presión	Rendimiento
Gasolina	Baja	Baja	150
Gasolina	Baja	Media	160
Gasolina	Baja	Alta	155
Gasolina	Media	Baja	165
Gasolina	Media	Media	170
Gasolina	Media	Alta	168
Gasolina	Alta	Baja	160
Gasolina	Alta	Media	158
Gasolina	Alta	Alta	162
Diésel	Baja	Baja	140
Diésel	Baja	Media	145
Diésel	Baja	Alta	148
Diésel	Media	Baja	150
Diésel	Media	Media	155
Diésel	Media	Alta	152
Diésel	Alta	Baja	148
Diésel	Alta	Media	150
Diésel	Alta	Alta	149

Combustible	Temperatura	Presión	Rendimiento
Eléctrico	Baja	Baja	130
Eléctrico	Baja	Media	135
Eléctrico	Baja	Alta	138
Eléctrico	Media	Baja	140
Eléctrico	Media	Media	145
Eléctrico	Media	Alta	142
Eléctrico	Alta	Baja	138
Eléctrico	Alta	Media	140
Eléctrico	Alta	Alta	139

Estudia el efecto de cada uno de los factores en el rendimiento, así como el efecto de las posibles interacciones.