

Problemas de Inferencia Estadística

Ejercicios resueltos paso a paso

Víctor Aceña Gil Isaac Martín de Diego
Carmen Lancho Martín

2025-09-30

Índice de Soluciones

Prefacio	4
Filosofía pedagógica	4
¿Cómo usar este manual?	4
Metodología de las soluciones	4
Requisitos de software	5
Introducción a la Inferencia Estadística	7
Ejercicio 1	7
Ejercicio 2	7
Ejercicio 3	8
Ejercicio 4	8
Ejercicio 5	9
Ejercicio 6	10
Ejercicio 7	11
Ejercicio 8	12
Ejercicio 9	13
Ejercicio 10	14
Análisis Exploratorio de Datos	17
Ejercicio 1	17
Ejercicio 2	18
Ejercicio 3	20
Ejercicio 4	21
Ejercicio 5	21
Ejercicio 6	22
Ejercicio 7	23
Ejercicio 8	24
Ejercicio 9	25
Ejercicio 10	26
Procesado y Limpieza de Datos	28
Ejercicio 1	28
Ejercicio 2	30
Intervalos de Confianza	40
Ejercicio 1: Conceptos Básicos	40

Ejercicio 2: Intervalo de Confianza Básico	41
Ejercicio 3: Nivel de Confianza Diferente	42
Ejercicio 4: Interpretación Práctica	43
Ejercicio 5: Varianza Conocida	44
Ejercicio 6: Varianza Desconocida	44
Ejercicio 7: Muestra Grande	45
Ejercicio 8: Proporción	46
Ejercicio 9: Comparación de Proporciones	47
Ejercicio 10: Interpretación Crítica	48
Contrastes de Hipótesis	49
Ejercicio 1: Conceptos Básicos	49
Ejercicio 2: Pasos en un Contraste de Hipótesis	50
Ejercicio 3: Errores tipo I y tipo II. Potencia	51
Ejercicio 4: Contraste para la media de una población normal con varianza conocida	53
Ejercicio 5: Contraste para la media de una población normal con varianza desconocida	54
Ejercicio 6: Contraste de hipótesis para la igualdad de medias de dos muestras independientes	54
Ejercicio 7: Contraste de hipótesis para la diferencia de proporciones	55
Ejercicio 8: Aplicación en un contexto real	56
Ejercicio 9: Prueba t de Student	57
Ejercicio 10: Prueba z para grandes muestras	58

Prefacio

Este manual de soluciones complementa el libro **Inferencia Estadística** y está diseñado para proporcionar un apoyo integral al proceso de aprendizaje. Cada solución ha sido desarrollada con el mismo rigor teórico-práctico que caracteriza al curso, ofreciendo no solo la respuesta correcta, sino también el razonamiento estadístico y la interpretación práctica necesarios para una comprensión profunda.

Filosofía pedagógica

Al igual que el libro principal, este manual sigue un enfoque “**teórico-práctico**” sin concesiones. Las soluciones están diseñadas para:

- **Reforzar** la comprensión de los conceptos fundamentales mediante aplicaciones concretas
- **Desarrollar** la intuición estadística a través de interpretaciones razonadas
- **Conectar** la teoría con la práctica mediante código R completamente funcional
- **Fomentar** el pensamiento crítico sobre las limitaciones y supuestos de cada método

¿Cómo usar este manual?

Para maximizar el beneficio de este recurso:

1. **Intentar primero:** Resuelve cada ejercicio por tu cuenta antes de consultar la solución
2. **Estudiar el proceso:** No solo copies el código, entiende la lógica detrás de cada paso
3. **Experimentar:** Modifica los parámetros y observa cómo cambian los resultados
4. **Reflexionar:** Considera las implicaciones prácticas de cada resultado obtenido

Metodología de las soluciones

Cada solución incluye:

- **Código R completo:** Totalmente ejecutable y comentado

- **Explicaciones paso a paso:** Qué hace cada línea y por qué
- **Interpretación de resultados:** Qué significan los números obtenidos
- **Gráficos explicativos:** Visualización de conceptos clave
- **Consejos prácticos:** Cuándo y cómo usar cada técnica

! Uso responsable

Este manual es una herramienta de aprendizaje, no un sustituto del pensamiento propio. Utilízalo para verificar tu comprensión y mejorar tu técnica, pero siempre tras haber hecho un esfuerzo genuino por resolver los problemas de forma independiente.

Requisitos de software

Para ejecutar las soluciones necesitas tener instalados los siguientes paquetes de R:

```
# Paquetes principales para análisis exploratorio de datos
install.packages(c(
  "ggplot2",      # Visualización de datos
  "dplyr",        # Manipulación de datos
  "tidyr",        # Restructuración de datos
  "readr",        # Lectura de archivos de datos
  "nycflights13"  # Dataset de vuelos usado en ejercicios
))
```

i Sobre los autores

Víctor Aceña Gil es graduado en Matemáticas por la UNED, máster en Tratamiento Estadístico y Computacional de la Información por la UCM y la UPM, doctor en Tecnologías de la Información y las Comunicaciones por la URJC y profesor del departamento de Informática y Estadística de la URJC. Miembro del grupo de investigación de alto rendimiento en Fundamentos y Aplicaciones de la Ciencia de Datos, DSLAB, de la URJC. Pertenece al grupo de innovación docente, DSLAB-TI.

Isaac Martín de Diego es diplomado en Estadística por la Universidad de Valladolid (UVA), licenciado en Ciencias y Técnicas Estadísticas por la Universidad Carlos III de Madrid (UC3M), doctor en Ingeniería Matemática por la UC3M, catedrático de Ciencias de la Computación e Inteligencia Artificial del departamento de Informática y Estadística de la URJC. Es fundador y coordinador del DSLAB y del DSLAB-TI.

Carmen Lancho Martín es graduada en Matemáticas y Estadística por la Universidad Complutense de Madrid (UCM), máster en Tratamiento Estadístico y Computacional de la Información por la UCM y la Universidad Politécnica de Madrid (UPM), doctora en Tecnologías de la Información y las Comunicaciones por la Universidad Rey Juan

Carlos (URJC) y profesora del departamento de Informática y Estadística de la URJC. Miembro del grupo de investigación de alto rendimiento en Fundamentos y Aplicaciones de la Ciencia de Datos, DSLAB, de la URJC. Pertenece al grupo de innovación docente, DSLAB-TI.

Esta obra está bajo una licencia de Creative Commons Atribución-CompartirIgual 4.0 Internacional.

Introducción a la Inferencia Estadística

Ejercicio 1

Describe en tus propias palabras qué es la Ciencia de Datos y su importancia en el análisis de grandes volúmenes de datos.

Solución: La Ciencia de Datos es una disciplina interdisciplinaria que se centra en la extracción de conocimiento significativo a partir de grandes conjuntos de datos. Es crucial en un mundo impulsado por los datos, ya que permite tomar decisiones informadas y hacer predicciones basadas en el análisis de datos. La Ciencia de Datos combina elementos de estadística, informática y conocimiento específico del dominio para interpretar datos y aplicar este conocimiento en diversas áreas como la medicina, las finanzas y la tecnología. Su importancia radica en su capacidad para transformar datos crudos en información valiosa que puede impulsar la innovación y la eficiencia en múltiples campos.

Ejercicio 2

Enumera las herramientas estadísticas que se utilizan en la inferencia estadística y explica brevemente su propósito.

Solución: En la inferencia estadística, se utilizan diversas herramientas para analizar datos y hacer generalizaciones sobre una población a partir de muestras:

- **Pruebas de Hipótesis:** Se utilizan para determinar si existe suficiente evidencia en una muestra de datos para inferir que una cierta condición es verdadera para toda la población.
- **Intervalos de Confianza:** Proporcionan un rango estimado que es probable que contenga el valor de un parámetro desconocido de la población, con un cierto nivel de confianza.
- **Análisis de Varianza (ANOVA):** Permite comparar tres o más medias de grupos para determinar si al menos una de las medias es diferente de las demás.
- **Chi-cuadrado (χ^2):** Es una prueba que mide la discrepancia entre los datos observados y los datos que se esperarían según un modelo específico.
- **T-test:** Evalúa si las medias de dos grupos son estadísticamente diferentes entre sí.
- **Correlación:** Mide la relación entre dos variables y la fuerza de esta relación.

- **Estadística Bayesiana:** Utiliza la probabilidad para representar la incertidumbre sobre los parámetros del modelo y actualiza esta incertidumbre a medida que se obtienen más datos.
- **Métodos de Muestreo:** Incluyen técnicas para seleccionar muestras representativas de la población para realizar inferencias estadísticas.
- **Métodos No Paramétricos:** Son técnicas que no asumen una distribución específica de los datos y son útiles cuando no se cumplen los supuestos de los métodos paramétricos.

Ejercicio 3

Define los términos “población” y “muestra” y explica la diferencia entre ambos.

Solución:

- **Población:** Se refiere al conjunto completo de elementos o resultados que se están estudiando, del cual se desean obtener conclusiones. La población incluye a todos los individuos, mediciones, objetos o eventos que cumplen con un conjunto de especificaciones previamente definidas. Por ejemplo, si estamos estudiando la altura de los estudiantes de una universidad, la población sería la altura de **todos** los estudiantes de esa universidad.
- **Muestra:** Es un subconjunto de la población que se selecciona para representarla. La muestra debe ser representativa de la población para que las inferencias hechas a partir de ella sean válidas. Por ejemplo, si elegimos a 100 estudiantes al azar de la universidad mencionada anteriormente, esos 100 estudiantes constituirían una muestra de la población.

La **diferencia principal** entre ambos términos es el alcance. Mientras que la población es el grupo completo que se quiere estudiar, la muestra es solo una parte de ese grupo. Las muestras se utilizan porque a menudo es impracticable o imposible estudiar toda la población debido a limitaciones de tiempo, costo o logística. Por lo tanto, se selecciona una muestra para obtener estimaciones o pruebas sobre la población completa.

Ejercicio 4

¿Qué es una distribución de probabilidad y cómo se relaciona con las variables cualitativas y cuantitativas?

Solución: Una **distribución de probabilidad** es una función matemática que describe la probabilidad de ocurrencia de los diferentes posibles resultados en un experimento. En otras palabras, asigna probabilidades a cada posible resultado de una variable aleatoria. Las distribuciones de probabilidad se relacionan con las variables cualitativas y cuantitativas de la siguiente manera:

- **Variables Cualitativas (o Categóricas):** Son aquellas que describen una cualidad o categoría y no tienen un orden o medida numérica inherente. Las distribuciones de probabilidad para estas variables son conocidas como **distribuciones discretas** y asignan probabilidades a resultados específicos. Un ejemplo es la **distribución binomial**, que puede modelar eventos como el lanzamiento de una moneda, donde los resultados son categóricos (cara o cruz).
- **Variables Cuantitativas:** Son variables que se pueden medir en una escala numérica y tienen sentido hablar de valores mayores o menores. Las distribuciones de probabilidad asociadas a estas variables son **distribuciones continuas** y asignan probabilidades a intervalos de números. Por ejemplo, la **distribución normal** es una distribución continua que se utiliza comúnmente para modelar fenómenos naturales como la altura o el peso de individuos.

Ejercicio 5

Realiza un resumen descriptivo de un conjunto de datos utilizando medidas de tendencia central y dispersión.

Solución: Imaginemos un conjunto de datos que representa las calificaciones de un grupo de estudiantes en un examen:

```
datos=c(72, 85, 90, 68, 88, 76, 95, 89, 75, 80)
datos
```

```
[1] 72 85 90 68 88 76 95 89 75 80
```

Media:

$$\text{Media} = \frac{72 + 85 + 90 + 68 + 88 + 76 + 95 + 89 + 75 + 80}{10} = \frac{818}{10} = 81.8$$

Mediana: Ordenamos los datos: 68, 72, 75, 76, 80, 85, 88, 89, 90, 95. Como hay 10 valores, la mediana es el promedio de los dos valores centrales:

$$\text{Mediana} = \frac{80 + 85}{2} = \frac{165}{2} = 82.5$$

Moda: No hay un valor que se repita más de una vez, por lo que no hay moda en este conjunto de datos.

Rango:

$$\text{Rango} = 95 - 68 = 27$$

Varianza: Primero, calculamos la media de los cuadrados de las desviaciones respecto a la media:

$$\sigma^2 = \frac{(72 - 81.8)^2 + (85 - 81.8)^2 + \dots + (80 - 81.8)^2}{10} = 71.4$$

Desviación Estándar:

$$\sigma = \sqrt{71.4} \approx 8.45$$

Cuartiles: - **Primer Cuartil (Q1):** Valor en el percentil 25 (primera mitad inferior de los datos):

$$Q1 = 75$$

- **Tercer Cuartil (Q3):** Valor en el percentil 75 (primera mitad superior de los datos):

$$Q3 = 89$$

Resumen Descriptivo

- **Media:** 81.8
- **Mediana:** 82.5
- **Moda:** No hay moda
- **Rango:** 27
- **Varianza:** 71.4
- **Desviación Estándar:** 8.45
- **Primer Cuartil (Q1):** 75
- **Tercer Cuartil (Q3):** 89

Este resumen descriptivo proporciona una visión clara y concisa de las características principales del conjunto de datos, permitiendo una mejor comprensión de su distribución y variabilidad.

Ejercicio 6

Explica la diferencia entre estadística descriptiva e inferencial y proporciona un ejemplo de cómo se utiliza cada una.

Solución: La **estadística descriptiva** y la **estadística inferencial** son dos ramas principales de la estadística que tienen propósitos y métodos diferentes:

- **Estadística Descriptiva:** Se centra en resumir y describir las características de un conjunto de datos. Utiliza medidas como la media, mediana, moda, rango y desviación estándar para dar una visión general de los datos. Por ejemplo, si tenemos los resultados de una prueba de matemáticas de una clase, la estadística descriptiva podría incluir el cálculo de la media de las calificaciones, la calificación más alta, la más baja y la variabilidad de las calificaciones.

- **Estadística Inferencial:** Va más allá de la descripción de los datos y busca hacer predicciones o generalizaciones sobre una población basándose en una muestra de datos. Utiliza herramientas como pruebas de hipótesis, intervalos de confianza y regresión para inferir patrones y tomar decisiones. Por ejemplo, si queremos saber si un nuevo método de enseñanza es efectivo, podríamos aplicarlo a una muestra de estudiantes y usar la estadística inferencial para determinar si los resultados observados en la muestra pueden generalizarse a todos los estudiantes.

Solución:

Ejercicio 7

Diseña un experimento para ilustrar cómo el muestreo aleatorio simple puede ser utilizado para estimar una característica de una población.

Solución: Para ilustrar cómo el muestreo aleatorio simple puede ser utilizado para estimar una característica de una población, consideremos el siguiente experimento:

Objetivo del Experimento: Estimar la proporción de personas en una ciudad que prefieren el transporte público sobre otros medios de transporte.

Población: Todos los residentes de la ciudad que son mayores de edad y utilizan algún medio de transporte para desplazarse.

Característica de Interés: Preferencia por el transporte público.

Procedimiento:

1. **Definición de la Población:** Identificar a todos los residentes de la ciudad que son mayores de edad y utilizan algún medio de transporte.
2. **Selección de la Muestra:**
 - Utilizar un registro actualizado de la población, como el padrón municipal, para obtener una lista de individuos.
 - Seleccionar una muestra aleatoria de individuos utilizando un generador de números aleatorios.
 - Determinar el tamaño de la muestra necesario para obtener resultados con un nivel de confianza y un margen de error deseado.
3. **Recolección de Datos:**
 - Contactar a los individuos seleccionados y preguntarles si prefieren el transporte público sobre otros medios de transporte.
 - Registrar las respuestas afirmativas y negativas.
4. **Análisis de Datos:**

- Calcular la proporción de respuestas afirmativas en la muestra.
- Utilizar esta proporción como una estimación puntual de la preferencia en la población total.

5. Estimación de la Población:

- Calcular un intervalo de confianza para la proporción estimada, lo que proporcionará un rango dentro del cual se espera que se encuentre la verdadera proporción de la población con un cierto nivel de confianza.

6. Conclusión:

- Presentar la proporción estimada y el intervalo de confianza como la estimación de la preferencia por el transporte público en la población.
- Discutir las limitaciones del estudio y la posibilidad de sesgo si la muestra no fue perfectamente aleatoria o si hubo una tasa de respuesta baja.

Ejercicio 8

Explica el Teorema Central del Límite y su relevancia en la inferencia estadística.

Solución: Teorema Central del Límite (TCL)

El Teorema Central del Límite es un principio fundamental en estadística que establece que, bajo ciertas condiciones, la distribución de la suma de un gran número de variables aleatorias independientes y idénticamente distribuidas (i.i.d.) tiende a aproximarse a una distribución normal (gaussiana), independientemente de la forma de la distribución original de las variables.

Enunciado del Teorema Central del Límite

Para una muestra de tamaño (n) tomada de una población con cualquier distribución de probabilidad con media (μ) y desviación estándar (σ), la distribución de la media muestral $\bar{X}$ se aproximará a una distribución normal a medida que (n) se haga grande. Matemáticamente, si ($X_1, X_2, \dots, X_n$) son variables aleatorias independientes e idénticamente distribuidas con media (μ) y desviación estándar (σ), entonces la media muestral $\bar{X}$ se distribuye aproximadamente como:

$$\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

Importancia y Relevancia en la Inferencia Estadística

1. **Justificación del Uso de la Distribución Normal:** El TCL permite justificar el uso de la distribución normal en la inferencia estadística. Incluso si la población original no está distribuida normalmente, la distribución de las medias muestrales se aproximará a una distribución normal si el tamaño de la muestra es suficientemente grande.
2. **Construcción de Intervalos de Confianza:** Permite construir intervalos de confianza para estimar parámetros poblacionales. Por ejemplo, al estimar la media poblacional, podemos utilizar la distribución normal para determinar un rango donde probablemente se encuentra la media verdadera.
3. **Pruebas de Hipótesis:** Facilita la realización de pruebas de hipótesis. Dado que la distribución de la media muestral es aproximadamente normal, se pueden aplicar métodos estadísticos basados en la normalidad para decidir si rechazar o no una hipótesis nula.
4. **Simplificación de Cálculos:** El TCL simplifica el análisis de datos, ya que permite trabajar con la distribución normal, que tiene propiedades bien definidas y es ampliamente comprendida y tabulada, facilitando los cálculos y la interpretación de los resultados.
5. **Aplicación Universal:** Es aplicable en una amplia gama de situaciones, desde la economía y la biología hasta la ingeniería y las ciencias sociales, siempre que se cumplan las condiciones necesarias (independencia y tamaño de muestra grande).

Ejercicio 9

Compara y contrasta la estadística paramétrica y no paramétrica, dando ejemplos de cuándo se utilizaría cada una.

Solución: La **estadística paramétrica** y la **estadística no paramétrica** son dos enfoques de análisis estadístico que tienen diferentes supuestos y aplicaciones. La **estadística paramétrica** se utiliza cuando los datos se ajustan a ciertos supuestos y se conoce la distribución subyacente, lo que permite hacer inferencias más precisas si estos supuestos se cumplen. Por otro lado, la **estadística no paramétrica** es más flexible y se puede utilizar en una variedad más amplia de situaciones, especialmente cuando los datos no cumplen con los supuestos de los métodos paramétricos.

- **Estadística Paramétrica:**

- **Supuestos:** Asume que los datos de la muestra provienen de una población que sigue una distribución de probabilidad conocida, generalmente la distribución normal. También asume homogeneidad de varianzas y la independencia de las observaciones.
- **Uso:** Se utiliza cuando se conoce la forma de la distribución subyacente de los datos o cuando se tiene una muestra grande que, por el Teorema Central del Límite, tiende a una distribución normal.
- **Ejemplos de Herramientas:** T-test, ANOVA, regresión lineal.

- **Ejemplo de Uso:** Si queremos comparar las alturas promedio de dos grupos de personas y sabemos que las alturas siguen una distribución normal, podríamos usar un T-test paramétrico.

- **Estadística No Paramétrica:**

- **Supuestos:** No hace suposiciones sobre la forma de la distribución de la población. Es útil cuando no se cumplen los suposiciones de normalidad o cuando se trata con muestras pequeñas.
- **Uso:** Se aplica en situaciones donde no se conoce la distribución de los datos o cuando los datos son ordinales o nominales.
- **Ejemplos de Herramientas:** Test de Wilcoxon, Test de Kruskal-Wallis, Test de Chi-cuadrado.
- **Ejemplo de Uso:** Si queremos comparar las medianas de los tiempos de respuesta de dos grupos en una prueba y los datos son claramente no normales o son rangos en lugar de medidas, podríamos usar un test de Wilcoxon no paramétrico.

Ejercicio 10

Discute las diferencias entre los enfoques frecuentista y bayesiano en la inferencia estadística y da un ejemplo de aplicación para cada uno.

Solución: La inferencia estadística se basa en métodos que nos permiten hacer conclusiones sobre una población a partir de datos muestrales. Existen dos enfoques principales en la inferencia estadística: el enfoque frecuentista y el enfoque bayesiano. A continuación, se presentan las diferencias clave entre estos enfoques y ejemplos de aplicación para cada uno.

Enfoque Frecuentista

Características Principales:

1. **Interpretación de Probabilidad:** La probabilidad se interpreta como la frecuencia relativa de eventos en el largo plazo. Es decir, si un experimento se repite infinitas veces, la probabilidad de un evento es la proporción de veces que ocurre.
2. **Estimación de Parámetros:** Se basa en el concepto de estimación puntual y de intervalos de confianza. Los parámetros poblacionales se consideran fijos pero desconocidos, y los datos son aleatorios.
3. **Pruebas de Hipótesis:** Utiliza pruebas de hipótesis y valores p para decidir si rechazar la hipótesis nula. Las decisiones se basan en la frecuencia de observación de datos extremos bajo la suposición de que la hipótesis nula es verdadera.
4. **No usa Información Priori:** Los análisis frecuentistas no incorporan información previa sobre los parámetros; sólo se basan en los datos actuales.

Ejemplo de Aplicación Frecuentista:

Imaginemos que una empresa desea saber si un nuevo medicamento es efectivo para reducir la presión arterial. Realizan un ensayo clínico donde:

- **Hipótesis Nula (H_0):** El medicamento no tiene efecto en la presión arterial (la media de la reducción de la presión arterial es 0).
- **Hipótesis Alternativa (H_1):** El medicamento reduce la presión arterial (la media de la reducción de la presión arterial es mayor que 0).

El análisis frecuentista implicaría:

1. Recoger datos muestrales de pacientes.
2. Calcular la media y la desviación estándar de la reducción en la presión arterial.
3. Realizar una prueba t para comparar la media muestral con 0.
4. Calcular el valor p para determinar la significancia estadística.
5. Rechazar o no la hipótesis nula en función del valor p y el nivel de significancia establecido (por ejemplo, 0.05).

Enfoque Bayesiano

Características Principales:

1. **Interpretación de Probabilidad:** La probabilidad se interpreta como un grado de creencia o confianza sobre la ocurrencia de un evento, dado el conocimiento disponible.
2. **Estimación de Parámetros:** Los parámetros poblacionales se tratan como variables aleatorias con distribuciones de probabilidad. Utiliza la distribución a priori (información previa) y los datos observados para obtener la distribución a posteriori.
3. **Actualización de Conocimientos:** Aplica el Teorema de Bayes para actualizar la probabilidad a medida que se dispone de nueva información.
4. **Incorporación de Información Priori:** Utiliza información previa sobre los parámetros en forma de distribuciones a priori, que se combinan con la información de los datos para obtener las distribuciones a posteriori.

Ejemplo de Aplicación Bayesiana:

Supongamos que un médico quiere estimar la probabilidad de que un paciente tenga una enfermedad dada, basándose en un resultado positivo de una prueba diagnóstica y en el conocimiento previo sobre la prevalencia de la enfermedad y la precisión de la prueba.

1. **Información a Priori:** El médico tiene una estimación previa (a priori) de la prevalencia de la enfermedad (por ejemplo, 1% de la población tiene la enfermedad).
2. **Datos Observados:** La sensibilidad (probabilidad de un resultado positivo dado que el paciente tiene la enfermedad) es 90% y la especificidad (probabilidad de un resultado negativo dado que el paciente no tiene la enfermedad) es 95%.
3. **Aplicación del Teorema de Bayes:**

- ($P(E|+)$): Probabilidad de tener la enfermedad dado un resultado positivo.
- ($P(+|E)$): Sensibilidad.
- ($P(+|\neg E)$): Probabilidad de un falso positivo (1 - especificidad).
- ($P(E)$): Prevalencia de la enfermedad.
- ($P(\neg E)$): Probabilidad de no tener la enfermedad (1 - prevalencia).

$$P(E|+) = \frac{P(+|E) \cdot P(E)}{P(+|E) \cdot P(E) + P(+|\neg E) \cdot P(\neg E)}$$

Sustituyendo los valores:

$$P(E|+) = \frac{0.90 \cdot 0.01}{0.90 \cdot 0.01 + 0.05 \cdot 0.99} = \frac{0.009}{0.009 + 0.0495} = \frac{0.009}{0.0585} \approx 0.154$$

El resultado indica que, dado un resultado positivo de la prueba, la probabilidad a posteriori de tener la enfermedad es aproximadamente 15.4%.

Conclusión

Frecuentista:

- No utiliza información previa.
- Se basa en la frecuencia de los eventos.
- Adecuado para análisis donde no se dispone de información previa o se quiere evitar la subjetividad.

Bayesiano:

- Utiliza información previa (a priori).
- Actualiza las probabilidades a medida que se dispone de nueva información.
- Adecuado para situaciones donde la información previa es relevante y valiosa.

Ambos enfoques son útiles y válidos, y la elección entre ellos depende del contexto del problema, la disponibilidad de información previa y las preferencias del investigador.

Análisis Exploratorio de Datos

Utilizar el dataframe denominado *bank* con el que hemos trabajado en el tema 2 de la asignatura para responder a las siguientes cuestiones:

```
library(ggplot2)
library(dplyr)
library(readr)

# Cargar el conjunto de datos
url <- "https://archive.ics.uci.edu/ml/machine-learning-databases/00222/bank.zip"
download.file(url, "bank.zip")
unzip("bank.zip", "bank-full.csv")
bank_data <- read.csv("bank-full.csv", sep=";")
```

Ejercicio 1

Estructura del DataFrame:

- ¿Cuántos campos y observaciones tiene el dataframe **bank**? Utiliza las funciones **head** y **dim**.

```
# Pregunta 1: Estructura del DataFrame
head(bank_data)
```

	age	job	marital	education	default	balance	housing	loan	contact	day
1	58	management	married	tertiary	no	2143	yes	no	unknown	5
2	44	technician	single	secondary	no	29	yes	no	unknown	5
3	33	entrepreneur	married	secondary	no	2	yes	yes	unknown	5
4	47	blue-collar	married	unknown	no	1506	yes	no	unknown	5
5	33	unknown	single	unknown	no	1	no	no	unknown	5
6	35	management	married	tertiary	no	231	yes	no	unknown	5
	month	duration	campaign	pdays	previous	poutcome	y			
1	may	261	1	-1	0	unknown	no			
2	may	151	1	-1	0	unknown	no			

```

3   may      76      1   -1      0   unknown no
4   may      92      1   -1      0   unknown no
5   may     198      1   -1      0   unknown no
6   may     139      1   -1      0   unknown no

```

```
dim(bank_data)
```

```
[1] 45211    17
```

Respuesta:

El dataframe `bank_data` contiene 45,211 observaciones (filas) y 17 variables (columnas). La función `head()` nos muestra las primeras 6 filas del conjunto de datos, donde podemos observar variables numéricas como `age`, `balance` y `duration`, así como variables categóricas como `job`, `marital` y `education`. Esta estructura nos permite analizar tanto características demográficas como comportamentales de los clientes contactados durante la campaña de marketing.

Ejercicio 2

Resumen del DataFrame:

- Evalúa el dataframe con la función `summary`.
- ¿Tiene observaciones con elementos faltantes (NA)?
- ¿A qué categorías corresponden las observaciones en la variable `job`?

```
# Pregunta 2: Resumen del DataFrame
summary(bank_data)
```

```

      age      job      marital      education
Min.   :18.00 Length:45211 Length:45211 Length:45211
1st Qu.:33.00 Class :character Class :character Class :character
Median :39.00 Mode  :character Mode  :character Mode  :character
Mean   :40.94
3rd Qu.:48.00
Max.   :95.00

 default      balance      housing      loan
Length:45211 Min.   : -8019 Length:45211 Length:45211
Class :character 1st Qu.:   72 Class :character Class :character
Mode  :character Median :  448 Mode  :character Mode  :character
              Mean   : 1362
              3rd Qu.: 1428

```

	Max. :102127		
contact	day	month	duration
Length:45211	Min. : 1.00	Length:45211	Min. : 0.0
Class :character	1st Qu.: 8.00	Class :character	1st Qu.: 103.0
Mode :character	Median :16.00	Mode :character	Median : 180.0
	Mean :15.81		Mean : 258.2
	3rd Qu.:21.00		3rd Qu.: 319.0
	Max. :31.00		Max. :4918.0
campaign	pdays	previous	poutcome
Min. : 1.000	Min. : -1.0	Min. : 0.0000	Length:45211
1st Qu.: 1.000	1st Qu.: -1.0	1st Qu.: 0.0000	Class :character
Median : 2.000	Median : -1.0	Median : 0.0000	Mode :character
Mean : 2.764	Mean : 40.2	Mean : 0.5803	
3rd Qu.: 3.000	3rd Qu.: -1.0	3rd Qu.: 0.0000	
Max. :63.000	Max. :871.0	Max. :275.0000	
y			
Length:45211			
Class :character			
Mode :character			

```
sum(is.na(bank_data))
```

```
[1] 0
```

```
unique(bank_data$job)
```

```
[1] "management" "technician" "entrepreneur" "blue-collar"
[5] "unknown" "retired" "admin." "services"
[9] "self-employed" "unemployed" "housemaid" "student"
```

Respuesta:

El resumen estadístico proporciona información clave sobre cada variable del dataset. El dataset no contiene valores faltantes (NA), lo cual facilita el análisis sin necesidad de imputación. La variable `job` clasifica a los clientes en 12 categorías profesionales: `admin.`, `blue-collar`, `entrepreneur`, `housemaid`, `management`, `retired`, `self-employed`, `services`, `student`, `technician`, `unemployed` y `unknown`. Las categorías más frecuentes son `blue-collar` (trabajadores manuales), `management` (gerentes) y `technician` (técnicos), lo que refleja una muestra diversa de perfiles profesionales en la base de clientes del banco.

Ejercicio 3


Distribución de la Edad:

- ¿Cuál es la edad máxima y mínima de los clientes en el dataframe?
- ¿Cuál es la media y la mediana de la edad de los clientes?

```
# Pregunta 3: Distribución de la Edad  
summary(bank_data$age)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
18.00	33.00	39.00	40.94	48.00	95.00

```
ggplot(bank_data, aes(x = age)) +  
  geom_histogram(binwidth = 5, fill = "lightblue", color = "black") +  
  labs(title = "Distribución de la Edad de los Clientes",  
        x = "Edad",  
        y = "Frecuencia") +  
  theme_minimal()
```



Respuesta:

La edad de los clientes varía entre 18 años (mínimo) y 95 años (máximo), con una media de 40.94 años y una mediana de 39 años. El histograma muestra una distribución ligeramente sesgada a la derecha, con la mayor concentración de clientes entre los 30 y 50 años. La proximidad entre la media y la mediana indica que no hay valores extremos que distorsionen significativamente la distribución central. La amplitud del rango etario sugiere que la campaña se dirigió a un público amplio, desde jóvenes adultos hasta personas de edad avanzada.

Ejercicio 4

Balance Promedio:

- ¿Cuál es el balance promedio anual (balance) de los clientes?
- ¿Cuál es el balance promedio anual de los clientes que han suscrito un depósito a plazo fijo (y = "yes")?

```
# Pregunta 4: Balance Promedio  
mean(bank_data$balance, na.rm = TRUE)
```

```
[1] 1362.272
```

```
mean(bank_data$balance[bank_data$y == "yes"], na.rm = TRUE)
```

```
[1] 1804.268
```

Respuesta:

El balance promedio anual de todos los clientes es de 1,362.27 €. Los clientes que suscribieron un depósito a plazo fijo tienen un balance promedio de 1,804.27 €, significativamente superior al promedio general. Esta diferencia de aproximadamente 442 € sugiere que el balance financiero es un factor relevante en la decisión de suscripción, ya que los clientes con mayor capacidad de ahorro tienden a estar más interesados en productos de inversión como los depósitos a plazo fijo.

Ejercicio 5

Frecuencia de Contacto:

- ¿Cuál es el número máximo y mínimo de contactos realizados durante esta campaña (campaign)?

```
# Pregunta 5: Frecuencia de Contacto
summary(bank_data$campaign)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
1.000	1.000	2.000	2.764	3.000	63.000

Respuesta:

Durante la campaña, el número de contactos realizados a los clientes varía entre 1 (mínimo) y 63 (máximo), con una media de 2.76 contactos por cliente. La mediana de 2 contactos indica que la mayoría de los clientes fueron contactados pocas veces, lo cual es una buena práctica para evitar saturar a los clientes. Sin embargo, la existencia de casos extremos con hasta 63 contactos sugiere que algunos clientes requirieron múltiples seguimientos, posiblemente clientes difíciles de convencer o con mayor interés que necesitaban información adicional antes de tomar una decisión.

Ejercicio 6

Análisis de Duración:

- ¿Cuál es la duración media y mediana del último contacto en segundos (`duration`)?
- ¿Cuál es la duración media del último contacto en segundos para los clientes que suscribieron un depósito a plazo fijo (`y = "yes"`)?

```
# Pregunta 6: Análisis de Duración
summary(bank_data$duration)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.0	103.0	180.0	258.2	319.0	4918.0

```
mean(bank_data$duration[bank_data$y == "yes"], na.rm = TRUE)
```

```
[1] 537.2946
```

Respuesta:


La duración del último contacto tiene una media de 258.16 segundos (aproximadamente 4.3 minutos) y una mediana de 180 segundos (3 minutos). Los clientes que suscribieron el depósito tuvieron conversaciones significativamente más largas, con una duración media de 537.29 segundos (aproximadamente 9 minutos). Esta diferencia de casi 5 minutos adicionales es notable y sugiere que la duración del contacto es un fuerte predictor del éxito de la campaña: conversaciones más extensas permiten explicar mejor el producto, resolver dudas y construir confianza con el cliente.

Ejercicio 7

Relación entre Variables:

- ¿Existe alguna relación entre el balance promedio anual y la duración del último contacto? Utiliza una visualización adecuada para responder a esta pregunta.

```
# Pregunta 7: Relación entre Balance y Duración
ggplot(bank_data, aes(x = balance, y = duration)) +
  geom_point(alpha = 0.5) +
  labs(title = "Relación entre Balance y Duración del Último Contacto",
       x = "Balance",
       y = "Duración (segundos)") +
  theme_minimal()
```



```
cor(bank_data$balance, bank_data$duration, use = "complete.obs")
```

```
[1] 0.02156038
```

Respuesta:

El diagrama de dispersión muestra una nube de puntos sin un patrón claro, y la correlación de Pearson entre balance y duración es prácticamente nula ($r = 0.022$). Esto indica que no existe

una relación lineal significativa entre el balance del cliente y la duración de la llamada. En otras palabras, el balance financiero del cliente no predice cuánto durará la conversación. Clientes con balances altos y bajos pueden tener conversaciones de cualquier duración, lo que sugiere que otros factores (como el interés del cliente, la habilidad del operador o la complejidad de las preguntas) son más determinantes en la duración del contacto.

Ejercicio 8

Segmentación por Trabajo:

- ¿Cuál es la media y mediana del balance anual de los clientes agrupados por tipo de trabajo (job)?

```
# Pregunta 8: Segmentación por Trabajo
bank_data %>% group_by(job) %>%
  summarise(media_balance = mean(balance, na.rm = TRUE),
            mediana_balance = median(balance, na.rm = TRUE))
```

```
# A tibble: 12 x 3
  job          media_balance mediana_balance
  <chr>          <dbl>          <dbl>
1 admin.         1136.           396
2 blue-collar    1079.           388
3 entrepreneur   1521.           352
4 housemaid      1392.           406
5 management     1764.           572
6 retired        1984.           787
7 self-employed  1648.           526
8 services        997.           340
9 student        1388.           502
10 technician    1253.           421
11 unemployed    1522.           529
12 unknown       1772.           677
```

Respuesta:

La segmentación por tipo de trabajo revela diferencias importantes en los balances. Los jubilados (retired) presentan el balance medio más alto (1,984 €), seguidos por trabajadores con ocupación desconocida (unknown) con 1,772 € y los gerentes (management) con 1,764 €. En el extremo opuesto, los trabajadores de servicios (services) tienen el balance medio más bajo (997 €), seguidos por los trabajadores manuales (blue-collar) con 1,079 €. Esta estratificación económica según la ocupación es lógica: los jubilados han tenido toda una vida laboral para

acumular ahorros, mientras que los trabajadores de servicios suelen tener salarios más bajos. Esta información es valiosa para segmentar las campañas de marketing, dirigiendo productos de mayor inversión a los grupos con mayor capacidad de ahorro.

Ejercicio 9

Análisis de Contactos Anteriores:

- ¿Cuál es el número máximo y mínimo de días que pasaron desde el último contacto de una campaña anterior (`pdays`)?
- ¿Cuál es la media de `pdays` para los clientes que suscribieron un depósito a plazo fijo (`y = "yes"`)?

```
# Pregunta 9: Análisis de Contactos Anteriores  
summary(bank_data$pdays)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-1.0	-1.0	-1.0	40.2	-1.0	871.0

```
mean(bank_data$pdays[bank_data$y == "yes"], na.rm = TRUE)
```

```
[1] 68.70297
```

Respuesta:

La variable `pdays` tiene un valor especial de -1 que indica que el cliente no fue contactado en campañas anteriores, y este es el valor más frecuente (mediana de -1). Para los clientes que sí fueron contactados previamente, el rango varía ampliamente hasta 871 días. La media de `pdays` para los clientes que suscribieron es de 68.70 días. Es importante notar que el valor de -1 domina la distribución, lo que sugiere que muchas conversiones exitosas provienen de clientes nuevos o que no habían sido contactados en campañas anteriores. Sin embargo, la media de 68.70 días para suscriptores indica que aquellos contactados previamente y que finalmente suscriben, lo hicieron después de aproximadamente 2 meses desde el último contacto, lo que podría indicar un tiempo óptimo para recontactar.

Ejercicio 10

Estudio General:

- Haciendo un estudio general de los datos, ¿qué puedes concluir?
- ¿Existe alguna relación significativa entre las variables `balance`, `duration`, y `campaign`?
Se recomienda hacer un análisis visual y estadístico de estas variables.

```
# Pregunta 10: Estudio General
# Puedes utilizar técnicas de análisis más avanzadas como correlación, regresión, etc.
cor(bank_data$balance, bank_data$duration, use = "complete.obs")
```

```
[1] 0.02156038
```


```
cor(bank_data$balance, bank_data$campaign, use = "complete.obs")
```

```
[1] -0.01457828
```

```
cor(bank_data$duration, bank_data$campaign, use = "complete.obs")
```

```
[1] -0.0845695
```

```
ggplot(bank_data, aes(x = campaign, y = balance)) +
  geom_point(alpha = 0.5) +
  labs(title = "Relación entre Campañas y Balance",
       x = "Número de Campañas",
       y = "Balance") +
  theme_minimal()
```



Respuesta:

El análisis general de los datos revela varios hallazgos importantes. En cuanto a las relaciones entre variables, las correlaciones son muy débiles: balance vs duration ($r = 0.022$), balance vs campaign ($r = -0.015$), y duration vs campaign ($r = -0.085$). Esto indica que estas tres variables operan de manera relativamente independiente entre sí.

Los factores más asociados al éxito de la campaña son: la duración del contacto emerge como el predictor más fuerte del éxito (conversaciones de ~9 minutos para suscriptores vs ~4 minutos para no suscriptores), el balance muestra una relación positiva pero moderada con la suscripción, y el número de contactos previos tiene una relación débil y negativa.

La segmentación de clientes muestra alta variabilidad en los balances según la ocupación, con jubilados (1,984 €), unknown (1,772 €) y gerentes (1,764 €) como los grupos más prometedores financieramente. La eficiencia de la campaña se caracteriza por contactos mayormente breves y eficientes (1-3 intentos), donde las conversaciones largas están fuertemente asociadas con conversiones exitosas.

En conclusión, el éxito de la campaña depende más de la calidad de la interacción (duración y contenido de la conversación) que de características demográficas o económicas del cliente. Las recomendaciones estratégicas incluyen: priorizar calidad sobre cantidad en los contactos, invertir en conversaciones más largas y detalladas, segmentar audiencias dirigiendo productos premium a ocupaciones con mayor capacidad económica, y limitar contactos repetidos para evitar saturar a clientes que no muestran interés inicial.

Procesado y Limpieza de Datos

```
library(tidyr)
library(dplyr)
```

Ejercicio 1

Crear el siguiente *dataframe* mediante estas instrucciones

```
set.seed(1234)
stocks <- data.frame(time = as.Date("2009-01-01") + 0:9,
                      Walmart = rnorm(10,20,1),
                      Target = rnorm(10,20,2),
                      Walgreens = rnorm(10,20,4)
)
stocks
```

	time	Walmart	Target	Walgreens
1	2009-01-01	18.79293	19.04561	20.53635
2	2009-01-02	20.27743	18.00323	18.03726
3	2009-01-03	21.08444	18.44749	18.23781
4	2009-01-04	17.65430	20.12892	21.83836
5	2009-01-05	20.42912	21.91899	17.22512
6	2009-01-06	20.50606	19.77943	14.20718
7	2009-01-07	19.42526	18.97798	22.29902
8	2009-01-08	19.45337	18.17761	15.90538
9	2009-01-09	19.43555	18.32566	19.93945
10	2009-01-10	19.10996	24.83167	16.25621

A continuación, realizar las siguientes operaciones de limpieza de datos:

- Como se puede observar, hay un problema de clave-valor en las compañías con sus observaciones. Por lo tanto, se pide transformar los datos para que tengan una clave “*stock*” y un valor “*precio*”. Utilizar la instrucción “*gather*”.

- Devolver el dataframe al estado original empleando la instrucción *spread*.
- Utilizando el operador tubería `%>%` se desea realizar las siguientes operaciones anidadas:
 - Transformar los datos para que tengan una clave “*stock*” y el valor sea el “*precio*”. Utilizar la instrucción “*gather*”.
 - Agrupar los datos por la clave “*stock*” mediante la instrucción “*group_by*”.
 - Obtener el precio mínimo y el máximo utilizando la instrucción “*summarise*”.

```
# Transformar los datos para que tengan una clave stock y el valor sea el precio.
# Opción 1:
new_stocks <- gather(data = stocks, key = stock, value = price, Walmart, Target, Walgreens)

# Opción 2:
new_stocks <- gather(data = stocks, key = stock, value = price, Walmart:Walgreens)

# Opción 3:
new_stocks <- gather(data = stocks, key = stock, value = price, -time)

# Devolver el dataframe al estado original utilizando la función "spread".
original_stocks <- spread(data = new_stocks, key = stock, value = price)

# Utilizando el operador tubería %>% realizar las operaciones anidadas.
stocks %>%
  gather(key = stock, value = price, Walmart:Walgreens) %>%
  group_by(stock) %>%
  summarise(min = min(price), max = max(price))
```

```
# A tibble: 3 x 3
  stock      min    max
  <chr>    <dbl> <dbl>
1 Target    18.0  24.8
2 Walgreens  14.2  22.3
3 Walmart   17.7  21.1
```

Respuesta:

El ejercicio demuestra tres operaciones fundamentales en la reestructuración de datos con *tidyr*. Primero, la función `gather()` convierte el dataframe de formato ancho a formato largo, transformando las columnas de las tres compañías (Walmart, Target, Walgreens) en dos columnas: una clave llamada “*stock*” que identifica la compañía y otra llamada “*price*” que contiene los valores. Se presentan tres formas equivalentes de realizar esta operación: especificando las columnas explícitamente, usando el operador de rango `:`, o excluyendo columnas con el signo `-`.

Segundo, la función `spread()` realiza la operación inversa, devolviendo el dataframe a su formato ancho original. Esta operación toma la columna clave “stock” y crea una columna separada para cada valor único, rellenándolas con los valores correspondientes de la columna “price”.

Finalmente, el uso del operador tubería `%>%` permite encadenar múltiples operaciones de forma legible. En este caso, se transforma el dataframe a formato largo con `gather()`, se agrupan las observaciones por compañía con `group_by()`, y se calculan estadísticos resumen (precio mínimo y máximo) para cada grupo usando `summarise()`. Esta secuencia de operaciones es típica en el análisis exploratorio de datos y demuestra el poder del enfoque tidyverse para manipulación de datos.

Ejercicio 2

En este ejercicio vamos a manejar datos contenidos en distintos *dataframes* y operar sobre ellos con *dplyr*.

1. Descargar el paquete *nycflights13*.
2. Evaluar el contenido de los dataframes proporcionados por el paquete. Utilizar *head* y *summary*.
3. Simplificar los dataframes originales a 100 observaciones mediante el comando *head*. Asignarlos a una variable que indique el tipo de dataframe añadiendo la coletilla “_simple”. Ejemplo: “flights_simple”.
4. Selecciona los tipos de aerolínea (“carrier”) mediante la instrucción *select* y el operador *unique* concatenados con el operador tubería `%>%`. (Utilizar “airlines_simple”).
5. Obtener la media y el número máximo de asientos (“seats”) que tienen los aviones. Utilizar el operador tubería `%>%` y la instrucción *summarise*.
6. Ordenar los aviones por su número de motores (“engines”) y número de asientos (“seats”). Utilizar la instrucción *arrange*.
7. Averigua qué número de cola (“tailnum”) comparten los dataframes “flights_simple” y “planes_simple” que has creado anteriormente. Obten su aerolínea (“carrier”). Utilizar la instrucción *inner_join*.
8. Cruzar los datos de vuelos (“flights”) con los aviones (“planes”) por el número de cola (“tailnum”) que no coincidan (usar la instrucción *anti_join*). De esos obtener aquellos con 2 o más motores (usar la instrucción *filter*). Finalmente obtener los distintos modelos de avión que satisfacen las premisas anteriores (usar la instrucción *unique*).
9. Crea una nueva variable (“total_delay”) que calcule el retraso total sumando los delays acumulados (“dep_delay”) y (“arr_delay”). Utilizar la instrucción *mutate*. Almacena el dataframe resultante en “flights_total”.
10. En base a la variable anteriormente obtenida (“total_delay”), devuelve los aviones que han llegado con antelación a su destino, es decir aquellos tal que la variable *total_delay* tiene valores negativos.

```
library(dplyr)
library(nycflights13)

# Observamos los distintos dataframes que nos proporcionan
print(head(flights))
```

```
# A tibble: 6 x 19
  year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
  <int> <int> <int>   <int>         <int>         <dbl>   <int>         <int>
1  2013     1     1     517             515           2     830             819
2  2013     1     1     533             529           4     850             830
3  2013     1     1     542             540           2     923             850
4  2013     1     1     544             545          -1    1004            1022
5  2013     1     1     554             600          -6     812             837
6  2013     1     1     554             558          -4     740             728
# i 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
#   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
#   hour <dbl>, minute <dbl>, time_hour <dtm>
```

```
print(head(airports))
```

```
# A tibble: 6 x 8
  faa   name                lat   lon   alt   tz dst  tzone
  <chr> <chr>                <dbl> <dbl> <dbl> <dbl> <chr> <chr>
1 04G   Lansdowne Airport      41.1 -80.6  1044   -5 A   America/Ne~
2 06A   Moton Field Municipal Airport 32.5 -85.7   264   -6 A   America/Ch~
3 06C   Schaumburg Regional    42.0 -88.1   801   -6 A   America/Ch~
4 06N   Randall Airport        41.4 -74.4   523   -5 A   America/Ne~
5 09J   Jekyll Island Airport   31.1 -81.4    11   -5 A   America/Ne~
6 0A9   Elizabethton Municipal Airport 36.4 -82.2  1593   -5 A   America/Ne~
```

```
print(head(weather))
```

```
# A tibble: 6 x 15
  origin year month   day hour temp dewp humid wind_dir wind_speed wind_gust
  <chr>   <int> <int> <int> <int> <dbl> <dbl> <dbl>   <dbl>    <dbl>    <dbl>
1 EWR    2013     1     1     1 39.0 26.1 59.4    270     10.4      NA
2 EWR    2013     1     1     2 39.0 27.0 61.6    250      8.06     NA
3 EWR    2013     1     1     3 39.0 28.0 64.4    240     11.5      NA
4 EWR    2013     1     1     4 39.9 28.0 62.2    250     12.7      NA
```

```

5 EWR      2013      1      1      5 39.0 28.0 64.4      260      12.7      NA
6 EWR      2013      1      1      6 37.9 28.0 67.2      240      11.5      NA
# i 4 more variables: precip <dbl>, pressure <dbl>, visib <dbl>,
#   time_hour <dtm>

```

```
print(head(airlines))
```

```

# A tibble: 6 x 2
  carrier name
  <chr>   <chr>
1 9E      Endeavor Air Inc.
2 AA      American Airlines Inc.
3 AS      Alaska Airlines Inc.
4 B6      JetBlue Airways
5 DL      Delta Air Lines Inc.
6 EV      ExpressJet Airlines Inc.

```

```
print(head(planes))
```

```

# A tibble: 6 x 9
  tailnum year type      manufacturer model engines seats speed engine
  <chr>   <int> <chr>      <chr>      <chr>   <int> <int> <int> <chr>
1 N10156  2004 Fixed wing multi ~ EMBRAER    EMB~      2    55    NA Turbo~
2 N102UW  1998 Fixed wing multi ~ AIRBUS    INDU~    2   182    NA Turbo~
3 N103US  1999 Fixed wing multi ~ AIRBUS    INDU~    2   182    NA Turbo~
4 N104UW  1999 Fixed wing multi ~ AIRBUS    INDU~    2   182    NA Turbo~
5 N10575  2002 Fixed wing multi ~ EMBRAER    EMB~      2    55    NA Turbo~
6 N105UW  1999 Fixed wing multi ~ AIRBUS    INDU~    2   182    NA Turbo~

```

```

# Comprobamos las variables mediante summary
print(summary(flights))

```

	year	month	day	dep_time	sched_dep_time
Min.	:2013	Min. : 1.000	Min. : 1.00	Min. : 1	Min. : 106
1st Qu.:	:2013	1st Qu.: 4.000	1st Qu.: 8.00	1st Qu.: 907	1st Qu.: 906
Median :	:2013	Median : 7.000	Median :16.00	Median :1401	Median :1359
Mean :	:2013	Mean : 6.549	Mean :15.71	Mean :1349	Mean :1344
3rd Qu.:	:2013	3rd Qu.:10.000	3rd Qu.:23.00	3rd Qu.:1744	3rd Qu.:1729
Max.	:2013	Max. :12.000	Max. :31.00	Max. :2400	Max. :2359
				NA's :8255	

dep_delay	arr_time	sched_arr_time	arr_delay
Min. : -43.00	Min. : 1	Min. : 1	Min. : -86.000
1st Qu.: -5.00	1st Qu.:1104	1st Qu.:1124	1st Qu.: -17.000
Median : -2.00	Median :1535	Median :1556	Median : -5.000
Mean : 12.64	Mean :1502	Mean :1536	Mean : 6.895
3rd Qu.: 11.00	3rd Qu.:1940	3rd Qu.:1945	3rd Qu.: 14.000
Max. :1301.00	Max. :2400	Max. :2359	Max. :1272.000
NA's :8255	NA's :8713		NA's :9430

carrier	flight	tailnum	origin
Length:336776	Min. : 1	Length:336776	Length:336776
Class :character	1st Qu.: 553	Class :character	Class :character
Mode :character	Median :1496	Mode :character	Mode :character
	Mean :1972		
	3rd Qu.:3465		
	Max. :8500		

dest	air_time	distance	hour
Length:336776	Min. : 20.0	Min. : 17	Min. : 1.00
Class :character	1st Qu.: 82.0	1st Qu.: 502	1st Qu.: 9.00
Mode :character	Median :129.0	Median : 872	Median :13.00
	Mean :150.7	Mean :1040	Mean :13.18
	3rd Qu.:192.0	3rd Qu.:1389	3rd Qu.:17.00
	Max. :695.0	Max. :4983	Max. :23.00
	NA's :9430		

minute	time_hour
Min. : 0.00	Min. :2013-01-01 05:00:00.00
1st Qu.: 8.00	1st Qu.:2013-04-04 13:00:00.00
Median :29.00	Median :2013-07-03 10:00:00.00
Mean :26.23	Mean :2013-07-03 05:22:54.64
3rd Qu.:44.00	3rd Qu.:2013-10-01 07:00:00.00
Max. :59.00	Max. :2013-12-31 23:00:00.00

```
print(summary(airports))
```

faa	name	lat	lon
Length:1458	Length:1458	Min. :19.72	Min. : -176.65
Class :character	Class :character	1st Qu.:34.26	1st Qu.: -119.19
Mode :character	Mode :character	Median :40.09	Median : -94.66
		Mean :41.65	Mean : -103.39
		3rd Qu.:45.07	3rd Qu.: -82.52
		Max. :72.27	Max. : 174.11

alt	tz	dst	tzone
Min. : -54.00	Min. : -10.000	Length:1458	Length:1458
1st Qu.: 70.25	1st Qu.: -8.000	Class :character	Class :character
Median : 473.00	Median : -6.000	Mode :character	Mode :character
Mean :1001.42	Mean : -6.519		
3rd Qu.:1062.50	3rd Qu.: -5.000		
Max. :9078.00	Max. : 8.000		

```
print(summary(weather))
```

origin	year	month	day
Length:26115	Min. :2013	Min. : 1.000	Min. : 1.00
Class :character	1st Qu.:2013	1st Qu.: 4.000	1st Qu.: 8.00
Mode :character	Median :2013	Median : 7.000	Median :16.00
	Mean :2013	Mean : 6.504	Mean :15.68
	3rd Qu.:2013	3rd Qu.: 9.000	3rd Qu.:23.00
	Max. :2013	Max. :12.000	Max. :31.00

hour	temp	dewp	humid
Min. : 0.00	Min. : 10.94	Min. : -9.94	Min. : 12.74
1st Qu.: 6.00	1st Qu.: 39.92	1st Qu.:26.06	1st Qu.: 47.05
Median :11.00	Median : 55.40	Median :42.08	Median : 61.79
Mean :11.49	Mean : 55.26	Mean :41.44	Mean : 62.53
3rd Qu.:17.00	3rd Qu.: 69.98	3rd Qu.:57.92	3rd Qu.: 78.79
Max. :23.00	Max. :100.04	Max. :78.08	Max. :100.00
	NA's :1	NA's :1	NA's :1

wind_dir	wind_speed	wind_gust	precip
Min. : 0.0	Min. : 0.000	Min. :16.11	Min. :0.000000
1st Qu.:120.0	1st Qu.: 6.905	1st Qu.:20.71	1st Qu.:0.000000
Median :220.0	Median : 10.357	Median :24.17	Median :0.000000
Mean :199.8	Mean : 10.518	Mean :25.49	Mean :0.004469
3rd Qu.:290.0	3rd Qu.: 13.809	3rd Qu.:28.77	3rd Qu.:0.000000
Max. :360.0	Max. :1048.361	Max. :66.75	Max. :1.210000
NA's :460	NA's :4	NA's :20778	

pressure	visib	time_hour
Min. : 983.8	Min. : 0.000	Min. :2013-01-01 01:00:00.0
1st Qu.:1012.9	1st Qu.:10.000	1st Qu.:2013-04-01 21:30:00.0
Median :1017.6	Median :10.000	Median :2013-07-01 14:00:00.0
Mean :1017.9	Mean : 9.255	Mean :2013-07-01 18:26:37.7
3rd Qu.:1023.0	3rd Qu.:10.000	3rd Qu.:2013-09-30 13:00:00.0
Max. :1042.1	Max. :10.000	Max. :2013-12-30 18:00:00.0
NA's :2729		

```
print(summary(airlines))
```

```
   carrier      name
Length:16   Length:16
Class :character Class :character
Mode  :character Mode  :character
```

```
print(summary(planes))
```

```
   tailnum      year      type      manufacturer
Length:3322   Min.   :1956   Length:3322   Length:3322
Class :character 1st Qu.:1997   Class :character  Class :character
Mode  :character Median :2001   Mode  :character  Mode  :character
               Mean  :2000
               3rd Qu.:2005
               Max.   :2013
               NA's   :70

   model      engines      seats      speed
Length:3322   Min.   :1.000   Min.    : 2.0   Min.    : 90.0
Class :character 1st Qu.:2.000   1st Qu.:140.0   1st Qu.:107.5
Mode  :character Median :2.000   Median :149.0   Median :162.0
               Mean  :1.995   Mean   :154.3   Mean   :236.8
               3rd Qu.:2.000   3rd Qu.:182.0   3rd Qu.:432.0
               Max.   :4.000   Max.    :450.0   Max.    :432.0
               NA's   :3299

   engine
Length:3322
Class :character
Mode  :character
```

Respuesta:

El paquete `nycflights13` proporciona cinco dataframes relacionados con vuelos que salieron de los aeropuertos de Nueva York en 2013. El dataframe `flights` contiene 336,776 observaciones con información sobre cada vuelo, incluyendo fecha, hora, aerolíneas, origen, destino y retrasos. `airports` contiene información sobre 1,458 aeropuertos incluyendo códigos, nombres y ubicaciones geográficas. `weather` proporciona 26,115 observaciones meteorológicas horarias

de los tres aeropuertos de origen. `airlines` es un pequeño dataframe con 16 aerolíneas y sus nombres completos. Finalmente, `planes` contiene información sobre 3,322 aviones, incluyendo fabricante, modelo, año de fabricación y características técnicas como número de asientos y motores. Estos dataframes están relacionados entre sí mediante claves como `tailnum` (número de cola del avión) y `carrier` (código de aerolínea), lo que permite realizar análisis complejos combinando múltiples fuentes de información.

```
# Simplificar los dataframes originales a 100 observaciones
flights_simple <- head(flights, 100)
airports_simple <- head(airports, 100)
weather_simple <- head(weather, 100)
airlines_simple <- head(airlines, 100)
planes_simple <- head(planes, 100)

# Selecciona los tipos de aerolínea
airlines_simple %>% unique %>% select(carrier)
```

```
# A tibble: 16 x 1
  carrier
  <chr>
1 9E
2 AA
3 AS
4 B6
5 DL
6 EV
7 F9
8 FL
9 HA
10 MQ
11 OO
12 UA
13 US
14 VX
15 WN
16 YV
```

Respuesta:

La simplificación de los dataframes a 100 observaciones facilita el trabajo exploratorio sin comprometer la comprensión de la estructura de datos. Al seleccionar los tipos de aerolínea del dataframe `airlines_simple` usando el operador tubería, obtenemos una lista de códigos

de aerolínea únicos. El uso de `unique()` elimina cualquier duplicado que pudiera existir, mientras que `select(carrier)` extrae únicamente la columna de interés. Esta combinación de operaciones es eficiente y legible, demostrando el estilo declarativo de programación que promueve dplyr.

```
# Obtener la media y el máximo de asientos
planes_simple %>% summarise(mean = mean(seats), max_engines = max(seats))
```

```
# A tibble: 1 x 2
  mean max_engines
  <dbl>      <int>
1  105.         330
```

Respuesta:

El análisis de la capacidad de asientos en los aviones revela estadísticos importantes sobre la flota. La función `summarise()` reduce el dataframe a una única fila conteniendo la media y el máximo de asientos. Esto permite identificar tanto la capacidad promedio de los aviones en el conjunto de datos como el avión de mayor capacidad. Esta información es valiosa para comprender la composición de la flota y puede influir en decisiones operativas relacionadas con la asignación de aviones a rutas específicas según la demanda esperada.

```
# Ordenar los aviones por número de motores y número de asientos
result1 <- arrange(planes_simple, engines, seats)
print(result1)
```

```
# A tibble: 100 x 9
  tailnum year type      manufacturer model engines seats speed engine
  <chr>   <int> <chr>      <chr>          <chr>   <int> <int> <int> <chr>
1 N10156  2004 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
2 N10575  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
3 N11106  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
4 N11107  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
5 N11109  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
6 N11113  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
7 N11119  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
8 N11121  2003 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
9 N11127  2003 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
10 N11137 2003 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
# i 90 more rows
```

Respuesta:

La función `arrange()` ordena el dataframe de aviones primero por número de motores y luego, dentro de cada grupo de motores, por número de asientos en orden ascendente. Esta ordenación revela la relación entre la complejidad técnica del avión (número de motores) y su capacidad (número de asientos). Típicamente, los aviones con menos asientos tienen menos motores, y conforme aumenta la capacidad, se requieren configuraciones con más motores para proporcionar la potencia necesaria. Este ordenamiento facilita la identificación de patrones en el diseño y capacidades de diferentes modelos de aeronaves.

```
# Averigua qué número de cola comparten los dataframes
shared <- inner_join(flights_simple, planes_simple, by = "tailnum")
shared_carrier <- shared$carrier
print(shared_carrier)
```

```
[1] "EV"
```

Respuesta:

La función `inner_join()` combina los dataframes `flights_simple` y `planes_simple` usando el número de cola (`tailnum`) como clave de unión, devolviendo únicamente las filas donde existe coincidencia en ambos dataframes. Esto permite identificar qué aviones del registro de vuelos tienen información técnica disponible en el dataframe de aviones. Al extraer la columna `carrier`, obtenemos las aerolíneas que operaron estos vuelos específicos. Esta operación es fundamental en análisis de datos relacionales, donde diferentes tablas contienen información complementaria sobre las mismas entidades y se requiere combinarlas para obtener un panorama completo.

```
# Cruzar datos que no coincidan
fp <- anti_join(planes_simple, flights_simple, by = "tailnum")
engines_fp <- filter(fp, engines >= 2)
result2 <- unique(engines_fp$model)
print(result2)
```

```
[1] "EMB-145XR" "A320-214" "EMB-145LR" "737-824" "767-332" "757-224"
```

Respuesta:

La operación `anti_join()` identifica aviones en `planes_simple` que no tienen vuelos correspondientes en `flights_simple`, es decir, aviones registrados que no aparecen en los primeros 100 vuelos analizados. Posteriormente, se filtran aquellos con 2 o más motores, típicamente aviones de mayor tamaño o alcance. Finalmente, se extraen los modelos únicos que satisfacen

estas condiciones. Esta secuencia de operaciones es útil para análisis de utilización de flota, permitiendo identificar qué aviones con ciertas características técnicas no están siendo utilizados o no aparecen en el período analizado, lo cual podría indicar aviones en mantenimiento, reserva, o asignados a otras rutas no capturadas en la muestra.

```
# Crear nueva variable de retraso total
flights_total <- mutate(flights_simple, total_delay = dep_delay + arr_delay)

# Devolver aviones que llegaron con antelación
filter(flights_total, total_delay < 0)
```

```
# A tibble: 57 x 20
  year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
  <int> <int> <int>   <int>         <int>         <dbl>   <int>         <int>
1  2013     1     1     544             545         -1     1004           1022
2  2013     1     1     554             600         -6       812           837
3  2013     1     1     557             600         -3       709           723
4  2013     1     1     557             600         -3       838           846
5  2013     1     1     558             600         -2       849           851
6  2013     1     1     558             600         -2       853           856
7  2013     1     1     558             600         -2       923           937
8  2013     1     1     559             559          0       702           706
9  2013     1     1     559             600         -1       854           902
10 2013     1     1     600             600          0       851           858
# i 47 more rows
# i 12 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
#   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
#   hour <dbl>, minute <dbl>, time_hour <dtm>, total_delay <dbl>
```

Respuesta:

La función `mutate()` crea una nueva columna `total_delay` que suma los retrasos de salida (`dep_delay`) y llegada (`arr_delay`), proporcionando una medida agregada del retraso acumulado durante todo el trayecto del vuelo. Valores positivos indican retraso total, mientras que valores negativos indican que el vuelo llegó antes de lo programado. Al filtrar por `total_delay < 0`, se identifican vuelos que, a pesar de cualquier retraso en la salida, lograron recuperar tiempo durante el vuelo y llegar anticipadamente a su destino. Esto puede ocurrir cuando los pilotos compensan retrasos iniciales aumentando la velocidad de crucero cuando las condiciones lo permiten, o cuando el tiempo de vuelo programado incluye márgenes de seguridad que no siempre se utilizan completamente. Estos casos son de interés para el análisis de eficiencia operativa y satisfacción del cliente.

Intervalos de Confianza

Ejercicio 1: Conceptos Básicos

Explica brevemente qué es un intervalo de confianza y por qué es importante en la estadística inferencial. Da un ejemplo sencillo de un intervalo de confianza.

Solución:

Un intervalo de confianza es un rango de valores, derivado de los datos muestrales, que se utiliza para estimar un parámetro desconocido de la población, como la media o la proporción. Este intervalo se construye de tal manera que, con un cierto nivel de confianza (por ejemplo, 95% o 99%), se espera que contenga el verdadero valor del parámetro poblacional.

Importancia en la estadística inferencial: (1) Proporciona una estimación del parámetro poblacional en lugar de un solo valor puntual, ofreciendo así más información sobre la precisión de la estimación. (2) Permite cuantificar la incertidumbre asociada a la estimación. Un intervalo de confianza más estrecho indica una estimación más precisa. (3) Ayuda en la toma de decisiones basadas en datos al proporcionar un rango de valores posibles para el parámetro poblacional. Esto es crucial en áreas como la investigación científica, la economía, la medicina y muchas otras.

Ejemplo: Supongamos que estamos interesados en estimar la media de las alturas de los estudiantes en una universidad. Tomamos una muestra aleatoria de 30 estudiantes y encontramos que la media muestral ($\bar{x}$) es de 170 cm y la desviación estándar (σ) es de 10 cm. Queremos calcular un intervalo de confianza del 95% para la media poblacional (μ).

1. **Determinar el nivel de confianza:** 95%. El nivel de significancia (α) es 0.05. El valor crítico (z) para un nivel de confianza del 95% es aproximadamente 1.96.
2. **Calcular el error estándar:**

$$\text{Error estándar} = \frac{\sigma}{\sqrt{n}} = \frac{10}{\sqrt{30}} \approx 1.83$$

3. **Calcular el margen de error:**

$$\text{Margen de error} = z \times \text{Error estándar} = 1.96 \times 1.83 \approx 3.59$$

4. Calcular el intervalo de confianza:

$$\text{Intervalo de confianza} = \bar{x} \pm \text{Margen de error} = 170 \pm 3.59 = (166.41, 173.59)$$

Interpretación: Con un 95% de confianza, podemos afirmar que la media de las alturas de todos los estudiantes en la universidad está entre 166.41 cm y 173.59 cm. Esto significa que si repitiéramos este proceso de muestreo muchas veces, aproximadamente el 95% de los intervalos calculados de esta manera contendrían la verdadera media poblacional.

Ejercicio 2: Intervalo de Confianza Básico

Dada una muestra aleatoria de tamaño 30 de una población normal con media muestral $\bar{x} = 50$ y desviación estándar $\sigma = 10$, calcula el intervalo de confianza del 95% para la media poblacional.

Solución:

Datos proporcionados: Tamaño de la muestra (n) = 30, media muestral ($\bar{x}$) = 50, desviación estándar (σ) = 10, nivel de confianza = 95%.

Paso 1 - Determinar el valor crítico: Para un nivel de confianza del 95%, el valor crítico z (para una distribución normal estándar) es aproximadamente 1.96.

Paso 2 - Calcular el error estándar de la media:

$$\text{Error estándar} = \frac{\sigma}{\sqrt{n}} = \frac{10}{\sqrt{30}} \approx 1.8257$$

Paso 3 - Calcular el margen de error:

$$\text{Margen de error} = z \times \text{Error estándar} = 1.96 \times 1.8257 \approx 3.5774$$

Paso 4 - Calcular el intervalo de confianza:

$$\text{Intervalo de confianza} = \bar{x} \pm \text{Margen de error} = 50 \pm 3.5774 = (46.4226, 53.5774)$$

Resultado: El intervalo de confianza del 95% para la media poblacional es aproximadamente (46.42, 53.58). Esto significa que con un 95% de confianza, podemos afirmar que la verdadera media poblacional se encuentra dentro de este rango.

Ejercicio 3: Nivel de Confianza Diferente

Utilizando la misma muestra del ejercicio anterior, calcula el intervalo de confianza del 99% para la media poblacional. Compara ambos intervalos y explica las diferencias.

Solución:

Para calcular el intervalo de confianza del 99% para la media poblacional utilizando la misma muestra, seguimos los mismos pasos que antes pero con el valor crítico correspondiente al 99% de confianza.

Datos proporcionados: Tamaño de la muestra (n) = 30, media muestral ($\bar{x}$) = 50, desviación estándar (σ) = 10, nivel de confianza = 99%.

Paso 1 - Determinar el valor crítico: Para un nivel de confianza del 99%, el valor crítico z es aproximadamente 2.576.

Paso 2 - Calcular el error estándar: El error estándar de la media es el mismo que antes:

$$\text{Error estándar} = \frac{10}{\sqrt{30}} \approx 1.8257$$

Paso 3 - Calcular el margen de error:

$$\text{Margen de error} = 2.576 \times 1.8257 \approx 4.7015$$

Paso 4 - Calcular el intervalo de confianza:

$$\text{Intervalo de confianza} = 50 \pm 4.7015 = (45.2985, 54.7015)$$

Comparación de los intervalos: Intervalo de confianza del 95% = (46.42, 53.58); Intervalo de confianza del 99% = (45.30, 54.70).

Explicación de las diferencias: (1) El intervalo de confianza del 99% es más amplio que el del 95%. Esto se debe a que al aumentar el nivel de confianza, necesitamos un intervalo más amplio para asegurarnos de que contiene el parámetro poblacional con mayor certeza. (2) Un intervalo de confianza más amplio (como el del 99%) proporciona mayor seguridad de que contiene la verdadera media poblacional, pero a costa de ser menos preciso. Un intervalo más estrecho (como el del 95%) es más preciso pero conlleva un menor nivel de certeza de que contiene la verdadera media poblacional. (3) El valor crítico para el 99% de confianza (2.576) es mayor que el valor crítico para el 95% de confianza (1.96), lo que contribuye al aumento del margen de error y, por ende, al ancho del intervalo.

En resumen, al aumentar el nivel de confianza del 95% al 99%, el intervalo de confianza se vuelve más amplio, lo que refleja un mayor grado de certeza de que el intervalo incluye la verdadera media poblacional.

Ejercicio 4: Interpretación Práctica

Un investigador encuentra que el intervalo de confianza del 95% para la media de una variable es (45, 55). Explica qué significa este intervalo en términos prácticos y cómo debería interpretarlo el investigador.

Solución:

Cuando un investigador encuentra que el intervalo de confianza del 95% para la media de una variable es (45, 55), esto significa lo siguiente:

Rango de valores probables: El intervalo (45, 55) representa un rango de valores dentro del cual se estima que se encuentra la verdadera media poblacional de la variable con un nivel de confianza del 95%.

Nivel de confianza: El nivel de confianza del 95% indica que si se repitiera el proceso de muestreo muchas veces y se calcularan intervalos de confianza del 95% para cada muestra, aproximadamente el 95% de esos intervalos incluirían la verdadera media poblacional.

Incertidumbre: El intervalo refleja la incertidumbre inherente a la estimación. Debido a la variabilidad de la muestra, no podemos estar 100% seguros de que la media poblacional esté exactamente en un punto específico, pero podemos afirmar con un 95% de confianza que está dentro del intervalo calculado.

Cómo interpretarlo: (1) La mejor estimación de la media poblacional basada en la muestra es que se encuentra entre 45 y 55. (2) Si el investigador necesita tomar decisiones basadas en la media de la población, puede hacerlo con la confianza de que la verdadera media está muy probablemente dentro de este rango. Por ejemplo, si está considerando un límite superior o inferior para una variable crítica, el intervalo le ayuda a entender dónde podría estar la verdadera media. (3) Al comunicar los resultados a otros, el investigador debe mencionar que el intervalo de confianza del 95% para la media es (45, 55). Esto proporciona una visión clara de la precisión y fiabilidad de la estimación basada en los datos de la muestra.

Ejemplo práctico: Supongamos que el investigador está estudiando la puntuación de satisfacción del cliente para un producto. Si el intervalo de confianza del 95% es (45, 55), puede interpretar que: La satisfacción promedio de los clientes está en algún lugar entre 45 y 55 en la escala utilizada, con un 95% de confianza. Si se está comparando este producto con otro cuya satisfacción promedio conocida es 60, el investigador puede argumentar que es muy probable (con un 95% de confianza) que la media de satisfacción del producto en estudio sea significativamente menor. Si la satisfacción mínima aceptable se define en 50, el investigador puede señalar que hay una posibilidad considerable de que la media real esté por debajo de este umbral, sugiriendo una necesidad de mejorar el producto.

En resumen, el intervalo de confianza proporciona una estimación del rango en el que se espera encontrar la verdadera media poblacional con un cierto nivel de confianza. Es una herramienta

clave en la estadística inferencial que ayuda a los investigadores a comunicar y tomar decisiones informadas basadas en sus datos muestrales.

Ejercicio 5: Varianza Conocida

Se sabe que la desviación estándar de las alturas de una población es de 5 cm. Se toma una muestra aleatoria de 40 individuos con una media muestral de 170 cm. Calcula el intervalo de confianza del 95% para la media poblacional.

Solución:

Datos proporcionados: Desviación estándar poblacional (σ) = 5 cm, tamaño de la muestra (n) = 40, media muestral ($\bar{x}$) = 170 cm, nivel de confianza = 95%.

Paso 1 - Determinar el valor crítico: Para un nivel de confianza del 95%, el valor crítico z es aproximadamente 1.96.

Paso 2 - Calcular el error estándar:

$$\text{Error estándar} = \frac{\sigma}{\sqrt{n}} = \frac{5}{\sqrt{40}} \approx 0.7906$$

Paso 3 - Calcular el margen de error:

$$\text{Margen de error} = 1.96 \times 0.7906 \approx 1.5496$$

Paso 4 - Calcular el intervalo de confianza:

$$\text{Intervalo de confianza} = 170 \pm 1.5496 = (168.4504, 171.5496)$$

Resultado: El intervalo de confianza del 95% para la media poblacional es aproximadamente (168.45, 171.55). Esto significa que con un 95% de confianza, podemos afirmar que la verdadera media poblacional de las alturas se encuentra dentro de este rango.

Ejercicio 6: Varianza Desconocida

En un estudio de satisfacción laboral, se toma una muestra de 25 empleados y se encuentra una media muestral de 78 puntos con una desviación estándar muestral de 12 puntos. Calcula el intervalo de confianza del 95% para la media poblacional.

Solución:

Para calcular el intervalo de confianza del 95% para la media poblacional, usaremos la media y la desviación estándar muestral. Dado que la muestra es pequeña ($n < 30$) y la desviación estándar poblacional no es conocida, utilizaremos la distribución t de Student.

Datos proporcionados: Tamaño de la muestra (n) = 25, media muestral ($\bar{x}$) = 78 puntos, desviación estándar muestral (s) = 12 puntos, nivel de confianza = 95%.

Paso 1 - Determinar el valor crítico t: Para un nivel de confianza del 95% y $n - 1 = 24$ grados de libertad, el valor crítico $t_{0.025, 24} \approx 2.064$.

Paso 2 - Calcular el error estándar:

$$\text{Error estándar} = \frac{s}{\sqrt{n}} = \frac{12}{\sqrt{25}} = 2.4$$

Paso 3 - Calcular el margen de error:

$$\text{Margen de error} = 2.064 \times 2.4 \approx 4.9536$$

Paso 4 - Calcular el intervalo de confianza:

$$\text{Intervalo de confianza} = 78 \pm 4.9536 = (73.0464, 82.9536)$$

Resultado: El intervalo de confianza del 95% para la media poblacional es aproximadamente (73.05, 82.95). Esto significa que con un 95% de confianza, podemos afirmar que la verdadera media poblacional de la satisfacción laboral se encuentra dentro de este rango.

Ejercicio 7: Muestra Grande

Una encuesta a 200 estudiantes universitarios encuentra que el gasto promedio mensual en libros es de \$100 con una desviación estándar de \$20. Calcula el intervalo de confianza del 95% para la media del gasto mensual en libros para todos los estudiantes universitarios.

Solución:

Datos proporcionados: Tamaño de la muestra (n) = 200, media muestral ($\bar{x}$) = 100, *desviación estándar muestral* (\$) = \$20, nivel de confianza = 95%.

Dado que la muestra es grande ($n > 30$), podemos utilizar la distribución normal estándar.

Paso 1 - Determinar el valor crítico: Para un nivel de confianza del 95%, el valor crítico z es aproximadamente 1.96.

Paso 2 - Calcular el error estándar:

$$\text{Error estándar} = \frac{20}{\sqrt{200}} \approx 1.4142$$

Paso 3 - Calcular el margen de error:

$$\text{Margen de error} = 1.96 \times 1.4142 \approx 2.7714$$

Paso 4 - Calcular el intervalo de confianza:

$$\text{Intervalo de confianza} = 100 \pm 2.7714 = (97.2286, 102.7714)$$

Resultado: El intervalo de confianza del 95% para la media del gasto mensual en libros es aproximadamente (97.23, 102.77). Esto significa que con un 95% de confianza, podemos afirmar que la verdadera media del gasto mensual en libros para todos los estudiantes universitarios se encuentra dentro de este rango.

Ejercicio 8: Proporción

En una muestra de 150 votantes, 90 indican que planean votar por el candidato A. Calcula el intervalo de confianza del 95% para la proporción de votantes que planean votar por el candidato A.

Solución:

Datos proporcionados: Tamaño de la muestra (n) = 150, número de éxitos (x) = 90, nivel de confianza = 95%.

Paso 1 - Calcular la proporción muestral:

$$\hat{p} = \frac{x}{n} = \frac{90}{150} = 0.6$$

Paso 2 - Determinar el valor crítico: Para un nivel de confianza del 95%, el valor crítico z es aproximadamente 1.96.

Paso 3 - Calcular el error estándar:

$$\text{Error estándar} = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} = \sqrt{\frac{0.6 \times 0.4}{150}} = 0.04$$

Paso 4 - Calcular el margen de error:

$$\text{Margen de error} = 1.96 \times 0.04 = 0.0784$$

Paso 5 - Calcular el intervalo de confianza:

$$\text{Intervalo de confianza} = 0.6 \pm 0.0784 = (0.5216, 0.6784)$$

Resultado: El intervalo de confianza del 95% para la proporción de votantes que planean votar por el candidato A es aproximadamente (0.5216, 0.6784). Esto significa que con un 95% de confianza, podemos afirmar que la verdadera proporción de votantes que planean votar por el candidato A se encuentra dentro de este rango.

Ejercicio 9: Comparación de Proporciones

Dos empresas están interesadas en la proporción de empleados que están satisfechos con su trabajo. En una muestra de 100 empleados de la empresa A, 60 se declaran satisfechos. En una muestra de 120 empleados de la empresa B, 90 se declaran satisfechos. Calcula el intervalo de confianza del 95% para la diferencia en las proporciones de empleados satisfechos entre las dos empresas.

Solución:

Datos proporcionados: Tamaño de la muestra de la empresa A (n_A) = 100, número de empleados satisfechos en A (x_A) = 60, tamaño de la muestra de la empresa B (n_B) = 120, número de empleados satisfechos en B (x_B) = 90.

Paso 1 - Calcular las proporciones muestrales:

$$\hat{p}_A = \frac{60}{100} = 0.60 \quad ; \quad \hat{p}_B = \frac{90}{120} = 0.75$$

Paso 2 - Determinar el valor crítico: Para un nivel de confianza del 95%, el valor crítico z es aproximadamente 1.96.

Paso 3 - Calcular el error estándar de la diferencia:

$$\text{Error estándar} = \sqrt{\frac{0.60 \times 0.40}{100} + \frac{0.75 \times 0.25}{120}} \approx 0.06296$$

Paso 4 - Calcular el margen de error:

$$\text{Margen de error} = 1.96 \times 0.06296 \approx 0.1234$$

Paso 5 - Calcular el intervalo de confianza:

$$\hat{p}_A - \hat{p}_B = 0.60 - 0.75 = -0.15$$

$$\text{Intervalo de confianza} = -0.15 \pm 0.1234 = (-0.2734, -0.0266)$$

Resultado: El intervalo de confianza del 95% para la diferencia en las proporciones es aproximadamente $(-0.2734, -0.0266)$. Esto significa que con un 95% de confianza, podemos afirmar que la proporción de empleados satisfechos es mayor en la empresa B que en la empresa A, y la diferencia se encuentra en el rango de -0.2734 a -0.0266 .

Ejercicio 10: Interpretación Crítica

Un informe estadístico presenta el intervalo de confianza del 95% para la media de una variable como (75, 85). El informe concluye que la media poblacional es 80. ¿Es esta conclusión válida? Explica por qué o por qué no, utilizando conceptos de la interpretación de intervalos de confianza.

Solución:

La conclusión del informe **NO es válida**. Existen varios problemas fundamentales:

1. Error en la interpretación del intervalo de confianza: El intervalo de confianza del 95% (75, 85) significa que si repitiéramos el proceso de muestreo muchas veces, aproximadamente el 95% de los intervalos calculados contendrían la verdadera media poblacional. No significa que haya un 95% de probabilidad de que la media esté en ese rango - la media poblacional es un valor fijo, no una variable aleatoria.

2. El valor 80 no es especial: Aunque 80 está dentro del intervalo de confianza, no hay nada que lo haga más probable que cualquier otro valor dentro del rango (75, 85). Los valores 76, 79, 82 o 84.5 son igualmente compatibles con los datos observados. Afirmar que “la media poblacional es 80” sin justificación adicional es arbitrario.

3. Confusión entre estimación puntual y el intervalo: El informe parece haber tomado el punto medio del intervalo (80) y lo presentó como “la media poblacional”. El intervalo de confianza indica incertidumbre - si tuviéramos certeza de que la media es exactamente 80, no necesitaríamos un intervalo.

Conclusión correcta: El informe debería concluir que “con un 95% de confianza, la media poblacional se encuentra entre 75 y 85”, o que “el valor 80 es compatible con los datos, pero también lo son todos los demás valores dentro del intervalo”. Afirmar que la media “es 80” contradice el propósito mismo del intervalo de confianza, que es reconocer la incertidumbre inherente a la estimación basada en muestras.

Contrastes de Hipótesis

Ejercicio 1: Conceptos Básicos

Define los conceptos básicos de un contraste de hipótesis: hipótesis nula (H_0), hipótesis alternativa (H_1), nivel de significación (α), región de rechazo y valor crítico.

Solución:

En un contraste de hipótesis, se evalúa una afirmación sobre una población a partir de datos muestrales. Los conceptos básicos que se utilizan son los siguientes:

Hipótesis Nula (H_0): La hipótesis nula (H_0) es una afirmación sobre el parámetro de la población que se asume verdadera hasta que se demuestre lo contrario. Generalmente, H_0 representa una situación de “no efecto” o “no diferencia”. Es la hipótesis que se pretende refutar. Por ejemplo, H_0 podría afirmar que la media poblacional μ es igual a un valor específico.

Hipótesis Alternativa (H_1): La hipótesis alternativa (H_1) es una afirmación que se acepta si los datos muestrales proporcionan suficiente evidencia para rechazar la hipótesis nula. H_1 representa una situación de “efecto” o “diferencia”. Puede ser una hipótesis unilateral (por ejemplo, $\mu > 0$ o $\mu < 0$) o bilateral (por ejemplo, $\mu \neq 0$).

Nivel de Significación (α): El nivel de significación (α) es la probabilidad de cometer un error tipo I, que es rechazar la hipótesis nula cuando en realidad es verdadera. Es un umbral predefinido que determina la sensibilidad del contraste de hipótesis. Comúnmente, se usan niveles de significación como $\alpha = 0.05$, $\alpha = 0.01$ o $\alpha = 0.10$. Un α de 0.05 indica una probabilidad del 5% de rechazar H_0 incorrectamente.

Región de Rechazo: La región de rechazo es el conjunto de valores de la estadística de prueba para los cuales se rechaza la hipótesis nula. Depende del nivel de significación y de la distribución de la estadística de prueba bajo H_0 . Si la estadística de prueba cae dentro de esta región, se considera que los datos muestrales proporcionan suficiente evidencia para rechazar H_0 .

Valor Crítico: El valor crítico es el límite que separa la región de rechazo del resto de la distribución de la estadística de prueba. Se determina en función del nivel de significación α y de la distribución de la estadística de prueba bajo H_0 . En una prueba unilateral, hay un único valor crítico, mientras que en una prueba bilateral hay dos valores críticos (uno en cada extremo de la distribución).

Ejemplo de Conceptos Aplicados: Supongamos que queremos probar si la media poblacional μ es igual a 50 con un nivel de significación $\alpha = 0.05$. **Hipótesis Nula (H_0):** $\mu = 50$. **Hipótesis Alternativa (H_1):** $\mu \neq 50$ (contraste bilateral). **Nivel de Significación (α):** 0.05. **Región de Rechazo:** Para un contraste bilateral con $\alpha = 0.05$, la región de rechazo estará en los extremos de la distribución de la estadística de prueba (por ejemplo, los valores de z mayores que $z_{0.025}$ o menores que $-z_{0.025}$, donde $z_{0.025}$ corresponde al valor crítico de la distribución normal estándar que deja un 2.5% de probabilidad en cada cola). **Valor Crítico:** Para una prueba z , los valores críticos serían ± 1.96 (aproximadamente) porque $P(Z > 1.96) = 0.025$ y $P(Z < -1.96) = 0.025$.

Si la estadística de prueba calculada a partir de los datos muestrales cae en la región de rechazo (es decir, es mayor que 1.96 o menor que -1.96), rechazamos H_0 . Si no cae en la región de rechazo, no rechazamos H_0 .

Ejercicio 2: Pasos en un Contraste de Hipótesis

Describe los pasos necesarios para realizar un contraste de hipótesis. Ilustra estos pasos con un ejemplo simple en el que se quiera comprobar si la media de una muestra es igual a un valor específico.

Solución:

Para realizar un contraste de hipótesis, se siguen los siguientes pasos:

1. **Formular las Hipótesis:** **Hipótesis Nula (H_0):** Es la hipótesis que se presume cierta hasta que se demuestre lo contrario. **Hipótesis Alternativa (H_1):** Es la hipótesis que se acepta si la evidencia sugiere que H_0 es falsa.
2. **Elegir el Nivel de Significación (α):** α es la probabilidad de cometer un error tipo I (rechazar H_0 cuando es verdadera). Comúnmente, $\alpha = 0.05$.
3. **Seleccionar la Estadística de Prueba:** Dependiendo del tipo de hipótesis y de los datos, se selecciona la estadística adecuada (por ejemplo, z para una distribución normal con varianza conocida, t para varianza desconocida).
4. **Calcular la Estadística de Prueba:** Utilizar los datos muestrales para calcular el valor de la estadística de prueba.
5. **Determinar la Región de Rechazo:** Con base en α y la distribución de la estadística de prueba, determinar los valores críticos y la región de rechazo.
6. **Tomar una Decisión:** Comparar el valor de la estadística de prueba con los valores críticos para decidir si se rechaza o no H_0 .
7. **Conclusión:** Interpretar los resultados en el contexto del problema original.

Ejemplo - Comprobar si la Media de una Muestra es Igual a un Valor Específico: Supongamos que queremos comprobar si la media de una población es igual a 50. Tenemos una muestra de tamaño $n = 30$, con una media muestral de $\bar{x} = 52$ y una desviación estándar conocida de $\sigma = 5$.

Paso 1 - Formular las Hipótesis: Hipótesis Nula (H_0): $\mu = 50$. Hipótesis Alternativa (H_1): $\mu \neq 50$ (contraste bilateral).

Paso 2 - Elegir el Nivel de Significación: $\alpha = 0.05$.

Paso 3 - Seleccionar la Estadística de Prueba: Dado que la varianza es conocida y la muestra es suficientemente grande, utilizamos la estadística z :

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

Paso 4 - Calcular la Estadística de Prueba:

$$z = \frac{52 - 50}{5/\sqrt{30}} \approx 2.19$$

Paso 5 - Determinar la Región de Rechazo: Para $\alpha = 0.05$ en una prueba bilateral, los valores críticos $z_{0.025}$ son aproximadamente ± 1.96 .

Paso 6 - Tomar una Decisión: Comparamos el valor de z calculado con los valores críticos. El valor $z = 2.19$ es mayor que 1.96, por lo que cae en la región de rechazo.

Paso 7 - Conclusión: Decisión: Rechazamos la hipótesis nula H_0 . Interpretación: Hay suficiente evidencia para concluir que la media poblacional es diferente de 50 al nivel de significación $\alpha = 0.05$.

Ejercicio 3: Errores tipo I y tipo II. Potencia

Explica la diferencia entre los errores tipo I y tipo II en un contraste de hipótesis. ¿Qué es la potencia de un test? Calcula la probabilidad de cometer un error tipo I (α) y un error tipo II (β) en un contraste de hipótesis dado.

Solución:

En un contraste de hipótesis, existen dos tipos de errores que se pueden cometer:

Error Tipo I (α): Es el error que se comete al rechazar la hipótesis nula (H_0) cuando en realidad es verdadera. La probabilidad de cometer un error tipo I es denotada por α , y se establece como el nivel de significación del test. Es decir, α es la probabilidad de rechazar H_0 incorrectamente. Si se fija $\alpha = 0.05$, significa que hay un 5% de riesgo de concluir que H_0 es falsa cuando en realidad es verdadera.

Error Tipo II (β): Es el error que se comete al no rechazar la hipótesis nula (H_0) cuando en realidad es falsa. La probabilidad de cometer un error tipo II es denotada por β . β representa la probabilidad de no detectar un efecto o diferencia cuando realmente existe.

Potencia de un Test: La potencia de un test es la probabilidad de rechazar H_0 cuando H_0 es falsa. Es decir, es la probabilidad de detectar un efecto o diferencia cuando realmente existe. La potencia se denota por $1 - \beta$. A mayor potencia, mayor capacidad del test para detectar un efecto real.

Cálculo de α y β en un Contraste de Hipótesis Dado: Supongamos un ejemplo donde se quiere contrastar la media poblacional μ con el valor 50 utilizando una muestra de tamaño $n = 30$, una desviación estándar conocida $\sigma = 5$, y un nivel de significación $\alpha = 0.05$.

Datos: $\mu_0 = 50$ (hipótesis nula), $\mu_1 = 52$ (hipótesis alternativa específica), $\sigma = 5$, $n = 30$, $\alpha = 0.05$.

Paso 1 - Determinar los valores críticos: Para $\alpha = 0.05$ (contraste bilateral):

$$z_{\alpha/2} = \pm 1.96$$

Paso 2 - Calcular los límites de la región de rechazo: Para $\alpha = 0.05$ y una media $\mu_0 = 50$:

$$\text{Límite inferior} = \mu_0 - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \approx 48.21$$

$$\text{Límite superior} = \mu_0 + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \approx 51.79$$

Paso 3 - Calcular β : Supongamos que la verdadera media poblacional es $\mu_1 = 52$. Calculamos la probabilidad de que la media muestral caiga en la región de no rechazo (48.21, 51.79) cuando la media real es 52: $z_1 = \frac{48.21-52}{5/\sqrt{30}} \approx -4.15$ $z_2 = \frac{51.79-52}{5/\sqrt{30}} \approx -0.23$

La probabilidad de que Z esté entre -4.15 y -0.23 es: $\beta = P(-4.15 < Z < -0.23) = P(Z < -0.23) - P(Z < -4.15) \approx 0.409 - 0 = 0.409$. Por lo tanto, $\beta \approx 0.41$.

Paso 4 - Calcular la Potencia del Test: $\$ \text{Potencia} = 1 - \beta = 1 - 0.41 = 0.59 \$$

Resumen: Error Tipo I (α): En este ejemplo, α es predefinido como 0.05, lo que significa que hay un 5% de probabilidad de rechazar H_0 cuando es verdadera. Error Tipo II (β): Calculado como 0.41, lo que significa que hay un 41% de probabilidad de no rechazar H_0 cuando $\mu = 52$. Potencia del Test: Calculada como 0.59, lo que significa que hay un 59% de probabilidad de rechazar H_0 cuando $\mu = 52$.

Ejercicio 4: Contraste para la media de una población normal con varianza conocida

Se tiene una muestra de tamaño $n = 30$ con una media muestral de $\bar{x} = 50$ y una varianza conocida de $\sigma^2 = 25$. Realiza un contraste de hipótesis para verificar si la media poblacional es 52 con un nivel de significación $\alpha = 0.05$.

Solución:

Datos: Tamaño de la muestra (n) = 30, media muestral ($\bar{x}$) = 50, varianza poblacional (σ^2) = 25 (desviación estándar $\sigma = 5$), media poblacional bajo H_0 (μ_0) = 52, nivel de significación (α) = 0.05.

Paso 1 - Formular las Hipótesis: Hipótesis Nula (H_0): $\mu = 52$. Hipótesis Alternativa (H_1): $\mu \neq 52$ (contraste bilateral).

Paso 2 - Elegir el Nivel de Significación: $\alpha = 0.05$.

Paso 3 - Seleccionar la Estadística de Prueba: Como la varianza es conocida, utilizamos la estadística z :

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

Paso 4 - Calcular la Estadística de Prueba:

$$z = \frac{50 - 52}{5/\sqrt{30}} \approx -2.19$$

Paso 5 - Determinar la Región de Rechazo: Para un nivel de significación $\alpha = 0.05$ en una prueba bilateral, los valores críticos son:

$$z_{\alpha/2} = \pm 1.96$$

. La región de rechazo son los valores de z que son menores que -1.96 o mayores que 1.96 .

Paso 6 - Tomar una Decisión: Comparamos el valor calculado de z con los valores críticos. Valor calculado: $z = -2.19$. Valores críticos: -1.96 y 1.96 . Dado que -2.19 es menor que -1.96 , el valor de z cae en la región de rechazo.

Paso 7 - Conclusión: Decisión: Rechazamos la hipótesis nula H_0 . Interpretación: Hay suficiente evidencia para concluir que la media poblacional es diferente de 52 al nivel de significación $\alpha = 0.05$.

Ejercicio 5: Contraste para la media de una población normal con varianza desconocida

Una muestra de tamaño $n = 20$ tiene una media muestral de $\bar{x} = 30$ y una desviación estándar muestral de $s = 5$. Realiza un contraste de hipótesis para probar si la media poblacional es diferente de 32 con un nivel de significación $\alpha = 0.01$.

Solución:

Paso 1 - Plantear las hipótesis: Hipótesis nula (H_0): $\mu = 32$. Hipótesis alternativa (H_1): $\mu \neq 32$.

Paso 2 - Seleccionar el nivel de significación: $\alpha = 0.01$.

Paso 3 - Calcular el estadístico de prueba: Usaremos el estadístico t para muestras pequeñas cuando la desviación estándar poblacional no es conocida:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

. Sustituyendo los valores: $\bar{x} = 30$, $\mu_0 = 32$, $s = 5$, $n = 20$:

$$t = \frac{30 - 32}{5/\sqrt{20}} \approx -1.79$$

Paso 4 - Determinar los grados de libertad y el valor crítico: Los grados de libertad (df) se calculan como $df = n - 1 = 19$. Para $\alpha = 0.01$, el valor crítico t_c es aproximadamente ± 2.861 (usando una tabla de valores críticos de t-Student o una calculadora estadística).

Paso 5 - Tomar una decisión: Comparamos el valor absoluto del estadístico de prueba con el valor crítico. Si $|t| > t_c$, rechazamos H_0 . Si $|t| \leq t_c$, no rechazamos H_0 . En este caso: $|t| = 1.79$, $t_c = 2.861$. Dado que $|t| < t_c$, no rechazamos H_0 .

Conclusión: Con un nivel de significación $\alpha = 0.01$, no hay suficiente evidencia para rechazar la hipótesis nula. Esto significa que no podemos concluir que la media poblacional sea diferente de 32.

Ejercicio 6: Contraste de hipótesis para la igualdad de medias de dos muestras independientes

Se tienen dos muestras independientes: Muestra A: $x_A = \{23, 21, 22, 24, 25, 23, 24, 22, 23, 24\}$. Muestra B: $x_B = \{18, 19, 17, 20, 18, 19, 18, 19, 20, 18\}$. Realiza un contraste de hipótesis para verificar si las medias de las dos poblaciones son diferentes con un nivel de significación $\alpha = 0.05$.

Solución:

Paso 1 - Plantear las hipótesis: Hipótesis nula (H_0): $\mu_A = \mu_B$ (las medias de las dos poblaciones son iguales). Hipótesis alternativa (H_1): $\mu_A \neq \mu_B$ (las medias de las dos poblaciones son diferentes).

Paso 2 - Seleccionar el nivel de significación: $\alpha = 0.05$.

Paso 3 - Calcular las estadísticas muestrales: Muestra A: $x_A = \{23, 21, 22, 24, 25, 23, 24, 22, 23, 24\}$. $\bar{x}_A = 23.1$, $s_A = 1.197$. Muestra B: $x_B = \{18, 19, 17, 20, 18, 19, 18, 19, 20, 18\}$. $\bar{x}_B = 18.6$, $s_B = 0.966$.

Paso 4 - Calcular el estadístico de prueba: Usaremos el estadístico t para comparar las medias de dos muestras independientes:

$$t = \frac{\bar{x}_A - \bar{x}_B}{\sqrt{\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}}}$$

Paso 5 - Determinar los grados de libertad: Los grados de libertad se pueden aproximar usando la fórmula de Welch-Satterthwaite:

$$df \approx \frac{\left(\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}\right)^2}{\frac{\left(\frac{s_A^2}{n_A}\right)^2}{n_A - 1} + \frac{\left(\frac{s_B^2}{n_B}\right)^2}{n_B - 1}}$$

Paso 6 - Tomar una decisión: Comparamos el valor absoluto del estadístico de prueba con el valor crítico. Si $|t| > t_c$, rechazamos H_0 . Si $|t| \leq t_c$, no rechazamos H_0 .

Resultados: Estadístico de prueba: $t = 9.25$. Grados de libertad (aproximados): $df \approx 17.23$. Valor crítico para $\alpha = 0.05$ en una prueba bilateral: $t_c = 2.108$.

Decisión: Comparando: $|t| = 9.25$, $t_c = 2.108$. Dado que $|t| > t_c$, rechazamos H_0 .

Conclusión: Con un nivel de significación $\alpha = 0.05$, hay suficiente evidencia para rechazar la hipótesis nula. Esto significa que podemos concluir que las medias de las dos poblaciones son significativamente diferentes.

Ejercicio 7: Contraste de hipótesis para la diferencia de proporciones

En un estudio se observa que de 200 hombres, 130 prefieren el producto A, mientras que de 250 mujeres, 140 prefieren el mismo producto. Realiza un contraste de hipótesis para determinar si existe una diferencia significativa en las proporciones de hombres y mujeres que prefieren el producto A con un nivel de significación $\alpha = 0.05$.

Solución:

Paso 1 - Plantear las hipótesis: Hipótesis nula (H_0): $p_1 = p_2$ (no hay diferencia en las proporciones de hombres y mujeres que prefieren el producto A). Hipótesis alternativa (H_1): $p_1 \neq p_2$ (hay una diferencia en las proporciones). Donde p_1 es la proporción de hombres y p_2 es la proporción de mujeres que prefieren el producto A.

Paso 2 - Seleccionar el nivel de significación: $\alpha = 0.05$.

Paso 3 - Calcular las proporciones muestrales: $n_1 = 200$, $x_1 = 130$, $\hat{p}_1 = \frac{130}{200} = 0.65$.
 $n_2 = 250$, $x_2 = 140$, $\hat{p}_2 = \frac{140}{250} = 0.56$.

Paso 4 - Calcular el estadístico de prueba:

$$z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1 - \hat{p}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

. Donde $\hat{p}$ es la proporción combinada:

$$\hat{p} = \frac{x_1 + x_2}{n_1 + n_2} = \frac{130 + 140}{200 + 250} = 0.6$$

Paso 5 - Determinar el valor crítico: Para $\alpha = 0.05$ en una prueba bilateral, el valor crítico z_c es aproximadamente ± 1.96 .

Paso 6 - Tomar una decisión: Comparamos el valor absoluto del estadístico de prueba con el valor crítico. Si $|z| > z_c$, rechazamos H_0 . Si $|z| \leq z_c$, no rechazamos H_0 .

Resultados: Proporciones muestrales: $\hat{p}_1 = 0.65$, $\hat{p}_2 = 0.56$. Proporción combinada: $\hat{p} = 0.6$. Estadístico de prueba: $z = 1.94$. Valor crítico: $z_c = 1.96$.

Decisión: Comparando: $|z| = 1.94$, $z_c = 1.96$. Dado que $|z| < z_c$, no rechazamos H_0 .

Conclusión: Con un nivel de significación $\alpha = 0.05$, no hay suficiente evidencia para rechazar la hipótesis nula. Esto significa que no podemos concluir que existe una diferencia significativa en las proporciones de hombres y mujeres que prefieren el producto A.

Ejercicio 8: Aplicación en un contexto real

Un fabricante afirma que el peso medio de sus paquetes de galletas es 500 gramos. Una muestra de 40 paquetes tiene una media de 495 gramos y una desviación estándar de 10 gramos. Realiza un contraste de hipótesis para comprobar la afirmación del fabricante con un nivel de significación $\alpha = 0.01$.

Solución:

Paso 1 - Plantear las hipótesis: Hipótesis nula (H_0): $\mu = 500$ gramos (el peso medio es 500 gramos). Hipótesis alternativa (H_1): $\mu \neq 500$ gramos (el peso medio es diferente de 500 gramos).

Paso 2 - Seleccionar el nivel de significación: $\alpha = 0.01$.

Paso 3 - Calcular el estadístico de prueba: Utilizamos el estadístico t para muestras grandes ($n > 30$):

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

. Sustituyendo los valores: $\bar{x} = 495$, $\mu_0 = 500$, $s = 10$, $n = 40$:

$$t = \frac{495 - 500}{10/\sqrt{40}} = \frac{-5}{10/6.32} \approx -3.16$$

Paso 4 - Determinar el valor crítico: Para $\alpha = 0.01$ en una prueba bilateral en la distribución t de Student con $df = 39$, el valor crítico t_c es aproximadamente ± 2.708 .

Paso 5 - Tomar una decisión: Comparamos el valor absoluto del estadístico de prueba con el valor crítico. Si $|t| > t_c$, rechazamos H_0 . Si $|t| \leq t_c$, no rechazamos H_0 . En este caso: $|t| = 3.16$, $t_c = 2.708$. Dado que $|t| > t_c$, rechazamos H_0 .

Conclusión: Con un nivel de significación $\alpha = 0.01$, hay suficiente evidencia para rechazar la hipótesis nula. Esto significa que podemos concluir que el peso medio de los paquetes de galletas es significativamente diferente de 500 gramos.

Ejercicio 9: Prueba t de Student

Se tiene una muestra de tamaño $n = 25$ de una población normal con una media muestral de $\bar{x} = 20$ y una desviación estándar muestral de $s = 4$. Realiza un contraste de hipótesis para probar si la media poblacional es mayor que 18 con un nivel de significación $\alpha = 0.05$.

Solución:

Paso 1 - Plantear las hipótesis: Hipótesis nula (H_0): $\mu \leq 18$ (la media poblacional es menor o igual a 18). Hipótesis alternativa (H_1): $\mu > 18$ (la media poblacional es mayor que 18).

Paso 2 - Seleccionar el nivel de significación: $\alpha = 0.05$.

Paso 3 - Calcular el estadístico de prueba: Utilizamos el estadístico t porque la muestra es pequeña ($n < 30$):

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

. Sustituyendo los valores: $\bar{x} = 20$, $\mu_0 = 18$, $s = 4$, $n = 25$:

$$t = \frac{20 - 18}{4/\sqrt{25}} = 2.5$$

Paso 4 - Determinar el valor crítico: Para $\alpha = 0.05$ en una prueba unilateral (cola derecha) en la distribución t de Student con $df = 24$, el valor crítico t_c es aproximadamente 1.711.

Paso 5 - Tomar una decisión: Comparamos el valor del estadístico de prueba con el valor crítico. Si $t > t_c$, rechazamos H_0 . Si $t \leq t_c$, no rechazamos H_0 . En este caso: $t = 2.5$, $t_c = 1.711$. Dado que $t > t_c$, rechazamos H_0 .

Conclusión: Con un nivel de significación $\alpha = 0.05$, hay suficiente evidencia para rechazar la hipótesis nula. Esto significa que podemos concluir que la media poblacional es mayor que 18.

Ejercicio 10: Prueba z para grandes muestras

Una encuesta a 500 personas revela que 320 están a favor de una nueva ley. Realiza un contraste de hipótesis para determinar si la proporción de personas a favor de la ley es diferente de 0.6 con un nivel de significación $\alpha = 0.05$.

Solución:

Paso 1 - Plantear las hipótesis: Hipótesis nula (H_0): $p = 0.6$ (la proporción de personas a favor de la ley es 0.6). Hipótesis alternativa (H_1): $p \neq 0.6$ (la proporción es diferente de 0.6).

Paso 2 - Seleccionar el nivel de significación: $\alpha = 0.05$.

Paso 3 - Calcular la proporción muestral:

$$\hat{p} = \frac{x}{n}$$

. Donde $x = 320$, $n = 500$:

$$\hat{p} = \frac{320}{500} = 0.64$$

Paso 4 - Calcular el estadístico de prueba: Utilizamos el estadístico z para proporciones:

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

. Sustituyendo los valores: $p_0 = 0.6$:

$$z = \frac{0.64 - 0.6}{\sqrt{\frac{0.6 \cdot (1-0.6)}{500}}} \approx 1.826$$

Paso 5 - Determinar el valor crítico: Para $\alpha = 0.05$ en una prueba bilateral, el valor crítico z_c es aproximadamente ± 1.96 .

Paso 6 - Tomar una decisión: Comparamos el valor absoluto del estadístico de prueba con el valor crítico. Si $|z| > z_c$, rechazamos H_0 . Si $|z| \leq z_c$, no rechazamos H_0 . En este caso: $|z| = 1.826$, $z_c = 1.96$. Dado que $|z| < z_c$, no rechazamos H_0 .

Conclusión: Con un nivel de significación $\alpha = 0.05$, no hay suficiente evidencia para rechazar la hipótesis nula. Esto significa que no podemos concluir que la proporción de personas a favor de la ley sea diferente de 0.6.