

Inferencia Estadística

Ejercicios

Resueltos

Grado en Ciencia de Datos e Ingeniería de Datos

AUTORES

- Víctor Aceña Gil
- Isaac Martín de Diego
- Carmen Lancho Martín

2025-2026



Índice de Soluciones

Prefacio	3
Filosofía pedagógica	3
¿Cómo usar este manual?	3
Metodología de las soluciones	3
Requisitos de software	4
Introducción a la Inferencia Estadística	6
Ejercicio 1	6
Ejercicio 2	6
Ejercicio 3	7
Ejercicio 4	7
Ejercicio 5	8
Ejercicio 6	9
Ejercicio 7	10
Ejercicio 8	11
Ejercicio 9	12
Ejercicio 10	13
Análisis Exploratorio de Datos	16
Ejercicio 1	16
Ejercicio 2	17
Ejercicio 3	19
Ejercicio 4	20
Ejercicio 5	20
Ejercicio 6	21
Ejercicio 7	22
Ejercicio 8	23
Ejercicio 9	24
Ejercicio 10	25
Procesado y Limpieza de Datos	27
Ejercicio 1	27
Ejercicio 2	29

Prefacio

Este manual de soluciones complementa el libro **Inferencia Estadística** y está diseñado para proporcionar un apoyo integral al proceso de aprendizaje. Cada solución ha sido desarrollada con el mismo rigor teórico-práctico que caracteriza al curso, ofreciendo no solo la respuesta correcta, sino también el razonamiento estadístico y la interpretación práctica necesarios para una comprensión profunda.

Filosofía pedagógica

Al igual que el libro principal, este manual sigue un enfoque “**teórico-práctico**” sin concesiones. Las soluciones están diseñadas para:

- **Reforzar** la comprensión de los conceptos fundamentales mediante aplicaciones concretas
- **Desarrollar** la intuición estadística a través de interpretaciones razonadas
- **Conectar** la teoría con la práctica mediante código R completamente funcional
- **Fomentar** el pensamiento crítico sobre las limitaciones y supuestos de cada método

¿Cómo usar este manual?

Para maximizar el beneficio de este recurso:

1. **Intentar primero:** Resuelve cada ejercicio por tu cuenta antes de consultar la solución
2. **Estudiar el proceso:** No solo copies el código, entiende la lógica detrás de cada paso
3. **Experimentar:** Modifica los parámetros y observa cómo cambian los resultados
4. **Reflexionar:** Considera las implicaciones prácticas de cada resultado obtenido

Metodología de las soluciones

Cada solución incluye:

- **Código R completo:** Totalmente ejecutable y comentado

- **Explicaciones paso a paso:** Qué hace cada línea y por qué
- **Interpretación de resultados:** Qué significan los números obtenidos
- **Gráficos explicativos:** Visualización de conceptos clave
- **Consejos prácticos:** Cuándo y cómo usar cada técnica

! Uso responsable

Este manual es una herramienta de aprendizaje, no un sustituto del pensamiento propio. Utilízalo para verificar tu comprensión y mejorar tu técnica, pero siempre tras haber hecho un esfuerzo genuino por resolver los problemas de forma independiente.

Requisitos de software

Para ejecutar las soluciones necesitas tener instalados los siguientes paquetes de R:

```
# Paquetes principales para análisis exploratorio de datos
install.packages(c(
  "ggplot2",      # Visualización de datos
  "dplyr",        # Manipulación de datos
  "tidyr",        # Restructuración de datos
  "readr",        # Lectura de archivos de datos
  "nycflights13"  # Dataset de vuelos usado en ejercicios
))
```

i Sobre los autores

Víctor Aceña Gil es graduado en Matemáticas por la UNED, máster en Tratamiento Estadístico y Computacional de la Información por la UCM y la UPM, doctor en Tecnologías de la Información y las Comunicaciones por la URJC y profesor del departamento de Informática y Estadística de la URJC. Miembro del grupo de investigación de alto rendimiento en Fundamentos y Aplicaciones de la Ciencia de Datos, DSLAB, de la URJC. Pertenece al grupo de innovación docente, DSLAB-TI.

Isaac Martín de Diego es diplomado en Estadística por la Universidad de Valladolid (UVA), licenciado en Ciencias y Técnicas Estadísticas por la Universidad Carlos III de Madrid (UC3M), doctor en Ingeniería Matemática por la UC3M, catedrático de Ciencias de la Computación e Inteligencia Artificial del departamento de Informática y Estadística de la URJC. Es fundador y coordinador del DSLAB y del DSLAB-TI.

Carmen Lancho Martín es graduada en Matemáticas y Estadística por la Universidad Complutense de Madrid (UCM), máster en Tratamiento Estadístico y Computacional de la Información por la UCM y la Universidad Politécnica de Madrid (UPM), doctora en Tecnologías de la Información y las Comunicaciones por la Universidad Rey Juan

Carlos (URJC) y profesora del departamento de Informática y Estadística de la URJC. Miembro del grupo de investigación de alto rendimiento en Fundamentos y Aplicaciones de la Ciencia de Datos, DSLAB, de la URJC. Pertenece al grupo de innovación docente, DSLAB-TI.

Esta obra está bajo una licencia de Creative Commons Atribución-CompartirIgual 4.0 Internacional.

Introducción a la Inferencia Estadística

Ejercicio 1

Describe en tus propias palabras qué es la Ciencia de Datos y su importancia en el análisis de grandes volúmenes de datos.

Solución: La Ciencia de Datos es una disciplina interdisciplinaria que se centra en la extracción de conocimiento significativo a partir de grandes conjuntos de datos. Es crucial en un mundo impulsado por los datos, ya que permite tomar decisiones informadas y hacer predicciones basadas en el análisis de datos. La Ciencia de Datos combina elementos de estadística, informática y conocimiento específico del dominio para interpretar datos y aplicar este conocimiento en diversas áreas como la medicina, las finanzas y la tecnología. Su importancia radica en su capacidad para transformar datos crudos en información valiosa que puede impulsar la innovación y la eficiencia en múltiples campos.

Ejercicio 2

Enumera las herramientas estadísticas que se utilizan en la inferencia estadística y explica brevemente su propósito.

Solución: En la inferencia estadística, se utilizan diversas herramientas para analizar datos y hacer generalizaciones sobre una población a partir de muestras:

- **Pruebas de Hipótesis:** Se utilizan para determinar si existe suficiente evidencia en una muestra de datos para inferir que una cierta condición es verdadera para toda la población.
- **Intervalos de Confianza:** Proporcionan un rango estimado que es probable que contenga el valor de un parámetro desconocido de la población, con un cierto nivel de confianza.
- **Análisis de Varianza (ANOVA):** Permite comparar tres o más medias de grupos para determinar si al menos una de las medias es diferente de las demás.
- **Chi-cuadrado (χ^2):** Es una prueba que mide la discrepancia entre los datos observados y los datos que se esperarían según un modelo específico.
- **T-test:** Evalúa si las medias de dos grupos son estadísticamente diferentes entre sí.
- **Correlación:** Mide la relación entre dos variables y la fuerza de esta relación.

- **Estadística Bayesiana:** Utiliza la probabilidad para representar la incertidumbre sobre los parámetros del modelo y actualiza esta incertidumbre a medida que se obtienen más datos.
- **Métodos de Muestreo:** Incluyen técnicas para seleccionar muestras representativas de la población para realizar inferencias estadísticas.
- **Métodos No Paramétricos:** Son técnicas que no asumen una distribución específica de los datos y son útiles cuando no se cumplen los supuestos de los métodos paramétricos.

Ejercicio 3

Define los términos “población” y “muestra” y explica la diferencia entre ambos.

Solución:

- **Población:** Se refiere al conjunto completo de elementos o resultados que se están estudiando, del cual se desean obtener conclusiones. La población incluye a todos los individuos, mediciones, objetos o eventos que cumplen con un conjunto de especificaciones previamente definidas. Por ejemplo, si estamos estudiando la altura de los estudiantes de una universidad, la población sería la altura de **todos** los estudiantes de esa universidad.
- **Muestra:** Es un subconjunto de la población que se selecciona para representarla. La muestra debe ser representativa de la población para que las inferencias hechas a partir de ella sean válidas. Por ejemplo, si elegimos a 100 estudiantes al azar de la universidad mencionada anteriormente, esos 100 estudiantes constituirían una muestra de la población.

La **diferencia principal** entre ambos términos es el alcance. Mientras que la población es el grupo completo que se quiere estudiar, la muestra es solo una parte de ese grupo. Las muestras se utilizan porque a menudo es impracticable o imposible estudiar toda la población debido a limitaciones de tiempo, costo o logística. Por lo tanto, se selecciona una muestra para obtener estimaciones o pruebas sobre la población completa.

Ejercicio 4

¿Qué es una distribución de probabilidad y cómo se relaciona con las variables cualitativas y cuantitativas?

Solución: Una **distribución de probabilidad** es una función matemática que describe la probabilidad de ocurrencia de los diferentes posibles resultados en un experimento. En otras palabras, asigna probabilidades a cada posible resultado de una variable aleatoria. Las distribuciones de probabilidad se relacionan con las variables cualitativas y cuantitativas de la siguiente manera:

- **Variables Cualitativas (o Categóricas):** Son aquellas que describen una cualidad o categoría y no tienen un orden o medida numérica inherente. Las distribuciones de probabilidad para estas variables son conocidas como **distribuciones discretas** y asignan probabilidades a resultados específicos. Un ejemplo es la **distribución binomial**, que puede modelar eventos como el lanzamiento de una moneda, donde los resultados son categóricos (cara o cruz).
- **Variables Cuantitativas:** Son variables que se pueden medir en una escala numérica y tienen sentido hablar de valores mayores o menores. Las distribuciones de probabilidad asociadas a estas variables son **distribuciones continuas** y asignan probabilidades a intervalos de números. Por ejemplo, la **distribución normal** es una distribución continua que se utiliza comúnmente para modelar fenómenos naturales como la altura o el peso de individuos.

Ejercicio 5

Realiza un resumen descriptivo de un conjunto de datos utilizando medidas de tendencia central y dispersión.

Solución: Imaginemos un conjunto de datos que representa las calificaciones de un grupo de estudiantes en un examen:

```
datos=c(72, 85, 90, 68, 88, 76, 95, 89, 75, 80)
datos
```

```
[1] 72 85 90 68 88 76 95 89 75 80
```

Media:

$$\text{Media} = \frac{72 + 85 + 90 + 68 + 88 + 76 + 95 + 89 + 75 + 80}{10} = \frac{818}{10} = 81.8$$

Mediana: Ordenamos los datos: 68, 72, 75, 76, 80, 85, 88, 89, 90, 95. Como hay 10 valores, la mediana es el promedio de los dos valores centrales:

$$\text{Mediana} = \frac{80 + 85}{2} = \frac{165}{2} = 82.5$$

Moda: No hay un valor que se repita más de una vez, por lo que no hay moda en este conjunto de datos.

Rango:

$$\text{Rango} = 95 - 68 = 27$$

Varianza: Primero, calculamos la media de los cuadrados de las desviaciones respecto a la media:

$$\sigma^2 = \frac{(72 - 81.8)^2 + (85 - 81.8)^2 + \dots + (80 - 81.8)^2}{10} = 71.4$$

Desviación Estándar:

$$\sigma = \sqrt{71.4} \approx 8.45$$

Cuartiles: - **Primer Cuartil (Q1):** Valor en el percentil 25 (primera mitad inferior de los datos):

$$Q1 = 75$$

- **Tercer Cuartil (Q3):** Valor en el percentil 75 (primera mitad superior de los datos):

$$Q3 = 89$$

Resumen Descriptivo

- **Media:** 81.8
- **Mediana:** 82.5
- **Moda:** No hay moda
- **Rango:** 27
- **Varianza:** 71.4
- **Desviación Estándar:** 8.45
- **Primer Cuartil (Q1):** 75
- **Tercer Cuartil (Q3):** 89

Este resumen descriptivo proporciona una visión clara y concisa de las características principales del conjunto de datos, permitiendo una mejor comprensión de su distribución y variabilidad.

Ejercicio 6

Explica la diferencia entre estadística descriptiva e inferencial y proporciona un ejemplo de cómo se utiliza cada una.

Solución: La **estadística descriptiva** y la **estadística inferencial** son dos ramas principales de la estadística que tienen propósitos y métodos diferentes:

- **Estadística Descriptiva:** Se centra en resumir y describir las características de un conjunto de datos. Utiliza medidas como la media, mediana, moda, rango y desviación estándar para dar una visión general de los datos. Por ejemplo, si tenemos los resultados de una prueba de matemáticas de una clase, la estadística descriptiva podría incluir el cálculo de la media de las calificaciones, la calificación más alta, la más baja y la variabilidad de las calificaciones.

- **Estadística Inferencial:** Va más allá de la descripción de los datos y busca hacer predicciones o generalizaciones sobre una población basándose en una muestra de datos. Utiliza herramientas como pruebas de hipótesis, intervalos de confianza y regresión para inferir patrones y tomar decisiones. Por ejemplo, si queremos saber si un nuevo método de enseñanza es efectivo, podríamos aplicarlo a una muestra de estudiantes y usar la estadística inferencial para determinar si los resultados observados en la muestra pueden generalizarse a todos los estudiantes.

Solución:

Ejercicio 7

Diseña un experimento para ilustrar cómo el muestreo aleatorio simple puede ser utilizado para estimar una característica de una población.

Solución: Para ilustrar cómo el muestreo aleatorio simple puede ser utilizado para estimar una característica de una población, consideremos el siguiente experimento:

Objetivo del Experimento: Estimar la proporción de personas en una ciudad que prefieren el transporte público sobre otros medios de transporte.

Población: Todos los residentes de la ciudad que son mayores de edad y utilizan algún medio de transporte para desplazarse.

Característica de Interés: Preferencia por el transporte público.

Procedimiento:

1. **Definición de la Población:** Identificar a todos los residentes de la ciudad que son mayores de edad y utilizan algún medio de transporte.
2. **Selección de la Muestra:**
 - Utilizar un registro actualizado de la población, como el padrón municipal, para obtener una lista de individuos.
 - Seleccionar una muestra aleatoria de individuos utilizando un generador de números aleatorios.
 - Determinar el tamaño de la muestra necesario para obtener resultados con un nivel de confianza y un margen de error deseado.
3. **Recolección de Datos:**
 - Contactar a los individuos seleccionados y preguntarles si prefieren el transporte público sobre otros medios de transporte.
 - Registrar las respuestas afirmativas y negativas.
4. **Análisis de Datos:**

- Calcular la proporción de respuestas afirmativas en la muestra.
- Utilizar esta proporción como una estimación puntual de la preferencia en la población total.

5. Estimación de la Población:

- Calcular un intervalo de confianza para la proporción estimada, lo que proporcionará un rango dentro del cual se espera que se encuentre la verdadera proporción de la población con un cierto nivel de confianza.

6. Conclusión:

- Presentar la proporción estimada y el intervalo de confianza como la estimación de la preferencia por el transporte público en la población.
- Discutir las limitaciones del estudio y la posibilidad de sesgo si la muestra no fue perfectamente aleatoria o si hubo una tasa de respuesta baja.

Ejercicio 8

Explica el Teorema Central del Límite y su relevancia en la inferencia estadística.

Solución: Teorema Central del Límite (TCL)

El Teorema Central del Límite es un principio fundamental en estadística que establece que, bajo ciertas condiciones, la distribución de la suma de un gran número de variables aleatorias independientes y idénticamente distribuidas (i.i.d.) tiende a aproximarse a una distribución normal (gaussiana), independientemente de la forma de la distribución original de las variables.

Enunciado del Teorema Central del Límite

Para una muestra de tamaño (n) tomada de una población con cualquier distribución de probabilidad con media (μ) y desviación estándar (σ), la distribución de la media muestral $\bar{X}$ se aproximará a una distribución normal a medida que (n) se haga grande. Matemáticamente, si ($X_1, X_2, \dots, X_n$) son variables aleatorias independientes e idénticamente distribuidas con media (μ) y desviación estándar (σ), entonces la media muestral $\bar{X}$ se distribuye aproximadamente como:

$$\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

Importancia y Relevancia en la Inferencia Estadística

1. **Justificación del Uso de la Distribución Normal:** El TCL permite justificar el uso de la distribución normal en la inferencia estadística. Incluso si la población original no está distribuida normalmente, la distribución de las medias muestrales se aproximará a una distribución normal si el tamaño de la muestra es suficientemente grande.
2. **Construcción de Intervalos de Confianza:** Permite construir intervalos de confianza para estimar parámetros poblacionales. Por ejemplo, al estimar la media poblacional, podemos utilizar la distribución normal para determinar un rango donde probablemente se encuentra la media verdadera.
3. **Pruebas de Hipótesis:** Facilita la realización de pruebas de hipótesis. Dado que la distribución de la media muestral es aproximadamente normal, se pueden aplicar métodos estadísticos basados en la normalidad para decidir si rechazar o no una hipótesis nula.
4. **Simplificación de Cálculos:** El TCL simplifica el análisis de datos, ya que permite trabajar con la distribución normal, que tiene propiedades bien definidas y es ampliamente comprendida y tabulada, facilitando los cálculos y la interpretación de los resultados.
5. **Aplicación Universal:** Es aplicable en una amplia gama de situaciones, desde la economía y la biología hasta la ingeniería y las ciencias sociales, siempre que se cumplan las condiciones necesarias (independencia y tamaño de muestra grande).

Ejercicio 9

Compara y contrasta la estadística paramétrica y no paramétrica, dando ejemplos de cuándo se utilizaría cada una.

Solución: La **estadística paramétrica** y la **estadística no paramétrica** son dos enfoques de análisis estadístico que tienen diferentes supuestos y aplicaciones. La **estadística paramétrica** se utiliza cuando los datos se ajustan a ciertos supuestos y se conoce la distribución subyacente, lo que permite hacer inferencias más precisas si estos supuestos se cumplen. Por otro lado, la **estadística no paramétrica** es más flexible y se puede utilizar en una variedad más amplia de situaciones, especialmente cuando los datos no cumplen con los supuestos de los métodos paramétricos.

- **Estadística Paramétrica:**

- **Supuestos:** Asume que los datos de la muestra provienen de una población que sigue una distribución de probabilidad conocida, generalmente la distribución normal. También asume homogeneidad de varianzas y la independencia de las observaciones.
- **Uso:** Se utiliza cuando se conoce la forma de la distribución subyacente de los datos o cuando se tiene una muestra grande que, por el Teorema Central del Límite, tiende a una distribución normal.
- **Ejemplos de Herramientas:** T-test, ANOVA, regresión lineal.

- **Ejemplo de Uso:** Si queremos comparar las alturas promedio de dos grupos de personas y sabemos que las alturas siguen una distribución normal, podríamos usar un T-test paramétrico.

- **Estadística No Paramétrica:**

- **Supuestos:** No hace suposiciones sobre la forma de la distribución de la población. Es útil cuando no se cumplen las suposiciones de normalidad o cuando se trata con muestras pequeñas.
- **Uso:** Se aplica en situaciones donde no se conoce la distribución de los datos o cuando los datos son ordinales o nominales.
- **Ejemplos de Herramientas:** Test de Wilcoxon, Test de Kruskal-Wallis, Test de Chi-cuadrado.
- **Ejemplo de Uso:** Si queremos comparar las medianas de los tiempos de respuesta de dos grupos en una prueba y los datos son claramente no normales o son rangos en lugar de medidas, podríamos usar un test de Wilcoxon no paramétrico.

Ejercicio 10

Discute las diferencias entre los enfoques frecuentista y bayesiano en la inferencia estadística y da un ejemplo de aplicación para cada uno.

Solución: La inferencia estadística se basa en métodos que nos permiten hacer conclusiones sobre una población a partir de datos muestrales. Existen dos enfoques principales en la inferencia estadística: el enfoque frecuentista y el enfoque bayesiano. A continuación, se presentan las diferencias clave entre estos enfoques y ejemplos de aplicación para cada uno.

Enfoque Frecuentista

Características Principales:

1. **Interpretación de Probabilidad:** La probabilidad se interpreta como la frecuencia relativa de eventos en el largo plazo. Es decir, si un experimento se repite infinitas veces, la probabilidad de un evento es la proporción de veces que ocurre.
2. **Estimación de Parámetros:** Se basa en el concepto de estimación puntual y de intervalos de confianza. Los parámetros poblacionales se consideran fijos pero desconocidos, y los datos son aleatorios.
3. **Pruebas de Hipótesis:** Utiliza pruebas de hipótesis y valores p para decidir si rechazar la hipótesis nula. Las decisiones se basan en la frecuencia de observación de datos extremos bajo la suposición de que la hipótesis nula es verdadera.
4. **No usa Información Priori:** Los análisis frecuentistas no incorporan información previa sobre los parámetros; sólo se basan en los datos actuales.

Ejemplo de Aplicación Frecuentista:

Imaginemos que una empresa desea saber si un nuevo medicamento es efectivo para reducir la presión arterial. Realizan un ensayo clínico donde:

- **Hipótesis Nula (H_0):** El medicamento no tiene efecto en la presión arterial (la media de la reducción de la presión arterial es 0).
- **Hipótesis Alternativa (H_1):** El medicamento reduce la presión arterial (la media de la reducción de la presión arterial es mayor que 0).

El análisis frecuentista implicaría:

1. Recoger datos muestrales de pacientes.
2. Calcular la media y la desviación estándar de la reducción en la presión arterial.
3. Realizar una prueba t para comparar la media muestral con 0.
4. Calcular el valor p para determinar la significancia estadística.
5. Rechazar o no la hipótesis nula en función del valor p y el nivel de significancia establecido (por ejemplo, 0.05).

Enfoque Bayesiano

Características Principales:

1. **Interpretación de Probabilidad:** La probabilidad se interpreta como un grado de creencia o confianza sobre la ocurrencia de un evento, dado el conocimiento disponible.
2. **Estimación de Parámetros:** Los parámetros poblacionales se tratan como variables aleatorias con distribuciones de probabilidad. Utiliza la distribución a priori (información previa) y los datos observados para obtener la distribución a posteriori.
3. **Actualización de Conocimientos:** Aplica el Teorema de Bayes para actualizar la probabilidad a medida que se dispone de nueva información.
4. **Incorporación de Información Priori:** Utiliza información previa sobre los parámetros en forma de distribuciones a priori, que se combinan con la información de los datos para obtener las distribuciones a posteriori.

Ejemplo de Aplicación Bayesiana:

Supongamos que un médico quiere estimar la probabilidad de que un paciente tenga una enfermedad dada, basándose en un resultado positivo de una prueba diagnóstica y en el conocimiento previo sobre la prevalencia de la enfermedad y la precisión de la prueba.

1. **Información a Priori:** El médico tiene una estimación previa (a priori) de la prevalencia de la enfermedad (por ejemplo, 1% de la población tiene la enfermedad).
2. **Datos Observados:** La sensibilidad (probabilidad de un resultado positivo dado que el paciente tiene la enfermedad) es 90% y la especificidad (probabilidad de un resultado negativo dado que el paciente no tiene la enfermedad) es 95%.
3. **Aplicación del Teorema de Bayes:**

- ($P(E|+)$): Probabilidad de tener la enfermedad dado un resultado positivo.
- ($P(+|E)$): Sensibilidad.
- ($P(+|\neg E)$): Probabilidad de un falso positivo (1 - especificidad).
- ($P(E)$): Prevalencia de la enfermedad.
- ($P(\neg E)$): Probabilidad de no tener la enfermedad (1 - prevalencia).

$$P(E|+) = \frac{P(+|E) \cdot P(E)}{P(+|E) \cdot P(E) + P(+|\neg E) \cdot P(\neg E)}$$

Sustituyendo los valores:

$$P(E|+) = \frac{0.90 \cdot 0.01}{0.90 \cdot 0.01 + 0.05 \cdot 0.99} = \frac{0.009}{0.009 + 0.0495} = \frac{0.009}{0.0585} \approx 0.154$$

El resultado indica que, dado un resultado positivo de la prueba, la probabilidad a posteriori de tener la enfermedad es aproximadamente 15.4%.

Conclusión

Frecuentista:

- No utiliza información previa.
- Se basa en la frecuencia de los eventos.
- Adecuado para análisis donde no se dispone de información previa o se quiere evitar la subjetividad.

Bayesiano:

- Utiliza información previa (a priori).
- Actualiza las probabilidades a medida que se dispone de nueva información.
- Adecuado para situaciones donde la información previa es relevante y valiosa.

Ambos enfoques son útiles y válidos, y la elección entre ellos depende del contexto del problema, la disponibilidad de información previa y las preferencias del investigador.

Análisis Exploratorio de Datos

Utilizar el dataframe denominado *bank* con el que hemos trabajado en el tema 2 de la asignatura para responder a las siguientes cuestiones:

```
library(ggplot2)
library(dplyr)
library(readr)

# Cargar el conjunto de datos
url <- "https://archive.ics.uci.edu/ml/machine-learning-databases/00222/bank.zip"
download.file(url, "bank.zip")
unzip("bank.zip", "bank-full.csv")
bank_data <- read.csv("bank-full.csv", sep=";")
```

Ejercicio 1

Estructura del DataFrame:

- ¿Cuántos campos y observaciones tiene el dataframe **bank**? Utiliza las funciones **head** y **dim**.

```
# Pregunta 1: Estructura del DataFrame
head(bank_data)
```

	age	job	marital	education	default	balance	housing	loan	contact	day
1	58	management	married	tertiary	no	2143	yes	no	unknown	5
2	44	technician	single	secondary	no	29	yes	no	unknown	5
3	33	entrepreneur	married	secondary	no	2	yes	yes	unknown	5
4	47	blue-collar	married	unknown	no	1506	yes	no	unknown	5
5	33	unknown	single	unknown	no	1	no	no	unknown	5
6	35	management	married	tertiary	no	231	yes	no	unknown	5
	month	duration	campaign	pdays	previous	poutcome	y			
1	may	261	1	-1	0	unknown	no			
2	may	151	1	-1	0	unknown	no			


```

3   may      76      1   -1      0  unknown no
4   may      92      1   -1      0  unknown no
5   may     198      1   -1      0  unknown no
6   may     139      1   -1      0  unknown no

```

```
dim(bank_data)
```

```
[1] 45211    17
```

Respuesta:

El dataframe `bank_data` contiene 45,211 observaciones (filas) y 17 variables (columnas). La función `head()` nos muestra las primeras 6 filas del conjunto de datos, donde podemos observar variables numéricas como `age`, `balance` y `duration`, así como variables categóricas como `job`, `marital` y `education`. Esta estructura nos permite analizar tanto características demográficas como comportamentales de los clientes contactados durante la campaña de marketing.

Ejercicio 2

Resumen del DataFrame:

- Evalúa el dataframe con la función `summary`.
- ¿Tiene observaciones con elementos faltantes (NA)?
- ¿A qué categorías corresponden las observaciones en la variable `job`?

```
# Pregunta 2: Resumen del DataFrame
summary(bank_data)
```

```

      age      job      marital      education
Min.   :18.00 Length:45211 Length:45211 Length:45211
1st Qu.:33.00 Class :character Class :character Class :character
Median :39.00 Mode  :character Mode  :character Mode  :character
Mean   :40.94
3rd Qu.:48.00
Max.   :95.00

 default      balance      housing      loan
Length:45211 Min.   : -8019 Length:45211 Length:45211
Class :character 1st Qu.:   72 Class :character Class :character
Mode  :character Median :  448 Mode  :character Mode  :character
              Mean   : 1362
              3rd Qu.: 1428

```

	Max. :102127		
contact	day	month	duration
Length:45211	Min. : 1.00	Length:45211	Min. : 0.0
Class :character	1st Qu.: 8.00	Class :character	1st Qu.: 103.0
Mode :character	Median :16.00	Mode :character	Median : 180.0
	Mean :15.81		Mean : 258.2
	3rd Qu.:21.00		3rd Qu.: 319.0
	Max. :31.00		Max. :4918.0
campaign	pdays	previous	poutcome
Min. : 1.000	Min. : -1.0	Min. : 0.0000	Length:45211
1st Qu.: 1.000	1st Qu.: -1.0	1st Qu.: 0.0000	Class :character
Median : 2.000	Median : -1.0	Median : 0.0000	Mode :character
Mean : 2.764	Mean : 40.2	Mean : 0.5803	
3rd Qu.: 3.000	3rd Qu.: -1.0	3rd Qu.: 0.0000	
Max. :63.000	Max. :871.0	Max. :275.0000	
y			
Length:45211			
Class :character			
Mode :character			

```
sum(is.na(bank_data))
```

```
[1] 0
```

```
unique(bank_data$job)
```

```
[1] "management" "technician" "entrepreneur" "blue-collar"
[5] "unknown" "retired" "admin." "services"
[9] "self-employed" "unemployed" "housemaid" "student"
```

Respuesta:

El resumen estadístico proporciona información clave sobre cada variable del dataset. El dataset no contiene valores faltantes (NA), lo cual facilita el análisis sin necesidad de imputación. La variable `job` clasifica a los clientes en 12 categorías profesionales: `admin.`, `blue-collar`, `entrepreneur`, `housemaid`, `management`, `retired`, `self-employed`, `services`, `student`, `technician`, `unemployed` y `unknown`. Las categorías más frecuentes son `blue-collar` (trabajadores manuales), `management` (gerentes) y `technician` (técnicos), lo que refleja una muestra diversa de perfiles profesionales en la base de clientes del banco.

Ejercicio 3


Distribución de la Edad:

- ¿Cuál es la edad máxima y mínima de los clientes en el dataframe?
- ¿Cuál es la media y la mediana de la edad de los clientes?

```
# Pregunta 3: Distribución de la Edad  
summary(bank_data$age)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
18.00	33.00	39.00	40.94	48.00	95.00

```
ggplot(bank_data, aes(x = age)) +  
  geom_histogram(binwidth = 5, fill = "lightblue", color = "black") +  
  labs(title = "Distribución de la Edad de los Clientes",  
        x = "Edad",  
        y = "Frecuencia") +  
  theme_minimal()
```



Respuesta:

La edad de los clientes varía entre 18 años (mínimo) y 95 años (máximo), con una media de 40.94 años y una mediana de 39 años. El histograma muestra una distribución ligeramente sesgada a la derecha, con la mayor concentración de clientes entre los 30 y 50 años. La proximidad entre la media y la mediana indica que no hay valores extremos que distorsionen significativamente la distribución central. La amplitud del rango etario sugiere que la campaña se dirigió a un público amplio, desde jóvenes adultos hasta personas de edad avanzada.

Ejercicio 4

Balance Promedio:

- ¿Cuál es el balance promedio anual (balance) de los clientes?
- ¿Cuál es el balance promedio anual de los clientes que han suscrito un depósito a plazo fijo (y = "yes")?

```
# Pregunta 4: Balance Promedio
mean(bank_data$balance, na.rm = TRUE)
```

```
[1] 1362.272
```

```
mean(bank_data$balance[bank_data$y == "yes"], na.rm = TRUE)
```

```
[1] 1804.268
```

Respuesta:

El balance promedio anual de todos los clientes es de 1,362.27 €. Los clientes que suscribieron un depósito a plazo fijo tienen un balance promedio de 1,804.27 €, significativamente superior al promedio general. Esta diferencia de aproximadamente 442 € sugiere que el balance financiero es un factor relevante en la decisión de suscripción, ya que los clientes con mayor capacidad de ahorro tienden a estar más interesados en productos de inversión como los depósitos a plazo fijo.

Ejercicio 5

Frecuencia de Contacto:

- ¿Cuál es el número máximo y mínimo de contactos realizados durante esta campaña (campaign)?

```
# Pregunta 5: Frecuencia de Contacto
summary(bank_data$campaign)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
1.000	1.000	2.000	2.764	3.000	63.000

Respuesta:

Durante la campaña, el número de contactos realizados a los clientes varía entre 1 (mínimo) y 63 (máximo), con una media de 2.76 contactos por cliente. La mediana de 2 contactos indica que la mayoría de los clientes fueron contactados pocas veces, lo cual es una buena práctica para evitar saturar a los clientes. Sin embargo, la existencia de casos extremos con hasta 63 contactos sugiere que algunos clientes requirieron múltiples seguimientos, posiblemente clientes difíciles de convencer o con mayor interés que necesitaban información adicional antes de tomar una decisión.

Ejercicio 6

Análisis de Duración:

- ¿Cuál es la duración media y mediana del último contacto en segundos (`duration`)?
- ¿Cuál es la duración media del último contacto en segundos para los clientes que suscribieron un depósito a plazo fijo (`y = "yes"`)?

```
# Pregunta 6: Análisis de Duración
summary(bank_data$duration)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.0	103.0	180.0	258.2	319.0	4918.0

```
mean(bank_data$duration[bank_data$y == "yes"], na.rm = TRUE)
```

```
[1] 537.2946
```

Respuesta:


La duración del último contacto tiene una media de 258.16 segundos (aproximadamente 4.3 minutos) y una mediana de 180 segundos (3 minutos). Los clientes que suscribieron el depósito tuvieron conversaciones significativamente más largas, con una duración media de 537.29 segundos (aproximadamente 9 minutos). Esta diferencia de casi 5 minutos adicionales es notable y sugiere que la duración del contacto es un fuerte predictor del éxito de la campaña: conversaciones más extensas permiten explicar mejor el producto, resolver dudas y construir confianza con el cliente.

Ejercicio 7

Relación entre Variables:

- ¿Existe alguna relación entre el balance promedio anual y la duración del último contacto? Utiliza una visualización adecuada para responder a esta pregunta.

```
# Pregunta 7: Relación entre Balance y Duración
ggplot(bank_data, aes(x = balance, y = duration)) +
  geom_point(alpha = 0.5) +
  labs(title = "Relación entre Balance y Duración del Último Contacto",
       x = "Balance",
       y = "Duración (segundos)") +
  theme_minimal()
```



```
cor(bank_data$balance, bank_data$duration, use = "complete.obs")
```

```
[1] 0.02156038
```

Respuesta:

El diagrama de dispersión muestra una nube de puntos sin un patrón claro, y la correlación de Pearson entre balance y duración es prácticamente nula ($r \approx 0.022$). Esto indica que no existe

una relación lineal significativa entre el balance del cliente y la duración de la llamada. En otras palabras, el balance financiero del cliente no predice cuánto durará la conversación. Clientes con balances altos y bajos pueden tener conversaciones de cualquier duración, lo que sugiere que otros factores (como el interés del cliente, la habilidad del operador o la complejidad de las preguntas) son más determinantes en la duración del contacto.

Ejercicio 8

Segmentación por Trabajo:

- ¿Cuál es la media y mediana del balance anual de los clientes agrupados por tipo de trabajo (job)?

```
# Pregunta 8: Segmentación por Trabajo
bank_data %>% group_by(job) %>%
  summarise(media_balance = mean(balance, na.rm = TRUE),
            mediana_balance = median(balance, na.rm = TRUE))
```

```
# A tibble: 12 x 3
  job          media_balance mediana_balance
  <chr>          <dbl>          <dbl>
1 admin.         1136.           396
2 blue-collar    1079.           388
3 entrepreneur   1521.           352
4 housemaid      1392.           406
5 management     1764.           572
6 retired        1984.           787
7 self-employed  1648.           526
8 services        997.           340
9 student        1388.           502
10 technician    1253.           421
11 unemployed    1522.           529
12 unknown       1772.           677
```

Respuesta:

La segmentación por tipo de trabajo revela diferencias importantes en los balances. Los jubilados (retired) presentan el balance medio más alto (1,984 €), seguidos por trabajadores con ocupación desconocida (unknown) con 1,772 € y los gerentes (management) con 1,764 €. En el extremo opuesto, los trabajadores de servicios (services) tienen el balance medio más bajo (997 €), seguidos por los trabajadores manuales (blue-collar) con 1,079 €. Esta estratificación económica según la ocupación es lógica: los jubilados han tenido toda una vida laboral para

acumular ahorros, mientras que los trabajadores de servicios suelen tener salarios más bajos. Esta información es valiosa para segmentar las campañas de marketing, dirigiendo productos de mayor inversión a los grupos con mayor capacidad de ahorro.

Ejercicio 9

Análisis de Contactos Anteriores:

- ¿Cuál es el número máximo y mínimo de días que pasaron desde el último contacto de una campaña anterior (`pdays`)?
- ¿Cuál es la media de `pdays` para los clientes que suscribieron un depósito a plazo fijo (`y = "yes"`)?

```
# Pregunta 9: Análisis de Contactos Anteriores  
summary(bank_data$pdays)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-1.0	-1.0	-1.0	40.2	-1.0	871.0

```
mean(bank_data$pdays[bank_data$y == "yes"], na.rm = TRUE)
```

```
[1] 68.70297
```

Respuesta:

La variable `pdays` tiene un valor especial de -1 que indica que el cliente no fue contactado en campañas anteriores, y este es el valor más frecuente (mediana de -1). Para los clientes que sí fueron contactados previamente, el rango varía ampliamente hasta 871 días. La media de `pdays` para los clientes que suscribieron es de 68.70 días. Es importante notar que el valor de -1 domina la distribución, lo que sugiere que muchas conversiones exitosas provienen de clientes nuevos o que no habían sido contactados en campañas anteriores. Sin embargo, la media de 68.70 días para suscriptores indica que aquellos contactados previamente y que finalmente suscriben, lo hicieron después de aproximadamente 2 meses desde el último contacto, lo que podría indicar un tiempo óptimo para recontactar.

Ejercicio 10

Estudio General:

- Haciendo un estudio general de los datos, ¿qué puedes concluir?
- ¿Existe alguna relación significativa entre las variables `balance`, `duration`, y `campaign`?
Se recomienda hacer un análisis visual y estadístico de estas variables.

```
# Pregunta 10: Estudio General
# Puedes utilizar técnicas de análisis más avanzadas como correlación, regresión, etc.
cor(bank_data$balance, bank_data$duration, use = "complete.obs")
```

```
[1] 0.02156038
```


```
cor(bank_data$balance, bank_data$campaign, use = "complete.obs")
```

```
[1] -0.01457828
```

```
cor(bank_data$duration, bank_data$campaign, use = "complete.obs")
```

```
[1] -0.0845695
```

```
ggplot(bank_data, aes(x = campaign, y = balance)) +
  geom_point(alpha = 0.5) +
  labs(title = "Relación entre Campañas y Balance",
       x = "Número de Campañas",
       y = "Balance") +
  theme_minimal()
```



Respuesta:

El análisis general de los datos revela varios hallazgos importantes. En cuanto a las relaciones entre variables, las correlaciones son muy débiles: balance vs duration ($r = 0.022$), balance vs campaign ($r = -0.015$), y duration vs campaign ($r = -0.085$). Esto indica que estas tres variables operan de manera relativamente independiente entre sí.

Los factores más asociados al éxito de la campaña son: la duración del contacto emerge como el predictor más fuerte del éxito (conversaciones de ~9 minutos para suscriptores vs ~4 minutos para no suscriptores), el balance muestra una relación positiva pero moderada con la suscripción, y el número de contactos previos tiene una relación débil y negativa.

La segmentación de clientes muestra alta variabilidad en los balances según la ocupación, con jubilados (1,984 €), unknown (1,772 €) y gerentes (1,764 €) como los grupos más prometedores financieramente. La eficiencia de la campaña se caracteriza por contactos mayormente breves y eficientes (1-3 intentos), donde las conversaciones largas están fuertemente asociadas con conversiones exitosas.

En conclusión, el éxito de la campaña depende más de la calidad de la interacción (duración y contenido de la conversación) que de características demográficas o económicas del cliente. Las recomendaciones estratégicas incluyen: priorizar calidad sobre cantidad en los contactos, invertir en conversaciones más largas y detalladas, segmentar audiencias dirigiendo productos premium a ocupaciones con mayor capacidad económica, y limitar contactos repetidos para evitar saturar a clientes que no muestran interés inicial.

Procesado y Limpieza de Datos

```
library(tidyr)
library(dplyr)
```

Ejercicio 1

Crear el siguiente *dataframe* mediante estas instrucciones

```
set.seed(1234)
stocks <- data.frame(time = as.Date("2009-01-01") + 0:9,
                     Walmart = rnorm(10,20,1),
                     Target = rnorm(10,20,2),
                     Walgreens = rnorm(10,20,4)
                     )
stocks
```

	time	Walmart	Target	Walgreens
1	2009-01-01	18.79293	19.04561	20.53635
2	2009-01-02	20.27743	18.00323	18.03726
3	2009-01-03	21.08444	18.44749	18.23781
4	2009-01-04	17.65430	20.12892	21.83836
5	2009-01-05	20.42912	21.91899	17.22512
6	2009-01-06	20.50606	19.77943	14.20718
7	2009-01-07	19.42526	18.97798	22.29902
8	2009-01-08	19.45337	18.17761	15.90538
9	2009-01-09	19.43555	18.32566	19.93945
10	2009-01-10	19.10996	24.83167	16.25621

A continuación, realizar las siguientes operaciones de limpieza de datos:

- Como se puede observar, hay un problema de clave-valor en las compañías con sus observaciones. Por lo tanto, se pide transformar los datos para que tengan una clave “*stock*” y un valor “*precio*”. Utilizar la instrucción “*gather*”.

- Devolver el dataframe al estado original empleando la instrucción *spread*.
- Utilizando el operador tubería `%>%` se desea realizar las siguientes operaciones anidadas:
 - Transformar los datos para que tengan una clave “*stock*” y el valor sea el “*precio*”. Utilizar la instrucción “*gather*”.
 - Agrupar los datos por la clave “*stock*” mediante la instrucción “*group_by*”.
 - Obtener el precio mínimo y el máximo utilizando la instrucción “*summarise*”.

```
# Transformar los datos para que tengan una clave stock y el valor sea el precio.
# Opción 1:
new_stocks <- gather(data = stocks, key = stock, value = price, Walmart, Target, Walgreens)

# Opción 2:
new_stocks <- gather(data = stocks, key = stock, value = price, Walmart:Walgreens)

# Opción 3:
new_stocks <- gather(data = stocks, key = stock, value = price, -time)

# Devolver el dataframe al estado original utilizando la función "spread".
original_stocks <- spread(data = new_stocks, key = stock, value = price)

# Utilizando el operador tubería %>% realizar las operaciones anidadas.
stocks %>%
  gather(key = stock, value = price, Walmart:Walgreens) %>%
  group_by(stock) %>%
  summarise(min = min(price), max = max(price))
```

```
# A tibble: 3 x 3
  stock      min    max
  <chr>    <dbl> <dbl>
1 Target    18.0  24.8
2 Walgreens  14.2  22.3
3 Walmart   17.7  21.1
```

Respuesta:

El ejercicio demuestra tres operaciones fundamentales en la reestructuración de datos con *tidyr*. Primero, la función `gather()` convierte el dataframe de formato ancho a formato largo, transformando las columnas de las tres compañías (Walmart, Target, Walgreens) en dos columnas: una clave llamada “*stock*” que identifica la compañía y otra llamada “*price*” que contiene los valores. Se presentan tres formas equivalentes de realizar esta operación: especificando las columnas explícitamente, usando el operador de rango `:`, o excluyendo columnas con el signo `-`.

Segundo, la función `spread()` realiza la operación inversa, devolviendo el dataframe a su formato ancho original. Esta operación toma la columna clave “stock” y crea una columna separada para cada valor único, rellenándolas con los valores correspondientes de la columna “price”.

Finalmente, el uso del operador tubería `%>%` permite encadenar múltiples operaciones de forma legible. En este caso, se transforma el dataframe a formato largo con `gather()`, se agrupan las observaciones por compañía con `group_by()`, y se calculan estadísticos resumen (precio mínimo y máximo) para cada grupo usando `summarise()`. Esta secuencia de operaciones es típica en el análisis exploratorio de datos y demuestra el poder del enfoque tidyverse para manipulación de datos.

Ejercicio 2

En este ejercicio vamos a manejar datos contenidos en distintos *dataframes* y operar sobre ellos con *dplyr*.

1. Descargar el paquete *nycflights13*.
2. Evaluar el contenido de los dataframes proporcionados por el paquete. Utilizar *head* y *summary*.
3. Simplificar los dataframes originales a 100 observaciones mediante el comando *head*. Asignarlos a una variable que indique el tipo de dataframe añadiendo la coletilla “_simple”. Ejemplo: “flights_simple”.
4. Selecciona los tipos de aerolínea (“carrier”) mediante la instrucción *select* y el operador *unique* concatenados con el operador tubería `%>%`. (Utilizar “airlines_simple”).
5. Obtener la media y el número máximo de asientos (“seats”) que tienen los aviones. Utilizar el operador tubería `%>%` y la instrucción *summarise*.
6. Ordenar los aviones por su número de motores (“engines”) y número de asientos (“seats”). Utilizar la instrucción *arrange*.
7. Averigua qué número de cola (“tailnum”) comparten los dataframes “flights_simple” y “planes_simple” que has creado anteriormente. Obten su aerolínea (“carrier”). Utilizar la instrucción *inner_join*.
8. Cruzar los datos de vuelos (“flights”) con los aviones (“planes”) por el número de cola (“tailnum”) que no coincidan (usar la instrucción *anti_join*). De esos obtener aquellos con 2 o más motores (usar la instrucción *filter*). Finalmente obtener los distintos modelos de avión que satisfacen las premisas anteriores (usar la instrucción *unique*).
9. Crea una nueva variable (“total_delay”) que calcule el retraso total sumando los delays acumulados (“dep_delay”) y (“arr_delay”). Utilizar la instrucción *mutate*. Almacena el dataframe resultante en “flights_total”.
10. En base a la variable anteriormente obtenida (“total_delay”), devuelve los aviones que han llegado con antelación a su destino, es decir aquellos tal que la variable *total_delay* tiene valores negativos.

```
library(dplyr)
library(nycflights13)

# Observamos los distintos dataframes que nos proporcionan
print(head(flights))
```

```
# A tibble: 6 x 19
  year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
  <int> <int> <int>   <int>         <int>         <dbl>   <int>         <int>
1  2013     1     1     517             515           2     830             819
2  2013     1     1     533             529           4     850             830
3  2013     1     1     542             540           2     923             850
4  2013     1     1     544             545          -1    1004            1022
5  2013     1     1     554             600          -6     812             837
6  2013     1     1     554             558          -4     740             728
# i 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
#   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
#   hour <dbl>, minute <dbl>, time_hour <dtm>
```

```
print(head(airports))
```

```
# A tibble: 6 x 8
  faa   name                lat lon alt tz dst tzone
  <chr> <chr>                <dbl> <dbl> <dbl> <dbl> <chr> <chr>
1 04G   Lansdowne Airport      41.1 -80.6 1044 -5 A America/Ne~
2 06A   Moton Field Municipal Airport 32.5 -85.7 264 -6 A America/Ch~
3 06C   Schaumburg Regional     42.0 -88.1 801 -6 A America/Ch~
4 06N   Randall Airport         41.4 -74.4 523 -5 A America/Ne~
5 09J   Jekyll Island Airport    31.1 -81.4 11 -5 A America/Ne~
6 0A9   Elizabethton Municipal Airport 36.4 -82.2 1593 -5 A America/Ne~
```

```
print(head(weather))
```

```
# A tibble: 6 x 15
  origin year month   day hour temp dewp humid wind_dir wind_speed wind_gust
  <chr>   <int> <int> <int> <int> <dbl> <dbl> <dbl>   <dbl>     <dbl>     <dbl>
1 EWR    2013     1     1     1 39.0 26.1 59.4    270      10.4      NA
2 EWR    2013     1     1     2 39.0 27.0 61.6    250       8.06     NA
3 EWR    2013     1     1     3 39.0 28.0 64.4    240      11.5      NA
4 EWR    2013     1     1     4 39.9 28.0 62.2    250      12.7      NA
```

```

5 EWR      2013      1      1      5 39.0 28.0 64.4      260      12.7      NA
6 EWR      2013      1      1      6 37.9 28.0 67.2      240      11.5      NA
# i 4 more variables: precip <dbl>, pressure <dbl>, visib <dbl>,
#   time_hour <dtm>

```

```
print(head(airlines))
```

```

# A tibble: 6 x 2
  carrier name
  <chr>   <chr>
1 9E      Endeavor Air Inc.
2 AA      American Airlines Inc.
3 AS      Alaska Airlines Inc.
4 B6      JetBlue Airways
5 DL      Delta Air Lines Inc.
6 EV      ExpressJet Airlines Inc.

```

```
print(head(planes))
```

```

# A tibble: 6 x 9
  tailnum year type      manufacturer model engines seats speed engine
  <chr>   <int> <chr>      <chr>          <chr>   <int> <int> <int> <chr>
1 N10156  2004 Fixed wing multi ~ EMBRAER      EMB~      2    55    NA Turbo~
2 N102UW  1998 Fixed wing multi ~ AIRBUS      INDU~    2   182    NA Turbo~
3 N103US  1999 Fixed wing multi ~ AIRBUS      INDU~    2   182    NA Turbo~
4 N104UW  1999 Fixed wing multi ~ AIRBUS      INDU~    2   182    NA Turbo~
5 N10575  2002 Fixed wing multi ~ EMBRAER      EMB~      2    55    NA Turbo~
6 N105UW  1999 Fixed wing multi ~ AIRBUS      INDU~    2   182    NA Turbo~

```

```

# Comprobamos las variables mediante summary
print(summary(flights))

```

	year	month	day	dep_time	sched_dep_time
Min.	:2013	Min. : 1.000	Min. : 1.00	Min. : 1	Min. : 106
1st Qu.:	:2013	1st Qu.: 4.000	1st Qu.: 8.00	1st Qu.: 907	1st Qu.: 906
Median :	:2013	Median : 7.000	Median :16.00	Median :1401	Median :1359
Mean :	:2013	Mean : 6.549	Mean :15.71	Mean :1349	Mean :1344
3rd Qu.:	:2013	3rd Qu.:10.000	3rd Qu.:23.00	3rd Qu.:1744	3rd Qu.:1729
Max.	:2013	Max. :12.000	Max. :31.00	Max. :2400	Max. :2359
				NA's :8255	

dep_delay	arr_time	sched_arr_time	arr_delay
Min. : -43.00	Min. : 1	Min. : 1	Min. : -86.000
1st Qu.: -5.00	1st Qu.:1104	1st Qu.:1124	1st Qu.: -17.000
Median : -2.00	Median :1535	Median :1556	Median : -5.000
Mean : 12.64	Mean :1502	Mean :1536	Mean : 6.895
3rd Qu.: 11.00	3rd Qu.:1940	3rd Qu.:1945	3rd Qu.: 14.000
Max. :1301.00	Max. :2400	Max. :2359	Max. :1272.000
NA's :8255	NA's :8713		NA's :9430

carrier	flight	tailnum	origin
Length:336776	Min. : 1	Length:336776	Length:336776
Class :character	1st Qu.: 553	Class :character	Class :character
Mode :character	Median :1496	Mode :character	Mode :character
	Mean :1972		
	3rd Qu.:3465		
	Max. :8500		

dest	air_time	distance	hour
Length:336776	Min. : 20.0	Min. : 17	Min. : 1.00
Class :character	1st Qu.: 82.0	1st Qu.: 502	1st Qu.: 9.00
Mode :character	Median :129.0	Median : 872	Median :13.00
	Mean :150.7	Mean :1040	Mean :13.18
	3rd Qu.:192.0	3rd Qu.:1389	3rd Qu.:17.00
	Max. :695.0	Max. :4983	Max. :23.00
	NA's :9430		

minute	time_hour
Min. : 0.00	Min. :2013-01-01 05:00:00.00
1st Qu.: 8.00	1st Qu.:2013-04-04 13:00:00.00
Median :29.00	Median :2013-07-03 10:00:00.00
Mean :26.23	Mean :2013-07-03 05:22:54.64
3rd Qu.:44.00	3rd Qu.:2013-10-01 07:00:00.00
Max. :59.00	Max. :2013-12-31 23:00:00.00

```
print(summary(airports))
```

faa	name	lat	lon
Length:1458	Length:1458	Min. :19.72	Min. : -176.65
Class :character	Class :character	1st Qu.:34.26	1st Qu.: -119.19
Mode :character	Mode :character	Median :40.09	Median : -94.66
		Mean :41.65	Mean : -103.39
		3rd Qu.:45.07	3rd Qu.: -82.52
		Max. :72.27	Max. : 174.11

alt	tz	dst	tzzone
Min. : -54.00	Min. : -10.000	Length:1458	Length:1458
1st Qu.: 70.25	1st Qu.: -8.000	Class :character	Class :character
Median : 473.00	Median : -6.000	Mode :character	Mode :character
Mean :1001.42	Mean : -6.519		
3rd Qu.:1062.50	3rd Qu.: -5.000		
Max. :9078.00	Max. : 8.000		

```
print(summary(weather))
```

origin	year	month	day
Length:26115	Min. :2013	Min. : 1.000	Min. : 1.00
Class :character	1st Qu.:2013	1st Qu.: 4.000	1st Qu.: 8.00
Mode :character	Median :2013	Median : 7.000	Median :16.00
	Mean :2013	Mean : 6.504	Mean :15.68
	3rd Qu.:2013	3rd Qu.: 9.000	3rd Qu.:23.00
	Max. :2013	Max. :12.000	Max. :31.00

hour	temp	dewp	humid
Min. : 0.00	Min. : 10.94	Min. : -9.94	Min. : 12.74
1st Qu.: 6.00	1st Qu.: 39.92	1st Qu.:26.06	1st Qu.: 47.05
Median :11.00	Median : 55.40	Median :42.08	Median : 61.79
Mean :11.49	Mean : 55.26	Mean :41.44	Mean : 62.53
3rd Qu.:17.00	3rd Qu.: 69.98	3rd Qu.:57.92	3rd Qu.: 78.79
Max. :23.00	Max. :100.04	Max. :78.08	Max. :100.00
	NA's :1	NA's :1	NA's :1

wind_dir	wind_speed	wind_gust	precip
Min. : 0.0	Min. : 0.000	Min. :16.11	Min. :0.000000
1st Qu.:120.0	1st Qu.: 6.905	1st Qu.:20.71	1st Qu.:0.000000
Median :220.0	Median : 10.357	Median :24.17	Median :0.000000
Mean :199.8	Mean : 10.518	Mean :25.49	Mean :0.004469
3rd Qu.:290.0	3rd Qu.: 13.809	3rd Qu.:28.77	3rd Qu.:0.000000
Max. :360.0	Max. :1048.361	Max. :66.75	Max. :1.210000
NA's :460	NA's :4	NA's :20778	

pressure	visib	time_hour
Min. : 983.8	Min. : 0.000	Min. :2013-01-01 01:00:00.0
1st Qu.:1012.9	1st Qu.:10.000	1st Qu.:2013-04-01 21:30:00.0
Median :1017.6	Median :10.000	Median :2013-07-01 14:00:00.0
Mean :1017.9	Mean : 9.255	Mean :2013-07-01 18:26:37.7
3rd Qu.:1023.0	3rd Qu.:10.000	3rd Qu.:2013-09-30 13:00:00.0
Max. :1042.1	Max. :10.000	Max. :2013-12-30 18:00:00.0
NA's :2729		

```
print(summary(airlines))
```

```
   carrier      name
Length:16   Length:16
Class :character  Class :character
Mode  :character  Mode  :character
```

```
print(summary(planes))
```

```
   tailnum      year      type      manufacturer
Length:3322   Min.   :1956   Length:3322   Length:3322
Class :character 1st Qu.:1997   Class :character  Class :character
Mode  :character Median :2001   Mode  :character  Mode  :character
               Mean  :2000
               3rd Qu.:2005
               Max.   :2013
               NA's   :70

   model      engines      seats      speed
Length:3322   Min.   :1.000   Min.   : 2.0   Min.   : 90.0
Class :character 1st Qu.:2.000   1st Qu.:140.0   1st Qu.:107.5
Mode  :character Median :2.000   Median :149.0   Median :162.0
               Mean  :1.995   Mean  :154.3   Mean  :236.8
               3rd Qu.:2.000   3rd Qu.:182.0   3rd Qu.:432.0
               Max.   :4.000   Max.   :450.0   Max.   :432.0
               NA's   :3299

   engine
Length:3322
Class :character
Mode  :character
```

Respuesta:

El paquete `nycflights13` proporciona cinco dataframes relacionados con vuelos que salieron de los aeropuertos de Nueva York en 2013. El dataframe `flights` contiene 336,776 observaciones con información sobre cada vuelo, incluyendo fecha, hora, aerolíneas, origen, destino y retrasos. `airports` contiene información sobre 1,458 aeropuertos incluyendo códigos, nombres y ubicaciones geográficas. `weather` proporciona 26,115 observaciones meteorológicas horarias

de los tres aeropuertos de origen. `airlines` es un pequeño dataframe con 16 aerolíneas y sus nombres completos. Finalmente, `planes` contiene información sobre 3,322 aviones, incluyendo fabricante, modelo, año de fabricación y características técnicas como número de asientos y motores. Estos dataframes están relacionados entre sí mediante claves como `tailnum` (número de cola del avión) y `carrier` (código de aerolínea), lo que permite realizar análisis complejos combinando múltiples fuentes de información.

```
# Simplificar los dataframes originales a 100 observaciones
flights_simple <- head(flights, 100)
airports_simple <- head(airports, 100)
weather_simple <- head(weather, 100)
airlines_simple <- head(airlines, 100)
planes_simple <- head(planes, 100)

# Selecciona los tipos de aerolínea
airlines_simple %>% unique %>% select(carrier)
```

```
# A tibble: 16 x 1
  carrier
  <chr>
1 9E
2 AA
3 AS
4 B6
5 DL
6 EV
7 F9
8 FL
9 HA
10 MQ
11 OO
12 UA
13 US
14 VX
15 WN
16 YV
```

Respuesta:

La simplificación de los dataframes a 100 observaciones facilita el trabajo exploratorio sin comprometer la comprensión de la estructura de datos. Al seleccionar los tipos de aerolínea del dataframe `airlines_simple` usando el operador tubería, obtenemos una lista de códigos

de aerolínea únicos. El uso de `unique()` elimina cualquier duplicado que pudiera existir, mientras que `select(carrier)` extrae únicamente la columna de interés. Esta combinación de operaciones es eficiente y legible, demostrando el estilo declarativo de programación que promueve dplyr.

```
# Obtener la media y el máximo de asientos
planes_simple %>% summarise(mean = mean(seats), max_engines = max(seats))
```

```
# A tibble: 1 x 2
  mean max_engines
  <dbl>      <int>
1  105.         330
```

Respuesta:

El análisis de la capacidad de asientos en los aviones revela estadísticos importantes sobre la flota. La función `summarise()` reduce el dataframe a una única fila conteniendo la media y el máximo de asientos. Esto permite identificar tanto la capacidad promedio de los aviones en el conjunto de datos como el avión de mayor capacidad. Esta información es valiosa para comprender la composición de la flota y puede influir en decisiones operativas relacionadas con la asignación de aviones a rutas específicas según la demanda esperada.

```
# Ordenar los aviones por número de motores y número de asientos
result1 <- arrange(planes_simple, engines, seats)
print(result1)
```

```
# A tibble: 100 x 9
  tailnum year type      manufacturer model engines seats speed engine
  <chr>   <int> <chr>      <chr>          <chr>   <int> <int> <int> <chr>
1 N10156  2004 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
2 N10575  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
3 N11106  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
4 N11107  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
5 N11109  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
6 N11113  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
7 N11119  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
8 N11121  2003 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
9 N11127  2003 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
10 N11137 2003 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
# i 90 more rows
```

Respuesta:

La función `arrange()` ordena el dataframe de aviones primero por número de motores y luego, dentro de cada grupo de motores, por número de asientos en orden ascendente. Esta ordenación revela la relación entre la complejidad técnica del avión (número de motores) y su capacidad (número de asientos). Típicamente, los aviones con menos asientos tienen menos motores, y conforme aumenta la capacidad, se requieren configuraciones con más motores para proporcionar la potencia necesaria. Este ordenamiento facilita la identificación de patrones en el diseño y capacidades de diferentes modelos de aeronaves.

```
# Averigua qué número de cola comparten los dataframes
shared <- inner_join(flights_simple, planes_simple, by = "tailnum")
shared_carrier <- shared$carrier
print(shared_carrier)
```

```
[1] "EV"
```

Respuesta:

La función `inner_join()` combina los dataframes `flights_simple` y `planes_simple` usando el número de cola (`tailnum`) como clave de unión, devolviendo únicamente las filas donde existe coincidencia en ambos dataframes. Esto permite identificar qué aviones del registro de vuelos tienen información técnica disponible en el dataframe de aviones. Al extraer la columna `carrier`, obtenemos las aerolíneas que operaron estos vuelos específicos. Esta operación es fundamental en análisis de datos relacionales, donde diferentes tablas contienen información complementaria sobre las mismas entidades y se requiere combinarlas para obtener un panorama completo.

```
# Cruzar datos que no coincidan
fp <- anti_join(planes_simple, flights_simple, by = "tailnum")
engines_fp <- filter(fp, engines >= 2)
result2 <- unique(engines_fp$model)
print(result2)
```

```
[1] "EMB-145XR" "A320-214" "EMB-145LR" "737-824" "767-332" "757-224"
```

Respuesta:

La operación `anti_join()` identifica aviones en `planes_simple` que no tienen vuelos correspondientes en `flights_simple`, es decir, aviones registrados que no aparecen en los primeros 100 vuelos analizados. Posteriormente, se filtran aquellos con 2 o más motores, típicamente aviones de mayor tamaño o alcance. Finalmente, se extraen los modelos únicos que satisfacen

estas condiciones. Esta secuencia de operaciones es útil para análisis de utilización de flota, permitiendo identificar qué aviones con ciertas características técnicas no están siendo utilizados o no aparecen en el período analizado, lo cual podría indicar aviones en mantenimiento, reserva, o asignados a otras rutas no capturadas en la muestra.

```
# Crear nueva variable de retraso total
flights_total <- mutate(flights_simple, total_delay = dep_delay + arr_delay)

# Devolver aviones que llegaron con antelación
filter(flights_total, total_delay < 0)
```

```
# A tibble: 57 x 20
  year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
  <int> <int> <int>   <int>         <int>      <dbl>    <int>         <int>
1  2013     1     1     544           545        -1     1004           1022
2  2013     1     1     554           600        -6      812           837
3  2013     1     1     557           600        -3      709           723
4  2013     1     1     557           600        -3      838           846
5  2013     1     1     558           600        -2      849           851
6  2013     1     1     558           600        -2      853           856
7  2013     1     1     558           600        -2      923           937
8  2013     1     1     559           559         0      702           706
9  2013     1     1     559           600        -1      854           902
10 2013     1     1     600           600         0      851           858
# i 47 more rows
# i 12 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
#   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
#   hour <dbl>, minute <dbl>, time_hour <dtm>, total_delay <dbl>
```

Respuesta:

La función `mutate()` crea una nueva columna `total_delay` que suma los retrasos de salida (`dep_delay`) y llegada (`arr_delay`), proporcionando una medida agregada del retraso acumulado durante todo el trayecto del vuelo. Valores positivos indican retraso total, mientras que valores negativos indican que el vuelo llegó antes de lo programado. Al filtrar por `total_delay < 0`, se identifican vuelos que, a pesar de cualquier retraso en la salida, lograron recuperar tiempo durante el vuelo y llegar anticipadamente a su destino. Esto puede ocurrir cuando los pilotos compensan retrasos iniciales aumentando la velocidad de crucero cuando las condiciones lo permiten, o cuando el tiempo de vuelo programado incluye márgenes de seguridad que no siempre se utilizan completamente. Estos casos son de interés para el análisis de eficiencia operativa y satisfacción del cliente.