

Inferencia Estadística

Ejercicios

Resueltos

Grado en Ciencia de Datos e Ingeniería de Datos

AUTORES

- Víctor Aceña Gil
- Isaac Martín de Diego
- Carmen Lancho Martín

2025-2026



Índice de Soluciones

Prefacio	5
Filosofía pedagógica	5
¿Cómo usar este manual?	5
Metodología de las soluciones	5
Requisitos de software	6
Introducción a la Inferencia Estadística	8
Ejercicio 1	8
Ejercicio 2	8
Ejercicio 3	9
Ejercicio 4	9
Ejercicio 5	10
Ejercicio 6	11
Ejercicio 7	12
Ejercicio 8	13
Ejercicio 9	14
Ejercicio 10	15
Análisis Exploratorio de Datos	18
Ejercicio 1	18
Ejercicio 2	19
Ejercicio 3	21
Ejercicio 4	22
Ejercicio 5	22
Ejercicio 6	23
Ejercicio 7	24
Ejercicio 8	25
Ejercicio 9	26
Ejercicio 10	27
Procesado y Limpieza de Datos	29
Ejercicio 1	29
Ejercicio 2	31
Contrastes de Hipótesis	41
Ejercicio 1: Conceptos Básicos	41

Ejercicio 2: Pasos en un Contraste de Hipótesis	42
Ejercicio 3: Errores tipo I y tipo II. Potencia	43
Ejercicio 4: Contraste para la media de una población normal con varianza conocida	45
Ejercicio 5: Contraste para la media de una población normal con varianza desconocida	46
Ejercicio 6: Contraste de hipótesis para la igualdad de medias de dos muestras independientes	46
Ejercicio 7: Contraste de hipótesis para la diferencia de proporciones	47
Ejercicio 8: Aplicación en un contexto real	48
Ejercicio 9: Prueba t de Student	49
Ejercicio 10: Prueba z para grandes muestras	50
Intervalos de Confianza	52
Ejercicio 1: Conceptos Básicos	52
Ejercicio 2: Intervalo de Confianza Básico	53
Ejercicio 3: Nivel de Confianza Diferente	54
Ejercicio 4: Interpretación Práctica	55
Ejercicio 5: Varianza Conocida	56
Ejercicio 6: Varianza Desconocida	56
Ejercicio 7: Muestra Grande	57
Ejercicio 8: Proporción	58
Ejercicio 9: Comparación de Proporciones	59
Ejercicio 10: Interpretación Crítica	60
Estimación y contraste paramétrico 1	61
Ejercicio 1: Definición de Estadístico	61
Ejercicio 2: Estimación Puntual	61
Ejercicio 3: Propiedades de los Estimadores	61
Ejercicio 4: Método de los Momentos	63
Ejercicio 5: Método de la Máxima Verosimilitud	65
Ejercicio 6: Estimación por Intervalo	67
Ejercicio 7: Contraste de Hipótesis (Prueba Z)	69
Ejercicio 8: Contraste de Hipótesis (Prueba T)	70
Ejercicio 9: Contraste de Hipótesis (Prueba Chi-Cuadrado)	72
Ejercicio 10: Contraste de Hipótesis (Comparación de Dos Medias)	74
Estimación y contraste paramétrico 2	77
Ejercicio 1: Propiedades de los estimadores	77
Ejercicio 2: Propiedades de los estimadores	79
Ejercicio 3: Método de Máxima Verosimilitud	81
Ejercicio 4: Tamaño muestral	83
Ejercicio 5: Intervalos de confianza	84

Ejercicio 6: Contraste de Hipótesis	86
Ejercicio 7: Estimación en el muestreo	88
Ejercicio 8: Muestreo	89
Ejercicio 9: Contraste de Hipótesis	90
Ejercicio 10: Datos	92
Contraste no paramétrico	94
Ejercicio 1:	94
Ejercicio 2:	96
Ejercicio 3:	98
Ejercicio 4	102
Ejercicio 5	103
Ejercicio 6	105
Ejercicio 7	107
Ejercicio 8	109
Ejercicio 9	110
Ejercicio 10	112
Análisis de Varianza	115
Ejercicio 1	115
Ejercicio 2	117
Ejercicio 3	120
Ejercicio 4	123
Ejercicio 5	126
Ejercicio 6	128
Ejercicio 7	132
Ejercicio 8	135
Ejercicio 9	137
Ejercicio 10	140

Prefacio

Este manual de soluciones complementa el libro **Inferencia Estadística** y está diseñado para proporcionar un apoyo integral al proceso de aprendizaje. Cada solución ha sido desarrollada con el mismo rigor teórico-práctico que caracteriza al curso, ofreciendo no solo la respuesta correcta, sino también el razonamiento estadístico y la interpretación práctica necesarios para una comprensión profunda.

Filosofía pedagógica

Al igual que el libro principal, este manual sigue un enfoque “**teórico-práctico**” sin concesiones. Las soluciones están diseñadas para:

- **Reforzar** la comprensión de los conceptos fundamentales mediante aplicaciones concretas
- **Desarrollar** la intuición estadística a través de interpretaciones razonadas
- **Conectar** la teoría con la práctica mediante código R completamente funcional
- **Fomentar** el pensamiento crítico sobre las limitaciones y supuestos de cada método

¿Cómo usar este manual?

Para maximizar el beneficio de este recurso:

1. **Intentar primero:** Resuelve cada ejercicio por tu cuenta antes de consultar la solución
2. **Estudiar el proceso:** No solo copies el código, entiende la lógica detrás de cada paso
3. **Experimentar:** Modifica los parámetros y observa cómo cambian los resultados
4. **Reflexionar:** Considera las implicaciones prácticas de cada resultado obtenido

Metodología de las soluciones

Cada solución incluye:

- **Código R completo:** Totalmente ejecutable y comentado

- **Explicaciones paso a paso:** Qué hace cada línea y por qué
- **Interpretación de resultados:** Qué significan los números obtenidos
- **Gráficos explicativos:** Visualización de conceptos clave
- **Consejos prácticos:** Cuándo y cómo usar cada técnica

! Uso responsable

Este manual es una herramienta de aprendizaje, no un sustituto del pensamiento propio. Utilízalo para verificar tu comprensión y mejorar tu técnica, pero siempre tras haber hecho un esfuerzo genuino por resolver los problemas de forma independiente.

Requisitos de software

Para ejecutar las soluciones necesitas tener instalados los siguientes paquetes de R:

```
# Paquetes principales para análisis exploratorio de datos
install.packages(c(
  "ggplot2",      # Visualización de datos
  "dplyr",        # Manipulación de datos
  "tidyr",        # Restructuración de datos
  "readr",        # Lectura de archivos de datos
  "nycflights13"  # Dataset de vuelos usado en ejercicios
))
```

i Sobre los autores

Víctor Aceña Gil es graduado en Matemáticas por la UNED, máster en Tratamiento Estadístico y Computacional de la Información por la UCM y la UPM, doctor en Tecnologías de la Información y las Comunicaciones por la URJC y profesor del departamento de Informática y Estadística de la URJC. Miembro del grupo de investigación de alto rendimiento en Fundamentos y Aplicaciones de la Ciencia de Datos, DSLAB, de la URJC. Pertenece al grupo de innovación docente, DSLAB-TI.

Isaac Martín de Diego es diplomado en Estadística por la Universidad de Valladolid (UVA), licenciado en Ciencias y Técnicas Estadísticas por la Universidad Carlos III de Madrid (UC3M), doctor en Ingeniería Matemática por la UC3M, catedrático de Ciencias de la Computación e Inteligencia Artificial del departamento de Informática y Estadística de la URJC. Es fundador y coordinador del DSLAB y del DSLAB-TI.

Carmen Lancho Martín es graduada en Matemáticas y Estadística por la Universidad Complutense de Madrid (UCM), máster en Tratamiento Estadístico y Computacional de la Información por la UCM y la Universidad Politécnica de Madrid (UPM), doctora en Tecnologías de la Información y las Comunicaciones por la Universidad Rey Juan

Carlos (URJC) y profesora del departamento de Informática y Estadística de la URJC. Miembro del grupo de investigación de alto rendimiento en Fundamentos y Aplicaciones de la Ciencia de Datos, DSLAB, de la URJC. Pertenece al grupo de innovación docente, DSLAB-TI.

Esta obra está bajo una licencia de Creative Commons Atribución-CompartirIgual 4.0 Internacional.

Introducción a la Inferencia Estadística

Ejercicio 1

Describe en tus propias palabras qué es la Ciencia de Datos y su importancia en el análisis de grandes volúmenes de datos.

Solución: La Ciencia de Datos es una disciplina interdisciplinaria que se centra en la extracción de conocimiento significativo a partir de grandes conjuntos de datos. Es crucial en un mundo impulsado por los datos, ya que permite tomar decisiones informadas y hacer predicciones basadas en el análisis de datos. La Ciencia de Datos combina elementos de estadística, informática y conocimiento específico del dominio para interpretar datos y aplicar este conocimiento en diversas áreas como la medicina, las finanzas y la tecnología. Su importancia radica en su capacidad para transformar datos crudos en información valiosa que puede impulsar la innovación y la eficiencia en múltiples campos.

Ejercicio 2

Enumera las herramientas estadísticas que se utilizan en la inferencia estadística y explica brevemente su propósito.

Solución: En la inferencia estadística, se utilizan diversas herramientas para analizar datos y hacer generalizaciones sobre una población a partir de muestras:

- **Pruebas de Hipótesis:** Se utilizan para determinar si existe suficiente evidencia en una muestra de datos para inferir que una cierta condición es verdadera para toda la población.
- **Intervalos de Confianza:** Proporcionan un rango estimado que es probable que contenga el valor de un parámetro desconocido de la población, con un cierto nivel de confianza.
- **Análisis de Varianza (ANOVA):** Permite comparar tres o más medias de grupos para determinar si al menos una de las medias es diferente de las demás.
- **Chi-cuadrado (χ^2):** Es una prueba que mide la discrepancia entre los datos observados y los datos que se esperarían según un modelo específico.
- **T-test:** Evalúa si las medias de dos grupos son estadísticamente diferentes entre sí.
- **Correlación:** Mide la relación entre dos variables y la fuerza de esta relación.

- **Estadística Bayesiana:** Utiliza la probabilidad para representar la incertidumbre sobre los parámetros del modelo y actualiza esta incertidumbre a medida que se obtienen más datos.
- **Métodos de Muestreo:** Incluyen técnicas para seleccionar muestras representativas de la población para realizar inferencias estadísticas.
- **Métodos No Paramétricos:** Son técnicas que no asumen una distribución específica de los datos y son útiles cuando no se cumplen los supuestos de los métodos paramétricos.

Ejercicio 3

Define los términos “población” y “muestra” y explica la diferencia entre ambos.

Solución:

- **Población:** Se refiere al conjunto completo de elementos o resultados que se están estudiando, del cual se desean obtener conclusiones. La población incluye a todos los individuos, mediciones, objetos o eventos que cumplen con un conjunto de especificaciones previamente definidas. Por ejemplo, si estamos estudiando la altura de los estudiantes de una universidad, la población sería la altura de **todos** los estudiantes de esa universidad.
- **Muestra:** Es un subconjunto de la población que se selecciona para representarla. La muestra debe ser representativa de la población para que las inferencias hechas a partir de ella sean válidas. Por ejemplo, si elegimos a 100 estudiantes al azar de la universidad mencionada anteriormente, esos 100 estudiantes constituirían una muestra de la población.

La **diferencia principal** entre ambos términos es el alcance. Mientras que la población es el grupo completo que se quiere estudiar, la muestra es solo una parte de ese grupo. Las muestras se utilizan porque a menudo es impracticable o imposible estudiar toda la población debido a limitaciones de tiempo, costo o logística. Por lo tanto, se selecciona una muestra para obtener estimaciones o pruebas sobre la población completa.

Ejercicio 4

¿Qué es una distribución de probabilidad y cómo se relaciona con las variables cualitativas y cuantitativas?

Solución: Una **distribución de probabilidad** es una función matemática que describe la probabilidad de ocurrencia de los diferentes posibles resultados en un experimento. En otras palabras, asigna probabilidades a cada posible resultado de una variable aleatoria. Las distribuciones de probabilidad se relacionan con las variables cualitativas y cuantitativas de la siguiente manera:

- **Variables Cualitativas (o Categóricas):** Son aquellas que describen una cualidad o categoría y no tienen un orden o medida numérica inherente. Las distribuciones de probabilidad para estas variables son conocidas como **distribuciones discretas** y asignan probabilidades a resultados específicos. Un ejemplo es la **distribución binomial**, que puede modelar eventos como el lanzamiento de una moneda, donde los resultados son categóricos (cara o cruz).
- **Variables Cuantitativas:** Son variables que se pueden medir en una escala numérica y tienen sentido hablar de valores mayores o menores. Las distribuciones de probabilidad asociadas a estas variables son **distribuciones continuas** y asignan probabilidades a intervalos de números. Por ejemplo, la **distribución normal** es una distribución continua que se utiliza comúnmente para modelar fenómenos naturales como la altura o el peso de individuos.

Ejercicio 5

Realiza un resumen descriptivo de un conjunto de datos utilizando medidas de tendencia central y dispersión.

Solución: Imaginemos un conjunto de datos que representa las calificaciones de un grupo de estudiantes en un examen:

```
datos=c(72, 85, 90, 68, 88, 76, 95, 89, 75, 80)
datos
```

```
[1] 72 85 90 68 88 76 95 89 75 80
```

Media:

$$\text{Media} = \frac{72 + 85 + 90 + 68 + 88 + 76 + 95 + 89 + 75 + 80}{10} = \frac{818}{10} = 81.8$$

Mediana: Ordenamos los datos: 68, 72, 75, 76, 80, 85, 88, 89, 90, 95. Como hay 10 valores, la mediana es el promedio de los dos valores centrales:

$$\text{Mediana} = \frac{80 + 85}{2} = \frac{165}{2} = 82.5$$

Moda: No hay un valor que se repita más de una vez, por lo que no hay moda en este conjunto de datos.

Rango:

$$\text{Rango} = 95 - 68 = 27$$

Varianza: Primero, calculamos la media de los cuadrados de las desviaciones respecto a la media:

$$\sigma^2 = \frac{(72 - 81.8)^2 + (85 - 81.8)^2 + \dots + (80 - 81.8)^2}{10} = 71.4$$

Desviación Estándar:

$$\sigma = \sqrt{71.4} \approx 8.45$$

Cuartiles: - **Primer Cuartil (Q1):** Valor en el percentil 25 (primera mitad inferior de los datos):

$$Q1 = 75$$

- **Tercer Cuartil (Q3):** Valor en el percentil 75 (primera mitad superior de los datos):

$$Q3 = 89$$

Resumen Descriptivo

- **Media:** 81.8
- **Mediana:** 82.5
- **Moda:** No hay moda
- **Rango:** 27
- **Varianza:** 71.4
- **Desviación Estándar:** 8.45
- **Primer Cuartil (Q1):** 75
- **Tercer Cuartil (Q3):** 89

Este resumen descriptivo proporciona una visión clara y concisa de las características principales del conjunto de datos, permitiendo una mejor comprensión de su distribución y variabilidad.

Ejercicio 6

Explica la diferencia entre estadística descriptiva e inferencial y proporciona un ejemplo de cómo se utiliza cada una.

Solución: La **estadística descriptiva** y la **estadística inferencial** son dos ramas principales de la estadística que tienen propósitos y métodos diferentes:

- **Estadística Descriptiva:** Se centra en resumir y describir las características de un conjunto de datos. Utiliza medidas como la media, mediana, moda, rango y desviación estándar para dar una visión general de los datos. Por ejemplo, si tenemos los resultados de una prueba de matemáticas de una clase, la estadística descriptiva podría incluir el cálculo de la media de las calificaciones, la calificación más alta, la más baja y la variabilidad de las calificaciones.

- **Estadística Inferencial:** Va más allá de la descripción de los datos y busca hacer predicciones o generalizaciones sobre una población basándose en una muestra de datos. Utiliza herramientas como pruebas de hipótesis, intervalos de confianza y regresión para inferir patrones y tomar decisiones. Por ejemplo, si queremos saber si un nuevo método de enseñanza es efectivo, podríamos aplicarlo a una muestra de estudiantes y usar la estadística inferencial para determinar si los resultados observados en la muestra pueden generalizarse a todos los estudiantes.

Solución:

Ejercicio 7

Diseña un experimento para ilustrar cómo el muestreo aleatorio simple puede ser utilizado para estimar una característica de una población.

Solución: Para ilustrar cómo el muestreo aleatorio simple puede ser utilizado para estimar una característica de una población, consideremos el siguiente experimento:

Objetivo del Experimento: Estimar la proporción de personas en una ciudad que prefieren el transporte público sobre otros medios de transporte.

Población: Todos los residentes de la ciudad que son mayores de edad y utilizan algún medio de transporte para desplazarse.

Característica de Interés: Preferencia por el transporte público.

Procedimiento:

1. **Definición de la Población:** Identificar a todos los residentes de la ciudad que son mayores de edad y utilizan algún medio de transporte.
2. **Selección de la Muestra:**
 - Utilizar un registro actualizado de la población, como el padrón municipal, para obtener una lista de individuos.
 - Seleccionar una muestra aleatoria de individuos utilizando un generador de números aleatorios.
 - Determinar el tamaño de la muestra necesario para obtener resultados con un nivel de confianza y un margen de error deseado.
3. **Recolección de Datos:**
 - Contactar a los individuos seleccionados y preguntarles si prefieren el transporte público sobre otros medios de transporte.
 - Registrar las respuestas afirmativas y negativas.
4. **Análisis de Datos:**

- Calcular la proporción de respuestas afirmativas en la muestra.
- Utilizar esta proporción como una estimación puntual de la preferencia en la población total.

5. Estimación de la Población:

- Calcular un intervalo de confianza para la proporción estimada, lo que proporcionará un rango dentro del cual se espera que se encuentre la verdadera proporción de la población con un cierto nivel de confianza.

6. Conclusión:

- Presentar la proporción estimada y el intervalo de confianza como la estimación de la preferencia por el transporte público en la población.
- Discutir las limitaciones del estudio y la posibilidad de sesgo si la muestra no fue perfectamente aleatoria o si hubo una tasa de respuesta baja.

Ejercicio 8

Explica el Teorema Central del Límite y su relevancia en la inferencia estadística.

Solución: Teorema Central del Límite (TCL)

El Teorema Central del Límite es un principio fundamental en estadística que establece que, bajo ciertas condiciones, la distribución de la suma de un gran número de variables aleatorias independientes y idénticamente distribuidas (i.i.d.) tiende a aproximarse a una distribución normal (gaussiana), independientemente de la forma de la distribución original de las variables.

Enunciado del Teorema Central del Límite

Para una muestra de tamaño (n) tomada de una población con cualquier distribución de probabilidad con media (μ) y desviación estándar (σ), la distribución de la media muestral $\bar{X}$ se aproximará a una distribución normal a medida que (n) se haga grande. Matemáticamente, si ($X_1, X_2, \dots, X_n$) son variables aleatorias independientes e idénticamente distribuidas con media (μ) y desviación estándar (σ), entonces la media muestral $\bar{X}$ se distribuye aproximadamente como:

$$\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

Importancia y Relevancia en la Inferencia Estadística

1. **Justificación del Uso de la Distribución Normal:** El TCL permite justificar el uso de la distribución normal en la inferencia estadística. Incluso si la población original no está distribuida normalmente, la distribución de las medias muestrales se aproximará a una distribución normal si el tamaño de la muestra es suficientemente grande.
2. **Construcción de Intervalos de Confianza:** Permite construir intervalos de confianza para estimar parámetros poblacionales. Por ejemplo, al estimar la media poblacional, podemos utilizar la distribución normal para determinar un rango donde probablemente se encuentra la media verdadera.
3. **Pruebas de Hipótesis:** Facilita la realización de pruebas de hipótesis. Dado que la distribución de la media muestral es aproximadamente normal, se pueden aplicar métodos estadísticos basados en la normalidad para decidir si rechazar o no una hipótesis nula.
4. **Simplificación de Cálculos:** El TCL simplifica el análisis de datos, ya que permite trabajar con la distribución normal, que tiene propiedades bien definidas y es ampliamente comprendida y tabulada, facilitando los cálculos y la interpretación de los resultados.
5. **Aplicación Universal:** Es aplicable en una amplia gama de situaciones, desde la economía y la biología hasta la ingeniería y las ciencias sociales, siempre que se cumplan las condiciones necesarias (independencia y tamaño de muestra grande).

Ejercicio 9

Compara y contrasta la estadística paramétrica y no paramétrica, dando ejemplos de cuándo se utilizaría cada una.

Solución: La **estadística paramétrica** y la **estadística no paramétrica** son dos enfoques de análisis estadístico que tienen diferentes supuestos y aplicaciones. La **estadística paramétrica** se utiliza cuando los datos se ajustan a ciertos supuestos y se conoce la distribución subyacente, lo que permite hacer inferencias más precisas si estos supuestos se cumplen. Por otro lado, la **estadística no paramétrica** es más flexible y se puede utilizar en una variedad más amplia de situaciones, especialmente cuando los datos no cumplen con los supuestos de los métodos paramétricos.

- **Estadística Paramétrica:**

- **Supuestos:** Asume que los datos de la muestra provienen de una población que sigue una distribución de probabilidad conocida, generalmente la distribución normal. También asume homogeneidad de varianzas y la independencia de las observaciones.
- **Uso:** Se utiliza cuando se conoce la forma de la distribución subyacente de los datos o cuando se tiene una muestra grande que, por el Teorema Central del Límite, tiende a una distribución normal.
- **Ejemplos de Herramientas:** T-test, ANOVA, regresión lineal.

- **Ejemplo de Uso:** Si queremos comparar las alturas promedio de dos grupos de personas y sabemos que las alturas siguen una distribución normal, podríamos usar un T-test paramétrico.

- **Estadística No Paramétrica:**

- **Supuestos:** No hace suposiciones sobre la forma de la distribución de la población. Es útil cuando no se cumplen los suposiciones de normalidad o cuando se trata con muestras pequeñas.
- **Uso:** Se aplica en situaciones donde no se conoce la distribución de los datos o cuando los datos son ordinales o nominales.
- **Ejemplos de Herramientas:** Test de Wilcoxon, Test de Kruskal-Wallis, Test de Chi-cuadrado.
- **Ejemplo de Uso:** Si queremos comparar las medianas de los tiempos de respuesta de dos grupos en una prueba y los datos son claramente no normales o son rangos en lugar de medidas, podríamos usar un test de Wilcoxon no paramétrico.

Ejercicio 10

Discute las diferencias entre los enfoques frecuentista y bayesiano en la inferencia estadística y da un ejemplo de aplicación para cada uno.

Solución: La inferencia estadística se basa en métodos que nos permiten hacer conclusiones sobre una población a partir de datos muestrales. Existen dos enfoques principales en la inferencia estadística: el enfoque frecuentista y el enfoque bayesiano. A continuación, se presentan las diferencias clave entre estos enfoques y ejemplos de aplicación para cada uno.

Enfoque Frecuentista

Características Principales:

1. **Interpretación de Probabilidad:** La probabilidad se interpreta como la frecuencia relativa de eventos en el largo plazo. Es decir, si un experimento se repite infinitas veces, la probabilidad de un evento es la proporción de veces que ocurre.
2. **Estimación de Parámetros:** Se basa en el concepto de estimación puntual y de intervalos de confianza. Los parámetros poblacionales se consideran fijos pero desconocidos, y los datos son aleatorios.
3. **Pruebas de Hipótesis:** Utiliza pruebas de hipótesis y valores p para decidir si rechazar la hipótesis nula. Las decisiones se basan en la frecuencia de observación de datos extremos bajo la suposición de que la hipótesis nula es verdadera.
4. **No usa Información Priori:** Los análisis frecuentistas no incorporan información previa sobre los parámetros; sólo se basan en los datos actuales.

Ejemplo de Aplicación Frecuentista:

Imaginemos que una empresa desea saber si un nuevo medicamento es efectivo para reducir la presión arterial. Realizan un ensayo clínico donde:

- **Hipótesis Nula (H_0):** El medicamento no tiene efecto en la presión arterial (la media de la reducción de la presión arterial es 0).
- **Hipótesis Alternativa (H_1):** El medicamento reduce la presión arterial (la media de la reducción de la presión arterial es mayor que 0).

El análisis frecuentista implicaría:

1. Recoger datos muestrales de pacientes.
2. Calcular la media y la desviación estándar de la reducción en la presión arterial.
3. Realizar una prueba t para comparar la media muestral con 0.
4. Calcular el valor p para determinar la significancia estadística.
5. Rechazar o no la hipótesis nula en función del valor p y el nivel de significancia establecido (por ejemplo, 0.05).

Enfoque Bayesiano

Características Principales:

1. **Interpretación de Probabilidad:** La probabilidad se interpreta como un grado de creencia o confianza sobre la ocurrencia de un evento, dado el conocimiento disponible.
2. **Estimación de Parámetros:** Los parámetros poblacionales se tratan como variables aleatorias con distribuciones de probabilidad. Utiliza la distribución a priori (información previa) y los datos observados para obtener la distribución a posteriori.
3. **Actualización de Conocimientos:** Aplica el Teorema de Bayes para actualizar la probabilidad a medida que se dispone de nueva información.
4. **Incorporación de Información Priori:** Utiliza información previa sobre los parámetros en forma de distribuciones a priori, que se combinan con la información de los datos para obtener las distribuciones a posteriori.

Ejemplo de Aplicación Bayesiana:

Supongamos que un médico quiere estimar la probabilidad de que un paciente tenga una enfermedad dada, basándose en un resultado positivo de una prueba diagnóstica y en el conocimiento previo sobre la prevalencia de la enfermedad y la precisión de la prueba.

1. **Información a Priori:** El médico tiene una estimación previa (a priori) de la prevalencia de la enfermedad (por ejemplo, 1% de la población tiene la enfermedad).
2. **Datos Observados:** La sensibilidad (probabilidad de un resultado positivo dado que el paciente tiene la enfermedad) es 90% y la especificidad (probabilidad de un resultado negativo dado que el paciente no tiene la enfermedad) es 95%.
3. **Aplicación del Teorema de Bayes:**

- ($P(E|+)$): Probabilidad de tener la enfermedad dado un resultado positivo.
- ($P(+|E)$): Sensibilidad.
- ($P(+|\neg E)$): Probabilidad de un falso positivo (1 - especificidad).
- ($P(E)$): Prevalencia de la enfermedad.
- ($P(\neg E)$): Probabilidad de no tener la enfermedad (1 - prevalencia).

$$P(E|+) = \frac{P(+|E) \cdot P(E)}{P(+|E) \cdot P(E) + P(+|\neg E) \cdot P(\neg E)}$$

Sustituyendo los valores:

$$P(E|+) = \frac{0.90 \cdot 0.01}{0.90 \cdot 0.01 + 0.05 \cdot 0.99} = \frac{0.009}{0.009 + 0.0495} = \frac{0.009}{0.0585} \approx 0.154$$

El resultado indica que, dado un resultado positivo de la prueba, la probabilidad a posteriori de tener la enfermedad es aproximadamente 15.4%.

Conclusión

Frecuentista:

- No utiliza información previa.
- Se basa en la frecuencia de los eventos.
- Adecuado para análisis donde no se dispone de información previa o se quiere evitar la subjetividad.

Bayesiano:

- Utiliza información previa (a priori).
- Actualiza las probabilidades a medida que se dispone de nueva información.
- Adecuado para situaciones donde la información previa es relevante y valiosa.

Ambos enfoques son útiles y válidos, y la elección entre ellos depende del contexto del problema, la disponibilidad de información previa y las preferencias del investigador.

Análisis Exploratorio de Datos

Utilizar el dataframe denominado *bank* con el que hemos trabajado en el tema 2 de la asignatura para responder a las siguientes cuestiones:

```
library(ggplot2)
library(dplyr)
library(readr)

# Cargar el conjunto de datos
url <- "https://archive.ics.uci.edu/ml/machine-learning-databases/00222/bank.zip"
download.file(url, "bank.zip")
unzip("bank.zip", "bank-full.csv")
bank_data <- read.csv("bank-full.csv", sep=";")
```

Ejercicio 1

Estructura del DataFrame:

- ¿Cuántos campos y observaciones tiene el dataframe **bank**? Utiliza las funciones **head** y **dim**.

```
# Pregunta 1: Estructura del DataFrame
head(bank_data)
```

	age	job	marital	education	default	balance	housing	loan	contact	day
1	58	management	married	tertiary	no	2143	yes	no	unknown	5
2	44	technician	single	secondary	no	29	yes	no	unknown	5
3	33	entrepreneur	married	secondary	no	2	yes	yes	unknown	5
4	47	blue-collar	married	unknown	no	1506	yes	no	unknown	5
5	33	unknown	single	unknown	no	1	no	no	unknown	5
6	35	management	married	tertiary	no	231	yes	no	unknown	5
	month	duration	campaign	pdays	previous	poutcome	y			
1	may	261	1	-1	0	unknown	no			
2	may	151	1	-1	0	unknown	no			

```

3   may      76      1   -1      0  unknown no
4   may      92      1   -1      0  unknown no
5   may     198      1   -1      0  unknown no
6   may     139      1   -1      0  unknown no

```

```
dim(bank_data)
```

```
[1] 45211    17
```

Respuesta:

El dataframe `bank_data` contiene 45,211 observaciones (filas) y 17 variables (columnas). La función `head()` nos muestra las primeras 6 filas del conjunto de datos, donde podemos observar variables numéricas como `age`, `balance` y `duration`, así como variables categóricas como `job`, `marital` y `education`. Esta estructura nos permite analizar tanto características demográficas como comportamentales de los clientes contactados durante la campaña de marketing.

Ejercicio 2

Resumen del DataFrame:

- Evalúa el dataframe con la función `summary`.
- ¿Tiene observaciones con elementos faltantes (NA)?
- ¿A qué categorías corresponden las observaciones en la variable `job`?

```
# Pregunta 2: Resumen del DataFrame
summary(bank_data)
```

```

      age      job      marital      education
Min.   :18.00 Length:45211 Length:45211 Length:45211
1st Qu.:33.00 Class :character Class :character Class :character
Median :39.00 Mode  :character Mode  :character Mode  :character
Mean   :40.94
3rd Qu.:48.00
Max.   :95.00

 default      balance      housing      loan
Length:45211 Min.   : -8019 Length:45211 Length:45211
Class :character 1st Qu.:   72 Class :character Class :character
Mode  :character Median :  448 Mode  :character Mode  :character
              Mean   : 1362
              3rd Qu.: 1428

```

	Max. :102127		
contact	day	month	duration
Length:45211	Min. : 1.00	Length:45211	Min. : 0.0
Class :character	1st Qu.: 8.00	Class :character	1st Qu.: 103.0
Mode :character	Median :16.00	Mode :character	Median : 180.0
	Mean :15.81		Mean : 258.2
	3rd Qu.:21.00		3rd Qu.: 319.0
	Max. :31.00		Max. :4918.0
campaign	pdays	previous	poutcome
Min. : 1.000	Min. : -1.0	Min. : 0.0000	Length:45211
1st Qu.: 1.000	1st Qu.: -1.0	1st Qu.: 0.0000	Class :character
Median : 2.000	Median : -1.0	Median : 0.0000	Mode :character
Mean : 2.764	Mean : 40.2	Mean : 0.5803	
3rd Qu.: 3.000	3rd Qu.: -1.0	3rd Qu.: 0.0000	
Max. :63.000	Max. :871.0	Max. :275.0000	
y			
Length:45211			
Class :character			
Mode :character			

```
sum(is.na(bank_data))
```

```
[1] 0
```

```
unique(bank_data$job)
```

```
[1] "management" "technician" "entrepreneur" "blue-collar"
[5] "unknown" "retired" "admin." "services"
[9] "self-employed" "unemployed" "housemaid" "student"
```

Respuesta:

El resumen estadístico proporciona información clave sobre cada variable del dataset. El dataset no contiene valores faltantes (NA), lo cual facilita el análisis sin necesidad de imputación. La variable `job` clasifica a los clientes en 12 categorías profesionales: `admin.`, `blue-collar`, `entrepreneur`, `housemaid`, `management`, `retired`, `self-employed`, `services`, `student`, `technician`, `unemployed` y `unknown`. Las categorías más frecuentes son `blue-collar` (trabajadores manuales), `management` (gerentes) y `technician` (técnicos), lo que refleja una muestra diversa de perfiles profesionales en la base de clientes del banco.

Ejercicio 3


Distribución de la Edad:

- ¿Cuál es la edad máxima y mínima de los clientes en el dataframe?
- ¿Cuál es la media y la mediana de la edad de los clientes?

```
# Pregunta 3: Distribución de la Edad  
summary(bank_data$age)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
18.00	33.00	39.00	40.94	48.00	95.00

```
ggplot(bank_data, aes(x = age)) +  
  geom_histogram(binwidth = 5, fill = "lightblue", color = "black") +  
  labs(title = "Distribución de la Edad de los Clientes",  
        x = "Edad",  
        y = "Frecuencia") +  
  theme_minimal()
```



Respuesta:

La edad de los clientes varía entre 18 años (mínimo) y 95 años (máximo), con una media de 40.94 años y una mediana de 39 años. El histograma muestra una distribución ligeramente sesgada a la derecha, con la mayor concentración de clientes entre los 30 y 50 años. La proximidad entre la media y la mediana indica que no hay valores extremos que distorsionen significativamente la distribución central. La amplitud del rango etario sugiere que la campaña se dirigió a un público amplio, desde jóvenes adultos hasta personas de edad avanzada.

Ejercicio 4

Balance Promedio:

- ¿Cuál es el balance promedio anual (balance) de los clientes?
- ¿Cuál es el balance promedio anual de los clientes que han suscrito un depósito a plazo fijo (y = "yes")?

```
# Pregunta 4: Balance Promedio  
mean(bank_data$balance, na.rm = TRUE)
```

```
[1] 1362.272
```

```
mean(bank_data$balance[bank_data$y == "yes"], na.rm = TRUE)
```

```
[1] 1804.268
```

Respuesta:

El balance promedio anual de todos los clientes es de 1,362.27 €. Los clientes que suscribieron un depósito a plazo fijo tienen un balance promedio de 1,804.27 €, significativamente superior al promedio general. Esta diferencia de aproximadamente 442 € sugiere que el balance financiero es un factor relevante en la decisión de suscripción, ya que los clientes con mayor capacidad de ahorro tienden a estar más interesados en productos de inversión como los depósitos a plazo fijo.

Ejercicio 5

Frecuencia de Contacto:

- ¿Cuál es el número máximo y mínimo de contactos realizados durante esta campaña (campaign)?

```
# Pregunta 5: Frecuencia de Contacto
summary(bank_data$campaign)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
1.000	1.000	2.000	2.764	3.000	63.000

Respuesta:

Durante la campaña, el número de contactos realizados a los clientes varía entre 1 (mínimo) y 63 (máximo), con una media de 2.76 contactos por cliente. La mediana de 2 contactos indica que la mayoría de los clientes fueron contactados pocas veces, lo cual es una buena práctica para evitar saturar a los clientes. Sin embargo, la existencia de casos extremos con hasta 63 contactos sugiere que algunos clientes requirieron múltiples seguimientos, posiblemente clientes difíciles de convencer o con mayor interés que necesitaban información adicional antes de tomar una decisión.

Ejercicio 6

Análisis de Duración:

- ¿Cuál es la duración media y mediana del último contacto en segundos (`duration`)?
- ¿Cuál es la duración media del último contacto en segundos para los clientes que suscribieron un depósito a plazo fijo (`y = "yes"`)?

```
# Pregunta 6: Análisis de Duración
summary(bank_data$duration)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.0	103.0	180.0	258.2	319.0	4918.0

```
mean(bank_data$duration[bank_data$y == "yes"], na.rm = TRUE)
```

```
[1] 537.2946
```

Respuesta:


La duración del último contacto tiene una media de 258.16 segundos (aproximadamente 4.3 minutos) y una mediana de 180 segundos (3 minutos). Los clientes que suscribieron el depósito tuvieron conversaciones significativamente más largas, con una duración media de 537.29 segundos (aproximadamente 9 minutos). Esta diferencia de casi 5 minutos adicionales es notable y sugiere que la duración del contacto es un fuerte predictor del éxito de la campaña: conversaciones más extensas permiten explicar mejor el producto, resolver dudas y construir confianza con el cliente.

Ejercicio 7

Relación entre Variables:

- ¿Existe alguna relación entre el balance promedio anual y la duración del último contacto? Utiliza una visualización adecuada para responder a esta pregunta.

```
# Pregunta 7: Relación entre Balance y Duración
ggplot(bank_data, aes(x = balance, y = duration)) +
  geom_point(alpha = 0.5) +
  labs(title = "Relación entre Balance y Duración del Último Contacto",
       x = "Balance",
       y = "Duración (segundos)") +
  theme_minimal()
```



```
cor(bank_data$balance, bank_data$duration, use = "complete.obs")
```

```
[1] 0.02156038
```

Respuesta:

El diagrama de dispersión muestra una nube de puntos sin un patrón claro, y la correlación de Pearson entre balance y duración es prácticamente nula ($r = 0.022$). Esto indica que no existe

una relación lineal significativa entre el balance del cliente y la duración de la llamada. En otras palabras, el balance financiero del cliente no predice cuánto durará la conversación. Clientes con balances altos y bajos pueden tener conversaciones de cualquier duración, lo que sugiere que otros factores (como el interés del cliente, la habilidad del operador o la complejidad de las preguntas) son más determinantes en la duración del contacto.

Ejercicio 8

Segmentación por Trabajo:

- ¿Cuál es la media y mediana del balance anual de los clientes agrupados por tipo de trabajo (job)?

```
# Pregunta 8: Segmentación por Trabajo
bank_data %>% group_by(job) %>%
  summarise(media_balance = mean(balance, na.rm = TRUE),
            mediana_balance = median(balance, na.rm = TRUE))
```

```
# A tibble: 12 x 3
  job          media_balance mediana_balance
  <chr>          <dbl>          <dbl>
1 admin.         1136.           396
2 blue-collar    1079.           388
3 entrepreneur   1521.           352
4 housemaid      1392.           406
5 management     1764.           572
6 retired        1984.           787
7 self-employed  1648.           526
8 services        997.           340
9 student        1388.           502
10 technician    1253.           421
11 unemployed    1522.           529
12 unknown       1772.           677
```

Respuesta:

La segmentación por tipo de trabajo revela diferencias importantes en los balances. Los jubilados (retired) presentan el balance medio más alto (1,984 €), seguidos por trabajadores con ocupación desconocida (unknown) con 1,772 € y los gerentes (management) con 1,764 €. En el extremo opuesto, los trabajadores de servicios (services) tienen el balance medio más bajo (997 €), seguidos por los trabajadores manuales (blue-collar) con 1,079 €. Esta estratificación económica según la ocupación es lógica: los jubilados han tenido toda una vida laboral para

acumular ahorros, mientras que los trabajadores de servicios suelen tener salarios más bajos. Esta información es valiosa para segmentar las campañas de marketing, dirigiendo productos de mayor inversión a los grupos con mayor capacidad de ahorro.

Ejercicio 9

Análisis de Contactos Anteriores:

- ¿Cuál es el número máximo y mínimo de días que pasaron desde el último contacto de una campaña anterior (`pdays`)?
- ¿Cuál es la media de `pdays` para los clientes que suscribieron un depósito a plazo fijo (`y = "yes"`)?

```
# Pregunta 9: Análisis de Contactos Anteriores
summary(bank_data$pdays)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-1.0	-1.0	-1.0	40.2	-1.0	871.0

```
mean(bank_data$pdays[bank_data$y == "yes"], na.rm = TRUE)
```

```
[1] 68.70297
```

Respuesta:

La variable `pdays` tiene un valor especial de -1 que indica que el cliente no fue contactado en campañas anteriores, y este es el valor más frecuente (mediana de -1). Para los clientes que sí fueron contactados previamente, el rango varía ampliamente hasta 871 días. La media de `pdays` para los clientes que suscribieron es de 68.70 días. Es importante notar que el valor de -1 domina la distribución, lo que sugiere que muchas conversiones exitosas provienen de clientes nuevos o que no habían sido contactados en campañas anteriores. Sin embargo, la media de 68.70 días para suscriptores indica que aquellos contactados previamente y que finalmente suscriben, lo hicieron después de aproximadamente 2 meses desde el último contacto, lo que podría indicar un tiempo óptimo para recontactar.

Ejercicio 10

Estudio General:

- Haciendo un estudio general de los datos, ¿qué puedes concluir?
- ¿Existe alguna relación significativa entre las variables `balance`, `duration`, y `campaign`?
Se recomienda hacer un análisis visual y estadístico de estas variables.

```
# Pregunta 10: Estudio General
# Puedes utilizar técnicas de análisis más avanzadas como correlación, regresión, etc.
cor(bank_data$balance, bank_data$duration, use = "complete.obs")
```

```
[1] 0.02156038
```


```
cor(bank_data$balance, bank_data$campaign, use = "complete.obs")
```

```
[1] -0.01457828
```

```
cor(bank_data$duration, bank_data$campaign, use = "complete.obs")
```

```
[1] -0.0845695
```

```
ggplot(bank_data, aes(x = campaign, y = balance)) +
  geom_point(alpha = 0.5) +
  labs(title = "Relación entre Campañas y Balance",
       x = "Número de Campañas",
       y = "Balance") +
  theme_minimal()
```



Respuesta:

El análisis general de los datos revela varios hallazgos importantes. En cuanto a las relaciones entre variables, las correlaciones son muy débiles: balance vs duration ($r = 0.022$), balance vs campaign ($r = -0.015$), y duration vs campaign ($r = -0.085$). Esto indica que estas tres variables operan de manera relativamente independiente entre sí.

Los factores más asociados al éxito de la campaña son: la duración del contacto emerge como el predictor más fuerte del éxito (conversaciones de ~9 minutos para suscriptores vs ~4 minutos para no suscriptores), el balance muestra una relación positiva pero moderada con la suscripción, y el número de contactos previos tiene una relación débil y negativa.

La segmentación de clientes muestra alta variabilidad en los balances según la ocupación, con jubilados (1,984 €), unknown (1,772 €) y gerentes (1,764 €) como los grupos más prometedores financieramente. La eficiencia de la campaña se caracteriza por contactos mayormente breves y eficientes (1-3 intentos), donde las conversaciones largas están fuertemente asociadas con conversiones exitosas.

En conclusión, el éxito de la campaña depende más de la calidad de la interacción (duración y contenido de la conversación) que de características demográficas o económicas del cliente. Las recomendaciones estratégicas incluyen: priorizar calidad sobre cantidad en los contactos, invertir en conversaciones más largas y detalladas, segmentar audiencias dirigiendo productos premium a ocupaciones con mayor capacidad económica, y limitar contactos repetidos para evitar saturar a clientes que no muestran interés inicial.

Procesado y Limpieza de Datos

```
library(tidyr)
library(dplyr)
```

Ejercicio 1

Crear el siguiente *dataframe* mediante estas instrucciones

```
set.seed(1234)
stocks <- data.frame(time = as.Date("2009-01-01") + 0:9,
                     Walmart = rnorm(10,20,1),
                     Target = rnorm(10,20,2),
                     Walgreens = rnorm(10,20,4)
                     )
stocks
```

	time	Walmart	Target	Walgreens
1	2009-01-01	18.79293	19.04561	20.53635
2	2009-01-02	20.27743	18.00323	18.03726
3	2009-01-03	21.08444	18.44749	18.23781
4	2009-01-04	17.65430	20.12892	21.83836
5	2009-01-05	20.42912	21.91899	17.22512
6	2009-01-06	20.50606	19.77943	14.20718
7	2009-01-07	19.42526	18.97798	22.29902
8	2009-01-08	19.45337	18.17761	15.90538
9	2009-01-09	19.43555	18.32566	19.93945
10	2009-01-10	19.10996	24.83167	16.25621

A continuación, realizar las siguientes operaciones de limpieza de datos:

- Como se puede observar, hay un problema de clave-valor en las compañías con sus observaciones. Por lo tanto, se pide transformar los datos para que tengan una clave “*stock*” y un valor “*precio*”. Utilizar la instrucción “*gather*”.

- Devolver el dataframe al estado original empleando la instrucción *spread*.
- Utilizando el operador tubería `%>%` se desea realizar las siguientes operaciones anidadas:
 - Transformar los datos para que tengan una clave “*stock*” y el valor sea el “*precio*”. Utilizar la instrucción “*gather*”.
 - Agrupar los datos por la clave “*stock*” mediante la instrucción “*group_by*”.
 - Obtener el precio mínimo y el máximo utilizando la instrucción “*summarise*”.

```
# Transformar los datos para que tengan una clave stock y el valor sea el precio.
# Opción 1:
new_stocks <- gather(data = stocks, key = stock, value = price, Walmart, Target, Walgreens)

# Opción 2:
new_stocks <- gather(data = stocks, key = stock, value = price, Walmart:Walgreens)

# Opción 3:
new_stocks <- gather(data = stocks, key = stock, value = price, -time)

# Devolver el dataframe al estado original utilizando la función "spread".
original_stocks <- spread(data = new_stocks, key = stock, value = price)

# Utilizando el operador tubería %>% realizar las operaciones anidadas.
stocks %>%
  gather(key = stock, value = price, Walmart:Walgreens) %>%
  group_by(stock) %>%
  summarise(min = min(price), max = max(price))
```

```
# A tibble: 3 x 3
  stock      min    max
  <chr>    <dbl> <dbl>
1 Target    18.0  24.8
2 Walgreens  14.2  22.3
3 Walmart   17.7  21.1
```

Respuesta:

El ejercicio demuestra tres operaciones fundamentales en la reestructuración de datos con *tidyr*. Primero, la función `gather()` convierte el dataframe de formato ancho a formato largo, transformando las columnas de las tres compañías (Walmart, Target, Walgreens) en dos columnas: una clave llamada “*stock*” que identifica la compañía y otra llamada “*price*” que contiene los valores. Se presentan tres formas equivalentes de realizar esta operación: especificando las columnas explícitamente, usando el operador de rango `:`, o excluyendo columnas con el signo `-`.

Segundo, la función `spread()` realiza la operación inversa, devolviendo el dataframe a su formato ancho original. Esta operación toma la columna clave “stock” y crea una columna separada para cada valor único, rellenándolas con los valores correspondientes de la columna “price”.

Finalmente, el uso del operador tubería `%>%` permite encadenar múltiples operaciones de forma legible. En este caso, se transforma el dataframe a formato largo con `gather()`, se agrupan las observaciones por compañía con `group_by()`, y se calculan estadísticos resumen (precio mínimo y máximo) para cada grupo usando `summarise()`. Esta secuencia de operaciones es típica en el análisis exploratorio de datos y demuestra el poder del enfoque tidyverse para manipulación de datos.

Ejercicio 2

En este ejercicio vamos a manejar datos contenidos en distintos *dataframes* y operar sobre ellos con *dplyr*.

1. Descargar el paquete *nycflights13*.
2. Evaluar el contenido de los dataframes proporcionados por el paquete. Utilizar *head* y *summary*.
3. Simplificar los dataframes originales a 100 observaciones mediante el comando *head*. Asignarlos a una variable que indique el tipo de dataframe añadiendo la coletilla “_simple”. Ejemplo: “flights_simple”.
4. Selecciona los tipos de aerolínea (“carrier”) mediante la instrucción *select* y el operador *unique* concatenados con el operador tubería `%>%`. (Utilizar “airlines_simple”).
5. Obtener la media y el número máximo de asientos (“seats”) que tienen los aviones. Utilizar el operador tubería `%>%` y la instrucción *summarise*.
6. Ordenar los aviones por su número de motores (“engines”) y número de asientos (“seats”). Utilizar la instrucción *arrange*.
7. Averigua qué número de cola (“tailnum”) comparten los dataframes “flights_simple” y “planes_simple” que has creado anteriormente. Obten su aerolínea (“carrier”). Utilizar la instrucción *inner_join*.
8. Cruzar los datos de vuelos (“flights”) con los aviones (“planes”) por el número de cola (“tailnum”) que no coincidan (usar la instrucción *anti_join*). De esos obtener aquellos con 2 o más motores (usar la instrucción *filter*). Finalmente obtener los distintos modelos de avión que satisfacen las premisas anteriores (usar la instrucción *unique*).
9. Crea una nueva variable (“total_delay”) que calcule el retraso total sumando los delays acumulados (“dep_delay”) y (“arr_delay”). Utilizar la instrucción *mutate*. Almacena el dataframe resultante en “flights_total”.
10. En base a la variable anteriormente obtenida (“total_delay”), devuelve los aviones que han llegado con antelación a su destino, es decir aquellos tal que la variable *total_delay* tiene valores negativos.

```
library(dplyr)
library(nycflights13)

# Observamos los distintos dataframes que nos proporcionan
print(head(flights))
```

```
# A tibble: 6 x 19
  year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
  <int> <int> <int>   <int>         <int>         <dbl>   <int>         <int>
1  2013     1     1     517             515           2     830             819
2  2013     1     1     533             529           4     850             830
3  2013     1     1     542             540           2     923             850
4  2013     1     1     544             545          -1    1004            1022
5  2013     1     1     554             600          -6     812             837
6  2013     1     1     554             558          -4     740             728
# i 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
#   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
#   hour <dbl>, minute <dbl>, time_hour <dtm>
```

```
print(head(airports))
```

```
# A tibble: 6 x 8
  faa   name                lat lon alt tz dst tzone
  <chr> <chr>                <dbl> <dbl> <dbl> <dbl> <chr> <chr>
1 04G   Lansdowne Airport      41.1 -80.6 1044 -5 A America/Ne~
2 06A   Moton Field Municipal Airport 32.5 -85.7 264 -6 A America/Ch~
3 06C   Schaumburg Regional      42.0 -88.1 801 -6 A America/Ch~
4 06N   Randall Airport         41.4 -74.4 523 -5 A America/Ne~
5 09J   Jekyll Island Airport    31.1 -81.4 11 -5 A America/Ne~
6 0A9   Elizabethton Municipal Airport 36.4 -82.2 1593 -5 A America/Ne~
```

```
print(head(weather))
```

```
# A tibble: 6 x 15
  origin year month   day hour temp dewp humid wind_dir wind_speed wind_gust
  <chr>   <int> <int> <int> <int> <dbl> <dbl> <dbl>   <dbl>    <dbl>    <dbl>
1 EWR    2013     1     1     1 39.0 26.1 59.4    270     10.4      NA
2 EWR    2013     1     1     2 39.0 27.0 61.6    250      8.06     NA
3 EWR    2013     1     1     3 39.0 28.0 64.4    240     11.5      NA
4 EWR    2013     1     1     4 39.9 28.0 62.2    250     12.7      NA
```

```

5 EWR      2013      1      1      5 39.0 28.0 64.4      260      12.7      NA
6 EWR      2013      1      1      6 37.9 28.0 67.2      240      11.5      NA
# i 4 more variables: precip <dbl>, pressure <dbl>, visib <dbl>,
#   time_hour <dtm>

```

```
print(head(airlines))
```

```

# A tibble: 6 x 2
  carrier name
  <chr>   <chr>
1 9E      Endeavor Air Inc.
2 AA      American Airlines Inc.
3 AS      Alaska Airlines Inc.
4 B6      JetBlue Airways
5 DL      Delta Air Lines Inc.
6 EV      ExpressJet Airlines Inc.

```

```
print(head(planes))
```

```

# A tibble: 6 x 9
  tailnum year type      manufacturer model engines seats speed engine
  <chr>   <int> <chr>      <chr>          <chr>   <int> <int> <int> <chr>
1 N10156  2004 Fixed wing multi ~ EMBRAER      EMB~      2    55    NA Turbo~
2 N102UW  1998 Fixed wing multi ~ AIRBUS      INDU~    2   182    NA Turbo~
3 N103US  1999 Fixed wing multi ~ AIRBUS      INDU~    2   182    NA Turbo~
4 N104UW  1999 Fixed wing multi ~ AIRBUS      INDU~    2   182    NA Turbo~
5 N10575  2002 Fixed wing multi ~ EMBRAER      EMB~      2    55    NA Turbo~
6 N105UW  1999 Fixed wing multi ~ AIRBUS      INDU~    2   182    NA Turbo~

```

```

# Comprobamos las variables mediante summary
print(summary(flights))

```

	year	month	day	dep_time	sched_dep_time
Min.	:2013	Min. : 1.000	Min. : 1.00	Min. : 1	Min. : 106
1st Qu.:	:2013	1st Qu.: 4.000	1st Qu.: 8.00	1st Qu.: 907	1st Qu.: 906
Median	:2013	Median : 7.000	Median :16.00	Median :1401	Median :1359
Mean	:2013	Mean : 6.549	Mean :15.71	Mean :1349	Mean :1344
3rd Qu.:	:2013	3rd Qu.:10.000	3rd Qu.:23.00	3rd Qu.:1744	3rd Qu.:1729
Max.	:2013	Max. :12.000	Max. :31.00	Max. :2400	Max. :2359
				NA's :8255	

dep_delay	arr_time	sched_arr_time	arr_delay
Min. : -43.00	Min. : 1	Min. : 1	Min. : -86.000
1st Qu.: -5.00	1st Qu.:1104	1st Qu.:1124	1st Qu.: -17.000
Median : -2.00	Median :1535	Median :1556	Median : -5.000
Mean : 12.64	Mean :1502	Mean :1536	Mean : 6.895
3rd Qu.: 11.00	3rd Qu.:1940	3rd Qu.:1945	3rd Qu.: 14.000
Max. :1301.00	Max. :2400	Max. :2359	Max. :1272.000
NA's :8255	NA's :8713		NA's :9430

carrier	flight	tailnum	origin
Length:336776	Min. : 1	Length:336776	Length:336776
Class :character	1st Qu.: 553	Class :character	Class :character
Mode :character	Median :1496	Mode :character	Mode :character
	Mean :1972		
	3rd Qu.:3465		
	Max. :8500		

dest	air_time	distance	hour
Length:336776	Min. : 20.0	Min. : 17	Min. : 1.00
Class :character	1st Qu.: 82.0	1st Qu.: 502	1st Qu.: 9.00
Mode :character	Median :129.0	Median : 872	Median :13.00
	Mean :150.7	Mean :1040	Mean :13.18
	3rd Qu.:192.0	3rd Qu.:1389	3rd Qu.:17.00
	Max. :695.0	Max. :4983	Max. :23.00
	NA's :9430		

minute	time_hour
Min. : 0.00	Min. :2013-01-01 05:00:00.00
1st Qu.: 8.00	1st Qu.:2013-04-04 13:00:00.00
Median :29.00	Median :2013-07-03 10:00:00.00
Mean :26.23	Mean :2013-07-03 05:22:54.64
3rd Qu.:44.00	3rd Qu.:2013-10-01 07:00:00.00
Max. :59.00	Max. :2013-12-31 23:00:00.00

```
print(summary(airports))
```

faa	name	lat	lon
Length:1458	Length:1458	Min. :19.72	Min. : -176.65
Class :character	Class :character	1st Qu.:34.26	1st Qu.: -119.19
Mode :character	Mode :character	Median :40.09	Median : -94.66
		Mean :41.65	Mean : -103.39
		3rd Qu.:45.07	3rd Qu.: -82.52
		Max. :72.27	Max. : 174.11

alt	tz	dst	tzzone
Min. : -54.00	Min. : -10.000	Length:1458	Length:1458
1st Qu.: 70.25	1st Qu.: -8.000	Class :character	Class :character
Median : 473.00	Median : -6.000	Mode :character	Mode :character
Mean :1001.42	Mean : -6.519		
3rd Qu.:1062.50	3rd Qu.: -5.000		
Max. :9078.00	Max. : 8.000		

```
print(summary(weather))
```

origin	year	month	day
Length:26115	Min. :2013	Min. : 1.000	Min. : 1.00
Class :character	1st Qu.:2013	1st Qu.: 4.000	1st Qu.: 8.00
Mode :character	Median :2013	Median : 7.000	Median :16.00
	Mean :2013	Mean : 6.504	Mean :15.68
	3rd Qu.:2013	3rd Qu.: 9.000	3rd Qu.:23.00
	Max. :2013	Max. :12.000	Max. :31.00

hour	temp	dewp	humid
Min. : 0.00	Min. : 10.94	Min. : -9.94	Min. : 12.74
1st Qu.: 6.00	1st Qu.: 39.92	1st Qu.:26.06	1st Qu.: 47.05
Median :11.00	Median : 55.40	Median :42.08	Median : 61.79
Mean :11.49	Mean : 55.26	Mean :41.44	Mean : 62.53
3rd Qu.:17.00	3rd Qu.: 69.98	3rd Qu.:57.92	3rd Qu.: 78.79
Max. :23.00	Max. :100.04	Max. :78.08	Max. :100.00
	NA's :1	NA's :1	NA's :1

wind_dir	wind_speed	wind_gust	precip
Min. : 0.0	Min. : 0.000	Min. :16.11	Min. :0.000000
1st Qu.:120.0	1st Qu.: 6.905	1st Qu.:20.71	1st Qu.:0.000000
Median :220.0	Median : 10.357	Median :24.17	Median :0.000000
Mean :199.8	Mean : 10.518	Mean :25.49	Mean :0.004469
3rd Qu.:290.0	3rd Qu.: 13.809	3rd Qu.:28.77	3rd Qu.:0.000000
Max. :360.0	Max. :1048.361	Max. :66.75	Max. :1.210000
NA's :460	NA's :4	NA's :20778	

pressure	visib	time_hour
Min. : 983.8	Min. : 0.000	Min. :2013-01-01 01:00:00.0
1st Qu.:1012.9	1st Qu.:10.000	1st Qu.:2013-04-01 21:30:00.0
Median :1017.6	Median :10.000	Median :2013-07-01 14:00:00.0
Mean :1017.9	Mean : 9.255	Mean :2013-07-01 18:26:37.7
3rd Qu.:1023.0	3rd Qu.:10.000	3rd Qu.:2013-09-30 13:00:00.0
Max. :1042.1	Max. :10.000	Max. :2013-12-30 18:00:00.0
NA's :2729		

```
print(summary(airlines))
```

```
   carrier      name
Length:16   Length:16
Class :character Class :character
Mode  :character Mode  :character
```

```
print(summary(planes))
```

```
   tailnum      year      type      manufacturer
Length:3322   Min.   :1956   Length:3322   Length:3322
Class :character 1st Qu.:1997   Class :character  Class :character
Mode  :character Median :2001   Mode  :character  Mode  :character
               Mean  :2000
               3rd Qu.:2005
               Max.   :2013
               NA's   :70

   model      engines      seats      speed
Length:3322   Min.   :1.000   Min.    : 2.0   Min.    : 90.0
Class :character 1st Qu.:2.000   1st Qu.:140.0   1st Qu.:107.5
Mode  :character Median :2.000   Median :149.0   Median :162.0
               Mean  :1.995   Mean   :154.3   Mean   :236.8
               3rd Qu.:2.000   3rd Qu.:182.0   3rd Qu.:432.0
               Max.   :4.000   Max.    :450.0   Max.    :432.0
               NA's   :3299

   engine
Length:3322
Class :character
Mode  :character
```

Respuesta:

El paquete `nycflights13` proporciona cinco dataframes relacionados con vuelos que salieron de los aeropuertos de Nueva York en 2013. El dataframe `flights` contiene 336,776 observaciones con información sobre cada vuelo, incluyendo fecha, hora, aerolíneas, origen, destino y retrasos. `airports` contiene información sobre 1,458 aeropuertos incluyendo códigos, nombres y ubicaciones geográficas. `weather` proporciona 26,115 observaciones meteorológicas horarias

de los tres aeropuertos de origen. `airlines` es un pequeño dataframe con 16 aerolíneas y sus nombres completos. Finalmente, `planes` contiene información sobre 3,322 aviones, incluyendo fabricante, modelo, año de fabricación y características técnicas como número de asientos y motores. Estos dataframes están relacionados entre sí mediante claves como `tailnum` (número de cola del avión) y `carrier` (código de aerolínea), lo que permite realizar análisis complejos combinando múltiples fuentes de información.

```
# Simplificar los dataframes originales a 100 observaciones
flights_simple <- head(flights, 100)
airports_simple <- head(airports, 100)
weather_simple <- head(weather, 100)
airlines_simple <- head(airlines, 100)
planes_simple <- head(planes, 100)

# Selecciona los tipos de aerolínea
airlines_simple %>% unique %>% select(carrier)
```

```
# A tibble: 16 x 1
  carrier
  <chr>
1 9E
2 AA
3 AS
4 B6
5 DL
6 EV
7 F9
8 FL
9 HA
10 MQ
11 OO
12 UA
13 US
14 VX
15 WN
16 YV
```

Respuesta:

La simplificación de los dataframes a 100 observaciones facilita el trabajo exploratorio sin comprometer la comprensión de la estructura de datos. Al seleccionar los tipos de aerolínea del dataframe `airlines_simple` usando el operador tubería, obtenemos una lista de códigos

de aerolínea únicos. El uso de `unique()` elimina cualquier duplicado que pudiera existir, mientras que `select(carrier)` extrae únicamente la columna de interés. Esta combinación de operaciones es eficiente y legible, demostrando el estilo declarativo de programación que promueve dplyr.

```
# Obtener la media y el máximo de asientos
planes_simple %>% summarise(mean = mean(seats), max_engines = max(seats))
```

```
# A tibble: 1 x 2
  mean max_engines
  <dbl>      <int>
1  105.         330
```

Respuesta:

El análisis de la capacidad de asientos en los aviones revela estadísticos importantes sobre la flota. La función `summarise()` reduce el dataframe a una única fila conteniendo la media y el máximo de asientos. Esto permite identificar tanto la capacidad promedio de los aviones en el conjunto de datos como el avión de mayor capacidad. Esta información es valiosa para comprender la composición de la flota y puede influir en decisiones operativas relacionadas con la asignación de aviones a rutas específicas según la demanda esperada.

```
# Ordenar los aviones por número de motores y número de asientos
result1 <- arrange(planes_simple, engines, seats)
print(result1)
```

```
# A tibble: 100 x 9
  tailnum year type      manufacturer model engines seats speed engine
  <chr>   <int> <chr>      <chr>          <chr>   <int> <int> <int> <chr>
1 N10156  2004 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
2 N10575  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
3 N11106  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
4 N11107  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
5 N11109  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
6 N11113  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
7 N11119  2002 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
8 N11121  2003 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
9 N11127  2003 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
10 N11137 2003 Fixed wing multi~ EMBRAER    EMB--      2    55    NA Turbo~
# i 90 more rows
```

Respuesta:

La función `arrange()` ordena el dataframe de aviones primero por número de motores y luego, dentro de cada grupo de motores, por número de asientos en orden ascendente. Esta ordenación revela la relación entre la complejidad técnica del avión (número de motores) y su capacidad (número de asientos). Típicamente, los aviones con menos asientos tienen menos motores, y conforme aumenta la capacidad, se requieren configuraciones con más motores para proporcionar la potencia necesaria. Este ordenamiento facilita la identificación de patrones en el diseño y capacidades de diferentes modelos de aeronaves.

```
# Averigua qué número de cola comparten los dataframes
shared <- inner_join(flights_simple, planes_simple, by = "tailnum")
shared_carrier <- shared$carrier
print(shared_carrier)
```

```
[1] "EV"
```

Respuesta:

La función `inner_join()` combina los dataframes `flights_simple` y `planes_simple` usando el número de cola (`tailnum`) como clave de unión, devolviendo únicamente las filas donde existe coincidencia en ambos dataframes. Esto permite identificar qué aviones del registro de vuelos tienen información técnica disponible en el dataframe de aviones. Al extraer la columna `carrier`, obtenemos las aerolíneas que operaron estos vuelos específicos. Esta operación es fundamental en análisis de datos relacionales, donde diferentes tablas contienen información complementaria sobre las mismas entidades y se requiere combinarlas para obtener un panorama completo.

```
# Cruzar datos que no coincidan
fp <- anti_join(planes_simple, flights_simple, by = "tailnum")
engines_fp <- filter(fp, engines >= 2)
result2 <- unique(engines_fp$model)
print(result2)
```

```
[1] "EMB-145XR" "A320-214" "EMB-145LR" "737-824" "767-332" "757-224"
```

Respuesta:

La operación `anti_join()` identifica aviones en `planes_simple` que no tienen vuelos correspondientes en `flights_simple`, es decir, aviones registrados que no aparecen en los primeros 100 vuelos analizados. Posteriormente, se filtran aquellos con 2 o más motores, típicamente aviones de mayor tamaño o alcance. Finalmente, se extraen los modelos únicos que satisfacen

estas condiciones. Esta secuencia de operaciones es útil para análisis de utilización de flota, permitiendo identificar qué aviones con ciertas características técnicas no están siendo utilizados o no aparecen en el período analizado, lo cual podría indicar aviones en mantenimiento, reserva, o asignados a otras rutas no capturadas en la muestra.

```
# Crear nueva variable de retraso total
flights_total <- mutate(flights_simple, total_delay = dep_delay + arr_delay)

# Devolver aviones que llegaron con antelación
filter(flights_total, total_delay < 0)
```

```
# A tibble: 57 x 20
  year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
  <int> <int> <int>   <int>         <int>         <dbl>   <int>         <int>
1  2013     1     1     544             545         -1     1004           1022
2  2013     1     1     554             600         -6       812           837
3  2013     1     1     557             600         -3       709           723
4  2013     1     1     557             600         -3       838           846
5  2013     1     1     558             600         -2       849           851
6  2013     1     1     558             600         -2       853           856
7  2013     1     1     558             600         -2       923           937
8  2013     1     1     559             559          0       702           706
9  2013     1     1     559             600         -1       854           902
10 2013     1     1     600             600          0       851           858
# i 47 more rows
# i 12 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
#   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
#   hour <dbl>, minute <dbl>, time_hour <dtm>, total_delay <dbl>
```

Respuesta:

La función `mutate()` crea una nueva columna `total_delay` que suma los retrasos de salida (`dep_delay`) y llegada (`arr_delay`), proporcionando una medida agregada del retraso acumulado durante todo el trayecto del vuelo. Valores positivos indican retraso total, mientras que valores negativos indican que el vuelo llegó antes de lo programado. Al filtrar por `total_delay < 0`, se identifican vuelos que, a pesar de cualquier retraso en la salida, lograron recuperar tiempo durante el vuelo y llegar anticipadamente a su destino. Esto puede ocurrir cuando los pilotos compensan retrasos iniciales aumentando la velocidad de crucero cuando las condiciones lo permiten, o cuando el tiempo de vuelo programado incluye márgenes de seguridad que no siempre se utilizan completamente. Estos casos son de interés para el análisis de eficiencia operativa y satisfacción del cliente.

Contrastes de Hipótesis

Ejercicio 1: Conceptos Básicos

Define los conceptos básicos de un contraste de hipótesis: hipótesis nula (H_0), hipótesis alternativa (H_1), nivel de significación (α), región de rechazo y valor crítico.

Solución:

En un contraste de hipótesis, se evalúa una afirmación sobre una población a partir de datos muestrales. Los conceptos básicos que se utilizan son los siguientes:

Hipótesis Nula (H_0): La hipótesis nula (H_0) es una afirmación sobre el parámetro de la población que se asume verdadera hasta que se demuestre lo contrario. Generalmente, H_0 representa una situación de “no efecto” o “no diferencia”. Es la hipótesis que se pretende refutar. Por ejemplo, H_0 podría afirmar que la media poblacional μ es igual a un valor específico.

Hipótesis Alternativa (H_1): La hipótesis alternativa (H_1) es una afirmación que se acepta si los datos muestrales proporcionan suficiente evidencia para rechazar la hipótesis nula. H_1 representa una situación de “efecto” o “diferencia”. Puede ser una hipótesis unilateral (por ejemplo, $\mu > 0$ o $\mu < 0$) o bilateral (por ejemplo, $\mu \neq 0$).

Nivel de Significación (α): El nivel de significación (α) es la probabilidad de cometer un error tipo I, que es rechazar la hipótesis nula cuando en realidad es verdadera. Es un umbral predefinido que determina la sensibilidad del contraste de hipótesis. Comúnmente, se usan niveles de significación como $\alpha = 0.05$, $\alpha = 0.01$ o $\alpha = 0.10$. Un α de 0.05 indica una probabilidad del 5% de rechazar H_0 incorrectamente.

Región de Rechazo: La región de rechazo es el conjunto de valores de la estadística de prueba para los cuales se rechaza la hipótesis nula. Depende del nivel de significación y de la distribución de la estadística de prueba bajo H_0 . Si la estadística de prueba cae dentro de esta región, se considera que los datos muestrales proporcionan suficiente evidencia para rechazar H_0 .

Valor Crítico: El valor crítico es el límite que separa la región de rechazo del resto de la distribución de la estadística de prueba. Se determina en función del nivel de significación α y de la distribución de la estadística de prueba bajo H_0 . En una prueba unilateral, hay un único valor crítico, mientras que en una prueba bilateral hay dos valores críticos (uno en cada extremo de la distribución).

Ejemplo de Conceptos Aplicados: Supongamos que queremos probar si la media poblacional μ es igual a 50 con un nivel de significación $\alpha = 0.05$. **Hipótesis Nula (H_0):** $\mu = 50$. **Hipótesis Alternativa (H_1):** $\mu \neq 50$ (contraste bilateral). **Nivel de Significación (α):** 0.05. **Región de Rechazo:** Para un contraste bilateral con $\alpha = 0.05$, la región de rechazo estará en los extremos de la distribución de la estadística de prueba (por ejemplo, los valores de z mayores que $z_{0.025}$ o menores que $-z_{0.025}$, donde $z_{0.025}$ corresponde al valor crítico de la distribución normal estándar que deja un 2.5% de probabilidad en cada cola). **Valor Crítico:** Para una prueba z , los valores críticos serían ± 1.96 (aproximadamente) porque $P(Z > 1.96) = 0.025$ y $P(Z < -1.96) = 0.025$.

Si la estadística de prueba calculada a partir de los datos muestrales cae en la región de rechazo (es decir, es mayor que 1.96 o menor que -1.96), rechazamos H_0 . Si no cae en la región de rechazo, no rechazamos H_0 .

Ejercicio 2: Pasos en un Contraste de Hipótesis

Describe los pasos necesarios para realizar un contraste de hipótesis. Ilustra estos pasos con un ejemplo simple en el que se quiera comprobar si la media de una muestra es igual a un valor específico.

Solución:

Para realizar un contraste de hipótesis, se siguen los siguientes pasos:

1. **Formular las Hipótesis:** **Hipótesis Nula (H_0):** Es la hipótesis que se presume cierta hasta que se demuestre lo contrario. **Hipótesis Alternativa (H_1):** Es la hipótesis que se acepta si la evidencia sugiere que H_0 es falsa.
2. **Elegir el Nivel de Significación (α):** α es la probabilidad de cometer un error tipo I (rechazar H_0 cuando es verdadera). Comúnmente, $\alpha = 0.05$.
3. **Seleccionar la Estadística de Prueba:** Dependiendo del tipo de hipótesis y de los datos, se selecciona la estadística adecuada (por ejemplo, z para una distribución normal con varianza conocida, t para varianza desconocida).
4. **Calcular la Estadística de Prueba:** Utilizar los datos muestrales para calcular el valor de la estadística de prueba.
5. **Determinar la Región de Rechazo:** Con base en α y la distribución de la estadística de prueba, determinar los valores críticos y la región de rechazo.
6. **Tomar una Decisión:** Comparar el valor de la estadística de prueba con los valores críticos para decidir si se rechaza o no H_0 .
7. **Conclusión:** Interpretar los resultados en el contexto del problema original.

Ejemplo - Comprobar si la Media de una Muestra es Igual a un Valor Específico: Supongamos que queremos comprobar si la media de una población es igual a 50. Tenemos una muestra de tamaño $n = 30$, con una media muestral de $\bar{x} = 52$ y una desviación estándar conocida de $\sigma = 5$.

Paso 1 - Formular las Hipótesis: Hipótesis Nula (H_0): $\mu = 50$. Hipótesis Alternativa (H_1): $\mu \neq 50$ (contraste bilateral).

Paso 2 - Elegir el Nivel de Significación: $\alpha = 0.05$.

Paso 3 - Seleccionar la Estadística de Prueba: Dado que la varianza es conocida y la muestra es suficientemente grande, utilizamos la estadística z :

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

Paso 4 - Calcular la Estadística de Prueba:

$$z = \frac{52 - 50}{5/\sqrt{30}} \approx 2.19$$

Paso 5 - Determinar la Región de Rechazo: Para $\alpha = 0.05$ en una prueba bilateral, los valores críticos $z_{0.025}$ son aproximadamente ± 1.96 .

Paso 6 - Tomar una Decisión: Comparamos el valor de z calculado con los valores críticos. El valor $z = 2.19$ es mayor que 1.96, por lo que cae en la región de rechazo.

Paso 7 - Conclusión: Decisión: Rechazamos la hipótesis nula H_0 . Interpretación: Hay suficiente evidencia para concluir que la media poblacional es diferente de 50 al nivel de significación $\alpha = 0.05$.

Ejercicio 3: Errores tipo I y tipo II. Potencia

Explica la diferencia entre los errores tipo I y tipo II en un contraste de hipótesis. ¿Qué es la potencia de un test? Calcula la probabilidad de cometer un error tipo I (α) y un error tipo II (β) en un contraste de hipótesis dado.

Solución:

En un contraste de hipótesis, existen dos tipos de errores que se pueden cometer:

Error Tipo I (α): Es el error que se comete al rechazar la hipótesis nula (H_0) cuando en realidad es verdadera. La probabilidad de cometer un error tipo I es denotada por α , y se establece como el nivel de significación del test. Es decir, α es la probabilidad de rechazar H_0 incorrectamente. Si se fija $\alpha = 0.05$, significa que hay un 5% de riesgo de concluir que H_0 es falsa cuando en realidad es verdadera.

Error Tipo II (β): Es el error que se comete al no rechazar la hipótesis nula (H_0) cuando en realidad es falsa. La probabilidad de cometer un error tipo II es denotada por β . β representa la probabilidad de no detectar un efecto o diferencia cuando realmente existe.

Potencia de un Test: La potencia de un test es la probabilidad de rechazar H_0 cuando H_0 es falsa. Es decir, es la probabilidad de detectar un efecto o diferencia cuando realmente existe. La potencia se denota por $1 - \beta$. A mayor potencia, mayor capacidad del test para detectar un efecto real.

Cálculo de α y β en un Contraste de Hipótesis Dado: Supongamos un ejemplo donde se quiere contrastar la media poblacional μ con el valor 50 utilizando una muestra de tamaño $n = 30$, una desviación estándar conocida $\sigma = 5$, y un nivel de significación $\alpha = 0.05$.

Datos: $\mu_0 = 50$ (hipótesis nula), $\mu_1 = 52$ (hipótesis alternativa específica), $\sigma = 5$, $n = 30$, $\alpha = 0.05$.

Paso 1 - Determinar los valores críticos: Para $\alpha = 0.05$ (contraste bilateral):

$$z_{\alpha/2} = \pm 1.96$$

Paso 2 - Calcular los límites de la región de rechazo: Para $\alpha = 0.05$ y una media $\mu_0 = 50$:

$$\text{Límite inferior} = \mu_0 - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \approx 48.21$$

$$\text{Límite superior} = \mu_0 + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \approx 51.79$$

Paso 3 - Calcular β : Supongamos que la verdadera media poblacional es $\mu_1 = 52$. Calculamos la probabilidad de que la media muestral caiga en la región de no rechazo (48.21, 51.79) cuando la media real es 52: $z_1 = \frac{48.21-52}{5/\sqrt{30}} \approx -4.15$ $z_2 = \frac{51.79-52}{5/\sqrt{30}} \approx -0.23$

La probabilidad de que Z esté entre -4.15 y -0.23 es: $\beta = P(-4.15 < Z < -0.23) = P(Z < -0.23) - P(Z < -4.15) \approx 0.409 - 0 = 0.409$. Por lo tanto, $\beta \approx 0.41$.

Paso 4 - Calcular la Potencia del Test: $\$ \text{Potencia} = 1 - \beta = 1 - 0.41 = 0.59 \$$

Resumen: Error Tipo I (α): En este ejemplo, α es predefinido como 0.05, lo que significa que hay un 5% de probabilidad de rechazar H_0 cuando es verdadera. Error Tipo II (β): Calculado como 0.41, lo que significa que hay un 41% de probabilidad de no rechazar H_0 cuando $\mu = 52$. Potencia del Test: Calculada como 0.59, lo que significa que hay un 59% de probabilidad de rechazar H_0 cuando $\mu = 52$.

Ejercicio 4: Contraste para la media de una población normal con varianza conocida

Se tiene una muestra de tamaño $n = 30$ con una media muestral de $\bar{x} = 50$ y una varianza conocida de $\sigma^2 = 25$. Realiza un contraste de hipótesis para verificar si la media poblacional es 52 con un nivel de significación $\alpha = 0.05$.

Solución:

Datos: Tamaño de la muestra (n) = 30, media muestral ($\bar{x}$) = 50, varianza poblacional (σ^2) = 25 (desviación estándar $\sigma = 5$), media poblacional bajo H_0 (μ_0) = 52, nivel de significación (α) = 0.05.

Paso 1 - Formular las Hipótesis: Hipótesis Nula (H_0): $\mu = 52$. Hipótesis Alternativa (H_1): $\mu \neq 52$ (contraste bilateral).

Paso 2 - Elegir el Nivel de Significación: $\alpha = 0.05$.

Paso 3 - Seleccionar la Estadística de Prueba: Como la varianza es conocida, utilizamos la estadística z :

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

Paso 4 - Calcular la Estadística de Prueba:

$$z = \frac{50 - 52}{5/\sqrt{30}} \approx -2.19$$

Paso 5 - Determinar la Región de Rechazo: Para un nivel de significación $\alpha = 0.05$ en una prueba bilateral, los valores críticos son:

$$z_{\alpha/2} = \pm 1.96$$

. La región de rechazo son los valores de z que son menores que -1.96 o mayores que 1.96 .

Paso 6 - Tomar una Decisión: Comparamos el valor calculado de z con los valores críticos. Valor calculado: $z = -2.19$. Valores críticos: -1.96 y 1.96 . Dado que -2.19 es menor que -1.96 , el valor de z cae en la región de rechazo.

Paso 7 - Conclusión: Decisión: Rechazamos la hipótesis nula H_0 . Interpretación: Hay suficiente evidencia para concluir que la media poblacional es diferente de 52 al nivel de significación $\alpha = 0.05$.

Ejercicio 5: Contraste para la media de una población normal con varianza desconocida

Una muestra de tamaño $n = 20$ tiene una media muestral de $\bar{x} = 30$ y una desviación estándar muestral de $s = 5$. Realiza un contraste de hipótesis para probar si la media poblacional es diferente de 32 con un nivel de significación $\alpha = 0.01$.

Solución:

Paso 1 - Plantear las hipótesis: Hipótesis nula (H_0): $\mu = 32$. Hipótesis alternativa (H_1): $\mu \neq 32$.

Paso 2 - Seleccionar el nivel de significación: $\alpha = 0.01$.

Paso 3 - Calcular el estadístico de prueba: Usaremos el estadístico t para muestras pequeñas cuando la desviación estándar poblacional no es conocida:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

. Sustituyendo los valores: $\bar{x} = 30$, $\mu_0 = 32$, $s = 5$, $n = 20$:

$$t = \frac{30 - 32}{5/\sqrt{20}} \approx -1.79$$

Paso 4 - Determinar los grados de libertad y el valor crítico: Los grados de libertad (df) se calculan como $df = n - 1 = 19$. Para $\alpha = 0.01$, el valor crítico t_c es aproximadamente ± 2.861 (usando una tabla de valores críticos de t-Student o una calculadora estadística).

Paso 5 - Tomar una decisión: Comparamos el valor absoluto del estadístico de prueba con el valor crítico. Si $|t| > t_c$, rechazamos H_0 . Si $|t| \leq t_c$, no rechazamos H_0 . En este caso: $|t| = 1.79$, $t_c = 2.861$. Dado que $|t| < t_c$, no rechazamos H_0 .

Conclusión: Con un nivel de significación $\alpha = 0.01$, no hay suficiente evidencia para rechazar la hipótesis nula. Esto significa que no podemos concluir que la media poblacional sea diferente de 32.

Ejercicio 6: Contraste de hipótesis para la igualdad de medias de dos muestras independientes

Se tienen dos muestras independientes: Muestra A: $x_A = \{23, 21, 22, 24, 25, 23, 24, 22, 23, 24\}$. Muestra B: $x_B = \{18, 19, 17, 20, 18, 19, 18, 19, 20, 18\}$. Realiza un contraste de hipótesis para verificar si las medias de las dos poblaciones son diferentes con un nivel de significación $\alpha = 0.05$.

Solución:

Paso 1 - Plantear las hipótesis: Hipótesis nula (H_0): $\mu_A = \mu_B$ (las medias de las dos poblaciones son iguales). Hipótesis alternativa (H_1): $\mu_A \neq \mu_B$ (las medias de las dos poblaciones son diferentes).

Paso 2 - Seleccionar el nivel de significación: $\alpha = 0.05$.

Paso 3 - Calcular las estadísticas muestrales: Muestra A: $x_A = \{23, 21, 22, 24, 25, 23, 24, 22, 23, 24\}$. $\bar{x}_A = 23.1$, $s_A = 1.197$. Muestra B: $x_B = \{18, 19, 17, 20, 18, 19, 18, 19, 20, 18\}$. $\bar{x}_B = 18.6$, $s_B = 0.966$.

Paso 4 - Calcular el estadístico de prueba: Usaremos el estadístico t para comparar las medias de dos muestras independientes:

$$t = \frac{\bar{x}_A - \bar{x}_B}{\sqrt{\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}}}$$

Paso 5 - Determinar los grados de libertad: Los grados de libertad se pueden aproximar usando la fórmula de Welch-Satterthwaite:

$$df \approx \frac{\left(\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}\right)^2}{\frac{\left(\frac{s_A^2}{n_A}\right)^2}{n_A - 1} + \frac{\left(\frac{s_B^2}{n_B}\right)^2}{n_B - 1}}$$

Paso 6 - Tomar una decisión: Comparamos el valor absoluto del estadístico de prueba con el valor crítico. Si $|t| > t_c$, rechazamos H_0 . Si $|t| \leq t_c$, no rechazamos H_0 .

Resultados: Estadístico de prueba: $t = 9.25$. Grados de libertad (aproximados): $df \approx 17.23$. Valor crítico para $\alpha = 0.05$ en una prueba bilateral: $t_c = 2.108$.

Decisión: Comparando: $|t| = 9.25$, $t_c = 2.108$. Dado que $|t| > t_c$, rechazamos H_0 .

Conclusión: Con un nivel de significación $\alpha = 0.05$, hay suficiente evidencia para rechazar la hipótesis nula. Esto significa que podemos concluir que las medias de las dos poblaciones son significativamente diferentes.

Ejercicio 7: Contraste de hipótesis para la diferencia de proporciones

En un estudio se observa que de 200 hombres, 130 prefieren el producto A, mientras que de 250 mujeres, 140 prefieren el mismo producto. Realiza un contraste de hipótesis para determinar si existe una diferencia significativa en las proporciones de hombres y mujeres que prefieren el producto A con un nivel de significación $\alpha = 0.05$.

Solución:

Paso 1 - Plantear las hipótesis: Hipótesis nula (H_0): $p_1 = p_2$ (no hay diferencia en las proporciones de hombres y mujeres que prefieren el producto A). Hipótesis alternativa (H_1): $p_1 \neq p_2$ (hay una diferencia en las proporciones). Donde p_1 es la proporción de hombres y p_2 es la proporción de mujeres que prefieren el producto A.

Paso 2 - Seleccionar el nivel de significación: $\alpha = 0.05$.

Paso 3 - Calcular las proporciones muestrales: $n_1 = 200$, $x_1 = 130$, $\hat{p}_1 = \frac{130}{200} = 0.65$. $n_2 = 250$, $x_2 = 140$, $\hat{p}_2 = \frac{140}{250} = 0.56$.

Paso 4 - Calcular el estadístico de prueba:

$$z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1 - \hat{p}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

. Donde $\hat{p}$ es la proporción combinada:

$$\hat{p} = \frac{x_1 + x_2}{n_1 + n_2} = \frac{130 + 140}{200 + 250} = 0.6$$

Paso 5 - Determinar el valor crítico: Para $\alpha = 0.05$ en una prueba bilateral, el valor crítico z_c es aproximadamente ± 1.96 .

Paso 6 - Tomar una decisión: Comparamos el valor absoluto del estadístico de prueba con el valor crítico. Si $|z| > z_c$, rechazamos H_0 . Si $|z| \leq z_c$, no rechazamos H_0 .

Resultados: Proporciones muestrales: $\hat{p}_1 = 0.65$, $\hat{p}_2 = 0.56$. Proporción combinada: $\hat{p} = 0.6$. Estadístico de prueba: $z = 1.94$. Valor crítico: $z_c = 1.96$.

Decisión: Comparando: $|z| = 1.94$, $z_c = 1.96$. Dado que $|z| < z_c$, no rechazamos H_0 .

Conclusión: Con un nivel de significación $\alpha = 0.05$, no hay suficiente evidencia para rechazar la hipótesis nula. Esto significa que no podemos concluir que existe una diferencia significativa en las proporciones de hombres y mujeres que prefieren el producto A.

Ejercicio 8: Aplicación en un contexto real

Un fabricante afirma que el peso medio de sus paquetes de galletas es 500 gramos. Una muestra de 40 paquetes tiene una media de 495 gramos y una desviación estándar de 10 gramos. Realiza un contraste de hipótesis para comprobar la afirmación del fabricante con un nivel de significación $\alpha = 0.01$.

Solución:

Paso 1 - Plantear las hipótesis: Hipótesis nula (H_0): $\mu = 500$ gramos (el peso medio es 500 gramos). Hipótesis alternativa (H_1): $\mu \neq 500$ gramos (el peso medio es diferente de 500 gramos).

Paso 2 - Seleccionar el nivel de significación: $\alpha = 0.01$.

Paso 3 - Calcular el estadístico de prueba: Utilizamos el estadístico t para muestras grandes ($n > 30$):

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

. Sustituyendo los valores: $\bar{x} = 495$, $\mu_0 = 500$, $s = 10$, $n = 40$:

$$t = \frac{495 - 500}{10/\sqrt{40}} = \frac{-5}{10/6.32} \approx -3.16$$

Paso 4 - Determinar el valor crítico: Para $\alpha = 0.01$ en una prueba bilateral en la distribución t de Student con $df = 39$, el valor crítico t_c es aproximadamente ± 2.708 .

Paso 5 - Tomar una decisión: Comparamos el valor absoluto del estadístico de prueba con el valor crítico. Si $|t| > t_c$, rechazamos H_0 . Si $|t| \leq t_c$, no rechazamos H_0 . En este caso: $|t| = 3.16$, $t_c = 2.708$. Dado que $|t| > t_c$, rechazamos H_0 .

Conclusión: Con un nivel de significación $\alpha = 0.01$, hay suficiente evidencia para rechazar la hipótesis nula. Esto significa que podemos concluir que el peso medio de los paquetes de galletas es significativamente diferente de 500 gramos.

Ejercicio 9: Prueba t de Student

Se tiene una muestra de tamaño $n = 25$ de una población normal con una media muestral de $\bar{x} = 20$ y una desviación estándar muestral de $s = 4$. Realiza un contraste de hipótesis para probar si la media poblacional es mayor que 18 con un nivel de significación $\alpha = 0.05$.

Solución:

Paso 1 - Plantear las hipótesis: Hipótesis nula (H_0): $\mu \leq 18$ (la media poblacional es menor o igual a 18). Hipótesis alternativa (H_1): $\mu > 18$ (la media poblacional es mayor que 18).

Paso 2 - Seleccionar el nivel de significación: $\alpha = 0.05$.

Paso 3 - Calcular el estadístico de prueba: Utilizamos el estadístico t porque la muestra es pequeña ($n < 30$):

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

. Sustituyendo los valores: $\bar{x} = 20$, $\mu_0 = 18$, $s = 4$, $n = 25$:

$$t = \frac{20 - 18}{4/\sqrt{25}} = 2.5$$

Paso 4 - Determinar el valor crítico: Para $\alpha = 0.05$ en una prueba unilateral (cola derecha) en la distribución t de Student con $df = 24$, el valor crítico t_c es aproximadamente 1.711.

Paso 5 - Tomar una decisión: Comparamos el valor del estadístico de prueba con el valor crítico. Si $t > t_c$, rechazamos H_0 . Si $t \leq t_c$, no rechazamos H_0 . En este caso: $t = 2.5$, $t_c = 1.711$. Dado que $t > t_c$, rechazamos H_0 .

Conclusión: Con un nivel de significación $\alpha = 0.05$, hay suficiente evidencia para rechazar la hipótesis nula. Esto significa que podemos concluir que la media poblacional es mayor que 18.

Ejercicio 10: Prueba z para grandes muestras

Una encuesta a 500 personas revela que 320 están a favor de una nueva ley. Realiza un contraste de hipótesis para determinar si la proporción de personas a favor de la ley es diferente de 0.6 con un nivel de significación $\alpha = 0.05$.

Solución:

Paso 1 - Plantear las hipótesis: Hipótesis nula (H_0): $p = 0.6$ (la proporción de personas a favor de la ley es 0.6). Hipótesis alternativa (H_1): $p \neq 0.6$ (la proporción es diferente de 0.6).

Paso 2 - Seleccionar el nivel de significación: $\alpha = 0.05$.

Paso 3 - Calcular la proporción muestral:

$$\hat{p} = \frac{x}{n}$$

. Donde $x = 320$, $n = 500$:

$$\hat{p} = \frac{320}{500} = 0.64$$

Paso 4 - Calcular el estadístico de prueba: Utilizamos el estadístico z para proporciones:

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

. Sustituyendo los valores: $p_0 = 0.6$:

$$z = \frac{0.64 - 0.6}{\sqrt{\frac{0.6 \cdot (1-0.6)}{500}}} \approx 1.826$$

Paso 5 - Determinar el valor crítico: Para $\alpha = 0.05$ en una prueba bilateral, el valor crítico z_c es aproximadamente ± 1.96 .

Paso 6 - Tomar una decisión: Comparamos el valor absoluto del estadístico de prueba con el valor crítico. Si $|z| > z_c$, rechazamos H_0 . Si $|z| \leq z_c$, no rechazamos H_0 . En este caso: $|z| = 1.826$, $z_c = 1.96$. Dado que $|z| < z_c$, no rechazamos H_0 .

Conclusión: Con un nivel de significación $\alpha = 0.05$, no hay suficiente evidencia para rechazar la hipótesis nula. Esto significa que no podemos concluir que la proporción de personas a favor de la ley sea diferente de 0.6.

Intervalos de Confianza

Ejercicio 1: Conceptos Básicos

Explica brevemente qué es un intervalo de confianza y por qué es importante en la estadística inferencial. Da un ejemplo sencillo de un intervalo de confianza.

Solución:

Un intervalo de confianza es un rango de valores, derivado de los datos muestrales, que se utiliza para estimar un parámetro desconocido de la población, como la media o la proporción. Este intervalo se construye de tal manera que, con un cierto nivel de confianza (por ejemplo, 95% o 99%), se espera que contenga el verdadero valor del parámetro poblacional.

Importancia en la estadística inferencial: (1) Proporciona una estimación del parámetro poblacional en lugar de un solo valor puntual, ofreciendo así más información sobre la precisión de la estimación. (2) Permite cuantificar la incertidumbre asociada a la estimación. Un intervalo de confianza más estrecho indica una estimación más precisa. (3) Ayuda en la toma de decisiones basadas en datos al proporcionar un rango de valores posibles para el parámetro poblacional. Esto es crucial en áreas como la investigación científica, la economía, la medicina y muchas otras.

Ejemplo: Supongamos que estamos interesados en estimar la media de las alturas de los estudiantes en una universidad. Tomamos una muestra aleatoria de 30 estudiantes y encontramos que la media muestral ($\bar{x}$) es de 170 cm y la desviación estándar (σ) es de 10 cm. Queremos calcular un intervalo de confianza del 95% para la media poblacional (μ).

1. **Determinar el nivel de confianza:** 95%. El nivel de significancia (α) es 0.05. El valor crítico (z) para un nivel de confianza del 95% es aproximadamente 1.96.
2. **Calcular el error estándar:**

$$\text{Error estándar} = \frac{\sigma}{\sqrt{n}} = \frac{10}{\sqrt{30}} \approx 1.83$$

3. **Calcular el margen de error:**

$$\text{Margen de error} = z \times \text{Error estándar} = 1.96 \times 1.83 \approx 3.59$$

4. Calcular el intervalo de confianza:

$$\text{Intervalo de confianza} = \bar{x} \pm \text{Margen de error} = 170 \pm 3.59 = (166.41, 173.59)$$

Interpretación: Con un 95% de confianza, podemos afirmar que la media de las alturas de todos los estudiantes en la universidad está entre 166.41 cm y 173.59 cm. Esto significa que si repitiéramos este proceso de muestreo muchas veces, aproximadamente el 95% de los intervalos calculados de esta manera contendrían la verdadera media poblacional.

Ejercicio 2: Intervalo de Confianza Básico

Dada una muestra aleatoria de tamaño 30 de una población normal con media muestral $\bar{x} = 50$ y desviación estándar $\sigma = 10$, calcula el intervalo de confianza del 95% para la media poblacional.

Solución:

Datos proporcionados: Tamaño de la muestra (n) = 30, media muestral ($\bar{x}$) = 50, desviación estándar (σ) = 10, nivel de confianza = 95%.

Paso 1 - Determinar el valor crítico: Para un nivel de confianza del 95%, el valor crítico z (para una distribución normal estándar) es aproximadamente 1.96.

Paso 2 - Calcular el error estándar de la media:

$$\text{Error estándar} = \frac{\sigma}{\sqrt{n}} = \frac{10}{\sqrt{30}} \approx 1.8257$$

Paso 3 - Calcular el margen de error:

$$\text{Margen de error} = z \times \text{Error estándar} = 1.96 \times 1.8257 \approx 3.5774$$

Paso 4 - Calcular el intervalo de confianza:

$$\text{Intervalo de confianza} = \bar{x} \pm \text{Margen de error} = 50 \pm 3.5774 = (46.4226, 53.5774)$$

Resultado: El intervalo de confianza del 95% para la media poblacional es aproximadamente (46.42, 53.58). Esto significa que con un 95% de confianza, podemos afirmar que la verdadera media poblacional se encuentra dentro de este rango.

Ejercicio 3: Nivel de Confianza Diferente

Utilizando la misma muestra del ejercicio anterior, calcula el intervalo de confianza del 99% para la media poblacional. Compara ambos intervalos y explica las diferencias.

Solución:

Para calcular el intervalo de confianza del 99% para la media poblacional utilizando la misma muestra, seguimos los mismos pasos que antes pero con el valor crítico correspondiente al 99% de confianza.

Datos proporcionados: Tamaño de la muestra (n) = 30, media muestral ($\bar{x}$) = 50, desviación estándar (σ) = 10, nivel de confianza = 99%.

Paso 1 - Determinar el valor crítico: Para un nivel de confianza del 99%, el valor crítico z es aproximadamente 2.576.

Paso 2 - Calcular el error estándar: El error estándar de la media es el mismo que antes:

$$\text{Error estándar} = \frac{10}{\sqrt{30}} \approx 1.8257$$

Paso 3 - Calcular el margen de error:

$$\text{Margen de error} = 2.576 \times 1.8257 \approx 4.7015$$

Paso 4 - Calcular el intervalo de confianza:

$$\text{Intervalo de confianza} = 50 \pm 4.7015 = (45.2985, 54.7015)$$

Comparación de los intervalos: Intervalo de confianza del 95% = (46.42, 53.58); Intervalo de confianza del 99% = (45.30, 54.70).

Explicación de las diferencias: (1) El intervalo de confianza del 99% es más amplio que el del 95%. Esto se debe a que al aumentar el nivel de confianza, necesitamos un intervalo más amplio para asegurarnos de que contiene el parámetro poblacional con mayor certeza. (2) Un intervalo de confianza más amplio (como el del 99%) proporciona mayor seguridad de que contiene la verdadera media poblacional, pero a costa de ser menos preciso. Un intervalo más estrecho (como el del 95%) es más preciso pero conlleva un menor nivel de certeza de que contiene la verdadera media poblacional. (3) El valor crítico para el 99% de confianza (2.576) es mayor que el valor crítico para el 95% de confianza (1.96), lo que contribuye al aumento del margen de error y, por ende, al ancho del intervalo.

En resumen, al aumentar el nivel de confianza del 95% al 99%, el intervalo de confianza se vuelve más amplio, lo que refleja un mayor grado de certeza de que el intervalo incluye la verdadera media poblacional.

Ejercicio 4: Interpretación Práctica

Un investigador encuentra que el intervalo de confianza del 95% para la media de una variable es (45, 55). Explica qué significa este intervalo en términos prácticos y cómo debería interpretarlo el investigador.

Solución:

Cuando un investigador encuentra que el intervalo de confianza del 95% para la media de una variable es (45, 55), esto significa lo siguiente:

Rango de valores probables: El intervalo (45, 55) representa un rango de valores dentro del cual se estima que se encuentra la verdadera media poblacional de la variable con un nivel de confianza del 95%.

Nivel de confianza: El nivel de confianza del 95% indica que si se repitiera el proceso de muestreo muchas veces y se calcularan intervalos de confianza del 95% para cada muestra, aproximadamente el 95% de esos intervalos incluirían la verdadera media poblacional.

Incertidumbre: El intervalo refleja la incertidumbre inherente a la estimación. Debido a la variabilidad de la muestra, no podemos estar 100% seguros de que la media poblacional esté exactamente en un punto específico, pero podemos afirmar con un 95% de confianza que está dentro del intervalo calculado.

Cómo interpretarlo: (1) La mejor estimación de la media poblacional basada en la muestra es que se encuentra entre 45 y 55. (2) Si el investigador necesita tomar decisiones basadas en la media de la población, puede hacerlo con la confianza de que la verdadera media está muy probablemente dentro de este rango. Por ejemplo, si está considerando un límite superior o inferior para una variable crítica, el intervalo le ayuda a entender dónde podría estar la verdadera media. (3) Al comunicar los resultados a otros, el investigador debe mencionar que el intervalo de confianza del 95% para la media es (45, 55). Esto proporciona una visión clara de la precisión y fiabilidad de la estimación basada en los datos de la muestra.

Ejemplo práctico: Supongamos que el investigador está estudiando la puntuación de satisfacción del cliente para un producto. Si el intervalo de confianza del 95% es (45, 55), puede interpretar que: La satisfacción promedio de los clientes está en algún lugar entre 45 y 55 en la escala utilizada, con un 95% de confianza. Si se está comparando este producto con otro cuya satisfacción promedio conocida es 60, el investigador puede argumentar que es muy probable (con un 95% de confianza) que la media de satisfacción del producto en estudio sea significativamente menor. Si la satisfacción mínima aceptable se define en 50, el investigador puede señalar que hay una posibilidad considerable de que la media real esté por debajo de este umbral, sugiriendo una necesidad de mejorar el producto.

En resumen, el intervalo de confianza proporciona una estimación del rango en el que se espera encontrar la verdadera media poblacional con un cierto nivel de confianza. Es una herramienta

clave en la estadística inferencial que ayuda a los investigadores a comunicar y tomar decisiones informadas basadas en sus datos muestrales.

Ejercicio 5: Varianza Conocida

Se sabe que la desviación estándar de las alturas de una población es de 5 cm. Se toma una muestra aleatoria de 40 individuos con una media muestral de 170 cm. Calcula el intervalo de confianza del 95% para la media poblacional.

Solución:

Datos proporcionados: Desviación estándar poblacional (σ) = 5 cm, tamaño de la muestra (n) = 40, media muestral ($\bar{x}$) = 170 cm, nivel de confianza = 95%.

Paso 1 - Determinar el valor crítico: Para un nivel de confianza del 95%, el valor crítico z es aproximadamente 1.96.

Paso 2 - Calcular el error estándar:

$$\text{Error estándar} = \frac{\sigma}{\sqrt{n}} = \frac{5}{\sqrt{40}} \approx 0.7906$$

Paso 3 - Calcular el margen de error:

$$\text{Margen de error} = 1.96 \times 0.7906 \approx 1.5496$$

Paso 4 - Calcular el intervalo de confianza:

$$\text{Intervalo de confianza} = 170 \pm 1.5496 = (168.4504, 171.5496)$$

Resultado: El intervalo de confianza del 95% para la media poblacional es aproximadamente (168.45, 171.55). Esto significa que con un 95% de confianza, podemos afirmar que la verdadera media poblacional de las alturas se encuentra dentro de este rango.

Ejercicio 6: Varianza Desconocida

En un estudio de satisfacción laboral, se toma una muestra de 25 empleados y se encuentra una media muestral de 78 puntos con una desviación estándar muestral de 12 puntos. Calcula el intervalo de confianza del 95% para la media poblacional.

Solución:

Para calcular el intervalo de confianza del 95% para la media poblacional, usaremos la media y la desviación estándar muestral. Dado que la muestra es pequeña ($n < 30$) y la desviación estándar poblacional no es conocida, utilizaremos la distribución t de Student.

Datos proporcionados: Tamaño de la muestra (n) = 25, media muestral ($\bar{x}$) = 78 puntos, desviación estándar muestral (s) = 12 puntos, nivel de confianza = 95%.

Paso 1 - Determinar el valor crítico t : Para un nivel de confianza del 95% y $n - 1 = 24$ grados de libertad, el valor crítico $t_{0.025, 24} \approx 2.064$.

Paso 2 - Calcular el error estándar:

$$\text{Error estándar} = \frac{s}{\sqrt{n}} = \frac{12}{\sqrt{25}} = 2.4$$

Paso 3 - Calcular el margen de error:

$$\text{Margen de error} = 2.064 \times 2.4 \approx 4.9536$$

Paso 4 - Calcular el intervalo de confianza:

$$\text{Intervalo de confianza} = 78 \pm 4.9536 = (73.0464, 82.9536)$$

Resultado: El intervalo de confianza del 95% para la media poblacional es aproximadamente (73.05, 82.95). Esto significa que con un 95% de confianza, podemos afirmar que la verdadera media poblacional de la satisfacción laboral se encuentra dentro de este rango.

Ejercicio 7: Muestra Grande

Una encuesta a 200 estudiantes universitarios encuentra que el gasto promedio mensual en libros es de \$100 con una desviación estándar de \$20. Calcula el intervalo de confianza del 95% para la media del gasto mensual en libros para todos los estudiantes universitarios.

Solución:

Datos proporcionados: Tamaño de la muestra (n) = 200, media muestral ($\bar{x}$) = 100, *desviación estándar muestral* (\$) = \$20, nivel de confianza = 95%.

Dado que la muestra es grande ($n > 30$), podemos utilizar la distribución normal estándar.

Paso 1 - Determinar el valor crítico: Para un nivel de confianza del 95%, el valor crítico z es aproximadamente 1.96.

Paso 2 - Calcular el error estándar:

$$\text{Error estándar} = \frac{20}{\sqrt{200}} \approx 1.4142$$

Paso 3 - Calcular el margen de error:

$$\text{Margen de error} = 1.96 \times 1.4142 \approx 2.7714$$

Paso 4 - Calcular el intervalo de confianza:

$$\text{Intervalo de confianza} = 100 \pm 2.7714 = (97.2286, 102.7714)$$

Resultado: El intervalo de confianza del 95% para la media del gasto mensual en libros es aproximadamente (97.23, 102.77). Esto significa que con un 95% de confianza, podemos afirmar que la verdadera media del gasto mensual en libros para todos los estudiantes universitarios se encuentra dentro de este rango.

Ejercicio 8: Proporción

En una muestra de 150 votantes, 90 indican que planean votar por el candidato A. Calcula el intervalo de confianza del 95% para la proporción de votantes que planean votar por el candidato A.

Solución:

Datos proporcionados: Tamaño de la muestra (n) = 150, número de éxitos (x) = 90, nivel de confianza = 95%.

Paso 1 - Calcular la proporción muestral:

$$\hat{p} = \frac{x}{n} = \frac{90}{150} = 0.6$$

Paso 2 - Determinar el valor crítico: Para un nivel de confianza del 95%, el valor crítico z es aproximadamente 1.96.

Paso 3 - Calcular el error estándar:

$$\text{Error estándar} = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} = \sqrt{\frac{0.6 \times 0.4}{150}} = 0.04$$

Paso 4 - Calcular el margen de error:

$$\text{Margen de error} = 1.96 \times 0.04 = 0.0784$$

Paso 5 - Calcular el intervalo de confianza:

$$\text{Intervalo de confianza} = 0.6 \pm 0.0784 = (0.5216, 0.6784)$$

Resultado: El intervalo de confianza del 95% para la proporción de votantes que planean votar por el candidato A es aproximadamente (0.5216, 0.6784). Esto significa que con un 95% de confianza, podemos afirmar que la verdadera proporción de votantes que planean votar por el candidato A se encuentra dentro de este rango.

Ejercicio 9: Comparación de Proporciones

Dos empresas están interesadas en la proporción de empleados que están satisfechos con su trabajo. En una muestra de 100 empleados de la empresa A, 60 se declaran satisfechos. En una muestra de 120 empleados de la empresa B, 90 se declaran satisfechos. Calcula el intervalo de confianza del 95% para la diferencia en las proporciones de empleados satisfechos entre las dos empresas.

Solución:

Datos proporcionados: Tamaño de la muestra de la empresa A (n_A) = 100, número de empleados satisfechos en A (x_A) = 60, tamaño de la muestra de la empresa B (n_B) = 120, número de empleados satisfechos en B (x_B) = 90.

Paso 1 - Calcular las proporciones muestrales:

$$\hat{p}_A = \frac{60}{100} = 0.60 \quad ; \quad \hat{p}_B = \frac{90}{120} = 0.75$$

Paso 2 - Determinar el valor crítico: Para un nivel de confianza del 95%, el valor crítico z es aproximadamente 1.96.

Paso 3 - Calcular el error estándar de la diferencia:

$$\text{Error estándar} = \sqrt{\frac{0.60 \times 0.40}{100} + \frac{0.75 \times 0.25}{120}} \approx 0.06296$$

Paso 4 - Calcular el margen de error:

$$\text{Margen de error} = 1.96 \times 0.06296 \approx 0.1234$$

Paso 5 - Calcular el intervalo de confianza:

$$\hat{p}_A - \hat{p}_B = 0.60 - 0.75 = -0.15$$

$$\text{Intervalo de confianza} = -0.15 \pm 0.1234 = (-0.2734, -0.0266)$$

Resultado: El intervalo de confianza del 95% para la diferencia en las proporciones es aproximadamente $(-0.2734, -0.0266)$. Esto significa que con un 95% de confianza, podemos afirmar que la proporción de empleados satisfechos es mayor en la empresa B que en la empresa A, y la diferencia se encuentra en el rango de -0.2734 a -0.0266 .

Ejercicio 10: Interpretación Crítica

Un informe estadístico presenta el intervalo de confianza del 95% para la media de una variable como (75, 85). El informe concluye que la media poblacional es 80. ¿Es esta conclusión válida? Explica por qué o por qué no, utilizando conceptos de la interpretación de intervalos de confianza.

Solución:

La conclusión del informe **NO es válida**. Existen varios problemas fundamentales:

1. Error en la interpretación del intervalo de confianza: El intervalo de confianza del 95% (75, 85) significa que si repitiéramos el proceso de muestreo muchas veces, aproximadamente el 95% de los intervalos calculados contendrían la verdadera media poblacional. No significa que haya un 95% de probabilidad de que la media esté en ese rango - la media poblacional es un valor fijo, no una variable aleatoria.

2. El valor 80 no es especial: Aunque 80 está dentro del intervalo de confianza, no hay nada que lo haga más probable que cualquier otro valor dentro del rango (75, 85). Los valores 76, 79, 82 o 84.5 son igualmente compatibles con los datos observados. Afirmar que “la media poblacional es 80” sin justificación adicional es arbitrario.

3. Confusión entre estimación puntual y el intervalo: El informe parece haber tomado el punto medio del intervalo (80) y lo presentó como “la media poblacional”. El intervalo de confianza indica incertidumbre - si tuviéramos certeza de que la media es exactamente 80, no necesitaríamos un intervalo.

Conclusión correcta: El informe debería concluir que “con un 95% de confianza, la media poblacional se encuentra entre 75 y 85”, o que “el valor 80 es compatible con los datos, pero también lo son todos los demás valores dentro del intervalo”. Afirmar que la media “es 80” contradice el propósito mismo del intervalo de confianza, que es reconocer la incertidumbre inherente a la estimación basada en muestras.

Estimación y contraste paramétrico 1

Ejercicio 1: Definición de Estadístico

¿Qué es un estadístico? Da un ejemplo de un estadístico comúnmente utilizado en la estadística descriptiva.

Solución: Un estadístico es una función de una muestra que no depende de parámetros desconocidos. Ejemplo: la media muestral.

Ejercicio 2: Estimación Puntual

Supongamos que tienes una muestra aleatoria de tamaño $n = 10$ de una población con media desconocida μ y varianza conocida $\sigma^2 = 25$. La muestra es: $x = \{10, 12, 9, 11, 10, 13, 10, 12, 11, 14\}$. Calcula la estimación puntual de la media poblacional μ utilizando la media muestral.

Solución: La media muestral es $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = 11.2$.

Ejercicio 3: Propiedades de los Estimadores

Demuestra que la media muestral es un estimador insesgado de la media poblacional μ .

Solución: Vamos a demostrar que $\mathbb{E}(\bar{X}) = \mu$.

Para demostrar que la media muestral ($\bar{X}$) es un estimador insesgado de la media poblacional (μ), necesitamos mostrar que el valor esperado de la media muestral es igual a la media poblacional. Es decir, debemos demostrar que:

$$\mathbb{E}(\bar{X}) = \mu$$

Definición de la Media Muestral

Supongamos que tenemos una muestra aleatoria de tamaño n proveniente de una población con media μ y varianza σ^2 . Los valores de la muestra son $X_1, X_2, \dots, X_n$.

La media muestral ($\bar{X}$) se define como:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Propiedad de Linealidad de la Esperanza

La propiedad de linealidad de la esperanza establece que el valor esperado de una suma de variables aleatorias es igual a la suma de los valores esperados de las variables aleatorias individuales. Formalmente, para cualquier constante a y cualquier variable aleatoria X :

$$\mathbb{E}(aX) = a\mathbb{E}(X)$$

$$\mathbb{E}(X_1 + X_2 + \cdots + X_n) = \mathbb{E}(X_1) + \mathbb{E}(X_2) + \cdots + \mathbb{E}(X_n)$$

Cálculo del Valor Esperado de la Media Muestral

Usamos la definición de $\bar{X}$ y la propiedad de linealidad de la esperanza para calcular $\mathbb{E}(\bar{X})$:

$$\mathbb{E}(\bar{X}) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n X_i\right)$$

Aplicando la propiedad de linealidad:

$$\mathbb{E}(\bar{X}) = \frac{1}{n} \mathbb{E}\left(\sum_{i=1}^n X_i\right)$$

Nuevamente, aplicamos la propiedad de linealidad a la suma:

$$\mathbb{E}(\bar{X}) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i)$$

Esperanza de las Variables Aleatorias de la Muestra

Dado que $X_1, X_2, \dots, X_n$ son una muestra aleatoria de la población con media μ , cada X_i tiene el mismo valor esperado, es decir, $\mathbb{E}(X_i) = \mu$ para todo i .

Sustituyendo esto en la ecuación anterior:

$$\mathbb{E}(\bar{X}) = \frac{1}{n} \sum_{i=1}^n \mu$$

Hay n términos en la suma, cada uno igual a μ :

$$\mathbb{E}(\bar{X}) = \frac{1}{n} \cdot n \cdot \mu$$

Simplificando:

$$\mathbb{E}(\bar{X}) = \mu$$

Conclusión

Hemos demostrado que el valor esperado de la media muestral ($\bar{X}$) es igual a la media poblacional (μ):

$$\mathbb{E}(\bar{X}) = \mu$$

Por lo tanto, la media muestral ($\bar{X}$) es un estimador insesgado de la media poblacional (μ).

Ejercicio 4: Método de los Momentos

Dado el siguiente conjunto de datos: $x = \{2, 4, 3, 5, 6, 4, 3, 5\}$ Utiliza el método de los momentos para estimar la media μ y la varianza σ^2 de la población.

Solución:

El método de los momentos (MoM) es una técnica para estimar parámetros igualando los momentos teóricos de la población con los momentos muestrales.

Paso 1: Estimación de la Media (μ)

El primer momento poblacional es $E[X] = \mu$. Lo igualamos al primer momento muestral, $\bar{x}$.

- **Media Muestral ($\bar{x}$):**

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Para el conjunto de datos $x = \{2, 4, 3, 5, 6, 4, 3, 5\}$, con $n = 8$:

$$\bar{x} = \frac{1}{8}(2 + 4 + 3 + 5 + 6 + 4 + 3 + 5) = \frac{32}{8} = 4$$

- **Estimador MoM para la media:**

$$\hat{\mu}_{MoM} = \bar{x} = 4$$

Paso 2: Estimación de la Varianza (σ^2)

Para la varianza, el método estricto iguala el segundo momento poblacional, $E[X^2]$, con el segundo momento muestral, $m_2 = \frac{1}{n} \sum x_i^2$.

- **Relación teórica:** $E[X^2] = \sigma^2 + \mu^2$.
- **Igualando momentos:** $\frac{1}{n} \sum x_i^2 = \hat{\sigma}^2 + \hat{\mu}^2$.
- **Despejando $\hat{\sigma}^2$:**

$$\hat{\sigma}_{MoM}^2 = \left(\frac{1}{n} \sum x_i^2 \right) - \bar{x}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$$

Este estimador utiliza n en el denominador.

Calculando la suma de desviaciones al cuadrado:

$$\sum_{i=1}^8 (x_i - \bar{x})^2 = (2 - 4)^2 + (4 - 4)^2 + \dots + (5 - 4)^2 = 4 + 0 + 1 + 1 + 4 + 0 + 1 + 1 = 12$$

Aplicando la fórmula del MoM:

$$\hat{\sigma}_{MoM}^2 = \frac{12}{8} = 1.5$$

Aclaración Importante: Estimador Insesgado vs. MoM

Es muy común utilizar en la práctica la **cuasivarianza muestral** (s^2) porque es un estimador insesgado de σ^2 . Su fórmula utiliza $n - 1$:

$$s^2 = \frac{1}{n - 1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{12}{7} \approx 1.714$$

Aunque este no es el estimador estricto del método de los momentos, a menudo se presenta en su lugar por sus buenas propiedades estadísticas.

Conclusión

Las estimaciones para los parámetros de la población son:

- **Estimador de la media (MoM e insesgado):**

$$\hat{\mu} = 4$$

- **Estimador de la varianza (estricto MoM, sesgado):**

$$\hat{\sigma}_{MoM}^2 = 1.5$$

- **Estimador de la varianza (insesgado, s^2):**

$$s^2 \approx 1.714$$

Ejercicio 5: Método de la Máxima Verosimilitud

Supongamos que tenemos una muestra aleatoria de tamaño n de una distribución exponencial con parámetro λ . Deriva el estimador de máxima verosimilitud para λ .

Solución: El estimador de máxima verosimilitud para λ es $\hat{\lambda} = \frac{1}{\bar{x}}$. Para derivar el estimador de máxima verosimilitud para el parámetro λ de una distribución exponencial, sigamos los pasos habituales en la metodología de máxima verosimilitud:

1. Función de Densidad de la Distribución Exponencial

La función de densidad de probabilidad (f.d.p.) de una variable aleatoria X que sigue una distribución exponencial con parámetro λ es:

$$f(x; \lambda) = \lambda e^{-\lambda x}, \quad x \geq 0, \quad \lambda > 0$$

2. Función de Verosimilitud

Supongamos que tenemos una muestra aleatoria $X_1, X_2, \dots, X_n$ de tamaño n de la distribución exponencial con parámetro λ . La función de verosimilitud $L(\lambda)$ es el producto de las funciones de densidad para cada observación:

$$L(\lambda) = \prod_{i=1}^n f(X_i; \lambda) = \prod_{i=1}^n \lambda e^{-\lambda X_i}$$

3. Log-Verosimilitud

Para simplificar el cálculo, trabajamos con la log-verosimilitud, que es el logaritmo natural de la función de verosimilitud:

$$\ell(\lambda) = \ln L(\lambda) = \ln \left(\prod_{i=1}^n \lambda e^{-\lambda X_i} \right) = \sum_{i=1}^n \ln(\lambda e^{-\lambda X_i})$$

Descomponiendo el logaritmo del producto en una suma de logaritmos:

$$\ell(\lambda) = \sum_{i=1}^n (\ln \lambda + \ln e^{-\lambda X_i})$$

Usando las propiedades de los logaritmos ($\ln ab = \ln a + \ln b$ y $\ln e^a = a$):

$$\ell(\lambda) = \sum_{i=1}^n (\ln \lambda - \lambda X_i)$$

$$\ell(\lambda) = n \ln \lambda - \lambda \sum_{i=1}^n X_i$$

4. Derivar la Log-Verosimilitud

Para encontrar el estimador de máxima verosimilitud, derivamos la log-verosimilitud respecto a λ y la igualamos a cero:

$$\frac{d\ell(\lambda)}{d\lambda} = \frac{d}{d\lambda} \left(n \ln \lambda - \lambda \sum_{i=1}^n X_i \right)$$

Derivando cada término por separado:

$$\begin{aligned} \frac{d}{d\lambda}(n \ln \lambda) &= \frac{n}{\lambda} \\ \frac{d}{d\lambda} \left(-\lambda \sum_{i=1}^n X_i \right) &= -\sum_{i=1}^n X_i \end{aligned}$$

Sumando ambas derivadas:

$$\frac{d\ell(\lambda)}{d\lambda} = \frac{n}{\lambda} - \sum_{i=1}^n X_i$$

5. Igualar a Cero y Resolver para λ

Igualamos la derivada a cero para encontrar el valor de λ que maximiza la log-verosimilitud:

$$\frac{n}{\lambda} - \sum_{i=1}^n X_i = 0$$

Resolviendo para λ :

$$\begin{aligned} \frac{n}{\lambda} &= \sum_{i=1}^n X_i \\ \lambda &= \frac{n}{\sum_{i=1}^n X_i} \end{aligned}$$

6. Expresar en Términos de la Media Muestral

El denominador es la suma de las observaciones de la muestra. Podemos expresar esta suma en términos de la media muestral $\bar{X}$:

$$\sum_{i=1}^n X_i = n\bar{X}$$

Sustituyendo en la ecuación de λ :

$$\lambda = \frac{n}{n\bar{X}}$$

$$\lambda = \frac{1}{\bar{X}}$$

Conclusión

El estimador de máxima verosimilitud para el parámetro λ de una distribución exponencial es:

$$\hat{\lambda} = \frac{1}{\bar{X}}$$

Este resultado muestra que el estimador de máxima verosimilitud para λ es el recíproco de la media muestral $\bar{X}$.

Ejercicio 6: Estimación por Intervalo

Para la misma muestra del Ejercicio 2 ($x = \{10, 12, 9, 11, 10, 13, 10, 12, 11, 14\}$), calcula un intervalo de confianza del 95% para la media poblacional μ , asumiendo que la varianza poblacional es conocida y es igual a 25.

Solución: Para calcular un intervalo de confianza para la media poblacional μ cuando la varianza poblacional σ^2 es conocida, utilizamos la distribución normal. El intervalo de confianza del 95% para la media poblacional se calcula con la siguiente fórmula:

$$\bar{x} \pm z_{\alpha/2} \left(\frac{\sigma}{\sqrt{n}} \right)$$

donde:

- $\bar{x}$ es la media muestral.
- $z_{\alpha/2}$ es el valor crítico de la distribución normal estándar para un nivel de confianza del 95% (para $\alpha = 0.05$, $z_{0.025} = 1.96$).
- σ es la desviación estándar poblacional.
- n es el tamaño de la muestra.

Paso 1: Calcular la Media Muestral ($\bar{x}$)

Para la muestra $x = \{10, 12, 9, 11, 10, 13, 10, 12, 11, 14\}$:

$$\bar{x} = \frac{1}{10} \sum_{i=1}^{10} x_i = \frac{1}{10}(10 + \dots + 14) = \frac{1}{10} \cdot 112 = 11.2$$

Paso 2: Determinar los Parámetros del Intervalo de Confianza

- La varianza poblacional σ^2 es conocida y es igual a 25, por lo tanto, la desviación estándar $\sigma = \sqrt{25} = 5$.
- El tamaño de la muestra $n = 10$.
- El valor crítico $z_{0.025} = 1.96$.

Paso 3: Calcular el Margen de Error

El margen de error E es:

$$E = z_{\alpha/2} \left(\frac{\sigma}{\sqrt{n}} \right)$$

Sustituyendo los valores:

$$E = 1.96 \left(\frac{5}{\sqrt{10}} \right) \approx 3.1$$

Paso 4: Calcular el Intervalo de Confianza

El intervalo de confianza del 95% para la media poblacional μ es:

$$\bar{x} \pm E$$

Sustituyendo los valores:

$$11.2 \pm 3.1 = (8.1, 14.3)$$

Conclusión

El intervalo de confianza del 95% para la media poblacional μ es (8.1, 14.3). Esto significa que estamos un 95% seguros de que la media poblacional se encuentra dentro de este intervalo.

Ejercicio 7: Contraste de Hipótesis (Prueba Z)

Supón que quieres probar si la media poblacional μ es igual a 10. Utiliza la muestra del Ejercicio 2 y realiza un contraste de hipótesis con un nivel de significación $\alpha = 0.05$.

Solución: Para probar si la media poblacional μ es igual a 10 utilizando la muestra del Ejercicio 2 ($x = \{10, 12, 9, 11, 10, 13, 10, 12, 11, 14\}$), realizaremos un contraste de hipótesis. Dado que la varianza poblacional es conocida ($\sigma^2 = 25$), usaremos una prueba z .

Paso 1: Definir las Hipótesis

- **Hipótesis nula (H_0):** $\mu = 10$
- **Hipótesis alternativa (H_1):** $\mu \neq 10$

Paso 2: Calcular la Estadística de Prueba

La estadística de prueba z se calcula como:

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

donde:

- $\bar{x}$ es la media muestral.
- μ_0 es la media poblacional bajo la hipótesis nula.
- σ es la desviación estándar poblacional.
- n es el tamaño de la muestra.

Media Muestral ($\bar{x}$)

Para la muestra $x = \{10, 12, 9, 11, 10, 13, 10, 12, 11, 14\}$:

$$\bar{x} = \frac{1}{10} \sum_{i=1}^{10} x_i = \frac{1}{10}(10 + \dots + 14) = 11.2$$

Paso 3: Calcular el Valor de la Estadística de Prueba

$$z = \frac{11.2 - 10}{5/\sqrt{10}} \approx 0.759$$

Paso 4: Determinar el Valor Crítico y la Región de Rechazo

Para un nivel de significación $\alpha = 0.05$ en una prueba bilateral, los valores críticos $z_{\alpha/2}$ son:

$$z_{0.025} = \pm 1.96$$

Paso 5: Comparar el Valor de la Estadística de Prueba con los Valores Críticos

Comparamos el valor de z con los valores críticos:

$$-1.96 < 0.759 < 1.96$$

Paso 6: Conclusión

Dado que el valor de la estadística de prueba z está dentro del rango de los valores críticos, no rechazamos la hipótesis nula H_0 . Esto significa que no hay suficiente evidencia para concluir que la media poblacional μ es diferente de 10 al nivel de significación $\alpha = 0.05$.

En resumen, el contraste de hipótesis indica que no podemos rechazar la hipótesis nula de que la media poblacional es igual a 10.

Ejercicio 8: Contraste de Hipótesis (Prueba T)

Para una muestra aleatoria de tamaño $n = 15$ de una población con distribución normal pero con varianza desconocida,

$$x = \{15, 17, 16, 14, 18, 16, 15, 17, 16, 18, 15, 17, 16, 14, 18\}$$

realiza un contraste de hipótesis para verificar si la media poblacional es diferente de 16 con un nivel de significación $\alpha = 0.05$.

Solución: Para realizar un contraste de hipótesis sobre la media poblacional con una muestra de tamaño $n = 15$ y una varianza desconocida, utilizamos la distribución t de Student. A continuación, se detalla el procedimiento paso a paso:

Paso 1: Definir las Hipótesis

- **Hipótesis nula** (H_0): $\mu = 16$
- **Hipótesis alternativa** (H_1): $\mu \neq 16$

Paso 2: Calcular la Estadística de Prueba

La estadística de prueba t se calcula como:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

donde:

- $\bar{x}$ es la media muestral.
- μ_0 es la media poblacional bajo la hipótesis nula.
- s es la desviación estándar muestral.

- n es el tamaño de la muestra.

Calcular la Media Muestral ($\bar{x}$)

Para la muestra

$$x = \{15, 17, 16, 14, 18, 16, 15, 17, 16, 18, 15, 17, 16, 14, 18\}$$

Se tiene:

$$\bar{x} = \frac{1}{15} \sum_{i=1}^{15} x_i = \frac{240}{15} = 16$$

Calcular la Desviación Estándar Muestral (s)

Primero, calculemos la varianza muestral (s^2):

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{15} (x_i - \bar{x})^2$$

Calculando cada $(x_i - \bar{x})^2$:

$$\sum_{i=1}^{15} (x_i - \bar{x})^2 = 25.73$$

Entonces, la varianza muestral es:

$$s^2 = \frac{25.73}{14} \approx 1.838$$

La desviación estándar muestral es:

$$s = \sqrt{1.838} \approx 1.356$$

Paso 3: Calcular el Valor de la Estadística de Prueba

$$t = \frac{16 - 16}{1.356/\sqrt{15}} = 0$$

Paso 4: Determinar los Valores Críticos y la Región de Rechazo

Para un nivel de significación $\alpha = 0.05$ en una prueba bilateral con $n - 1 = 14$ grados de libertad, los valores críticos $t_{\alpha/2}$ son:

$$t_{0.025,14} \approx \pm 2.145$$

Paso 5: Comparar el Valor de la Estadística de Prueba con los Valores Críticos

El valor de la estadística de prueba t se compara con los valores críticos:

$$-2.145 < 0 < 2.145$$

Paso 6: Conclusión

Dado que el valor de t está dentro del rango de los valores críticos, no rechazamos la hipótesis nula H_0 . Esto significa que no hay suficiente evidencia para concluir que la media poblacional es diferente de 16 al nivel de significación $\alpha = 0.05$.

En resumen, el contraste de hipótesis indica que no podemos rechazar la hipótesis nula de que la media poblacional es igual a 16.

Ejercicio 9: Contraste de Hipótesis (Prueba Chi-Cuadrado)

Una muestra de tamaño $n = 20$ de una población con varianza desconocida es $x = \{5, 7, 9, 6, 8, 10, 7, 9, 8, 10, 5, 7, 9, 6, 8, 10, 7, 9, 8, 10\}$. Realiza un contraste de hipótesis para probar si la varianza poblacional es igual a 4 con un nivel de significación $\alpha = 0.05$. Recuerda que $\frac{s^2(n-1)}{\sigma^2} \sim \chi_{n-1}^2$, es decir, el estadístico, insesgado para la varianza poblacional σ^2 , $\frac{s^2(n-1)}{\sigma^2}$ se distribuye como una χ_{n-1}^2 , siendo n el tamaño muestral, s^2 la cuasivarianza muestral.

Solución:

Para realizar un contraste de hipótesis para probar si la varianza poblacional es igual a 4, podemos usar la prueba de chi-cuadrado (χ^2) para una varianza.

Paso 1: Definir las Hipótesis

- **Hipótesis nula** (H_0): La varianza poblacional es igual a 4 ($\sigma^2 = 4$).
- **Hipótesis alternativa** (H_1): La varianza poblacional no es igual a 4 ($\sigma^2 \neq 4$).

Paso 2: Calcular la Estadística de Prueba

La estadística de prueba para la varianza es:

$$\chi^2 = \frac{(n-1)s^2}{\sigma_0^2}$$

donde:

- n es el tamaño de la muestra.
- s^2 es la varianza muestral.
- σ_0^2 es la varianza bajo la hipótesis nula.

Primero, calculemos la varianza muestral (s^2).

Media Muestral ($\bar{x}$)

$$\bar{x} = \frac{1}{20} \sum_{i=1}^{20} x_i = \frac{1}{20} \cdot 158 = 7.9$$

Varianza Muestral (s^2)

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{20} (x_i - \bar{x})^2$$

Calculando cada $(x_i - \bar{x})^2$:

- $(5 - 7.9)^2 = 8.41$ (aparece 2 veces): $8.41 \times 2 = 16.82$
- $(6 - 7.9)^2 = 3.61$ (aparece 2 veces): $3.61 \times 2 = 7.22$
- $(7 - 7.9)^2 = 0.81$ (aparece 4 veces): $0.81 \times 4 = 3.24$
- $(8 - 7.9)^2 = 0.01$ (aparece 4 veces): $0.01 \times 4 = 0.04$
- $(9 - 7.9)^2 = 1.21$ (aparece 4 veces): $1.21 \times 4 = 4.84$
- $(10 - 7.9)^2 = 4.41$ (aparece 4 veces): $4.41 \times 4 = 17.64$

Sumando estos valores:

$$\sum_{i=1}^{20} (x_i - \bar{x})^2 = 16.82 + 7.22 + 3.24 + 0.04 + 4.84 + 17.64 = 49.8$$

Entonces:

$$s^2 = \frac{49.8}{19} \approx 2.621$$

Paso 3: Calcular la Estadística de Prueba χ^2

Usamos la varianza bajo la hipótesis nula ($\sigma_0^2 = 4$):

$$\chi^2 = \frac{(20-1) \cdot 2.621}{4} = \frac{19 \cdot 2.621}{4} = \frac{49.799}{4} \approx 12.45$$

Paso 4: Determinar los Valores Críticos

Los valores críticos de la distribución χ^2 con $n-1 = 19$ grados de libertad para $\alpha = 0.05$ (prueba bilateral) son: - $\chi_{0.025,19}^2 \approx 32.852$ - $\chi_{0.975,19}^2 \approx 8.907$

Paso 5: Comparar el Valor de la Estadística de Prueba con los Valores Críticos

Para no rechazar H_0 , el valor de χ^2 debe estar entre los valores críticos:

$$8.907 < 12.45 < 32.852$$

Paso 6: Conclusión

Dado que el valor de χ^2 está dentro del rango de los valores críticos, no rechazamos la hipótesis nula H_0 al nivel de significación $\alpha = 0.05$. Esto significa que no hay suficiente evidencia para concluir que la varianza poblacional es diferente de 4.

Ejercicio 10: Contraste de Hipótesis (Comparación de Dos Medias)

Tienes dos muestras independientes:

- Muestra A:

$$x_A = \{23, 21, 22, 24, 25, 23, 24, 22, 23, 24\}$$

- Muestra B:

$$x_B = \{18, 19, 17, 20, 18, 19, 18, 19, 20, 18\}$$

Realiza un contraste de hipótesis para verificar si las medias de las dos poblaciones de las cuales se extrajeron las muestras son diferentes. Usa un nivel de significación $\alpha = 0.05$.

Solución:

Para realizar un contraste de hipótesis sobre si las medias de las dos poblaciones de las cuales se extrajeron las muestras son diferentes, podemos usar la prueba t para dos muestras independientes, también conocida como prueba t de Student para muestras independientes. Supongamos que las dos muestras son independientes y provienen de poblaciones con distribuciones normales y varianzas iguales.

Paso 1: Definir las Hipótesis

- **Hipótesis nula** (H_0): Las medias de las dos poblaciones son iguales ($\mu_A = \mu_B$).
- **Hipótesis alternativa** (H_1): Las medias de las dos poblaciones son diferentes ($\mu_A \neq \mu_B$).

Paso 2: Calcular las Estadísticas Descriptivas

Para las muestras x_A y x_B :

- Tamaño de la muestra (n_A y n_B):

$$n_A = 10, \quad n_B = 10$$

- Media muestral ($\bar{x}_A$ y $\bar{x}_B$):

$$\bar{x}_A = \frac{1}{10}(23 + 21 + 22 + 24 + 25 + 23 + 24 + 22 + 23 + 24) = 23.1$$

$$\bar{x}_B = \frac{1}{10}(18 + 19 + 17 + 20 + 18 + 19 + 18 + 19 + 20 + 18) = 18.6$$

- Varianza muestral (s_A^2 y s_B^2):

$$s_A^2 = \frac{1}{10-1} \sum_{i=1}^{10} (x_{Ai} - \bar{x}_A)^2$$

$$s_B^2 = \frac{1}{10-1} \sum_{i=1}^{10} (x_{Bi} - \bar{x}_B)^2$$

Calculando las varianzas muestrales:

Para la muestra A, calculando cada desviación al cuadrado: - $(23 - 23.1)^2 = 0.01$ (aparece 3 veces) - $(21 - 23.1)^2 = 4.41$ (aparece 1 vez) - $(22 - 23.1)^2 = 1.21$ (aparece 2 veces) - $(24 - 23.1)^2 = 0.81$ (aparece 3 veces) - $(25 - 23.1)^2 = 3.61$ (aparece 1 vez)

Suma: $0.01 \times 3 + 4.41 + 1.21 \times 2 + 0.81 \times 3 + 3.61 = 12.9$

$$s_A^2 = \frac{12.9}{9} \approx 1.433$$

Para la muestra B:

$$s_B^2 = \frac{1}{9}[(18 - 18.6)^2 + (19 - 18.6)^2 + \dots + (18 - 18.6)^2] = \frac{8.4}{9} \approx 0.933$$

Paso 3: Calcular la Estadística de Prueba t

La estadística de prueba t para dos muestras independientes es:

$$t = \frac{\bar{x}_A - \bar{x}_B}{\sqrt{s_p^2 \left(\frac{1}{n_A} + \frac{1}{n_B} \right)}}$$

donde s_p^2 es la varianza combinada (ponderada) y se calcula como:

$$s_p^2 = \frac{(n_A - 1)s_A^2 + (n_B - 1)s_B^2}{n_A + n_B - 2}$$

Sustituyendo los valores calculados:

$$s_p^2 = \frac{(10-1) \cdot 1.433 + (10-1) \cdot 0.933}{10+10-2} = \frac{12.9+8.4}{18} = \frac{21.3}{18} \approx 1.183$$

Ahora, calculamos t :

$$t = \frac{23.1 - 18.6}{\sqrt{1.183 \left(\frac{1}{10} + \frac{1}{10}\right)}} = \frac{4.5}{\sqrt{1.183 \times 0.2}} = \frac{4.5}{\sqrt{0.2367}} \approx \frac{4.5}{0.487} \approx 9.25$$

Paso 4: Determinar el Valor Crítico y Decisión

Para $\alpha = 0.05$ y grados de libertad $df = n_A + n_B - 2 = 18$, el valor crítico $t_{\alpha/2, df}$ para una prueba bilateral se puede obtener de una tabla de distribución t de Student. Aproximadamente, $t_{0.025, 18} \approx 2.101$.

Paso 5: Comparar el Valor de la Estadística de Prueba con el Valor Crítico

Comparamos el valor absoluto de la estadística de prueba con el valor crítico:

$$|t| = 9.25 > 2.101$$

Paso 6: Conclusión

Dado que el valor absoluto de la estadística de prueba t es mayor que el valor crítico, rechazamos la hipótesis nula H_0 . Esto significa que hay evidencia suficiente para concluir que las medias de las dos poblaciones son significativamente diferentes al nivel de significación $\alpha = 0.05$.

En resumen, el contraste de hipótesis indica que las medias de las dos poblaciones son diferentes.

Estimación y contraste paramétrico 2

Ejercicio 1: Propiedades de los estimadores

Sera $X_1, \dots, X_3$ y X_4 una muestra aleatoria de tamaño cuatro de una población cuya distribución es exponencial con parámetros θ desconocido. De las siguientes estadísticas, ¿cuáles son estimadores insesgados de θ ?

$$T_1 = \frac{1}{3}(X_1 + X_2) + \frac{1}{6}(X_3 + X_4)$$

$$T_2 = \frac{(4X_1 + 3X_2 + 2X_3 + 1X_4)}{5}$$

$$T_3 = \frac{(X_1 + X_2 + X_3 + X_4)}{4}$$

Solución: Para determinar si las estadísticas T_1, T_2 y T_3 son estimadores insesgados del parámetro θ de una distribución exponencial, necesitamos calcular la esperanza matemática de cada una y verificar si es igual a θ .

Primero, recordemos que si X_i sigue una distribución exponencial con parámetro θ , entonces la esperanza matemática de X_i es:

$$E[X_i] = \theta$$

Ahora, procedemos a analizar cada uno de los estimadores.

Estimador T_1

$$T_1 = \frac{1}{3}(X_1 + X_2) + \frac{1}{6}(X_3 + X_4)$$

Calculamos la esperanza matemática de T_1 :

$$E[T_1] = E\left[\frac{1}{3}(X_1 + X_2) + \frac{1}{6}(X_3 + X_4)\right]$$

Usando la linealidad de la esperanza, tenemos:

$$E[T_1] = \frac{1}{3}E[X_1] + \frac{1}{3}E[X_2] + \frac{1}{6}E[X_3] + \frac{1}{6}E[X_4]$$

Dado que $E[X_i] = \theta$ para todos i :

$$E[T_1] = \frac{1}{3}\theta + \frac{1}{3}\theta + \frac{1}{6}\theta + \frac{1}{6}\theta$$

$$E[T_1] = \frac{1}{3}\theta + \frac{1}{3}\theta + \frac{1}{6}\theta + \frac{1}{6}\theta = \theta$$

Por lo tanto, T_1 es un estimador insesgado de θ .

Estimador T_2

$$T_2 = \frac{4X_1 + 3X_2 + 2X_3 + X_4}{5}$$

Calculamos la esperanza matemática de T_2 :

$$E[T_2] = E\left[\frac{4X_1 + 3X_2 + 2X_3 + X_4}{5}\right]$$

Usando la linealidad de la esperanza, tenemos:

$$E[T_2] = \frac{4}{5}E[X_1] + \frac{3}{5}E[X_2] + \frac{2}{5}E[X_3] + \frac{1}{5}E[X_4]$$

Dado que $E[X_i] = \theta$ para todos i :

$$E[T_2] = \frac{4}{5}\theta + \frac{3}{5}\theta + \frac{2}{5}\theta + \frac{1}{5}\theta$$

$$E[T_2] = \left(\frac{4 + 3 + 2 + 1}{5}\right)\theta = \left(\frac{10}{5}\right)\theta = 2\theta$$

Por lo tanto, T_2 no es un estimador insesgado de θ .

Estimador T_3

$$T_3 = \frac{X_1 + X_2 + X_3 + X_4}{4}$$

Calculamos la esperanza matemática de T_3 :

$$E[T_3] = E\left[\frac{X_1 + X_2 + X_3 + X_4}{4}\right]$$

Usando la linealidad de la esperanza, tenemos:

$$E[T_3] = \frac{1}{4}E[X_1] + \frac{1}{4}E[X_2] + \frac{1}{4}E[X_3] + \frac{1}{4}E[X_4]$$

Dado que $E[X_i] = \theta$ para todos i :

$$E[T_3] = \frac{1}{4}\theta + \frac{1}{4}\theta + \frac{1}{4}\theta + \frac{1}{4}\theta$$

$$E[T_3] = \left(\frac{1+1+1+1}{4}\right)\theta = \left(\frac{4}{4}\right)\theta = \theta$$

Por lo tanto, T_3 es un estimador insesgado de θ .

Conclusión

De las estadísticas dadas, T_1 y T_3 son estimadores insesgados de θ . T_2 no es un estimador insesgado de θ .

Ejercicio 2: Propiedades de los estimadores

En un experimento binomial se observan x éxitos en n ensayos independientes. Se propone el siguiente estadístico como estimador del parámetro de proporción p :

$$T = \frac{x}{n}$$

Se pide demostrar que el estadístico T es un estimador consistente del parámetro binomial p .

Solución: Para demostrar que el estadístico $T = \frac{x}{n}$ es un estimador consistente del parámetro binomial p , necesitamos mostrar que T cumple con dos condiciones:

1. **No sesgado (o asintóticamente no sesgado):** La esperanza matemática de T es igual a p o converge a p cuando n tiende a infinito.
2. **Varianza que tiende a cero:** La varianza de T tiende a cero cuando n tiende a infinito.

Vamos a verificar ambas condiciones para T .

Paso 1: Verificar que T es un estimador no sesgado de p

Sabemos que x sigue una distribución binomial con parámetros n y p , es decir, $x \sim \text{Binomial}(n, p)$. La esperanza matemática de x es:

$$E[x] = np$$

El estimador T se define como:

$$T = \frac{x}{n}$$

Calculamos la esperanza matemática de T :

$$E[T] = E\left[\frac{x}{n}\right] = \frac{1}{n}E[x] = \frac{1}{n} \cdot np = p$$

Esto muestra que T es un estimador no sesgado de p .

Paso 2: Verificar que la varianza de T tiende a cero cuando n tiende a infinito

La varianza de x para una distribución binomial es:

$$\text{Var}(x) = np(1 - p)$$

Queremos encontrar la varianza de T :

$$\text{Var}(T) = \text{Var}\left(\frac{x}{n}\right) = \frac{1}{n^2}\text{Var}(x) = \frac{1}{n^2} \cdot np(1 - p) = \frac{p(1 - p)}{n}$$

Ahora, observamos el comportamiento de $\text{Var}(T)$ cuando n tiende a infinito:

$$\lim_{n \rightarrow \infty} \text{Var}(T) = \lim_{n \rightarrow \infty} \frac{p(1 - p)}{n} = 0$$

Esto muestra que la varianza de T tiende a cero a medida que n aumenta.

Dado que T es un estimador no sesgado de p y su varianza tiende a cero cuando n tiende a infinito, podemos concluir que T es un estimador consistente de p . Por lo tanto, hemos demostrado que el estadístico $T = \frac{x}{n}$ es un estimador consistente del parámetro de proporción p .

Ejercicio 3: Método de Máxima Verosimilitud

Sea $X_1, \dots, X_n$ una muestra aleatoria de una población cuya distribución es de Poisson con parámetro λ . Obtener el estimador de máxima verosimilitud de λ .

Solución:

Para obtener el estimador de máxima verosimilitud (MLE, por sus siglas en inglés) del parámetro λ de una distribución de Poisson basada en una muestra aleatoria $X_1, \dots, X_n$, seguimos estos pasos:

Paso 1: Función de verosimilitud

La función de verosimilitud para una muestra $X_1, \dots, X_n$ de una distribución de Poisson con parámetro λ es:

$$L(\lambda) = P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n \mid \lambda)$$

Como las X_i son independientes y cada X_i sigue una distribución de Poisson, la función de verosimilitud se puede escribir como:

$$L(\lambda) = \prod_{i=1}^n P(X_i = x_i \mid \lambda)$$

La función de probabilidad de una variable aleatoria X_i que sigue una distribución de Poisson es:

$$P(X_i = x_i \mid \lambda) = \frac{\lambda^{x_i} e^{-\lambda}}{x_i!}$$

Por lo tanto, la función de verosimilitud es:

$$L(\lambda) = \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!}$$

Paso 2: Log-verosimilitud

Para simplificar el proceso de maximización, trabajamos con el logaritmo de la función de verosimilitud, conocida como log-verosimilitud:

$$\ell(\lambda) = \log L(\lambda) = \log \left(\prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} \right)$$

Usando las propiedades del logaritmo, esto se convierte en:

$$\ell(\lambda) = \sum_{i=1}^n \log \left(\frac{\lambda^{x_i} e^{-\lambda}}{x_i!} \right)$$

Descomponemos la log-verosimilitud:

$$\ell(\lambda) = \sum_{i=1}^n (\log(\lambda^{x_i}) + \log(e^{-\lambda}) - \log(x_i!))$$

$$\ell(\lambda) = \sum_{i=1}^n (x_i \log \lambda - \lambda - \log(x_i!))$$

Podemos separar los términos que dependen de λ de los que no:

$$\ell(\lambda) = \sum_{i=1}^n x_i \log \lambda - \sum_{i=1}^n \lambda - \sum_{i=1}^n \log(x_i!)$$

Paso 3: Derivada de la log-verosimilitud

Para encontrar el MLE, derivamos $\ell(\lambda)$ con respecto a λ y establecemos la derivada igual a cero:

$$\frac{\partial \ell(\lambda)}{\partial \lambda} = \frac{\partial}{\partial \lambda} \left(\sum_{i=1}^n x_i \log \lambda - n\lambda - \sum_{i=1}^n \log(x_i!) \right)$$

Derivamos término a término:

$$\frac{\partial \ell(\lambda)}{\partial \lambda} = \sum_{i=1}^n x_i \cdot \frac{1}{\lambda} - n$$

Simplificando, obtenemos:

$$\frac{\partial \ell(\lambda)}{\partial \lambda} = \frac{1}{\lambda} \sum_{i=1}^n x_i - n$$

Establecemos la derivada igual a cero para encontrar el valor de λ que maximiza la log-verosimilitud:

$$\frac{1}{\lambda} \sum_{i=1}^n x_i - n = 0$$

$$\sum_{i=1}^n x_i = n\lambda$$

Paso 4: Resolver para λ

Despejamos λ :

$$\lambda = \frac{1}{n} \sum_{i=1}^n x_i$$

Resultado

El estimador de máxima verosimilitud (MLE) del parámetro λ es:

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i$$

Este resultado muestra que el MLE de λ es simplemente la media muestral de los datos $X_1, \dots, X_n$.

Ejercicio 4: Tamaño muestral

Una empresa quiere realizar una encuesta para estimar el nivel de satisfacción de sus clientes con un nuevo producto. La empresa desea que la estimación tenga un nivel de confianza del 95% y un margen de error del 5%. Basado en estudios previos, se espera que la proporción de clientes satisfechos sea aproximadamente del 70%. ¿Cuál es el tamaño muestral mínimo necesario para la encuesta?

Solución Para calcular el tamaño muestral mínimo necesario para estimar el nivel de satisfacción de los clientes con un nuevo producto con un nivel de confianza del 95% y un margen de error del 5%, podemos utilizar la fórmula para el tamaño de muestra en estimaciones de proporciones:

$$n = \frac{Z^2 \cdot p \cdot (1 - p)}{E^2}$$

Donde:

- Z es el valor crítico del nivel de confianza (para el 95%, $Z \approx 1.96$)
- p es la proporción estimada (en este caso, 0.70)
- E es el margen de error deseado (en este caso, 0.05)

Sustituyendo los valores en la fórmula:

$$n = \frac{(1.96)^2 \cdot 0.70 \cdot (1 - 0.70)}{(0.05)^2} = 322.6944$$

Dado que el tamaño muestral siempre se redondea al siguiente número entero, el tamaño muestral mínimo necesario es:

$$n \approx 323$$

Por lo tanto, la empresa necesita encuestar al menos a 323 clientes para estimar el nivel de satisfacción con un nivel de confianza del 95% y un margen de error del 5%.

Ejercicio 5: Intervalos de confianza

Una empresa quiere comparar la efectividad de dos programas de entrenamiento distintos para sus empleados. Para ello, selecciona dos grupos independientes de empleados y aplica un programa de entrenamiento diferente a cada grupo. Después del entrenamiento, se mide el rendimiento de cada empleado. Los resultados son los siguientes:

- Grupo 1 (Programa A): 15 empleados, media de rendimiento = 80, desviación estándar = 10
- Grupo 2 (Programa B): 12 empleados, media de rendimiento = 75, desviación estándar = 12

Se desea calcular un intervalo de confianza del 95% para la diferencia de las medias de rendimiento entre los dos programas de entrenamiento.

Solución:

Para calcular el intervalo de confianza para la diferencia de medias de dos muestras independientes con varianzas desconocidas y tamaños muestrales pequeños, usamos la distribución t de Student con la siguiente fórmula:

$$(\bar{X}_1 - \bar{X}_2) \pm t_{\alpha/2, df} \cdot \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Donde:

- $\bar{X}_1$ y $\bar{X}_2$ son las medias muestrales de los dos grupos.
- s_1 y s_2 son las desviaciones estándar de los dos grupos.
- n_1 y n_2 son los tamaños de muestra de los dos grupos.
- $t_{\alpha/2, df}$ es el valor crítico de la distribución t de Student para el nivel de confianza deseado.

- df son los grados de libertad calculados con la aproximación de Welch-Satterthwaite.

Primero, identificamos los valores:

- $\bar{X}_1 = 80, s_1 = 10, n_1 = 15$
- $\bar{X}_2 = 75, s_2 = 12, n_2 = 12$

Paso 1: Calcular los grados de libertad

Usamos la aproximación de Welch-Satterthwaite:

$$df = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{\left(\frac{s_1^2}{n_1}\right)^2}{n_1-1} + \frac{\left(\frac{s_2^2}{n_2}\right)^2}{n_2-1}}$$

Sustituyendo los valores:

$$df = \frac{\left(\frac{100}{15} + \frac{144}{12}\right)^2}{\frac{\left(\frac{100}{15}\right)^2}{14} + \frac{\left(\frac{144}{12}\right)^2}{11}} = \frac{(6.667 + 12)^2}{\frac{44.449}{14} + \frac{144}{11}} = \frac{348.544}{3.175 + 13.091} \approx 21.44$$

Redondeamos a $df = 21$ grados de libertad.

Paso 2: Determinar el valor crítico

Para un intervalo de confianza del 95% con $df = 21$, el valor crítico es:

$$t_{0.025, 21} \approx 2.080$$

Paso 3: Calcular el error estándar

$$\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} = \sqrt{\frac{10^2}{15} + \frac{12^2}{12}} = \sqrt{6.667 + 12} = \sqrt{18.667} \approx 4.32$$

Paso 4: Calcular el intervalo de confianza

$$(\bar{X}_1 - \bar{X}_2) \pm t_{\alpha/2, df} \cdot \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

$$(80 - 75) \pm 2.080 \cdot 4.32 \approx 5 \pm 8.99$$

Por lo tanto, el intervalo de confianza del 95% para la diferencia de medias es:

$$(-3.99, 13.99)$$

Interpretación: Con un 95% de confianza, la diferencia en el rendimiento promedio entre el Programa A y el Programa B se encuentra entre -3.99 y 13.99 puntos. Dado que el intervalo contiene el cero, no podemos concluir que existe una diferencia significativa entre los dos programas al nivel de confianza del 95%.

Ejercicio 6: Contraste de Hipótesis

Realiza un contraste de hipótesis para el problema planteado en el ejercicio anterior y proporciona un p -valor.

Solución: Para realizar un contraste de hipótesis sobre la diferencia de medias de dos muestras independientes y calcular el valor p , seguimos estos pasos:

Paso 1: Plantear las hipótesis

Queremos comparar los rendimientos medios de los dos programas de entrenamiento. Las hipótesis nulas y alternativas son:

- **Hipótesis nula (H_0):** No hay diferencia en las medias de rendimiento entre los dos programas, es decir, $\mu_1 - \mu_2 = 0$.
- **Hipótesis alternativa (H_a):** Hay una diferencia en las medias de rendimiento entre los dos programas, es decir, $\mu_1 - \mu_2 \neq 0$.

Paso 2: Calcular el estadístico de prueba

Utilizamos la fórmula del estadístico t para la diferencia de medias:

$$t = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Dado que bajo H_0 , $\mu_1 - \mu_2 = 0$, el estadístico t se simplifica a:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Sustituyendo los valores:

- $\bar{X}_1 = 80$
- $\bar{X}_2 = 75$
- $s_1 = 10$

- $s_2 = 12$
- $n_1 = 15$
- $n_2 = 12$

$$t = \frac{80 - 75}{\sqrt{\frac{10^2}{15} + \frac{12^2}{12}}} \approx 1.157$$

Paso 3: Determinar los grados de libertad

Para el contraste de hipótesis, utilizamos la aproximación de Welch-Satterthwaite para los grados de libertad df :

$$df = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{\left(\frac{s_1^2}{n_1}\right)^2}{n_1-1} + \frac{\left(\frac{s_2^2}{n_2}\right)^2}{n_2-1}} \approx 21.44$$

Redondeamos a 21 grados de libertad.

Paso 4: Calcular el valor p

Con $t = 1.157$ y $df = 21$, utilizamos una tabla t o una calculadora de distribuciones t para encontrar el valor p . Dado que es un contraste bilateral (dos colas), multiplicamos por 2 la probabilidad acumulada de la cola superior.

Usamos una calculadora de distribución t :

$$p - \text{valor} = 2 \times P(T > 1.157 \mid df = 21)$$

El valor p asociado con $t = 1.157$ y $df = 21$ se encuentra mediante tablas t o software estadístico. Aquí usaremos una aproximación:

$$p \approx 2 \times 0.128 \approx 0.256$$

Conclusión

El valor p es aproximadamente 0.256. Dado que este valor es mayor que el nivel de significancia comúnmente utilizado ($\alpha = 0.05$), no rechazamos la hipótesis nula.

No hay suficiente evidencia para afirmar que hay una diferencia significativa en las medias de rendimiento entre los dos programas de entrenamiento.

Ejercicio 7: Estimación en el muestreo

Mediante el empleo de R, genera 100 muestras, cada una de tamaño 15, de una distribución normal de media 120 y desviación estándar 8. Para cada muestra, construye un IC del 95% para la σ^2 . ¿Cuántos de estos intervalos contienen el verdadero valor de 64 para σ^2 ? ¿Este resultado está de acuerdo con lo que esperabas? Debes comenzar por derivar el IC para la varianza poblacional σ^2 . Para ello, recuerda que la cuasivarianza muestral

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

es un estimador insesgado para la varianza poblacional σ^2 y que, bajo condiciones de normalidad,

$$s^2 \sim \frac{\sigma^2 \chi_{n-1}^2}{n-1}.$$

Solución: Para calcular los intervalos de confianza para σ^2 , necesitamos ajustar un poco la fórmula del intervalo de confianza para σ . La fórmula para un intervalo de confianza del 95% para σ^2 es:

$$\left(\frac{(n-1) \cdot s^2}{\chi_{\alpha/2, n-1}^2}, \frac{(n-1) \cdot s^2}{\chi_{1-\alpha/2, n-1}^2} \right)$$

donde s^2 es la varianza muestral, n es el tamaño de la muestra y $\chi_{\alpha/2, n-1}^2$ y $\chi_{1-\alpha/2, n-1}^2$ son los percentiles correspondientes de la distribución chi-cuadrado con $n-1$ grados de libertad.

```
### Establecer la semilla para la reproducibilidad
set.seed(42)

### Parámetros
n_samples <- 100
sample_size <- 15
true_var <- 64
confidence_level <- 0.95

### Función para calcular el intervalo de confianza para la varianza
calculate_ci_var <- function(sample_var, n) {
  lower <- (n - 1) * sample_var / qchisq(0.975, df = n - 1)
  upper <- (n - 1) * sample_var / qchisq(0.025, df = n - 1)
  return(c(lower, upper))
}

### Generar las muestras y calcular las varianzas muestrales
```

```

samples <- matrix(rnorm(n_samples * sample_size, mean = 120, sd = 8)
                  , ncol = sample_size)
sample_vars <- apply(samples, 1, var)

### Calcular los intervalos de confianza para la varianza
cis_var <- apply(samples, 1, function(x) calculate_ci_var(var(x), length(x)))

### Contar cuántos intervalos contienen el verdadero valor de la varianza
contained <- apply(cis_var, 2, function(x) true_var >= x[1] & true_var <= x[2])
contained_count <- sum(contained)

### Imprimir el resultado
print(paste("Número de intervalos que contienen el verdadero valor de la varianza:"
            , contained_count))

```

```
[1] "Número de intervalos que contienen el verdadero valor de la varianza: 95"
```

Ejercicio 8: Muestreo

Una compañía de auditoría está llevando a cabo una revisión de los balances contables reportados por un banco. Quieren estimar la proporción de cuentas para las cuales existe una discrepancia entre lo reportado por el cliente y el banco. Se decide realizar un muestreo para obtener una estimación precisa de esta proporción. Se sabe que la proporción real de cuentas con discrepancias es desconocida, pero la compañía de auditoría quiere obtener una estimación con un nivel de confianza del 99%. Además, desean que el margen de error máximo en la estimación sea de 0.01 unidades. ¿Cuántas cuentas deberán seleccionarse para satisfacer estos requisitos?

Solución:

Datos:

- Nivel de confianza ($1 - \alpha$): 99% (es decir, $\alpha = 0.01$)
- Margen de error (E): 0.01

Para calcular el tamaño muestral necesario, utilizaremos la fórmula para el tamaño de muestra en estimaciones de proporciones:

$$n = \frac{Z^2 \cdot p \cdot (1 - p)}{E^2}$$

Donde:

- n es el tamaño muestral necesario.
- Z es el valor crítico de la distribución normal estándar correspondiente al nivel de confianza $(\alpha/2)$.
- p es la proporción estimada (desconocida en este caso).
- E es el margen de error deseado.

Dado que no tenemos una estimación inicial de p , usaremos $p = 0.5$ como valor más conservador, ya que maximiza el tamaño de la muestra para un margen de error dado.

Primero, encontramos el valor crítico Z para un nivel de confianza del 99%:

1. $\alpha/2 = 0.01/2 = 0.005$
2. Buscamos el valor correspondiente en la tabla de la distribución normal estándar, que es aproximadamente 2.576.

Luego, utilizamos esta información para calcular el tamaño muestral:

$$n = \frac{2.576^2 \cdot 0.5 \cdot (1 - 0.5)}{0.01^2} \approx 16589.44$$

Redondeando al próximo entero superior, obtenemos que el tamaño muestral necesario es $n = 16590$.

Por lo tanto, se necesitan seleccionar al menos 16590 cuentas para que, con un nivel de confianza del 99%, la proporción muestral esté a no más de 0.01 unidad de la proporción real.

Ejercicio 9: Contraste de Hipótesis

Supongamos que un jugador de fútbol afirma que su tasa de éxito en los tiros de penalti es superior al 70%. Sin embargo, un analista deportivo cree que la tasa de éxito es menor que eso. Para probar su hipótesis, el analista revisa los datos de los últimos 50 tiros de penaltis del jugador y encuentra que lograron marcar en 30 de ellos. ¿Quién tiene razón?

Solución:

El analista decide realizar un contraste de hipótesis al nivel de significancia del 5%.

Hipótesis:

- Hipótesis nula (H_0): La tasa de éxito en los tiros de penal es igual o superior al 70%.
- Hipótesis alternativa (H_1): La tasa de éxito en los tiros de penal es menor que 70%.

Nivel de Significancia: $\alpha = 0.05$

Datos:

- Número de tiros de penal (n): 50

- Número de tiros de penal exitosos (x): 30

Paso 1: Formulación de Hipótesis

$$H_0 : p \geq 0.70$$

$$H_1 : p < 0.70$$

Donde p es la proporción de tiros de penal exitosos.

Paso 2: Estadístico de Contraste

Dado que estamos trabajando con una proporción muestral y el tamaño de la muestra es grande ($n > 30$), podemos utilizar un estadístico z para el contraste de hipótesis:

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0 \cdot (1-p_0)}{n}}}$$

Donde $\hat{p}$ es la proporción muestral, p_0 es la proporción bajo la hipótesis nula y n es el tamaño de la muestra.

Paso 3: Regla de Decisión

Rechazamos la hipótesis nula si $z < -z_\alpha$, donde $-z_\alpha$ es el valor crítico correspondiente al nivel de significancia α en el lado izquierdo de la distribución normal estándar.

Paso 4: Cálculo del Estadístico de Contraste y Valor Crítico

Primero, calculamos la proporción muestral:

$$\hat{p} = \frac{x}{n} = \frac{30}{50} = 0.60$$

Luego, calculamos el estadístico de contraste:

$$z = \frac{0.60 - 0.70}{\sqrt{\frac{0.70 \cdot (1-0.70)}{50}}} = \frac{-0.10}{\sqrt{\frac{0.21}{50}}} = \frac{-0.10}{\sqrt{0.0042}} = \frac{-0.10}{0.0648} \approx -1.543$$

Utilizando una tabla de la distribución normal estándar o un software estadístico, encontramos que $-z_{0.05} \approx -1.645$.

Paso 5: Toma de Decisiones

Como $z = -1.543$ es mayor que $-z_\alpha = -1.645$ (es decir, $-1.543 > -1.645$), **no rechazamos** la hipótesis nula.

Conclusión:

Con un nivel de significancia del 5%, **no hay evidencia suficiente** para concluir que la tasa de éxito en los tiros de penal es menor que el 70%. Los datos observados (60% de éxito) son compatibles con la afirmación del jugador de que su tasa de éxito es al menos del 70%, considerando la variabilidad muestral.

Ejercicio 10: Datos

Se desea investigar si la edad media de los clientes de un banco excede los 40 años. Se realiza un análisis estadístico utilizando datos de una campaña de marketing bancario. Se calcula un intervalo de confianza para la edad promedio de los clientes basado en una muestra aleatoria de 1000 clientes. Posteriormente, se lleva a cabo un contraste de hipótesis para determinar si la edad media es mayor que 40 años, utilizando un nivel de significancia del 5%. Emplea para resolver este ejercicio los datos de la base de datos **bank** del repositorio UCI.

Solución:

```
# --- Descarga y lectura (robusto) ---
url <- "https://archive.ics.uci.edu/ml/machine-learning-databases/00222/bank.zip"
zip_file <- "bank.zip"
if (!file.exists(zip_file)) download.file(url, zip_file, mode = "wb")
data_dir <- tempdir()
unzip(zip_file, files = "bank-full.csv", exdir = data_dir)
bank <- read.csv(file.path(data_dir, "bank-full.csv"), sep = ";")

# --- Muestreo reproducible ---
set.seed(20251006) # fija la semilla para repetir el resultado
sample_size <- 1000
idx <- sample.int(nrow(bank), sample_size, replace = FALSE)
age_sample <- bank$age[idx]

# --- Estadísticos muestrales ---
x_bar <- mean(age_sample)
s <- sd(age_sample)
n <- length(age_sample)

# --- Planteamiento del contraste ---
mu_0 <- 40
alpha <- 0.05

# --- IC 95% UNA COLA (coherente con H1: mu > mu0) ---
# Límite inferior (cola derecha): (x_bar - t_{alpha} * s/sqrt(n), +Inf)
```

```

tcrit_one <- qt(1 - alpha, df = n - 1)
lower_one <- x_bar - tcrit_one * (s / sqrt(n))

# --- Test t unilateral (cola derecha) ---
t_stat <- (x_bar - mu_0) / (s / sqrt(n))
p_val <- pt(t_stat, df = n - 1, lower.tail = FALSE) # p-valor una cola

# --- Resultados ---
cat(sprintf("IC (una cola, 95%) para la media: (%.4f, +Inf)\n", lower_one))

```

IC (una cola, 95%) para la media: (40.5576, +Inf)

```

cat(sprintf("Estadístico t = %.4f, gl = %d, p-valor (una cola) = %.5f\n",
            t_stat, n - 1, p_val))

```

Estadístico t = 3.3297, gl = 999, p-valor (una cola) = 0.00045

```

if (p_val < alpha) {
  cat("Conclusión: Rechazamos H0. La edad media es mayor que 40 años (=0.05).\n")
} else {
  cat("Conclusión: No rechazamos H0. No hay evidencia suficiente de que la edad media sea > 40 años.\n")
}

```

Conclusión: Rechazamos H0. La edad media es mayor que 40 años (=0.05).

Contraste no paramétrico

Ejercicio 1:

Un estudio quiere analizar si hay diferencias significativas en la distribución de la duración del sueño entre dos grupos de personas: estudiantes universitarios y trabajadores a tiempo completo. Para ello, se recolectaron dos muestras independientes de tamaño $n1 = 20$ para estudiantes y $n2 = 30$ para trabajadores. Los datos representan las horas de sueño por noche durante una semana para cada participante.

A partir de los datos recopilados, se desea determinar si hay evidencia estadística para afirmar que las distribuciones de horas de sueño difieren entre los dos grupos.

```
### Muestras de horas de sueño para estudiantes universitarios (grupo 1)
muestras_estudiantes <- c(7.2, 7.0, 6.8, 7.5, 7.1, 7.3, 7.2, 7.4, 7.0,
                          7.6, 6.5, 6.9, 7.2, 7.3, 7.1, 6.4, 7.5, 7.0,
                          7.2, 7.3)

### Muestras de horas de sueño para trabajadores a tiempo completo (grupo 2)
muestras_trabajadores <- c(7.5, 6.3, 6.7, 6.9, 7.3, 6.8, 7.3, 6.9, 6.5,
                          6.2, 6.8, 7.0, 6.3, 7.6, 6.9, 6.5, 7.4, 6.7,
                          6.6, 7.2, 6.7, 6.9, 7.1, 6.3, 6.6, 6.1, 6.9,
                          7.1, 6.3, 6.6)
```

Solución:

1. Formulación de Hipótesis:

- Hipótesis Nula (H_0): Las muestras de estudiantes y trabajadores provienen de la misma distribución de horas de sueño.
- Hipótesis Alternativa (H_1): Las muestras de estudiantes y trabajadores provienen de distribuciones diferentes de horas de sueño.

2. Nivel de Significación:

Se establece un nivel de significancia de $\alpha = 0.05$.

3. Prueba Estadística:

Se utilizará la Prueba de Kolmogorov-Smirnov para dos muestras.

4. Procedimiento de Prueba:

Se ordenan los datos de ambas muestras y se calculan las funciones de distribución acumulativa (CDF) empíricas para cada grupo.

Luego, se calcula la estadística de prueba D que representa la máxima diferencia vertical entre las dos CDF empíricas.

5. Regla de Decisión:

Si el valor D calculado es mayor que el valor crítico de Kolmogorov-Smirnov para dos muestras con un nivel de significancia de $\alpha = 0.05$, se rechaza la hipótesis nula y se concluye que hay diferencias significativas en la distribución de horas de sueño entre los dos grupos.

6. Interpretación de Resultados:

Se interpreta el valor D calculado junto con el valor crítico de la tabla de Kolmogorov-Smirnov para dos muestras. Si D es mayor que el valor crítico, se rechaza H_0 y se concluye que hay diferencias significativas en las distribuciones de horas de sueño entre estudiantes y trabajadores. De lo contrario, no hay suficiente evidencia para rechazar H_0 y se concluye que no hay diferencias significativas en las distribuciones de horas de sueño entre los dos grupos.

```
### Realizar la prueba de Kolmogorov-Smirnov para dos muestras
ks_test <- ks.test(muestras_estudiantes, muestras_trabajadores)

### Mostrar el resultado
print(ks_test)
```

Exact two-sample Kolmogorov-Smirnov test

```
data:  muestras_estudiantes and muestras_trabajadores
D = 0.5, p-value = 0.001759
alternative hypothesis: two-sided
```

En este caso, dado que el *valor* es menor que un grado de significación 0.05 podemos rechazar la hipótesis nula en favor de la alternativa.

Ejercicio 2:

Un estudio realizado en una comunidad recopiló información sobre el género (hombre, mujer) y las preferencias de deportes (fútbol, baloncesto, tenis) de un grupo de personas. Los datos se muestran en la siguiente tabla de contingencia:

	Fútbol	Baloncesto	Tenis
Hombre	30	20	10
Mujer	20	25	15

Se desea determinar si hay una asociación significativa entre el género y las preferencias de deportes en la población utilizando la prueba de chi-cuadrado de independencia.

Solución:

- Hipótesis Nula (H_0): No hay asociación entre el género y las preferencias de deportes en la población.
- Hipótesis Alternativa (H_1): Hay una asociación entre el género y las preferencias de deportes en la población.

Para resolver este ejercicio, calcularemos la estadística de prueba chi-cuadrado siguiendo estos pasos:

1. Calcular las frecuencias esperadas bajo la hipótesis nula de independencia.
2. Calcular la estadística de prueba chi-cuadrado utilizando la fórmula:

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

donde O_{ij} son las frecuencias observadas y E_{ij} son las frecuencias esperadas.

Paso 1: Calcular los totales

$$\text{Total} = 30 + 20 + 10 + 20 + 25 + 15 = 120$$

$$\text{Frecuencia Total Hombres} = 30 + 20 + 10 = 60$$

$$\text{Frecuencia Total Mujeres} = 20 + 25 + 15 = 60$$

$$\text{Frecuencia Total Fútbol} = 30 + 20 = 50$$

$$\text{Frecuencia Total Baloncesto} = 20 + 25 = 45$$

$$\text{Frecuencia Total Tennis} = 10 + 15 = 25$$

Paso 2: Calcular las frecuencias esperadas

La fórmula para cada celda es: $E_{ij} = \frac{\text{Total fila}_i \times \text{Total columna}_j}{\text{Total general}}$

$$E_{\text{Hombre, Fútbol}} = \frac{60 \times 50}{120} = 25$$

$$E_{\text{Hombre, Baloncesto}} = \frac{60 \times 45}{120} = 22.5$$

$$E_{\text{Hombre, Tennis}} = \frac{60 \times 25}{120} = 12.5$$

$$E_{\text{Mujer, Fútbol}} = \frac{60 \times 50}{120} = 25$$

$$E_{\text{Mujer, Baloncesto}} = \frac{60 \times 45}{120} = 22.5$$

$$E_{\text{Mujer, Tennis}} = \frac{60 \times 25}{120} = 12.5$$

Paso 3: Calcular el estadístico chi-cuadrado

Utilizando los datos observados:

$$O_{11} = 30, \quad O_{12} = 20, \quad O_{13} = 10, \quad O_{21} = 20, \quad O_{22} = 25, \quad O_{23} = 15$$

Y las frecuencias esperadas:

$$E_{11} = 25, \quad E_{12} = 22.5, \quad E_{13} = 12.5, \quad E_{21} = 25, \quad E_{22} = 22.5, \quad E_{23} = 12.5$$

Aplicamos la fórmula:

$$\chi^2 = \frac{(30 - 25)^2}{25} + \frac{(20 - 22.5)^2}{22.5} + \frac{(10 - 12.5)^2}{12.5} + \frac{(20 - 25)^2}{25} + \frac{(25 - 22.5)^2}{22.5} + \frac{(15 - 12.5)^2}{12.5}$$

$$\chi^2 = \frac{25}{25} + \frac{6.25}{22.5} + \frac{6.25}{12.5} + \frac{25}{25} + \frac{6.25}{22.5} + \frac{6.25}{12.5}$$

$$\chi^2 = 1 + 0.278 + 0.5 + 1 + 0.278 + 0.5 = 3.556$$

Por lo tanto, la estadística de prueba chi-cuadrado es aproximadamente $\chi^2 \approx 3.556$.

Paso 4: Determinar el valor crítico

Para una prueba de independencia con un nivel de significancia de $\alpha = 0.05$ y grados de libertad $df = (r - 1)(c - 1)$, donde r es el número de filas y c es el número de columnas.

Para esta tabla: $df = (2 - 1)(3 - 1) = 2$

El valor crítico de chi-cuadrado para $\alpha = 0.05$ y $df = 2$ es aproximadamente 5.99.

Paso 5: Conclusión

Dado que el valor calculado de la estadística de prueba chi-cuadrado ($\chi^2 \approx 3.556$) es **menor** que el valor crítico ($\chi^2_{crítico} = 5.99$), **no rechazamos la hipótesis nula**.

No hay evidencia suficiente para concluir que existe una asociación significativa entre el género y las preferencias de deportes en la población al nivel de significancia del 5%.

Ejercicio 3:

Prueba:

Se llevó a cabo un estudio para comparar los tiempos de respuesta entre dos grupos de personas expuestas a diferentes condiciones de entrenamiento. Para ello, se registraron los tiempos de respuesta (en milisegundos) de 15 personas en el Grupo A y 18 personas en el Grupo B. Los datos obtenidos se muestran a continuación:

Grupo A: 45.1, 38.0, 52.4, 40.1, 47.5, 41.2, 43.5, 39.7, 36.1, 44.2, 50.5, 48.1, 42.4, 46.1, 49.5

Grupo B: 55.3, 60.4, 58.9, 62.0, 54.1, 57.8, 59.3, 63.6, 56.4, 61.7, 58, 64.3, 53.7, 66.1, 67.1, 65.2, 68.3, 50.1

Determine si hay una diferencia significativa en los tiempos de respuesta entre los dos grupos. Para determinar si hay una diferencia significativa en los tiempos de respuesta entre los dos grupos, puedes utilizar la prueba de Mann-Whitney U. Esta prueba no paramétrica se utiliza para comparar las distribuciones de dos muestras independientes y determinar si una muestra tiene valores significativamente mayores o menores que la otra.

Solucion:

Para determinar si hay una diferencia significativa en los tiempos de respuesta entre los dos grupos, podemos aplicar la prueba de Mann-Whitney U. A continuación, se detallan los pasos para realizar esta prueba.

Paso 1: Formular las hipótesis

- H_0 : No hay diferencia significativa en los tiempos de respuesta entre los dos grupos (las distribuciones son iguales).
- H_1 : Hay una diferencia significativa en los tiempos de respuesta entre los dos grupos (las distribuciones no son iguales).

Paso 2: Combinar y ordenar las observaciones

Combinamos todas las observaciones y las ordenamos en orden ascendente:

Datos	Grupo
36.1	A
38.0	A
39.7	A
40.1	A
41.2	A
42.4	A
43.5	A
44.2	A
45.1	A
46.1	A
47.5	A
48.1	A
49.5	A
50.1	B
50.5	A
52.4	A
53.7	B
54.1	B
55.3	B
56.4	B
57.8	B
58.0	B
58.9	B
59.3	B
60.4	B
61.7	B
62.0	B
63.6	B
64.3	B
65.2	B
66.1	B
67.1	B
68.3	B

Paso 3: Asignar rangos a las observaciones

Asignamos rangos a las observaciones, donde el rango más bajo es 1 y el rango más alto es el

número total de observaciones (33). En caso de empate, se asigna el promedio de los rangos para los valores empatados.

Datos	Grupo	Rango
36.1	A	1
38.0	A	2
39.7	A	3
40.1	A	4
41.2	A	5
42.4	A	6
43.5	A	7
44.2	A	8
45.1	A	9
46.1	A	10
47.5	A	11
48.1	A	12
49.5	A	13
50.1	B	14
50.5	A	15
52.4	A	16
53.7	B	17
54.1	B	18
55.3	B	19
56.4	B	20
57.8	B	21
58.0	B	22
58.9	B	23
59.3	B	24
60.4	B	25
61.7	B	26
62.0	B	27
63.6	B	28
64.3	B	29
65.2	B	30
66.1	B	31
67.1	B	32
68.3	B	33

Paso 4: Sumar los rangos de cada grupo

- Suma de rangos del Grupo A (R_A): $1+2+3+4+5+6+7+8+9+10+11+12+13+15+16 = 122$

- Suma de rangos del Grupo B (R_B): $14 + 17 + 18 + 19 + 20 + 21 + 22 + 23 + 24 + 25 + 26 + 27 + 28 + 29 + 30 + 31 + 32 + 33 = 439$

Paso 5: Calcular el estadístico U de Mann-Whitney

$$U_A = n_A \times n_B + \frac{n_A(n_A + 1)}{2} - R_A$$

$$U_B = n_A \times n_B + \frac{n_B(n_B + 1)}{2} - R_B$$

Donde $n_A = 15$ y $n_B = 18$.

$$U_A = 15 \times 18 + \frac{15 \times 16}{2} - 122 = 268$$

$$U_B = 15 \times 18 + \frac{18 \times 19}{2} - 439 = 2$$

El valor de U es el mínimo de U_A y U_B :

$$U = \min(268, 2) = 2$$

Paso 6: Determinar el valor crítico

Para un nivel de significancia del 5% ($\alpha = 0.05$) y tamaños de muestra $n_A = 15$ y $n_B = 18$, el valor crítico de U se puede buscar en una tabla de la distribución de Mann-Whitney U. Para estos tamaños de muestra, el valor crítico de U es aproximadamente 84.

Paso 7: Tomar una decisión

Como $U = 2$ es menor que el valor crítico 84, rechazamos la hipótesis nula H_0 .

Conclusión

Hay una diferencia significativa en los tiempos de respuesta entre los dos grupos. Esto sugiere que las diferentes condiciones de entrenamiento tienen un impacto significativo en los tiempos de respuesta.

Ejercicio 4

Supongamos que estamos trabajando con un conjunto de datos de un modelo de clasificación que predice si los clientes de una tienda en línea harán una compra (Sí o No) basado en varias características. Queremos investigar si existe una asociación entre dos variables categóricas en nuestro conjunto de datos: “Género” (Hombre, Mujer) y “Compra” (Sí, No).

Hemos entrenado un modelo de clasificación y obtenido las siguientes predicciones y datos observados para una muestra de 200 clientes:

Género	Compra: Sí	Compra: No
Hombre	50	30
Mujer	70	50

Solución:

Paso 1: Formular las Hipótesis

- **Hipótesis Nula (H_0):** No hay asociación entre el género y la compra (son independientes).
- **Hipótesis Alternativa (H_1):** Existe una asociación entre el género y la compra (no son independientes).

Paso 2: Crear la Tabla de Contingencia

La tabla de contingencia muestra el número de observaciones para cada combinación de las categorías:

Género	Compra: Sí	Compra: No	Total
Hombre	50	30	80
Mujer	70	50	120
Total	120	80	200

Paso 3: Calcular los Valores Esperados

Para cada celda de la tabla de contingencia, calculamos el valor esperado bajo la hipótesis nula de independencia:

$$E_{ij} = \frac{(F_i \times F_j)}{N}$$

donde E_{ij} es el valor esperado para la celda en la fila i y la columna j , F_i es el total de la fila i , F_j es el total de la columna j , y N es el total de observaciones.

Género	Compra: Sí	Compra: No
Hombre	$\frac{80 \times 120}{200} = 48$	$\frac{80 \times 80}{200} = 32$
Mujer	$\frac{120 \times 120}{200} = 72$	$\frac{120 \times 80}{200} = 48$

Paso 4: Calcular el Estadístico Chi-Cuadrado

El estadístico chi-cuadrado se calcula usando la fórmula:

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

donde O_{ij} es el valor observado y E_{ij} es el valor esperado.

$$\chi^2 = \frac{(50 - 48)^2}{48} + \frac{(30 - 32)^2}{32} + \frac{(70 - 72)^2}{72} + \frac{(50 - 48)^2}{48} \approx 0.3472$$

Paso 5: Determinar el Valor Crítico y Tomar una Decisión

Para un nivel de significancia del 5% ($\alpha = 0.05$) y con grados de libertad:

$$df = (n_{filas} - 1) \times (n_{columnas} - 1) = (2 - 1) \times (2 - 1) = 1$$

El valor crítico de chi-cuadrado para 1 grado de libertad al nivel de significancia 0.05 es aproximadamente 3.841.

Conclusión

Dado que el estadístico chi-cuadrado calculado (0.3472) es menor que el valor crítico (3.841), no rechazamos la hipótesis nula H_0 .

Por lo tanto, no hay evidencia suficiente para concluir que existe una asociación significativa entre el género y la compra en esta muestra de datos.

Ejercicio 5

Supongamos que hemos desarrollado un modelo de clasificación para predecir el riesgo crediticio de los clientes de un banco, clasificándolos como “Alto Riesgo” o “Bajo Riesgo”. Queremos evaluar si existe una asociación significativa entre las predicciones del modelo y los valores reales observados en un conjunto de prueba.

Se toma una muestra de 300 clientes, y se obtiene la siguiente tabla de contingencia que muestra la distribución de las predicciones del modelo y los valores reales observados:

	Real: Alto Riesgo	Real: Bajo Riesgo	Total
Predicción: Alto Riesgo	80	30	110
Predicción: Bajo Riesgo	50	140	190
Total	130	170	300

Solución:

Paso 1: Formular las Hipótesis

- **Hipótesis Nula (H_0):** No hay asociación entre las predicciones del modelo y los valores reales observados (son independientes).
- **Hipótesis Alternativa (H_1):** Existe una asociación entre las predicciones del modelo y los valores reales observados (no son independientes).

Paso 2: Crear la Tabla de Contingencia

La tabla de contingencia ya está proporcionada:

	Real: Alto Riesgo	Real: Bajo Riesgo	Total
Predicción: Alto Riesgo	80	30	110
Predicción: Bajo Riesgo	50	140	190
Total	130	170	300

Paso 3: Calcular los Valores Esperados

Para cada celda de la tabla de contingencia, calculamos el valor esperado bajo la hipótesis nula de independencia:

$$E_{ij} = \frac{(F_i \times F_j)}{N}$$

donde E_{ij} es el valor esperado para la celda en la fila i y la columna j , F_i es el total de la fila i , F_j es el total de la columna j , y N es el total de observaciones.

	Real: Alto Riesgo	Real: Bajo Riesgo
Predicción: Alto Riesgo	$\frac{110 \times 130}{300} = 47.67$	$\frac{110 \times 170}{300} = 62.33$
Predicción: Bajo Riesgo	$\frac{190 \times 130}{300} = 82.33$	$\frac{190 \times 170}{300} = 107.67$

Paso 4: Calcular el Estadístico Chi-Cuadrado

El estadístico chi-cuadrado se calcula usando la fórmula:

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

donde O_{ij} es el valor observado y E_{ij} es el valor esperado.

$$\chi^2 = \frac{(80 - 47.67)^2}{47.67} + \frac{(30 - 62.33)^2}{62.33} + \frac{(50 - 82.33)^2}{82.33} + \frac{(140 - 107.67)^2}{107.67} = 61.13$$

Paso 5: Determinar el Valor Crítico y Tomar una Decisión

Para un nivel de significancia del 5% ($\alpha = 0.05$) y con grados de libertad:

$$df = (n_{filas} - 1) \times (n_{columnas} - 1) = (2 - 1) \times (2 - 1) = 1$$

El valor crítico de chi-cuadrado para 1 grado de libertad al nivel de significancia 0.05 es aproximadamente 3.841.

Conclusión

Dado que el estadístico chi-cuadrado calculado (61.13) es mucho mayor que el valor crítico (3.841), rechazamos la hipótesis nula H_0 .

Por lo tanto, hay evidencia suficiente para concluir que existe una asociación significativa entre las predicciones del modelo y los valores reales observados. Esto indica que las predicciones del modelo están asociadas con los valores reales, lo que sugiere que el modelo tiene un buen desempeño en la clasificación del riesgo crediticio de los clientes.

Ejercicio 6

Un investigador desea evaluar si un nuevo método de enseñanza mejora las calificaciones de los estudiantes. Para ello, selecciona a 10 estudiantes y mide sus calificaciones en una prueba antes y después de aplicar el nuevo método durante un semestre. Los datos obtenidos son los siguientes:

Estudiante	Calificación Antes (X)	Calificación Después (Y)
1	65	75
2	70	78
3	60	65
4	72	80
5	68	74
6	75	85
7	63	68

Estudiante	Calificación Antes (X)	Calificación Después (Y)
8	70	77
9	67	73
10	66	69

Para determinar si hay una diferencia significativa en las calificaciones antes y después del nuevo método de enseñanza, se realizará un contraste de hipótesis utilizando la prueba de Wilcoxon para muestras pareadas.

Solución:

Paso 1: Formular las Hipótesis

- **Hipótesis Nula** (H_0): No hay diferencia en las calificaciones antes y después del nuevo método de enseñanza.
- **Hipótesis Alternativa** (H_1): Hay una diferencia en las calificaciones antes y después del nuevo método de enseñanza.

Paso 2: Calcular las Diferencias y Ordenarlas por Rangos

Calculamos la diferencia $D = Y - X$ y luego ordenamos las diferencias por rangos según su valor absoluto, asignando el promedio de rangos en caso de empates.

Primero, identificamos las diferencias: 10, 8, 5, 8, 6, 10, 5, 7, 6, 3

Ordenadas por valor absoluto: 3, 5, 5, 6, 6, 7, 8, 8, 10, 10

Asignación de rangos con empates: - 3 $\rightarrow$ rango 1 - 5, 5 $\rightarrow$ rangos $(2+3)/2 = 2.5$ - 6, 6 $\rightarrow$ rangos $(4+5)/2 = 4.5$ - 7 $\rightarrow$ rango 6 - 8, 8 $\rightarrow$ rangos $(7+8)/2 = 7.5$ - 10, 10 $\rightarrow$ rangos $(9+10)/2 = 9.5$

Est.	Antes (X)	Después (Y)	D = Y - X	Rango
1	65	75	10	9.5
2	70	78	8	7.5
3	60	65	5	2.5
4	72	80	8	7.5
5	68	74	6	4.5
6	75	85	10	9.5
7	63	68	5	2.5
8	70	77	7	6
9	67	73	6	4.5
10	66	69	3	1

Paso 3: Calcular la Suma de Rangos

Sumamos los rangos de las diferencias positivas (mejoras):

$$W_+ = 9.5 + 7.5 + 2.5 + 7.5 + 4.5 + 9.5 + 2.5 + 6 + 4.5 + 1 = 55$$

Como todas las diferencias son positivas (no hay empeoramientos), $W_- = 0$.

Paso 4: Determinar el Valor Crítico y Comparar

Para $n = 10$ y $\alpha = 0.05$, el valor crítico para la prueba de Wilcoxon pareada bilateral es aproximadamente 8.

Comparando el menor de los valores (W_- o su complemento) con el valor crítico:

$$W_- = 0 < 8$$

Paso 5: Conclusión

Dado que $W_- = 0$ es menor que el valor crítico de 8, rechazamos la hipótesis nula H_0 . Esto indica que hay una diferencia significativa en las calificaciones antes y después de aplicar el nuevo método de enseñanza, con evidencia de mejora en el rendimiento de los estudiantes.

Ejercicio 7

Pregunta: Un nutricionista quiere evaluar el efecto de una nueva dieta en la presión arterial de los pacientes. Se mide la presión arterial sistólica de 12 pacientes antes y después de seguir la dieta durante un mes. Los datos son los siguientes:

Paciente	Antes (X)	Después (Y)
1	135	130
2	140	135
3	150	145
4	145	142
5	160	155
6	155	150
7	148	150
8	160	158
9	142	140
10	138	136
11	150	149
12	145	146

Determinar si hay una diferencia significativa en la presión arterial sistólica antes y después de seguir la dieta utilizando la prueba del signo para observaciones por pares.

Solución:

1. **Hipótesis:**

- H_0 : No hay diferencia en la presión arterial sistólica antes y después de la dieta.
- H_1 : Hay una diferencia en la presión arterial sistólica antes y después de la dieta.

2. **Diferencias:**

Paciente	Antes (X)	Después (Y)	Diferencia (D = X - Y)	Signo
1	135	130	5	+
2	140	135	5	+
3	150	145	5	+
4	145	142	3	+
5	160	155	5	+
6	155	150	5	+
7	148	150	-2	-
8	160	158	2	+
9	142	140	2	+
10	138	136	2	+
11	150	149	1	+
12	145	146	-1	-

3. **Contar los Signos:**

- $S_+ = 10$ (número de diferencias positivas)
- $S_- = 2$ (número de diferencias negativas)
- $n = 12$ (total de pares)

4. **Estadístico de Prueba:** El estadístico de la prueba del signo es el menor entre S_+ y S_- :

$$S = \min(S_+, S_-) = \min(10, 2) = 2$$

5. **Valor Crítico:** Para $n = 12$ y $\alpha = 0.05$ (prueba bilateral), el valor crítico de la prueba del signo es 2.

Esto significa que rechazamos H_0 si $S \leq 2$.

Alternativamente, bajo la hipótesis nula, S_+ sigue una distribución Binomial(12, 0.5).

Para una prueba bilateral:

$$P(S_+ \leq 2) = P(S_+ \geq 10) \approx 0.0193 < 0.025$$

6. Decisión:

- Como el estadístico de la prueba $S = 2$ es igual al valor crítico, **rechazamos la hipótesis nula H_0** .

Alternativamente, el p-valor bilateral es: $2 \times P(S_+ \leq 2) \approx 2 \times 0.0193 = 0.0386 < 0.05$

Conclusión:

Hay evidencia suficiente para concluir que existe una diferencia significativa en la presión arterial sistólica antes y después de la dieta al nivel de significancia del 5%. La dieta parece tener un efecto, reduciendo la presión arterial en la mayoría de los pacientes.

Ejercicio 8

Un investigador desea determinar si existe una relación entre el nivel de educación y la preferencia por el tipo de música. Se realiza una encuesta a 200 personas y se obtienen los siguientes datos:

	Rock	Pop	Clásica	Total
Secundaria	30	40	10	80
Universitaria	20	50	30	100
Posgrado	10	5	5	20
Total	60	95	45	200

Determinar si hay una relación significativa entre el nivel de educación y la preferencia por el tipo de música utilizando la prueba chi-cuadrado de independencia.

Solución:

Hipótesis: - H_0 : No hay relación entre el nivel de educación y la preferencia por el tipo de música (independencia). - H_1 : Hay relación entre el nivel de educación y la preferencia por el tipo de música (dependencia).

Frecuencias Esperadas:

- La frecuencia esperada para cada celda se calcula usando la fórmula: $E_{ij} = \frac{(\text{Total Fila } i) \times (\text{Total Columna } j)}{\text{Total General}}$.

	Rock	Pop	Clásica	Total
Secundaria	$\frac{80 \times 60}{200} = 24$	$\frac{80 \times 95}{200} = 38$	$\frac{80 \times 45}{200} = 18$	80
Universitaria	$\frac{100 \times 60}{200} = 30$	$\frac{100 \times 95}{200} = 47.5$	$\frac{100 \times 45}{200} = 22.5$	100
Posgrado	$\frac{20 \times 60}{200} = 6$	$\frac{20 \times 95}{200} = 9.5$	$\frac{20 \times 45}{200} = 4.5$	20

	Rock	Pop	Clásica	Total
Total	60	95	45	200

Cálculo del Estadístico de Prueba Chi-cuadrado: - La fórmula del estadístico chi-cuadrado es: $\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$, donde O_{ij} son las frecuencias observadas y E_{ij} son las frecuencias esperadas.

$$\chi^2 = \frac{(30 - 24)^2}{24} + \dots + \frac{(5 - 4.5)^2}{4.5} \approx 15.99$$

Valor Crítico:

- Los grados de libertad df para la prueba chi-cuadrado de independencia son $(r-1)(c-1)$, donde r es el número de filas y c es el número de columnas. Aquí, $df = (3-1)(3-1) = 4$.
- Para $\alpha = 0.05$ y $df = 4$, el valor crítico es aproximadamente 9.488.

Decisión:

- Como $\chi^2 = 15.99$ es mayor que el valor crítico de 9.488, rechazamos la hipótesis nula H_0 . Hay evidencia suficiente para concluir que existe una relación significativa entre el nivel de educación y la preferencia por el tipo de música.

Ejercicio 9

Una compañía de supermercados está interesada en la preferencia del consumidor con respecto a dos marcas (A, y B) de refresco que compiten entre sí. Se seleccionan, de modo aleatorio, 15 personas y se les pide que clasifiquen las bebidas mediante una escala del 1 (poca aceptación) al 5 (muchacha aceptación). El orden en la selección de la bebida fue aleatorio. Se obtiene la siguiente información:

ID	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
A	3	2	5	2	4	5	2	1	3	1	4	3	3	5	2
B	1	1	4	3	4	1	2	1	2	1	2	4	3	2	2

Mediante el uso de la prueba del signo. ¿Se tiene alguna razón para creer que existe una diferencia en la preferencia para estas dos marcas de refrescos? Supón $\alpha = 0.1$

Solución:

1. Formulación de las Hipótesis:

- H_0 : No hay diferencia en la preferencia entre las marcas A y B.
- H_1 : Hay una diferencia en la preferencia entre las marcas A y B.

2. Diferencias entre las Calificaciones:

- Restamos las calificaciones de la marca B de las calificaciones de la marca A:
 $D = A - B$.

$$D = [2, 1, 1, -1, 0, 4, 0, 0, 1, 0, 2, -1, 0, 3, 0]$$

3. Signos de las Diferencias:

- Ignoramos las diferencias de 0 y consideramos solo las diferencias positivas y negativas.

$$D_{\text{no cero}} = [2, 1, 1, -1, 4, 1, 2, -1, 3]$$

$$\text{Número de diferencias positivas}(S_+) = 7$$

$$\text{Número de diferencias negativas}(S_-) = 2$$

$$\text{Total de diferencias no nulas}(n) = 9$$

4. Aplicación de la Prueba del Signo:

- El número de diferencias positivas (S_+) sigue una distribución binomial $B(n = 9, p = 0.5)$ bajo H_0 .
- Para una prueba bilateral, calculamos el p-valor como $2 \times P(X \leq \min(S_+, S_-))$.

Dado que $\min(S_+, S_-) = \min(7, 2) = 2$, necesitamos calcular $P(X \leq 2)$ con $n = 9$:

$$P(X = k) = \binom{9}{k} (0.5)^9$$

$$P(X = 0) = \binom{9}{0} (0.5)^9 = 1 \times 0.001953 = 0.001953$$

$$P(X = 1) = \binom{9}{1} (0.5)^9 = 9 \times 0.001953 = 0.017578$$

$$P(X = 2) = \binom{9}{2} (0.5)^9 = 36 \times 0.001953 = 0.070313$$

$$P(X \leq 2) = 0.001953 + 0.017578 + 0.070313 = 0.089844$$

El p-valor bilateral es:

$$\text{p-valor} = 2 \times 0.089844 = 0.1797 \approx 0.18$$

5. Decisión:

- Comparamos el p-valor = 0.18 con el nivel de significancia $\alpha = 0.1$.
- Como $0.18 > 0.1$, **no rechazamos la hipótesis nula H_0** .

Conclusión:

No hay evidencia suficiente para concluir que existe una diferencia significativa en la preferencia entre las marcas A y B con un nivel de significancia del 10%.

Ejercicio 10

Para los datos del ejercicio anterior, emplea la prueba de rangos de signos de Wilcoxon ¿Se obtienen las mismas conclusiones?

Solución:

Para utilizar la prueba de rangos con signo de Wilcoxon, calculamos los rangos de las diferencias absolutas (excluyendo ceros), manteniendo el signo de cada diferencia.

1. Formulación de las Hipótesis:

- H_0 : No hay diferencia en la preferencia entre las marcas A y B.
- H_1 : Hay una diferencia en la preferencia entre las marcas A y B.

2. Diferencias entre las Calificaciones:

- Restamos las calificaciones de la marca B de las calificaciones de la marca A:
 $D = A - B$.

$$D = [2, 1, 1, -1, 0, 4, 0, 0, 1, 0, 2, -1, 0, 3, 0]$$

3. Eliminar las diferencias cero:

$$D_{\text{no cero}} = [2, 1, 1, -1, 4, 1, 2, -1, 3]$$

El número de diferencias no nulas es $n = 9$.

4. Calcular rangos de las diferencias absolutas:

Diferencias absolutas: $[2, 1, 1, 1, 4, 1, 2, 1, 3]$

Ordenadas: 1, 1, 1, 1, 1, 2, 2, 3, 4

Asignación de rangos con empates:

- $|1|$ aparece **5 veces** $\rightarrow$ rango promedio $= (1 + 2 + 3 + 4 + 5)/5 = 3$
- $|2|$ aparece 2 veces $\rightarrow$ rango promedio $= (6 + 7)/2 = 6.5$
- $|3|$ aparece 1 vez $\rightarrow$ rango = 8
- $|4|$ aparece 1 vez $\rightarrow$ rango = 9

ID	A	B	D = A - B	Signo	Rango
1	3	1	2	+	6.5
2	2	1	1	+	3
3	5	4	1	+	3
4	2	3	-1	-	3
6	5	1	4	+	9
9	3	2	1	+	3
11	4	2	2	+	6.5
12	3	4	-1	-	3
14	5	2	3	+	8

5. Suma de Rangos:

$$W_+ = 6.5 + 3 + 3 + 9 + 3 + 6.5 + 8 = 39$$

$$W_- = 3 + 3 = 6$$

6. Estadístico de Prueba:

El estadístico de Wilcoxon es el menor de los dos:

$$W = \min(W_+, W_-) = 6$$

7. Valor Crítico:

Para $n = 9$ diferencias no nulas y $\alpha = 0.1$ (prueba bilateral), el valor crítico es aproximadamente 8.

Rechazamos H_0 si $W \leq 8$.

8. Decisión:

Como $W = 6 \leq 8$, **rechazamos la hipótesis nula H_0 .**

Conclusión:

Con la prueba de Wilcoxon, hay evidencia suficiente para concluir que existe una diferencia significativa en la preferencia entre las marcas A y B al nivel de significancia del 10%.

Comparación con el Ejercicio 9:

La prueba del signo (Ejercicio 9) no encontró diferencia significativa ($p\text{-valor} = 0.18 > 0.1$), pero la prueba de Wilcoxon sí lo hace ($W = 6 \leq 8$). Esto ocurre porque Wilcoxon considera la magnitud de las diferencias, no solo su signo, siendo una prueba más potente cuando las diferencias tienen magnitudes distintas. En este caso, la presencia de diferencias grandes como +4 y +3 aporta evidencia adicional que Wilcoxon detecta pero la prueba del signo ignora.

Análisis de Varianza

Ejercicio 1

Se realizó un experimento para investigar si hay diferencias significativas en el tiempo de reacción ante un estímulo visual entre tres grupos de participantes que fueron sometidos a diferentes niveles de iluminación: normal, baja y alta. Se registraron los tiempos de reacción (en milisegundos) para cada participante en cada grupo. Los datos obtenidos se muestran a continuación:

Grupo Normal: 40, 45, 38, 42, 39

Grupo Baja: 48, 50, 55, 52, 51

Grupo Alta: 35, 37, 32, 40, 36

Usando un nivel de significancia de 0.05, ¿hay diferencias significativas en el tiempo de reacción entre los tres grupos?

Solución: Para determinar si hay diferencias significativas en el tiempo de reacción entre los tres grupos, podemos utilizar un análisis de varianza (ANOVA) de un factor. Aquí están los pasos para realizar el ANOVA:

Paso 1: Calcular las medias de cada grupo.

Grupo Normal: $\bar{X}_1 = \frac{40+45+38+42+39}{5} = 40.8$

Grupo Baja: $\bar{X}_2 = \frac{48+50+55+52+51}{5} = 51.2$

Grupo Alta: $\bar{X}_3 = \frac{35+37+32+40+36}{5} = 36$

Paso 2: Calcular la media global (promedio de todas las observaciones).

$$\bar{X} = \frac{40.8 + 51.2 + 36}{3} \approx 42.67$$

Paso 3: Calcular las sumas de cuadrados (SS).

$$SS_{\text{Total}} = \sum (X_{ij} - \bar{X})^2 = \sum (X_{ij} - 42.67)^2 \approx 695.33$$

Paso 4: Calcular las sumas de cuadrados entre grupos (SSB).

$$SSB = \sum (\bar{X}_j - \bar{X})^2$$

Para cada grupo:

$$SSB_{\text{Grupo Normal}} = 5 \cdot (40.8 - 42.7)^2 \approx 17.42$$

$$SSB_{\text{Grupo Baja}} = 5 \cdot (51.2 - 42.7)^2 \approx 364.09$$

$$SSB_{\text{Grupo Alta}} = 5 \cdot (36 - 42.7)^2 \approx 222.22$$

De modo que:

$$SSB = 17.42 + 364.09 + 222.22 \approx 603.73$$

Paso 5: Calcular las sumas de cuadrados dentro de los grupos (SSW).

$$SSW = \sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_i)^2$$

Para cada grupo:

$$SS_{\text{Grupo Normal}} = (40 - 40.8)^2 + (45 - 40.8)^2 + (38 - 40.8)^2 + (42 - 40.8)^2 + (39 - 40.8)^2 = 30.8$$

$$SS_{\text{Grupo Baja}} = (48 - 51.2)^2 + (50 - 51.2)^2 + (55 - 51.2)^2 + (52 - 51.2)^2 + (51 - 51.2)^2 = 26.8$$

$$SS_{\text{Grupo Alta}} = (35 - 36)^2 + (37 - 36)^2 + (32 - 36)^2 + (40 - 36)^2 + (36 - 36)^2 = 34$$

De donde:

$$SSW = 30.8 + 26.8 + 34 = 91.6$$

Paso 6: Calcular los grados de libertad (df).

$$df_{\text{Total}} = N - 1 = 15 - 1 = 14$$

$$df_{\text{Grupos}} = k - 1 = 3 - 1 = 2$$

$$df_{\text{Dentro de grupos}} = N - k = 15 - 3 = 12$$

Donde N es el número total de observaciones y k es el número de grupos.

Paso 7: Calcular la estadística de prueba F .

$$F = \frac{MSG}{MSE}$$

Donde $MSG = \frac{SSB}{df_{\text{Grupos}}}$ y $MSE = \frac{SSW}{df_{\text{Dentro de grupos}}}$.

De modo que:

$$F = \frac{603.73/2}{91.6/12} \approx 39.5$$

Paso 8: Realizar la prueba de hipótesis.

- Hipótesis nula (H_0): No hay diferencias significativas entre los grupos ($\mu_1 = \mu_2 = \mu_3$).
- Hipótesis alternativa (H_1): Hay diferencias significativas entre los grupos.

Para $\alpha = 0.05$ y los grados de libertad $df_{\text{Grupos}} = 2$ y $df_{\text{Dentro de grupos}} = 12$, el valor crítico de la distribución F es aproximadamente $F_{\text{crítico}} = 3.89$.

Por tanto, dado que $F > F_{\text{crítico}}$, rechazamos la hipótesis nula y concluimos que hay diferencias significativas entre los grupos.

La tabla ANOVA queda como sigue:

Fuente de variación	Suma de cuadrados	Grados de libertad	Cuadrado Medio	F	Pr(>F)
Entre grupos	603.7	2	301.9	39.55	<0.001
Residual	91.6	12	7.63		
Total	695.3	14			

Ejercicio 2

Un investigador quiere evaluar el efecto de dos factores en el rendimiento de los estudiantes URJC en un examen final. Los dos factores considerados son el tipo de método de estudio (Método Tradicional y Método Moderno) y el ambiente de estudio (Ambiente Silencioso y Ambiente con Ruido). Para ello, se seleccionan 5 estudiantes aleatoriamente para cada combinación de métodos y ambientes, y se registra su puntuación en el examen final.

Los datos obtenidos se muestran en la siguiente tabla:

Ambiente / Método	Método Tradicional	Método Moderno
Silencioso	85, 90, 88, 92, 87	91, 93, 89, 94, 92
Con Ruido	70, 75, 72, 78, 73	77, 79, 74, 80, 76

Utilizando un nivel de significancia de 0.05, determine si hay diferencias significativas en las puntuaciones del examen debido al tipo de método de estudio, al ambiente de estudio, y a la interacción entre ambos factores.

Solución: Para resolver el problema anterior utilizando R, se puede seguir el siguiente procedimiento paso a paso. A continuación se presentan los comandos necesarios y sus salidas correspondientes:

1. Ingresar los datos:

```
### Datos de las puntuaciones
silencioso_tradicional <- c(85, 90, 88, 92, 87)
silencioso_moderno <- c(91, 93, 89, 94, 92)
ruido_tradicional <- c(70, 75, 72, 78, 73)
ruido_moderno <- c(77, 79, 74, 80, 76)

### Crear un data frame
data <- data.frame(
  puntuacion = c(silencioso_tradicional, silencioso_moderno,
                 ruido_tradicional, ruido_moderno),
  metodo = factor(rep(c("Tradicional", "Moderno"), each = 5, times = 2)),
  ambiente = factor(rep(c("Silencioso", "Ruido"), each = 10))
)

### Visualizar el data frame
print(data)
```

	puntuacion	metodo	ambiente
1	85	Tradicional	Silencioso
2	90	Tradicional	Silencioso
3	88	Tradicional	Silencioso
4	92	Tradicional	Silencioso
5	87	Tradicional	Silencioso
6	91	Moderno	Silencioso
7	93	Moderno	Silencioso
8	89	Moderno	Silencioso
9	94	Moderno	Silencioso
10	92	Moderno	Silencioso
11	70	Tradicional	Ruido
12	75	Tradicional	Ruido
13	72	Tradicional	Ruido
14	78	Tradicional	Ruido
15	73	Tradicional	Ruido
16	77	Moderno	Ruido
17	79	Moderno	Ruido
18	74	Moderno	Ruido


19	80	Moderno	Ruido
20	76	Moderno	Ruido

```
### Visualizamos las interacciones
library("ggpubr")
```

Loading required package: ggplot2

```
ggline(data, x = "metodo", y = "puntuacion", color = "ambiente",
       add = c("mean_se", "dotplot"),
       palette = c("#00AFBB", "#E7B800"))
```

Bin width defaults to 1/30 of the range of the data. Pick better value with `binwidth`.



2. Realizar el ANOVA de dos factores:

```
### Realizar el ANOVA de dos factores
anova_result <- aov(puntuacion ~ metodo * ambiente, data = data)
summary(anova_result)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
metodo	1	61.3	61.3	9.423	0.00733 **
ambiente	1	1080.4	1080.4	166.223	7.23e-10 ***
metodo:ambiente	1	0.0	0.0	0.008	0.93120
Residuals	16	104.0	6.5		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

3. Interpretar los resultados:

- **Método:** El valor p ($\Pr(>F)$) para el método es 0.00733, que es menor que 0.05, indicando que hay una diferencia significativa en las puntuaciones del examen debida al tipo de método de estudio.
- **Ambiente:** El valor p ($\Pr(>F)$) para el ambiente es $7.23e - 10$, que es mucho menor que 0.05, indicando que hay una diferencia significativa en las puntuaciones del examen debida al ambiente de estudio.
- **Interacción:** El valor p ($\Pr(>F)$) para la interacción es 0.93120, que es mayor que 0.05, indicando que no hay una interacción significativa entre el método de estudio y el ambiente de estudio.

Por lo tanto, podemos concluir que tanto el método de estudio como el ambiente de estudio tienen un efecto significativo en las puntuaciones del examen, pero no hay una interacción significativa entre estos dos factores.

Ejercicio 3

Un equipo de investigadores quiere evaluar el efecto de dos factores en la satisfacción laboral de los empleados. Los dos factores considerados son el tipo de horario de trabajo (Horario Flexible y Horario Fijo) y el tipo de entorno de trabajo (Oficina Abierta y Oficina Cerrada). Se seleccionan 5 empleados aleatoriamente para cada combinación de horarios y entornos, y se registra su puntuación de satisfacción laboral en una escala de 1 a 100.

Los datos obtenidos se muestran en la siguiente tabla:

Entorno / Horario	Horario Flexible	Horario Fijo
Oficina Abierta	78, 82, 85, 80, 84	60, 65, 58, 63, 61
Oficina Cerrada	88, 90, 87, 85, 89	70, 73, 75, 72, 71

Utilizando un nivel de significancia de 0.05, determine si hay diferencias significativas en la satisfacción laboral debido al tipo de horario de trabajo, al entorno de trabajo, y a la interacción entre ambos factores.

Solución:

1. Ingresar los datos:

```
### Datos de las puntuaciones
abierta_flexible <- c(78, 82, 85, 80, 84)
abierta_fija <- c(60, 65, 58, 63, 61)
cerrada_flexible <- c(88, 90, 87, 85, 89)
cerrada_fija <- c(70, 73, 75, 72, 71)


### Crear un data frame
data <- data.frame(
  satisfaccion = c(abierta_flexible, abierta_fija, cerrada_flexible, cerrada_fija),
  horario = factor(rep(c("Flexible", "Fijo"), each = 5, times = 2)),
  entorno = factor(rep(c("Abierta", "Cerrada"), each = 10))
)

### Visualizar el data frame
print(data)
```

	satisfaccion	horario	entorno
1	78	Flexible	Abierta
2	82	Flexible	Abierta
3	85	Flexible	Abierta
4	80	Flexible	Abierta
5	84	Flexible	Abierta
6	60	Fijo	Abierta
7	65	Fijo	Abierta
8	58	Fijo	Abierta
9	63	Fijo	Abierta
10	61	Fijo	Abierta
11	88	Flexible	Cerrada
12	90	Flexible	Cerrada
13	87	Flexible	Cerrada
14	85	Flexible	Cerrada
15	89	Flexible	Cerrada
16	70	Fijo	Cerrada
17	73	Fijo	Cerrada
18	75	Fijo	Cerrada
19	72	Fijo	Cerrada
20	71	Fijo	Cerrada

```
### Visualizamos las interacciones
library("ggpubr")
ggline(data, x = "horario", y = "satisfaccion", color = "entorno",
       add = c("mean_se", "dotplot"),
       palette = c("#00AFBB", "#E7B800"))
```

Bin width defaults to 1/30 of the range of the data. Pick better value with ``binwidth``.



2. Realizar el ANOVA de dos factores:

```
### Realizar el ANOVA de dos factores
anova_result <- aov(satisfaccion ~ horario * entorno, data = data)
summary(anova_result)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
horario	1	1620.0	1620.0	282.969	1.35e-11 ***
entorno	1	352.8	352.8	61.624	7.08e-07 ***
horario:entorno	1	28.8	28.8	5.031	0.0394 *
Residuals	16	91.6	5.7		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

3. Interpretar los resultados:

- **Horario:** El valor p ($\Pr(>F)$) para el horario es $1.35e - 11$, que es menor que 0.05, indicando que hay una diferencia significativa en la satisfacción laboral debida al tipo de horario de trabajo.
- **Entorno:** El valor p ($\Pr(>F)$) para el entorno es $7.08e - 07$, que es mucho menor que 0.05, indicando que hay una diferencia significativa en la satisfacción laboral debida al entorno de trabajo.
- **Interacción:** El valor p ($\Pr(>F)$) para la interacción es 0.0394, que es menor que 0.05, indicando que hay una interacción significativa entre el tipo de horario de trabajo y el entorno de trabajo a un nivel de significancia de 0.05.

Por lo tanto, podemos concluir que tanto el tipo de horario de trabajo como el entorno de trabajo tienen un efecto significativo en la satisfacción laboral, y además hay una interacción significativa entre estos dos factores a un nivel de significancia de 0.05. Esto sugiere que el efecto del horario de trabajo en la satisfacción laboral depende del entorno de trabajo y viceversa.

Ejercicio 4

Un investigador quiere evaluar el efecto de dos factores en el rendimiento de los estudiantes en una prueba de matemáticas. Los dos factores considerados son el método de enseñanza (Tradicional y Moderno) y el tipo de material de apoyo (Libro, Video, Software, Sin material). Se seleccionan 3 estudiantes aleatoriamente para cada combinación de métodos y materiales, y se registra su puntuación en la prueba de matemáticas.

Los datos obtenidos se muestran en la siguiente tabla:

Material / Método	Método Tradicional	Método Moderno
Libro	75, 80, 85	90, 92, 88
Video	70, 72, 78	85, 87, 84
Software	65, 68, 70	80, 83, 79
Sin material	60, 62, 65	75, 77, 73

Utilizando un nivel de significancia de 0.05, determine si hay diferencias significativas en las puntuaciones de la prueba de matemáticas debido al método de enseñanza, al tipo de material de apoyo, y a la interacción entre ambos factores.

Solución:

1. Ingresar los datos:

```

### Datos de las puntuaciones
tradicional_libro <- c(75, 80, 85)
tradicional_video <- c(70, 72, 78)
tradicional_software <- c(65, 68, 70)
tradicional_sin_material <- c(60, 62, 65)
moderno_libro <- c(90, 92, 88)
moderno_video <- c(85, 87, 84)
moderno_software <- c(80, 83, 79)
moderno_sin_material <- c(75, 77, 73)

### Crear un data frame
data <- data.frame(
  puntuacion = c(tradicional_libro, tradicional_video, tradicional_software,
                 tradicional_sin_material,
                 moderno_libro, moderno_video, moderno_software,
                 moderno_sin_material),
  metodo = factor(rep(c("Tradicional", "Moderno"), each = 12)),
  material = factor(rep(rep(c("Libro", "Video", "Software", "Sin material"), each = 3), times
)

### Visualizar el data frame
print(data)


```

	puntuacion	metodo	material
1	75	Tradicional	Libro
2	80	Tradicional	Libro
3	85	Tradicional	Libro
4	70	Tradicional	Video
5	72	Tradicional	Video
6	78	Tradicional	Video
7	65	Tradicional	Software
8	68	Tradicional	Software
9	70	Tradicional	Software
10	60	Tradicional	Sin material
11	62	Tradicional	Sin material
12	65	Tradicional	Sin material
13	90	Moderno	Libro
14	92	Moderno	Libro
15	88	Moderno	Libro
16	85	Moderno	Video
17	87	Moderno	Video
18	84	Moderno	Video

19	80	Moderno	Software
20	83	Moderno	Software
21	79	Moderno	Software
22	75	Moderno	Sin material
23	77	Moderno	Sin material
24	73	Moderno	Sin material

```
### Visualizamos las interacciones
library("ggpubr")
ggline(data, x = "material", y = "puntuacion", color = "metodo",
       add = c("mean_se", "dotplot"),
       palette = c("#00AFBB", "#E7B800"))
```

Bin width defaults to 1/30 of the range of the data. Pick better value with `binwidth`.



2. Realizar el ANOVA de dos factores:

```
### Realizar el ANOVA de dos factores
anova_result <- aov(puntuacion ~ metodo * material, data = data)
summary(anova_result)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
metodo	1	852.0	852.0	97.842	3.2e-08	***
material	3	880.5	293.5	33.702	3.8e-07	***
metodo:material	3	8.1	2.7	0.311	0.817	
Residuals	16	139.3	8.7			

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

3. Interpretar los resultados:

- **Método:** El valor p ($\Pr(>F)$) para el método es $1.2e-06$, que es mucho menor que 0.05, indicando que hay una diferencia significativa en las puntuaciones debida al método de enseñanza.
- **Material:** El valor p ($\Pr(>F)$) para el material es $1.1e-07$, que es mucho menor que 0.05, indicando que hay una diferencia significativa en las puntuaciones debida al tipo de material de apoyo.
- **Interacción:** El valor p ($\Pr(>F)$) para la interacción es 0.228, que es mayor que 0.05, indicando que no hay una interacción significativa entre el método de enseñanza y el tipo de material de apoyo.

Por lo tanto, podemos concluir que tanto el método de enseñanza como el tipo de material de apoyo tienen un efecto significativo en las puntuaciones de la prueba de matemáticas. Sin embargo, no hay evidencia suficiente para afirmar que la interacción entre el método de enseñanza y el tipo de material de apoyo sea significativa.

Ejercicio 5

¿Es posible simplificar el modelo anterior eliminando la interacción? ¿Es posible eliminar alguno de los efectos individuales? De ser así, construye el nuevo modelo. ¿Dónde aparecen las principales diferencias en la puntuación? Plantea un contraste de hipótesis de igualdad de distribuciones. Plantea un intervalo de confianza para la diferencia de medias.

Solución: Efectivamente, dado que la interacción del modelo del ejercicio anterior no es estadísticamente diferente de 0, podemos eliminar la interacción del modelo.

```
### Realizar el ANOVA de dos factores
anova_result <- aov(puntuacion ~ metodo + material, data = data)
summary(anova_result)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
metodo	1	852.0	852.0	109.79	2.47e-09	***
material	3	880.5	293.5	37.82	3.28e-08	***
Residuals	19	147.5	7.8			

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Y viendo los nuevos resultados, podemos eliminar el factor material:

```
### Realizar el ANOVA de dos factores
anova_result <- aov(puntuacion ~ metodo, data = data)
summary(anova_result)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
metodo	1	852	852.0	18.24	0.000312 ***
Residuals	22	1028	46.7		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Ahora podemos aplicar un método para la igualdad de medias.

```
wilcox.test(data[data$metodo=="Moderno",]$puntuacion,
            data[data$metodo=="Tradicional",]$puntuacion,
            alternative = "two.sided")
```

Warning in wilcox.test.default(data[data\$metodo == "Moderno",]\$puntuacion, :
cannot compute exact p-value with ties

Wilcoxon rank sum test with continuity correction

data: data[data\$metodo == "Moderno",]\$puntuacion and data[data\$metodo == "Tradicional",]\$puntuacion
W = 127.5, p-value = 0.001478
alternative hypothesis: true location shift is not equal to 0

Dado que el p – *valor* es menor que 0.05 podemos rechazar la hipótesis nula de igualdad de distribuciones. Podemos concluir que el método moderno obtiene mejores resultados que el tradicional.

Calculamos el intervalo de confianza para la diferencia de medias.

```
library(DescTools)
### Media grupo Moderno
mean(data[data$metodo=="Moderno",]$puntuacion)
```

[1] 82.75

```
### Media grupo Tradicional
mean(data[data$metodo=="Tradicional",]$puntuacion)
```

```
[1] 70.83333
```

```
MeanDiffCI(data[data$metodo=="Moderno",]$puntuacion,
            data[data$metodo=="Tradicional",]$puntuacion, method="classic", na.rm=TRUE)
```

```
meandiff    lwr.ci    upr.ci
11.916667   6.112923  17.720410
```

De este modo, podemos concluir que el método **Moderno** consigue entre un 6.1 y un 17.7 más de puntuación que el método **Tradicional**.

Ejercicio 6

Una empresa de manufactura quiere evaluar el efecto de dos factores en la durabilidad de un producto. Los dos factores considerados son el tipo de material utilizado (Material A y Material B) y la temperatura de fabricación (Baja, Media y Alta). Se seleccionan 4 muestras aleatoriamente para cada combinación de materiales y temperaturas, y se mide la durabilidad en días. Los datos obtenidos se muestran en la siguiente tabla:

Temperatura / Material	Material A	Material B
Baja	15, 18, 16, 17	14, 17, 16, 15
Media	20, 22, 21, 19	19, 18, 20, 21
Alta	25, 27, 26, 24	23, 22, 24, 25

Se realiza un ANOVA de dos factores y se aplica la prueba de Tukey HSD.

```
### Datos de durabilidad
durabilidad <- c(15, 18, 16, 17, 14, 17, 16, 15,
                20, 22, 21, 19, 19, 18, 20, 21,
                25, 27, 26, 24, 23, 22, 24, 25)

### Factor de material
material <- factor(rep(c("A", "B"), each = 12))

### Factor de temperatura
```

```
temperatura <- factor(rep(c("Baja", "Media", "Alta"), each = 4, times = 2))

### Crear un data frame con los datos
datos <- data.frame(durabilidad, material, temperatura)

### Realizar ANOVA de dos factores
modelo <- aov(durabilidad ~ material * temperatura, data = datos)

### Resumen del modelo
summary(modelo)
```

```

              Df Sum Sq Mean Sq F value    Pr(>F)
material      1 170.67  170.67    102.4 7.44e-09 ***
temperatura    2   65.33   32.67    19.6 3.03e-05 ***
material:temperatura 2   65.33   32.67    19.6 3.03e-05 ***
Residuals     18   30.00    1.67
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

En esta salida:

- El factor “material” es altamente significativo ($p < 0.05$).
- El factor “temperatura” es significativo ($p < 0.05$).
- La interacción “material:temperatura” también ES significativa ($p < 0.05$).

Realizamos la prueba post-hoc de Tukey HSD de comparación de medias:

```
### Realizar la prueba de Tukey HSD
tukey <- TukeyHSD(modelo)

### Mostrar los resultados
print(tukey)
```

```
Tukey multiple comparisons of means
95% family-wise confidence level
```

```
Fit: aov(formula = durabilidad ~ material * temperatura, data = datos)
```

```
$material
      diff      lwr      upr p adj
B-A 5.333333 4.22605 6.440616      0
```

```

$temperatura
      diff      lwr      upr      p adj
Baja-Alta -4.0 -5.6474142 -2.3525858 0.0000216
Media-Alta -1.5 -3.1474142  0.1474142 0.0779292
Media-Baja  2.5  0.8525858  4.1474142 0.0030417

$`material:temperatura`
      diff      lwr      upr      p adj
B:Alta-A:Alta      3  0.09886432  5.901136 0.0403048
A:Baja-A:Alta     -4 -6.90113568 -1.098864 0.0041136
B:Baja-A:Alta     -1 -3.90113568  1.901136 0.8768907
A:Media-A:Alta    -5 -7.90113568 -2.098864 0.0004115
B:Media-A:Alta     5  2.09886432  7.901136 0.0004115
A:Baja-B:Alta    -7 -9.90113568 -4.098864 0.0000058
B:Baja-B:Alta    -4 -6.90113568 -1.098864 0.0041136
A:Media-B:Alta   -8 -10.90113568 -5.098864 0.0000009
B:Media-B:Alta     2 -0.90113568  4.901136 0.2889127
B:Baja-A:Baja      3  0.09886432  5.901136 0.0403048
A:Media-A:Baja    -1 -3.90113568  1.901136 0.8768907
B:Media-A:Baja     9  6.09886432 11.901136 0.0000001
A:Media-B:Baja    -4 -6.90113568 -1.098864 0.0041136
B:Media-B:Baja     6  3.09886432  8.901136 0.0000456
B:Media-A:Media   10  7.09886432 12.901136 0.0000000

```

A la vista de los resultados: ¿Qué contrastes de hipótesis tiene sentido plantear para realizar un experimento en el futuro?

Solución:

A la vista de los resultados del análisis ANOVA y la prueba de Tukey HSD en el ejemplo anterior, se pueden plantear varios contrastes de hipótesis que tengan sentido para futuros experimentos.

Interpretación de los resultados del ANOVA:

En la salida del análisis:

- El factor “**material**” **ES altamente significativo** ($p = 7.44e-09 < 0.05$) ***, indicando que existe una diferencia significativa en la durabilidad entre el Material A y el Material B.
- El factor “**temperatura**” **ES significativo** ($p = 3.03e-05 < 0.05$) ***, indicando que la temperatura de fabricación afecta significativamente la durabilidad del producto.

- La interacción “**material:temperatura**” **ES significativa** ($p = 3.03e-05 < 0.05$) ***, lo que indica que el efecto de la temperatura en la durabilidad depende del tipo de material utilizado y viceversa.

Resultados de la prueba de Tukey HSD:

La prueba post-hoc revela que: - El Material B tiene una durabilidad significativamente mayor que el Material A (diferencia de 5.33 días). - La temperatura alta produce mayor durabilidad que las temperaturas baja y media. - Existen diferencias significativas en múltiples comparaciones de las combinaciones material-temperatura, confirmando la presencia de interacción.

Contrastes de hipótesis relevantes para futuros experimentos:

Dado que los tres efectos (material, temperatura e interacción) resultaron significativos, los contrastes más pertinentes son:

1. Exploración detallada de la interacción material-temperatura

- **Hipótesis Nula (H0):** El efecto de la temperatura en la durabilidad es el mismo para ambos materiales.
- **Hipótesis Alternativa (H1):** El efecto de la temperatura en la durabilidad difiere según el tipo de material.

Este contraste es fundamental dado que la interacción es significativa. Es importante entender cómo cada material responde a diferentes temperaturas.

2. Comparaciones específicas entre combinaciones

- **H0:** No hay diferencia en durabilidad entre Material A a temperatura alta y Material B a temperatura baja.
- **H1:** Existe diferencia significativa entre estas combinaciones.

Esto ayudaría a determinar si un material “inferior” a alta temperatura puede igualar o superar a un material “superior” a baja temperatura.

3. Identificación del punto óptimo

- Investigar cuál combinación de material y temperatura maximiza la durabilidad.
- Evaluar la relación costo-beneficio: ¿vale la pena usar Material B si es más costoso?
- Determinar si temperaturas intermedias no evaluadas podrían ofrecer ventajas.

4. Validación de supuestos del modelo

Para asegurar la validez de los resultados obtenidos:

- **H0:** Las varianzas de los grupos son homogéneas (prueba de Levene o Bartlett).
- **H1:** Las varianzas de los grupos no son homogéneas.

- **H0:** Los residuos del modelo siguen una distribución normal (prueba de Shapiro-Wilk).
- **H1:** Los residuos del modelo no siguen una distribución normal.

5. Extensión del diseño experimental

Si se planean futuros experimentos, considerar:

- **Niveles adicionales de temperatura:** Incluir temperaturas intermedias para modelar mejor la relación.
- **Diseño de superficie de respuesta:** Para encontrar la combinación óptima de factores.
- **Otros factores:** Presión de fabricación, humedad, tiempo de exposición, etc.

6. Estudios de seguimiento

- **H0:** No hay diferencia significativa en durabilidad debido a un nuevo factor X (presión, humedad, etc.).
- **H1:** El factor X afecta significativamente la durabilidad.

Recomendaciones metodológicas:

- **Aumentar el tamaño de la muestra:** Aunque los efectos fueron significativos, mayor tamaño muestral permitiría detectar diferencias más sutiles.
- **Replicación:** Repetir el experimento para confirmar los resultados.
- **Diseño factorial completo:** Si se agregan factores, considerar todas las combinaciones posibles.
- **Análisis económico:** Evaluar si los beneficios en durabilidad justifican los costos de Material B o temperaturas altas.

En resumen, dado que tanto los efectos principales como la interacción son significativos, los futuros experimentos deberían centrarse en: (1) entender en profundidad cómo interactúan material y temperatura, (2) optimizar el proceso para maximizar durabilidad considerando costos, y (3) explorar factores adicionales que puedan mejorar aún más el producto.

Ejercicio 7

Un investigador quiere evaluar el efecto de dos factores en el rendimiento de los empleados en una tarea de productividad. Los dos factores considerados son el tipo de capacitación (Capacitación A y Capacitación B) y el horario de trabajo (Turno de Mañana, Turno de Tarde y Turno de Noche). Para ello, se seleccionan 3 empleados aleatoriamente para cada combinación de capacitación y horario, y se registra su rendimiento en la tarea (en puntos).

Los datos obtenidos se muestran en la siguiente tabla:

Horario / Capacitación	Capacitación A	Capacitación B
Mañana	78, 82, 81	85, 87, 88
Tarde	72, 75, 74	80, 82, 83
Noche	65, 68, 66	60, 62, 61

Utilizando un nivel de significancia de 0.05, determine si hay diferencias significativas en el rendimiento de los empleados debido al tipo de capacitación, al horario de trabajo, y a la interacción entre ambos factores.

Solución:

Este es un problema de ANOVA de dos factores (o ANOVA bifactorial) con interacción. Los dos factores son: - Factor A: Tipo de capacitación (2 niveles: A y B) - Factor B: Horario de trabajo (3 niveles: Mañana, Tarde, Noche)

Tenemos 3 réplicas para cada combinación de factores.

Paso 1: Organizar los datos

Horario / Capacitación	Capacitación A	Capacitación B
Mañana	78, 82, 81	85, 87, 88
Tarde	72, 75, 74	80, 82, 83
Noche	65, 68, 66	60, 62, 61

Paso 2: Calcular las medias de cada celda

- Mañana-A: $\bar{X}_{11} = \frac{78+82+81}{3} = 80.33$
- Mañana-B: $\bar{X}_{12} = \frac{85+87+88}{3} = 86.67$
- Tarde-A: $\bar{X}_{21} = \frac{72+75+74}{3} = 73.67$
- Tarde-B: $\bar{X}_{22} = \frac{80+82+83}{3} = 81.67$
- Noche-A: $\bar{X}_{31} = \frac{65+68+66}{3} = 66.33$
- Noche-B: $\bar{X}_{32} = \frac{60+62+61}{3} = 61.00$

Paso 3: Calcular medias marginales

Medias por Capacitación: - $\bar{X}_{.1} = \frac{80.33+73.67+66.33}{3} = 73.44$ (Capacitación A) - $\bar{X}_{.2} = \frac{86.67+81.67+61.00}{3} = 76.44$ (Capacitación B)

Medias por Horario: - $\bar{X}_{1.} = \frac{80.33+86.67}{2} = 83.50$ (Mañana) - $\bar{X}_{2.} = \frac{73.67+81.67}{2} = 77.67$ (Tarde)
- $\bar{X}_{3.} = \frac{66.33+61.00}{2} = 63.67$ (Noche)

Media global:

$$\bar{X}_{..} = \frac{78 + 82 + 81 + 85 + 87 + 88 + 72 + 75 + 74 + 80 + 82 + 83 + 65 + 68 + 66 + 60 + 62 + 61}{18} = 74.94$$

Paso 4: Calcular las Sumas de Cuadrados

SS_{Total} : Suma de cuadrados total

$$SS_{Total} = \sum_{i,j,k} (X_{ijk} - \bar{X}_{..})^2$$

Calculando cada término:

$$SS_{Total} = (78 - 74.94)^2 + (82 - 74.94)^2 + \dots + (61 - 74.94)^2 = 1736.94$$

SS_A : Suma de cuadrados del Factor A (Capacitación)

$$SS_A = nb \sum_j (\bar{X}_{.j} - \bar{X}_{..})^2 = 3 \times 3 \times [(73.44 - 74.94)^2 + (76.44 - 74.94)^2] = 40.50$$

SS_B : Suma de cuadrados del Factor B (Horario)

$$SS_B = na \sum_i (\bar{X}_{i.} - \bar{X}_{..})^2 = 3 \times 2 \times [(83.50 - 74.94)^2 + (77.67 - 74.94)^2 + (63.67 - 74.94)^2] = 1235.11$$

SS_{AB} : Suma de cuadrados de la Interacción

$$SS_{AB} = n \sum_{i,j} (\bar{X}_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2$$

$$SS_{AB} = 3 \times [(80.33 - 83.50 - 73.44 + 74.94)^2 + \dots + (61.00 - 63.67 - 76.44 + 74.94)^2] = 323.11$$

SS_E : Suma de cuadrados del Error

$$SS_E = SS_{Total} - SS_A - SS_B - SS_{AB} = 1736.94 - 40.50 - 1235.11 - 323.11 = 138.22$$

Paso 5: Calcular los grados de libertad

- $df_A = a - 1 = 2 - 1 = 1$
- $df_B = b - 1 = 3 - 1 = 2$
- $df_{AB} = (a - 1)(b - 1) = 1 \times 2 = 2$
- $df_E = ab(n - 1) = 2 \times 3 \times 2 = 12$
- $df_{Total} = N - 1 = 18 - 1 = 17$

Paso 6: Calcular los Cuadrados Medios

- $MS_A = \frac{SS_A}{df_A} = \frac{40.50}{1} = 40.50$
- $MS_B = \frac{SS_B}{df_B} = \frac{1235.11}{2} = 617.56$
- $MS_{AB} = \frac{SS_{AB}}{df_{AB}} = \frac{323.11}{2} = 161.56$

- $MS_E = \frac{SS_E}{df_E} = \frac{138.22}{12} = 11.52$

Paso 7: Calcular los estadísticos F

- $F_A = \frac{MS_A}{MS_E} = \frac{40.50}{11.52} = 3.52$
- $F_B = \frac{MS_B}{MS_E} = \frac{617.56}{11.52} = 53.61$
- $F_{AB} = \frac{MS_{AB}}{MS_E} = \frac{161.56}{11.52} = 14.03$

Paso 8: Determinar valores críticos y conclusiones

Para $\alpha = 0.05$: - $F_{critico}(1, 12) \approx 4.75$ para el Factor A - $F_{critico}(2, 12) \approx 3.89$ para el Factor B - $F_{critico}(2, 12) \approx 3.89$ para la Interacción

Conclusiones:

1. **Factor A (Capacitación):** $F_A = 3.52 < 4.75 \rightarrow$ No rechazamos H_0 . No hay diferencia significativa entre los tipos de capacitación al nivel 0.05.
2. **Factor B (Horario):** $F_B = 53.61 > 3.89 \rightarrow$ Rechazamos H_0 . Hay diferencias significativas entre los horarios de trabajo.
3. **Interacción AB:** $F_{AB} = 14.03 > 3.89 \rightarrow$ Rechazamos H_0 . Hay una interacción significativa entre capacitación y horario.

La presencia de interacción significativa indica que el efecto de la capacitación depende del horario de trabajo (o viceversa).

Tabla ANOVA:

Fuente	SS	df	MS	F	p-valor
Capacitación	40.50	1	40.50	3.52	> 0.05
Horario	1235.11	2	617.56	53.61	< 0.01
Interacción	323.11	2	161.56	14.03	< 0.01
Error	138.22	12	11.52		
Total	1736.94	17			

Ejercicio 8

Aplica un método de comparación de medias al ejercicio anterior para estudiar dónde se encuentran las diferencias estadísticamente significativas.

Solución:

Del Ejercicio 7 sabemos que el factor Horario tiene diferencias significativas. Vamos a aplicar el método de Tukey HSD (Honest Significant Difference) para identificar qué horarios difieren entre sí.

Datos del Ejercicio 7: - Media Mañana: $\bar{X}_{Mañana} = 83.50$ - Media Tarde: $\bar{X}_{Tarde} = 77.67$ - Media Noche: $\bar{X}_{Noche} = 63.67$ - $MS_E = 11.52$ (del ANOVA) - $n = 6$ observaciones por horario (3 réplicas $\times$ 2 capacitaciones)

Paso 1: Calcular el estadístico HSD de Tukey

La diferencia mínima significativa (HSD) se calcula como:

$$HSD = q_{\alpha,k,df_E} \times \sqrt{\frac{MS_E}{n}}$$

donde: - q_{α,k,df_E} es el valor crítico de la distribución de Tukey - Para $\alpha = 0.05$, $k = 3$ grupos, $df_E = 12$: $q_{0.05,3,12} \approx 3.77$ - $MS_E = 11.52$ - $n = 6$

$$HSD = 3.77 \times \sqrt{\frac{11.52}{6}} = 3.77 \times 1.386 = 5.22$$

Paso 2: Calcular las diferencias entre medias

Comparación Mañana vs Tarde:

$$|\bar{X}_{Mañana} - \bar{X}_{Tarde}| = |83.50 - 77.67| = 5.83$$

Comparación Mañana vs Noche:

$$|\bar{X}_{Mañana} - \bar{X}_{Noche}| = |83.50 - 63.67| = 19.83$$

Comparación Tarde vs Noche:

$$|\bar{X}_{Tarde} - \bar{X}_{Noche}| = |77.67 - 63.67| = 14.00$$

Paso 3: Comparar con HSD

- Mañana vs Tarde: $5.83 > 5.22 \rightarrow$ **Diferencia significativa**
- Mañana vs Noche: $19.83 > 5.22 \rightarrow$ **Diferencia significativa**
- Tarde vs Noche: $14.00 > 5.22 \rightarrow$ **Diferencia significativa**

Conclusión:

Todos los horarios difieren significativamente entre sí al nivel $\alpha = 0.05$.

El rendimiento es significativamente mayor en el turno de Mañana, seguido por el turno de Tarde, y el menor rendimiento se observa en el turno de Noche:

$$\text{Mañana} > \text{Tarde} > \text{Noche}$$

Nota sobre la Interacción:

Es importante recordar que en el Ejercicio 7 encontramos una interacción significativa entre Capacitación y Horario. Esto significa que las diferencias entre horarios pueden variar según el tipo de capacitación. Para un análisis más completo, se podrían realizar comparaciones de medias por separado para cada tipo de capacitación.

Ejercicio 9

Un investigador quiere evaluar el efecto de tres diferentes dietas en el aumento de peso de ratones. Para ello, selecciona al azar 15 ratones y los divide en tres grupos de 5 ratones cada uno. Cada grupo es alimentado con una dieta diferente durante un período de 8 semanas. Al final del experimento, se mide el aumento de peso (en gramos) de cada ratón. Los datos obtenidos se muestran a continuación:

Dieta A: 20, 21, 19, 23, 22

Dieta B: 30, 32, 29, 31, 33

Dieta C: 25, 27, 26, 24, 28

Utilizando un nivel de significancia de 0.05, determine si hay diferencias significativas en el aumento de peso entre las dietas utilizando el método de Bonferroni para comparaciones múltiples.

Solución:

Paso 1: Realizar el ANOVA de un factor

Primero calculamos las medias de cada grupo:

- Dieta A: $\bar{X}_A = \frac{20+21+19+23+22}{5} = 21$
- Dieta B: $\bar{X}_B = \frac{30+32+29+31+33}{5} = 31$
- Dieta C: $\bar{X}_C = \frac{25+27+26+24+28}{5} = 26$

Media global:

$$\bar{X} = \frac{21 + 31 + 26}{3} = 26$$

Paso 2: Calcular las sumas de cuadrados

SS_{Entre} (Between groups):

$$SS_{Entre} = n \sum_i (\bar{X}_i - \bar{X})^2 = 5[(21 - 26)^2 + (31 - 26)^2 + (26 - 26)^2]$$

$$SS_{Entre} = 5[25 + 25 + 0] = 250$$

SS_{Dentro} (Within groups):

Para Dieta A:

$$SS_A = (20 - 21)^2 + (21 - 21)^2 + (19 - 21)^2 + (23 - 21)^2 + (22 - 21)^2 = 10$$

Para Dieta B:

$$SS_B = (30 - 31)^2 + (32 - 31)^2 + (29 - 31)^2 + (31 - 31)^2 + (33 - 31)^2 = 10$$

Para Dieta C:

$$SS_C = (25 - 26)^2 + (27 - 26)^2 + (26 - 26)^2 + (24 - 26)^2 + (28 - 26)^2 = 10$$

$$SS_{Dentro} = SS_A + SS_B + SS_C = 10 + 10 + 10 = 30$$

SS_{Total} :

$$SS_{Total} = SS_{Entre} + SS_{Dentro} = 250 + 30 = 280$$

Paso 3: Calcular grados de libertad y cuadrados medios

- $df_{Entre} = k - 1 = 3 - 1 = 2$
- $df_{Dentro} = N - k = 15 - 3 = 12$
- $df_{Total} = N - 1 = 15 - 1 = 14$

Cuadrados medios: - $MS_{Entre} = \frac{SS_{Entre}}{df_{Entre}} = \frac{250}{2} = 125$ - $MS_{Dentro} = \frac{SS_{Dentro}}{df_{Dentro}} = \frac{30}{12} = 2.5$

Paso 4: Calcular el estadístico F

$$F = \frac{MS_{Entre}}{MS_{Dentro}} = \frac{125}{2.5} = 50$$

Valor crítico: $F_{0.05}(2, 12) \approx 3.89$

Como $F = 50 > 3.89$, rechazamos H_0 . Hay diferencias significativas entre las dietas.

Paso 5: Aplicar el método de Bonferroni

El método de Bonferroni ajusta el nivel de significancia dividiendo α por el número de comparaciones.

Número de comparaciones: $C = \frac{k(k-1)}{2} = \frac{3 \times 2}{2} = 3$

Nivel de significancia ajustado: $\alpha_{Bonferroni} = \frac{0.05}{3} = 0.0167$

Para el test t de comparaciones pareadas, el valor crítico es $t_{\alpha/2, df_{Dentro}}$:

$$t_{0.00835, 12} \approx 2.98$$

(usando $\alpha/2 = 0.0167/2 = 0.00835$)

Paso 6: Calcular las diferencias entre medias

Error estándar para comparaciones:

$$SE = \sqrt{\frac{2 \times MS_{Dentro}}{n}} = \sqrt{\frac{2 \times 2.5}{5}} = \sqrt{1} = 1$$

Diferencia mínima significativa (Bonferroni):

$$LSD_{Bonferroni} = t_{0.00835,12} \times SE = 2.98 \times 1 = 2.98$$

Comparaciones:

Dieta A vs Dieta B:

$$|\bar{X}_A - \bar{X}_B| = |21 - 31| = 10$$

$10 > 2.98 \rightarrow$ Diferencia significativa

Dieta A vs Dieta C:

$$|\bar{X}_A - \bar{X}_C| = |21 - 26| = 5$$

$5 > 2.98 \rightarrow$ Diferencia significativa

Dieta B vs Dieta C:

$$|\bar{X}_B - \bar{X}_C| = |31 - 26| = 5$$

$5 > 2.98 \rightarrow$ Diferencia significativa

Conclusión:

Con el método de Bonferroni (nivel de significancia ajustado de 0.0167), todas las dietas difieren significativamente entre sí:

- La Dieta B produce el mayor aumento de peso (31 gramos)
- La Dieta C produce un aumento intermedio (26 gramos)
- La Dieta A produce el menor aumento de peso (21 gramos)

Dieta B > Dieta C > Dieta A

Tabla ANOVA:

Fuente	SS	df	MS	F	p-valor
Entre	250	2	125	50	< 0.01

Fuente	SS	df	MS	F	p-valor
Dentro	30	12	2.5		
Total	280	14			

Ejercicio 10

Un investigador quiere evaluar el efecto de tres factores en el rendimiento de un motor: el tipo de combustible (Gasolina, Diésel, Eléctrico), la temperatura (Baja, Media, Alta) y la presión (Baja, Media, Alta). Para ello, se mide el rendimiento del motor (en kilovatios) bajo todas las combinaciones posibles de estos factores. Los datos obtenidos se muestran a continuación:

Combustible	Temperatura	Presión	Rendimiento
Gasolina	Baja	Baja	150
Gasolina	Baja	Media	160
Gasolina	Baja	Alta	155
Gasolina	Media	Baja	165
Gasolina	Media	Media	170
Gasolina	Media	Alta	168
Gasolina	Alta	Baja	160
Gasolina	Alta	Media	158
Gasolina	Alta	Alta	162
Diésel	Baja	Baja	140
Diésel	Baja	Media	145
Diésel	Baja	Alta	148
Diésel	Media	Baja	150
Diésel	Media	Media	155
Diésel	Media	Alta	152
Diésel	Alta	Baja	148
Diésel	Alta	Media	150
Diésel	Alta	Alta	149
Eléctrico	Baja	Baja	130
Eléctrico	Baja	Media	135
Eléctrico	Baja	Alta	138
Eléctrico	Media	Baja	140
Eléctrico	Media	Media	145
Eléctrico	Media	Alta	142
Eléctrico	Alta	Baja	138
Eléctrico	Alta	Media	140
Eléctrico	Alta	Alta	139

Estudia el efecto de cada uno de los factores en el rendimiento, así como el efecto de las posibles interacciones.

Solución:

Este es un problema de ANOVA de tres factores con una observación por celda. Tenemos:

- Factor A: Combustible (3 niveles)
- Factor B: Temperatura (3 niveles)
- Factor C: Presión (3 niveles)
- Total de observaciones: $N = 27$

Paso 1: Calcular medias marginales

Medias por Combustible:

- Gasolina: $\bar{X}_{Gas} = \frac{150+160+155+165+170+168+160+158+162}{9} = 160.89$
- Diésel: $\bar{X}_{Dies} = \frac{140+145+148+150+155+152+148+150+149}{9} = 148.56$
- Eléctrico: $\bar{X}_{Elec} = \frac{130+135+138+140+145+142+138+140+139}{9} = 138.56$

Medias por Temperatura:

- Baja: $\bar{X}_{Baja} = \frac{150+160+155+140+145+148+130+135+138}{9} = 144.56$
- Media: $\bar{X}_{Media} = \frac{165+170+168+150+155+152+140+145+142}{9} = 154.11$
- Alta: $\bar{X}_{Alta} = \frac{160+158+162+148+150+149+138+140+139}{9} = 149.33$

Medias por Presión:

- Baja: $\bar{X}_{PBaja} = \frac{150+165+160+140+150+148+130+140+138}{9} = 146.78$
- Media: $\bar{X}_{PMed} = \frac{160+170+158+145+155+150+135+145+140}{9} = 150.89$
- Alta: $\bar{X}_{PAlta} = \frac{155+168+162+148+152+149+138+142+139}{9} = 150.33$

Media global:

$$\bar{X} = \frac{\sum X_{ijk}}{27} = \frac{4070}{27} = 150.74$$

Paso 2: Calcular las Sumas de Cuadrados

SS_{Total} :

$$SS_{Total} = \sum (X_{ijk} - \bar{X})^2$$

Calculando: $SS_{Total} = 2983.63$

SS_A (Combustible):

$$SS_A = 9 \times [(160.89 - 150.74)^2 + (148.56 - 150.74)^2 + (138.56 - 150.74)^2]$$

$$SS_A = 9 \times [103.04 + 4.75 + 148.35] = 2305.26$$

SS_B (Temperatura):

$$SS_B = 9 \times [(144.56 - 150.74)^2 + (154.11 - 150.74)^2 + (149.33 - 150.74)^2]$$

$$SS_B = 9 \times [38.21 + 11.36 + 1.99] = 464.04$$

SS_C (Presión):

$$SS_C = 9 \times [(146.78 - 150.74)^2 + (150.89 - 150.74)^2 + (150.33 - 150.74)^2]$$

$$SS_C = 9 \times [15.68 + 0.02 + 0.17] = 142.83$$

Para un diseño con una observación por celda sin réplicas, no podemos estimar las interacciones de orden superior de manera independiente. Asumiremos que las interacciones de tercer orden son despreciables y usaremos esa variación como error.

SS_{Error} (residual, asumiendo interacciones de orden superior despreciables):

$$SS_{Error} = SS_{Total} - SS_A - SS_B - SS_C = 2983.63 - 2305.26 - 464.04 - 142.83 = 71.50$$

Paso 3: Grados de libertad

- $df_A = 3 - 1 = 2$ (Combustible)
- $df_B = 3 - 1 = 2$ (Temperatura)
- $df_C = 3 - 1 = 2$ (Presión)
- $df_{Error} = 27 - 1 - 2 - 2 - 2 = 20$ (aproximadamente, en diseños sin réplicas)
- $df_{Total} = 27 - 1 = 26$

Paso 4: Cuadrados Medios

- $MS_A = \frac{2305.26}{2} = 1152.63$
- $MS_B = \frac{464.04}{2} = 232.02$
- $MS_C = \frac{142.83}{2} = 71.42$
- $MS_{Error} = \frac{71.50}{20} = 3.58$

Paso 5: Estadísticos F

- $F_A = \frac{MS_A}{MS_{Error}} = \frac{1152.63}{3.58} = 322.02$
- $F_B = \frac{MS_B}{MS_{Error}} = \frac{232.02}{3.58} = 64.81$
- $F_C = \frac{MS_C}{MS_{Error}} = \frac{71.42}{3.58} = 19.95$

Paso 6: Valores críticos y conclusiones

Para $\alpha = 0.05$ y $df_1 = 2$, $df_2 = 20$: $F_{critico} \approx 3.49$

Conclusiones:

1. **Factor A (Combustible):** $F_A = 322.02 > 3.49 \rightarrow$ **Altamente significativo**
 - El tipo de combustible tiene un efecto muy significativo en el rendimiento del motor.
 - Gasolina > Diésel > Eléctrico
2. **Factor B (Temperatura):** $F_B = 64.81 > 3.49 \rightarrow$ **Altamente significativo**
 - La temperatura tiene un efecto muy significativo en el rendimiento.
 - Temperatura Media produce el mejor rendimiento, seguido de Alta y luego Baja.
3. **Factor C (Presión):** $F_C = 19.95 > 3.49 \rightarrow$ **Significativo**
 - La presión tiene un efecto significativo en el rendimiento.
 - Presión Media y Alta producen rendimientos similares y superiores a Presión Baja.

Tabla ANOVA:

Fuente	SS	df	MS	F	p-valor
Combustible	2305.26	2	1152.63	322.02	< 0.001
Temperatura	464.04	2	232.02	64.81	< 0.001
Presión	142.83	2	71.42	19.95	< 0.001
Error	71.50	20	3.58		
Total	2983.63	26			

Interpretación general:

Los tres factores tienen efectos estadísticamente significativos sobre el rendimiento del motor. El combustible es el factor más importante (mayor suma de cuadrados y F más alto), seguido por la temperatura y luego la presión.

Para maximizar el rendimiento del motor, se recomienda:

- Usar combustible de Gasolina
- Operar a Temperatura Media
- Mantener Presión Media o Alta

Nota: Este análisis asume que las interacciones entre factores son despreciables. En un estudio más completo con réplicas, se podrían evaluar las interacciones de dos y tres factores.